

Filtragem online de múons baseada em calorimetria de altas energias e com fina segmentação usando Redes Neurais Artificiais

Pedro Henrique Braga Lisboa
Laboratório de Processamento de Sinais
Universidade Federal do Rio de Janeiro
Rio de Janeiro, Brasil
pedro.lisboa@lps.ufrj.br

Luciano Manhães de Andrade Filho
Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal de Juiz de Fora
Juiz de Fora, Brasil
luciano.andrade@engenharia.ufjf.br

Natanael Nunes de Moura Junior
Signal Processing Laboratory
Universidade Federal do Rio de Janeiro
Rio de Janeiro, Brasil
natmourajr@lps.ufrj.br

José Manoel de Seixas
Signal Processing Laboratory
Universidade Federal do Rio de Janeiro
Rio de Janeiro, Brasil
seixas@lps.ufrj.br

Resumo—A Física de Partículas Elementares estuda as interações fundamentais da natureza, analisando as partículas que compõem o universo. O CERN abriga o LHC, o maior acelerador de partículas do mundo, onde colisões de feixes de partículas são usadas para investigar o comportamento das partículas previstas pelo Modelo Padrão. O experimento ATLAS é o maior do LHC e possui subdetectores que analisam as colisões. Com a elevada taxa de colisões no LHC, torna-se imprescindível um sistema de filtragem online eficiente para identificar os eventos de interesse. Este trabalho tem como objetivo explorar o uso de informações de calorimetria para auxiliar na detecção de múons, partículas de interesse nos estudos conduzidos pelo Experimento ATLAS. Com as futuras atualizações planejadas para o LHC, visando o aumento da taxa de colisões, será necessário aprimorar o sistema de filtragem para assegurar sua maior eficiência diante dessas novas condições. O estudo analisou o desempenho de Redes Neurais Artificiais como algoritmo de filtragem de múons na próxima fase de operação do detector, levando em conta as futuras atualizações programadas para o LHC. Os resultados obtidos demonstraram a promissora capacidade das Redes Neurais Artificiais para a detecção eficiente de múons, estabelecendo uma base sólida para futuras melhorias no sistema de filtragem de múons do Experimento ATLAS.

Index Terms—Redes Neurais Artificiais, Física de Altas Energias, Calorimetria, Múons

I. INTRODUÇÃO

A Física de Partículas Elementares tem como objetivo o estudo das interações fundamentais da natureza, buscando compreender a produção, interação e decaimento das partículas elementares que compõem o universo. Uma das abordagens utilizadas para investigar esses fenômenos é a produção de feixes de partículas em laboratório. Através da colisão dessas partículas, é possível observar experimentalmente o comportamento das partículas previstas pelo Modelo Padrão das Partículas Elementares, bem como suas possíveis extensões [1].

No Centro Europeu de Pesquisa Nuclear ou *European Organization for Nuclear Research* (CERN), está localizado o Grande Colisor de Hádrons ou *Large Hadron Collider* (LHC), considerado o maior e mais potente acelerador de partículas do mundo. O LHC opera por meio de colisões de dois feixes de partículas em quatro pontos posicionados ao longo do acelerador, cada um deles reservado para um experimento específico [2]. Nestes pontos estão instalados os detectores dos experimentos *A Large Ion Collider Experiment* (ALICE) [3], *Large Hadron Collider beauty* (LHCb) [4], *Compact Muon Solenoid* (CMS) [5] e *A Toroidal LHC ApparatuS* (ATLAS) [6], responsáveis por investigar e analisar os resultados dessas colisões.




Figura 1. Diagrama ilustrativo do detector ATLAS. Fonte: [7]

O ATLAS, apresentado na Figura 1 é o maior experimento do LHC, com dimensões de 44 metros de comprimento e 25 metros de altura. Sendo um experimento de propósito geral, o ATLAS abrange um grande espectro de processos

físicos resultantes de colisões próton-próton no LHC. Este detector é projetado em um formato cilíndrico e é composto por quatro subdetectores essenciais: o detector de trajetória [8], o sistema de calorimetria, que é composto pelos calorímetros eletromagnético e hadrônico [9], e o espectrômetro de múons [10]. Além destes destacam-se os ímãs supercondutores no formato solenoide e toroidais e o Sistema de Filtragem ou *Trigger*, que é responsável por selecionar quais eventos serão armazenados em mídia física ou não.

Os fenômenos físicos de interesse no LHC são de natureza excepcionalmente rara, exigindo assim que os detectores operem com uma taxa de colisões extremamente alta, com uma colisão ocorrendo a cada 25 nanossegundos para a geração de uma quantidade suficiente de eventos de interesse [11]. Essa taxa de colisões resulta em um volume de dados da ordem de 60 terabytes por segundo, tornando indispensável a implementação de um sistema de filtragem online (*Trigger*) para identificar e separar os eventos de interesse para aquisição subsequente. Uma parte desse sistema consiste na detecção da passagem de múons (*Trigger de Múons*).

O LHC foi planejado para passar por várias atualizações em seus equipamentos, visando aumentar a luminosidade e energia das colisões. Essas alterações impõem exigências adicionais aos subdetectores, devido ao aumento do nível de radiação resultante das colisões. Além disso, essas alterações também implicam no aumento da taxa de eventos, o que demanda sistemas de filtragem mais eficientes [11].

O calorímetro hadrônico de telhas (*TileCal*) foi projetado também contando com o seu uso como uma ferramenta para auxiliar na filtragem de múons. A eletrônica desse calorímetro possui uma saída analógica dedicada à um sistema desenvolvido para detecção dessa partícula. Esse sistema, denominado *TileMuon* [11], começou a operar a partir de 2018 com o uso de um hardware dedicado para digitalização e subsequente aplicação do algoritmo de detecção.

Esse não foi o primeiro uso de sistemas de calorimetria para detecção de múons. O experimento ZEUS, pertencente ao acelerador de partículas HERA (Hadron Elektron Ring Anlage) na Alemanha, fez uma alteração no calorímetro mais externo, adicionando câmaras de alumínio para auxiliar na detecção de múons [12].

Dentro do contexto do *TileMuon*, um estudo com o uso de filtragem casada para detecção de múons com os sinais do Calorímetro Hadrônico de Telhas pode ser visto em [11] e [13].

Com as futuras atualizações planejadas para os níveis de energia e luminosidade, o experimento ATLAS entrará em uma nova fase de atualização [14] e, consequentemente, o sistema *TileMuon* também será atualizado. Nessa nova fase, o canal de leitura principal do *TileCal* será implementado para atender aos requisitos de latência e processamento necessários para auxiliar nos sistemas de *Trigger*. Como resultado, não será mais necessário ter um hardware dedicado para o *TileMuon*, e os algoritmos de detecção serão implementados no mesmo sistema de digitalização e processamento de sinais padrão do subdetector.

Este trabalho se insere no contexto do projeto *TileMuon*, avaliando o desempenho de Redes Neurais Artificiais como algoritmo para filtragem de múons para a próxima fase de operação do detector.

O restante do trabalho se organiza da seguinte forma: na Seção II temos uma breve descrição dos subsistemas do detector ATLAS, objeto principal de estudo deste trabalho. Nesta seção são destacados dois dos principais subsistemas que compõem o detector, o Calorímetro Hadrônico e o Sistema de *Trigger* de Múons. Na Seção III são apresentados os modelos de aprendizado de máquina que foram aplicados ao problema de detecção de Múons do Detector ATLAS, com ênfase a redes neurais artificiais. Já na Seção IV, a descrição sucinta do método proposto é realizada. Os dados experimentais, bem como os resultados obtidos são abordados na Seção V, enquanto que as conclusões são discutidas na Seção VI, que encerra o trabalho.

II. O DETECTOR ATLAS

Na região interna do detector, próxima ao ponto de colisão, encontra-se o Detector de Trajetória, cuja função é medir a trajetória das partículas carregadas eletricamente geradas após uma colisão. Ao redor do Detector de Trajetória, estão localizados os calorímetros. O calorímetro eletromagnético [15] é responsável por estimar a energia de partículas que interagem por meio da força eletromagnética, como fótons, elétrons e pósitrons. Já o calorímetro hadrônico tem a função de estimar a energia depositada por partículas que interagem através da força forte, ou seja, aquelas que interagem com os núcleos atômicos presentes nas camadas do detector.

O Espectrômetro de Múons está localizado na parte mais externa do detector e é responsável pela detecção dos múons, que desempenham um papel importante em diversos processos físicos de interesse para o ATLAS. Esse espectrômetro opera em uma região com forte campo magnético, capaz de curvar a trajetória dos múons. Ao observar a passagem dos múons em vários pontos ao longo dos detectores, é possível reconstruir sua trajetória e estimar sua energia com base na curvatura. [16]

A. Calorímetro Hadrônico de Telhas

Os calorímetros são instrumentos utilizados para absorver e medir a energia das partículas que passam por eles. No contexto do experimento ATLAS, existem dois tipos de calorímetros: o calorímetro eletromagnético e o calorímetro hadrônico. O calorímetro hadrônico é responsável por amostrar a energia das partículas hadrônicas, que interagem com os núcleos atômicos do material que compõe o calorímetro [11].

Durante a interação das partículas com o material do calorímetro, ocorre o depósito de energia nos núcleos atômicos. Esses núcleos excitados emitem partículas hadrônicas adicionais e raios gama de baixa energia. Essa sucessão de interações gera uma cascata de partículas, as quais interagem novamente com o material do calorímetro, resultando na excitação das células de detecção [17].

onde $s[k]$ representa o pulso digitalizado correspondente à resposta do sistema à energia depositada no canal por uma partícula e $n[k]$ o ruído do canal. No caso, tanto $g[k]$ quanto $n[k]$ são realizações de processos estocásticos $S(k)$ e $N(k)$ que descrevem, respectivamente, a natureza do pulso e do ruído. Consequentemente podemos descrever o sinal recebido $x[k]$ como a realização de um processo $X(k)$. O problema de detecção pode ser modelado através de um teste de hipóteses, onde a hipótese nula H_0 corresponde à ausência do pulso, ou seja $x[k] = n[k]$, e a hipótese alternativa H_1 à presença do pulso somado ao ruído do canal, como descrito na Equação 1. Pode-se mostrar que a razão de verossimilhança [22]

$$\Lambda(x) = \frac{f_{X|H_1}(x|H_1)}{f_{X|H_0}(x|H_0)} \underset{H_0}{\underset{H_1}{\geq}} \gamma, \quad (2)$$

maximiza a eficiência de detecção, onde $f_{X|H_1}$ e $f_{X|H_0}$ correspondem às funções de densidade de probabilidade do sinal recebido para as hipóteses de pulso recebido e apenas ruído, respectivamente. O parâmetro γ representa um valor de patamar, projetado de forma a maximizar a eficiência de detecção.

Quando as probabilidades $f_{X|H_1}$ e $f_{X|H_0}$ podem ser descritas analiticamente no problema em questão, é possível demonstrar que a razão de verossimilhança maximiza a relação sinal-ruído (SNR) [22]. Quando as probabilidades não são conhecidas a priori ou não podem ser descritas analiticamente, é possível estimá-las empiricamente por meio do algoritmo de detecção utilizando um conjunto de dados. No entanto, nesse caso, não há garantia de maximização da relação sinal-ruído (SNR) e, consequentemente, da eficiência de detecção, como ocorre no caso analítico.

A. Filtro Casado Determinístico

No caso do pulso de interesse $s[k]$ ser determinístico e o ruído $n[k]$ gaussiano, as probabilidades de H_0 e H_1 podem ser respectivamente descritas por

$$\begin{aligned} f_{X|H_1}(\mathbf{x}) &= \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} e^{-\frac{1}{2}(\mathbf{x}-\mathbf{s})^T \Sigma^{-1}(\mathbf{x}-\mathbf{s})} \\ f_{X|H_0}(\mathbf{x}) &= \frac{1}{\sqrt{(2\pi)^N |\Sigma|}} e^{-\frac{1}{2}\mathbf{x}^T \Sigma^{-1}\mathbf{x}} \end{aligned} \quad (3)$$

em que $\mathbf{s} = [s_1, s_2, \dots, s_n]^T$ é o vetor médio do pulso de interesse, Σ é a matriz de covariância do ruído e $|\Sigma|$ o seu determinante. Nesse caso, a razão de verossimilhança dependerá unicamente do fator

$$\mathbf{x} \Sigma^{-1} \mathbf{s} \underset{H_0}{\underset{H_1}{\geq}} \gamma'. \quad (4)$$

No contexto de sinais corrompidos por ruído gaussiano aditivo, esse modelo é conhecido como filtro casado, ou filtro correlator. Quando o ruído é branco e descorrelacionado, a matriz de covariância se torna a matriz identidade, e a razão de verossimilhança simplifica para o produto interno entre o sinal recebido e o pulso de referência. Por outro lado, quando o ruído é correlacionado, a matriz Σ^{-1} serve

para descorrelacionar as amostras do sinal recebido antes de compará-las com o pulso de interesse.

Embora a energia depositada pelos múons no TileCal não seja determinística, é possível tirar proveito do fato de que a eletrônica do detector fornece um pulso analógico fixo e estável [13]. Isso permite aproximar o pulso de interesse para um múon incidente como determinístico, utilizando uma estimativa empírica do pulso de referência. Essa abordagem considera que, embora a amplitude do pulso varie devido à estocasticidade na energia depositada nos canais, ainda é possível obter um pulso de referência que capture as características essenciais do sinal de interesse. Dessa forma, simplifica-se o problema de detecção desconsiderando a variabilidade intrínseca do sinal.

B. Redes Neurais Artificiais

Redes Neurais Artificiais são modelos não-paramétricos em relação à distribuição dos dados de entrada, compostos por unidades de processamento não-lineares chamadas neurônios. Esses neurônios possuem funções com parâmetros adaptativos, permitindo que sejam otimizados durante o treinamento do modelo.

Nas redes neurais artificiais do tipo feed-forward, essas unidades básicas são organizadas em camadas, onde a entrada dos neurônios é formada pela saída da camada anterior. Dessa forma, uma camada i com M neurônios aplicada à um sinal de entrada com N amostras terá sua saída representada por

$$h_i(x) = f(\mathbf{W}_{M \times N} \mathbf{x} + b_M), \quad (5)$$

onde b é um vetor com os parâmetros de viés, f uma não-linearidade e $\mathbf{W}_{M \times N}$ a matriz de parâmetros dos M neurônios.

Essa configuração resulta em uma série de transformações em cascata aplicadas aos dados de entrada, permitindo que as redes neurais artificiais realizem mapeamentos não-lineares e de alta dimensionalidade, desde que haja uma quantidade suficiente de dados disponível. [23]

Sendo assim, uma rede neural com K camadas pode ser usada para estimar a probabilidade *a posteriori* $f_{x \sim X}(s|x)$ da presença de um pulso de interesse dado o sinal recebido

$$f_{x \sim X}(s|x) = h_K(h_{K-1}(\dots(h_2(h_1(\mathbf{x}))). \quad (6)$$

Da mesma forma que no método de filtragem casada, a saída da rede pode ser comparada com um patamar de decisão

$$f_{x \sim X}(s|x) \underset{H_0}{\underset{H_1}{\geq}} \gamma \quad (7)$$

para determinar a presença ou não do pulso de interesse no sinal de entrada.

No presente trabalho, a função *sigmoid*

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (8)$$

foi usada como não-linearidade da camada de saída. Essa função mapeia todos os valores da camada anterior para o

intervalo $[0,1]$, fazendo com que $f_{x \sim X}(s|x)$ seja uma função de probabilidade válida.

É possível demonstrar que uma rede neural composta por uma camada de entrada, uma camada escondida e uma camada de saída é capaz de aproximar qualquer função real $f(x)$ em sua saída com a precisão desejada. No entanto, essa capacidade depende da presença de um número suficiente de neurônios na camada escondida e o uso de certos tipos de não-linearidade na rede [24] [25].

Devido à natureza não-convexa do treinamento desses modelos, as redes neurais feed-forward são geralmente treinadas utilizando métodos de otimização iterativos baseados no cálculo do gradiente de uma função de custo pré-estabelecida. Nesses casos, o algoritmo de backpropagation é comumente usado para calcular os gradientes. [23]

IV. MÉTODO

A. Validação Cruzada

A validação cruzada é uma técnica utilizada para avaliar modelos estatísticos e determinar sua capacidade de generalização para conjuntos de dados independentes dos utilizados no treinamento. Esse procedimento envolve a subdivisão do conjunto de dados em um subconjunto de teste e um de treinamento. O subconjunto de treinamento é usado para otimizar os parâmetros do modelo, enquanto o subconjunto de teste é utilizado para validar o seu desempenho. [26] Neste estudo, utilizou-se a técnica de validação cruzada do tipo k-fold.

No k-fold, o conjunto de dados é dividido em k partições, sendo uma delas selecionada como conjunto de teste e as demais utilizadas para treinar o modelo. Esse processo é repetido k vezes, alternando a partição de teste a cada iteração. Ao final, a estimativa do erro de generalização pode ser obtida calculando-se a média e a variância dos resultados obtidos em cada etapa.

B. Figuras de Mérito

Para avaliar os modelos de detecção, utilizamos as figuras de mérito de falso alarme e probabilidade de detecção. O falso alarme (FA) é uma figura de mérito que avalia a proporção de eventos erroneamente identificados como sinal em relação ao total de eventos de ruído. Em outras palavras, o falso alarme mede a taxa de erros cometidos pelo modelo ao classificar as amostras negativas como positivas. [26]

Um alto índice de falso alarme indica que o modelo tem dificuldade em distinguir corretamente as amostras de ruído das amostras de sinal. No contexto do TileMuon e do Trigger de Múons, um falso alarme ocorreria quando um evento de ruído de fundo nas células D é erroneamente classificado como a passagem de um múon pelo calorímetro. Por outro lado, a probabilidade de detecção é definida como a proporção de eventos de sinal (múons) corretamente detectados pelo modelo. Assim, um modelo com alta probabilidade de detecção é eficiente em identificar corretamente a passagem de múons pelo calorímetro. [26]

Os valores de falso alarme e probabilidade de detecção variam em proporções inversas, dependendo do valor de limiar

de classificação definido na saída do modelo para distinguir entre sinal e ruído. Os modelos são otimizados para maximizar a separação das distribuições de saída do modelo para as duas classes. No ponto de interseção das distribuições, ocorrerá a ambiguidade na detecção. Ao variarmos o valor de limiar para um dos lados dessa ambiguidade, estaremos aumentando, por exemplo, a proporção de eventos de sinal corretamente classificados, ao mesmo tempo em que aumentamos a taxa de falso alarme. Se variarmos o limiar para o outro lado, o efeito oposto ocorrerá.

Nesse contexto, a curva ROC (Receiver Operating Characteristic, em inglês) é uma representação gráfica que combina informações sobre a probabilidade de detecção e o falso alarme, à medida que o limiar varia. Ela é capaz de mostrar o falso alarme e a probabilidade de detecção em dois eixos distintos, permitindo a avaliação do desempenho do modelo em diferentes pontos de operação. A área sob a curva ROC (AUC, do inglês "Area Under the Curve") também pode ser utilizada como uma métrica para resumir o desempenho de um modelo. Quanto melhor o modelo na tarefa de detecção, maior será a área sob a curva ROC. Essa medida é útil para comparar diferentes modelos e determinar qual deles possui uma capacidade de detecção superior.

V. RESULTADOS EXPERIMENTAIS

Os resultados do trabalho estão divididos em duas subseções, a primeira temos a descrição dos dados utilizados, já a segunda são os resultados dos modelos propriamente ditos.

A. Conjunto de Dados

Neste trabalho, as análises foram conduzidas utilizando um conjunto de 120.000 observações experimentais de sinal e ruído. Essas observações foram obtidas dos dois canais da célula D5, a partir dos 64 módulos em cada lado do Barril Estendido. As observações de sinal foram adquiridas a partir de dados coletados durante a operação do ATLAS em 2018. Cada evento coletado consiste de 7 amostras digitalizadas a 10 bits no TileCal, para eventos que passaram pelos níveis L1 e HLT de Trigger e foram identificados como múons com energia mínima de 20GeV. As informações de η e ϕ , obtidas dos dados de Trigger, são utilizadas para determinar em qual célula e módulo do TileCal ocorreu a passagem do múon. Os eventos de ruído foram obtidos durante tomadas de dados de calibração do TileCal, quando o sub detector está operando sem a presença de feixes no LHC. Esses eventos são compostos pelo ruído branco gaussiano somados a um valor de linha de base (pedestal) característico da eletrônica do detector. Vale ressaltar que esse valor de pedestal também está presente nas amostras de sinal, porém não contribui para a detecção de múons. Neste trabalho, propomos testar o desempenho das Redes Neurais com e sem a remoção desse valor de pedestal.

B. Resultados dos Modelos

Em cada iteração, o valor de pedestal foi estimado a partir da primeira amostra de todos os eventos de ruído presentes nas partições utilizadas para o treinamento. Em seguida, tanto

REFERÊNCIAS

- [1] W. Cottingham and D. Greenwood, *An introduction to the standard model of particle physics*. United Kingdom: Cambridge University Press, 1998.
- [2] “LHC Machine,” *JINST*, vol. 3, p. S08001, 2008.
- [3] K. Aamodt *et al.*, “The ALICE experiment at the CERN LHC,” *JINST*, vol. 3, p. S08002, 2008.
- [4] A. A. Alves, Jr. *et al.*, “The LHCb Detector at the LHC,” *JINST*, vol. 3, p. S08005, 2008.
- [5] S. Chatrchyan *et al.*, “The CMS Experiment at the CERN LHC,” *JINST*, vol. 3, p. S08004, 2008.
- [6] G. Aad *et al.*, “The ATLAS Experiment at the CERN Large Hadron Collider,” *JINST*, vol. 3, p. S08003, 2008.
- [7] T. Ciodaro, J. M. de Seixas, and A. Cerqueira, “Use of hadronic calorimetry information in the atlas level-1 muon trigger,” *IEEE Transactions on Nuclear Science*, vol. 61, no. 2, pp. 1047–1055, 2014.
- [8] E. Ros, “Atlas inner detector,” *Nuclear Physics B - Proceedings Supplements*, vol. 120, pp. 235–238, 2003. Proceedings of the 8th International Conference on B-Physics at Hadron Machines.
- [9] A. Airapetian *et al.*, “ATLAS calorimeter performance Technical Design Report,” 12 1996.
- [10] S. Palestini, “The muon spectrometer of the ATLAS experiment,” *Nucl. Phys. B Proc. Suppl.*, vol. 125, pp. 337–345, 2003.
- [11] V. A. Ferraz, *Detecção online eficiente de eventos raros utilizando detectores finamente segmentados*. PhD thesis, COPPE/UFRJ, Rio de Janeiro, Brasil, 20XX.
- [12] K. Edwards *et al.*, “ZEUS, A DETECTOR FOR HERA: LETTER OF INTENT,” 6 1985.
- [13] D. O. Gonçalves, *Detecção online embarcada de sinais raros com baixa relação sinal-ruído em ambientes com alta taxa de eventos*. PhD thesis, PPÉE/UFJF, Juiz de Fora, Brasil, 2021.
- [14] ATLAS Collaboration, “Technical design report for the phase-ii upgrade of the atlas tile calorimeter,” Tech. Rep. CERN-LHCC-2017-019, ATLAS-TDR-028, CERN, 2017.
- [15] N. Nikiforou, “Performance of the atlas liquid argon calorimeter after three years of lhc operation and plans for a future upgrade,” in *2013 3rd International Conference on Advancements in Nuclear Instrumentation, Measurement Methods and their Applications (ANIMMA)*, pp. 1–12, 2013.
- [16] “ATLAS muon spectrometer: Technical design report,” 6 1997.
- [17] G. F. Knoll, *Radiation Detection and Measurement*. New York: Wiley, 4th ed., 2010.
- [18] “ATLAS tile calorimeter: Technical design report,” 12 1996.
- [19] “Approved tile calorimeter plots.” <https://twiki.cern.ch/twiki/bin/view/AtlasPublic/ApprovedPlotsTile>, 2023. Acessado em Junho de 2023.
- [20] R. Wigmans, *Calorimetry: Energy Measurement in Particle Physics*. Oxford, UK: Oxford University Press, 2000.
- [21] L. Landau, “On the energy loss of fast particles by ionization,” *J. Phys. (USSR)*, vol. 8, pp. 201–205, 1944.
- [22] H. L. Van Trees, *Detection, Estimation, and Modulation Theory, Part I*. New York, NY: Wiley, 2nd ed., 2013.
- [23] S. Haykin, *Neural Networks and Learning Machines*. Pearson, 3rd ed., 2009.
- [24] G. V. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals and Systems*, vol. 2, pp. 303–314, 1989.
- [25] M. Leshno, V. Y. Lin, A. Pinkus, and S. Schocken, “Multilayer feedforward networks with a nonpolynomial activation function can approximate any function,” *Neural Networks*, vol. 6, no. 6, pp. 861–867, 1993.
- [26] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*. New York, NY: Springer, 2nd ed., 2009.