



Universidade Federal de Juiz de Fora
Programa de Pós-Graduação em
Engenharia Elétrica

Leandro Rodrigues Manso Silva

ESTUDO E IMPLEMENTAÇÃO DE TÉCNICAS DE DETECÇÃO E
COMPRESSÃO DE DISTÚRBIOS ELÉTRICOS

Tese de Doutorado

Juiz de Fora
2016

Leandro Rodrigues Manso Silva

ESTUDO E IMPLEMENTAÇÃO DE TÉCNICAS DE DETECÇÃO E
COMPRESSÃO DE DISTÚRBIOS ELÉTRICOS

Tese apresentada ao Programa de Pós-Graduação
em Engenharia Elétrica, área de concentração: Sis-
temas Eletrônicos, da Faculdade de Engenharia da
Universidade Federal de Juiz de Fora como requi-
sito parcial para obtenção do grau de Doutor.

Orientador: Prof. Carlos Augusto Duque, D.Sc.

Orientador: Prof. Luciano Manhães de Andrade Filho, D.Sc.

Juiz de Fora

2016

Silva, Leandro Rodrigues Manso

Inteligência computacional aplicada à modelagem de cargas não-lineares e estimação de contribuição harmônica / Leandro Rodrigues Manso Silva. - 2012.

103 f. : il.

Dissertação (Mestrado em Engenharia Elétrica) - Universidade Federal de Juiz de Fora, 2012

1.Sistemas elétricos de potência. 2. Redes neurais. I. Título.

CDU 621.3.0

Leandro Rodrigues Manso Silva

ESTUDO E IMPLEMENTAÇÃO DE TÉCNICAS DE DETECÇÃO E
COMPRESSÃO DE DISTÚRBIOS ELÉTRICOS

Tese apresentada ao Programa de Pós-Graduação
em Engenharia Elétrica, área de concentração: Sis-
temas Eletrônicos, da Faculdade de Engenharia da
Universidade Federal de Juiz de Fora como requi-
sito parcial para obtenção do grau de Doutor.

Aprovada em 24 de fevereiro de 2016.

BANCA EXAMINADORA:

Prof. Carlos Augusto Duque, D.Sc.

Universidade Federal de Juiz de Fora, UFJF- Orientador

Prof. Luciano Manhães de Andrade Filho, D.Sc.

Universidade Federal de Juiz de Fora, UFJF- Orientador

Prof. Moisés Vidal Ribeiro, D.Sc.

Universidade Federal de Juiz de Fora, UFJF

Prof. Augusto Santiago Cerqueira, D.Sc.

Universidade Federal de Juiz de Fora, UFJF

Prof. Eduardo Antônio Barros da Silva, Ph.D.

Universidade Federal do Rio de Janeiro, UFRJ

Prof. Danton Diego Ferreira , D.Sc.

Universidade Federal de Lavras, UFLA

*À minha família e
aos meus amigos.*

AGRADECIMENTOS

Agradeço primeiramente a Deus e de maneira especial aos meus pais, Ricardo e Graça, pelo apoio incondicional durante todos esses anos. Aos meus avós, Jayme (*in memoriam*) e Nancy e a minha tia Laíla, pelo apoio e incentivo durante toda minha formação e pela atenção e carinho dedicados a mim.

À minha amada noiva Fabiana pelo companheirismo, paciência, carinho, amor, dedicação e apoio incondicional em todos os momentos.

Ao professor Carlos Augusto Duque, pelos ensinamentos, incentivo, atenção, amizade e confiança depositada em mim durante todos esses anos de orientação.

Ao professor Luciano Manhães pela amizade, orientação e incentivo durante todo o trabalho.

Ao professor Augusto Santiago Cerqueira pelas contribuições sempre muito válidas.

Aos amigos de LAPTEL e PSCOPE, em especial ao Eder Kapisch que muito me ajudou neste trabalho.

Aos amigos do NAEP, pela amizade e momentos de descontração.

À CAPES, à FAPEMIG, à Universidade Federal de Juiz de Fora e à Faculdade de Engenharia por todo o suporte e pelas ferramentas necessárias ao desenvolvimento deste trabalho.

*Aprender é a única coisa de que a mente
nunca se cansa, nunca tem medo e nunca
se arrepende.*

Leonardo da Vinci

RESUMO

O presente trabalho apresenta o desenvolvimento de métodos de compressão e descompressão de sinais elétricos advindos de sistemas de potência. O método de compressão é baseada em três estágios: a Detecção de Novidades; um estágio de Compressão com Perdas, baseado na Transformada Wavelet Discreta; e finalmente, um estágio de Compressão sem Perdas, baseado no algoritmo *Lempel-Ziv-Welch*. Foi desenvolvido também, um método para a reconstrução dos sinais comprimidos, que é baseado na Transformada Wavelet Inversa, núcleos de Transformada Discreta de Fourier e na frequência estimada do sinal. A parte de compressão utiliza técnicas de processamento digital de sinais em tempo real, e foi desenvolvida de modo a ser implementada em plataforma FPGA, e a parte de descompressão é executada em um software *offline*. O trabalho apresenta também um estudo de técnicas de representação esparsa de sinais em dicionários redundantes, com o objetivo de avaliar seu desempenho quando aplicadas à compressão de sinais elétricos, e também, a viabilidade de implementá-las em tempo real, substituindo a Transformada Wavelet Discreta, no estágio de Compressão com Perdas no sistema mencionado anteriormente.

Palavras-chave: Compressão de Sinais, Distúrbios Elétricos, Detector de Novidade, Transformada Wavelet, Representação Esparsa.

ABSTRACT

The present work presents the development of a method for power systems signal compression and decompression. The compression method is based in three stages: the novelty detection; the Lossy Compression based on the Discrete Wavelet Transform; and a Lossless Compression stage based on Lempel-Ziv-Welch algorithm. A decompression method was also developed to reconstruct the compressed signals, it is based on Inverse Wavelet Transform, Discrete Fourier Transform cores and the estimated frequency of the signal. The compression part uses digital signal processing techniques in real time, and it was developed to be implemented in FPGA platform. The decompression part runs offline in a PC software. This work also presents a study of sparse representation over redundant dictionaries techniques, in order to evaluate its performance when applied to electrical signal compression, and also the feasibility of implementing them in real time, replacing the Wavelet Transform compression stage in the system mentioned above.

Keywords: Signal Compression, Electrical Disturbance, Novelty Detector, Wavelet Transform, Sparse Representation.

LISTA DE ILUSTRAÇÕES

Figura 1	Diagrama de blocos do sistema de compressão proposto.	37
Figura 2	Diagrama de blocos do detector proposto.	39
Figura 3	Exemplo de resultado da detecção sem a utilização da lógica para evitar a detecção de sinais com frequência variante.	40
Figura 4	Exemplo de resultado da detecção com a utilização da lógica para evitar a detecção de sinais com frequência variante.	40
Figura 5	Estimação da frequência média.	41
Figura 6	Amostras no cruzamento por zero: interpolação linear.	42
Figura 7	Correção da estimação do período entre dois cruzamentos por zero.	43
Figura 8	Árvore de decomposição wavelet.	43
Figura 9	Informações que devem ser empacotadas de acordo com o status do <i>frame</i> atual e do <i>frame</i> anterior.	44
Figura 10	Fluxograma dos passos executados pelo Montador de Pacotes.	46
Figura 11	Fluxograma a ser seguido para reconstruir um sinal a partir do arquivo compactado.	47

Figura 12	Algoritmo de decodificação do arquivo.	48
Figura 13	Fluxograma que descreve a reconstrução dos <i>frames</i> que são de novidade.	50
Figura 14	Fluxograma que descreve a reconstrução dos <i>frames</i> que não são de novidade.	51
Figura 15	Decomposição SWRDFT.	52
Figura 16	Reconstrução SWRDFT.	53
Figura 17	Exemplo de sinal reconstruído sem correção na frequência.	53
Figura 18	Exemplo de sinal reconstruído com a frequência corrigida.	55
Figura 19	Fluxograma do algoritmo implementado para a obtenção do número de níveis de decomposição.	58
Figura 20	Árvore de decomposição wavelet.	58
Figura 21	Gráfico ilustrativo da curva da função custo do MDL (SAITO, 1994).	60
Figura 22	Resposta em frequência do banco de filtros wavelet selecionado.	62
Figura 23	Funções de Limiarização: (a) limiarização suave; (b) limiarização abrupta.	65
Figura 24	Limiarização dos coeficientes para um sinal com transitório.	67
Figura 25	Limiarização dos coeficientes para um sinal com notches.	68

Figura 26	Limiarização dos coeficientes para um sinal com harmônicos.	68
Figura 27	Erro médio quadrático entre o sinal quantizado e o sinal não quantizado.	70
Figura 28	Relação sinal ruído, calculada de acordo com a equação (4.14).	70
Figura 29	Diagrama de blocos do detector proposto.	73
Figura 30	Comparação entre as curvas ROC dos detectores para o Caso1.	77
Figura 31	Comparação entre as curvas ROC dos detectores para o Caso2.	78
Figura 32	Comparação entre as curvas ROC dos detectores para o Caso3.	79
Figura 33	Comparação entre as curvas ROC dos detectores para o Caso4.	80
Figura 34	Reconstrução do sinal durante o retorno de um afundamento.	84
Figura 35	Reconstrução do sinal durante presença de inter-harmônicos	84
Figura 36	Frames de novidade detectados para o sinal do Caso S2.	85
Figura 37	Frames de novidade detectados para o sinal do Caso S3.	86
Figura 38	Frames de novidade detectados para o sinal do Caso S4.	87
Figura 39	Reconstrução do sinal com variação de frequência	88

Figura 40	Reconstrução do sinal com variação de frequência	90
Figura 41	Bancada montada para testes do protótipo.	91
Figura 42	Bancada montada para testes do protótipo. A fonte Omicron ao fundo, o módulo de condicionamento à direita e o módulo de processamento à esquerda.	92
Figura 43	OMP - Orthogonal Matching Pursuit (ELAD, 2010).	100
Figura 44	MP - Matching Pursuit (ELAD, 2010).	101
Figura 45	StOMP - Stagewise Orthogonal Matching Pursuit.	102
Figura 46	ROMP - Regularized Orthogonal Matching Pursuit.	103
Figura 47	SSF - Separable Surrogate Functionals Iterative-shrinkage.	107
Figura 48	Erro Médio Quadrático para sinais contendo transitórios.	108
Figura 49	Correlação para sinais contendo transitórios.	109
Figura 50	Correlação para sinais contendo harmônicos estacionários.	110
Figura 51	Correlação para sinais contendo harmônicos variantes no tempo. ...	111
Figura 52	Correlação para sinais contendo Sags e Swells.	111
Figura 53	Número de elementos para sinais contendo transitórios.	112

Figura 54	Alguns elementos do dicionário proposto pertencentes a base wavelet.	113
Figura 55	Número de elementos para sinais contendo harmônicos estacionários.	114
Figura 56	Número de elementos para sinais contendo harmônicos variantes no tempo.	115
Figura 57	Número de elementos para sinais contendo sags e swells.	115
Figura 58	Fonte Omicron modelo CMC-256-6 <i>plus</i> .	135
Figura 59	Variação da amplitude e da frequência do sinal do Caso S4.	139
Figura 60	Variação da frequência do sinal do Caso S5.	140

LISTA DE TABELAS

Tabela 1	Percentual de coeficientes necessários para reconstrução dos sinais. .	61
Tabela 2	Correlação entre o sinal original e o sinal reconstruído.	61
Tabela 3	Percentual de coeficientes que ficaram acima do limiar.	65
Tabela 4	Percentual de energia do sinal reconstruído em relação ao sinal original.	66
Tabela 5	Resultados Compressão Offline.	89
Tabela 6	Resultados para o Caso 6.	89
Tabela 7	Resultados Compressão Online	93
Tabela 8	Comparação entre os tamanhos dos arquivos comprimidos.	94
Tabela 9	Comparação entre os métodos de compressão.	116
Tabela 10	Percentual de elementos selecionados de cada uma das bases que compõem o dicionário.	116
Tabela 11	Número de níveis de decomposição para wavelets mãe da família das Daubechies.	127
Tabela 12	Número de níveis de decomposição para wavelets mãe da família das	

	Symlets.	127
Tabela 13	Número de níveis de decomposição para wavelets mãe da família das Coiflets.	128
Tabela 14	Coiflets	128
Tabela 15	Número de níveis de decomposição para wavelets mãe da família das Biortogonais.	129
Tabela 16	Número de níveis de decomposição para wavelets mãe da família das Biortogonais Reversas.	129
Tabela 17	Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Daubechies.	130
Tabela 18	Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Daubechies.	130
Tabela 19	Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Symlets.	131
Tabela 20	Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Symlets.	131
Tabela 21	Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Coiflets.	132
Tabela 22	Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Coiflets.	132
Tabela 23	Percentual de coeficientes necessários para reconstrução dos sinais uti-	

	lizando wavelets mãe da família das Biortogonais.	133
Tabela 24	Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Biortogonais.	133
Tabela 25	Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Biortogonais Reversas.	134
Tabela 26	Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Biortogonais Reversas.	134
Tabela 27	Descrição temporal do sinal do caso S1.	136
Tabela 28	Descrição temporal do sinal do caso S2.	137
Tabela 29	Descrição temporal do sinal do caso S3.	138

LISTA DE ABREVIATURAS E SIGLAS

- DCT** Transformada Discreta de Cosseno, (do inglês, *Discrete Cossine Transform*)
- DEF** Diferença de Energia entre Frames
- DFT** Transformada Discreta de Fourier, (do inglês, *Discrete Fourier Transform*)
- DWT** Transformada Wavelet de Tempo Discreto, (do inglês, *Discrete Wavelet Transform*)
- FDR** Registrador de Dados de Falha, (do inglês, *Fault Data Recorder*)
- FOCUSS** *FOcal Undetermined System Solver*
- FPGA** *Field Programmable Gate Array*
- IDWT** Transformada Wavelet Inversa de Tempo Discreto, (do inglês, *Inverse Discrete Wavelet Transform*)
- IRLS** *Iterative-Reweighed-Least-Squares*
- LZW** *Lempel-Ziv-Welch*
- MAD** Desvio Absoluto Mediano, (do inglês, *Median Absolute Deviation*)
- MDL** *Minimum Description Length*
- MOD** *Method of Optimal Directions*
- MP** *Matching Pursuit*
- MSE** Erro Médio Quadrático, (do inglês *Mean Squared Error*)
- NMSE** Erro Médio Quadrático Normalizado, (do inglês, *Normalized Mean Squared Error*)
- PL** Programação Linear
- NF-WDFT** *Notch Filtering-Warped Discrete Fourier Transform*
- OMP** *Orthogonal Matching Prsuit*

PQDA Analisador de Dados de Qualidade de Energia, (do inglês, *Power Quality Data Analyzer*)

PQDIF *Power Quality Data Interchange Format*

QEE Qualidade de Energia Elétrica

RISC *Reduced Instruction Set Computer*

ROMP *Regularized Orthogonal Matching Pursuit*

SNR Relação Sinal Ruído, (do inglês, *Signal to Noise Ratio*)

SEP Sistemas Elétricos de Potência

SSF *Separable Surrogate Functionals*

StOMP *Stagewise Orthogonal Matching Pursuit*

SWRDFT Transformada Discreta de Fourier Recursiva de Janela Deslizante, (do inglês, *Sliding Window Recurssive Discrete Fourier Transform*)

WMP *Weak Matching Pursuit*

WPT Transformada *Wavelet Packet*, (do inglês, *Wavelet Packet Transform*)

SUMÁRIO

1	Introdução	24
1.1	Motivação	25
1.2	Objetivos	26
1.3	Organização Geral do Texto	26
2	Revisão Bibliográfica	28
2.1	Compactação de Sinais Elétricos	28
2.2	Representação Esparsa de Sinais Através de Dicionários Redundantes . . .	31
2.3	Conclusões Parciais	36
3	Sistema de compressão e descompressão de dados da rede elétrica	37
3.1	Sistema de compressão	37
3.1.1	Segmentação	38
3.1.2	Detecção de Novidade	38
3.1.3	Estimação da Frequência	41
3.1.4	Compressão com Perdas	43
3.1.5	Montador de Pacotes	44
3.1.6	Compressão sem Perdas	47
3.2	Sistema de descompressão	47
3.2.1	Reconstrução dos <i>frames</i> de novidade	49
3.2.2	Reconstrução dos <i>frames</i> de não novidade	49
3.3	Conclusões Parciais	55
4	Critérios Utilizados para a seleção da melhor árvore de decomposição	

wavelet, limiarização e quantização dos coeficientes	56
4.1 Seleção do banco de filtros para compressão dos distúrbios elétricos	56
4.1.1 Obtenção do número de níveis de decomposição	57
4.1.2 Seleção da wavelet mãe	59
4.2 Limiarização dos Coeficientes	62
4.3 Quantização dos Coeficientes	69
4.4 Conclusões Parciais	71
5 Detector de Novidades	72
5.1 Detecção de Novidade	72
5.2 Proposta de um Detector de Novidades	73
5.2.1 Diferença de Energia entre Frames (DEF)	75
5.2.2 Energia do Resíduo (ER)	76
5.3 Comparação entre as métricas de Detecção	76
5.3.1 Caso1	77
5.3.2 Caso2	78
5.3.3 Caso3	79
5.3.4 Caso4	79
5.4 Conclusões Parciais	80
6 Resultados	81
6.1 Sinais de Teste	81
6.2 Testes Offline	82
6.2.1 Caso S1	83
6.2.2 Caso S2	85
6.2.3 Caso S3	86
6.2.4 Caso S4	86
6.2.5 Caso S5	88

6.2.6	Caso S6 - Sinal Real	89
6.3	Testes Online - Implementação em tempo real	90
6.4	Conclusões Parciais	93
7	Representação Esparsa para compressão de sinais elétricos	95
7.1	Representação esparsa utilizando dicionários redundantes	95
7.2	Construção do Dicionário	97
7.3	Algoritmos para Representação Esparsa	98
7.3.1	Algoritmos Gulosos	99
7.3.1.1	Orthogonal Matching Pursuit - OMP	99
7.3.1.2	Matching Pursuit - MP	100
7.3.1.3	Stagewise Orthogonal Matching Pursuit - StOMP	101
7.3.1.4	Regularized Orthogonal Matching Pursuit - ROMP	103
7.3.2	Algoritmos Iterativos de Redução - <i>Iterative Shrinkage Algorithms</i>	104
7.3.2.1	Separate Surrogate Functionals Method - SSF	105
7.4	Análise de desempenho dos algoritmos	107
7.4.1	Qualidade da Aproximação	108
7.4.2	Número de Elementos utilizados	112
7.5	Comparação com a Compressão Utilizando Wavelets	115
7.6	Conclusões Parciais	117
8	Conclusão	118
8.1	Trabalhos Futuros	120
	Referências	121
	Apêndice A – Tabelas referentes aos resultados obtidos nas análises re-	
	ferentes à obtenção da melhor árvore de decomposição wavelet	127

A.1	Tabelas utilizadas na análise relativa à escolha do número de níveis de de- composição	127
A.2	Tabelas utilizadas nas análises relativas à escolha da melhor wacelet mãe .	130
Apêndice B – Descrição dos Sinais utilizados nos Testes		135
B.1	Caso S1:	136
B.2	Caso S2:	137
B.3	Caso S3:	138
B.4	Caso S4:	139
B.5	Caso S5:	140
Apêndice C – Produção Bibliográfica		141
C.1	Artigos em Congressos Nacionais	141
C.2	Artigos em Congressos Internacionais	141
C.3	Artigos Aceitos para Publicação em Periódicos	142
C.4	Patentes	144

1 INTRODUÇÃO

A aquisição contínua de distúrbios elétricos é necessária em muitas aplicações de sistemas de potência, tais como proteção, controle e análise de qualidade de energia. A razão para adquirir e armazenar esta grande quantidade de dados é apoiada pelo fato de que o pós-processamento dos dados pode revelar informações não observadas anteriormente e que podem auxiliar nas melhorias do sistema, na solução de problemas, otimização de algoritmos, entre outros aspectos. Além da aplicação natural, que é avaliar a qualidade do sistema.

O aumento da demanda por energia elétrica e a crescente utilização de geração dispersa e distribuída, interligadas aos sistemas elétricos de potência, tornam a operação, o controle e a proteção destes sistemas missões cada vez mais complexas. Além disso, visando aprimorar o fornecimento da energia elétrica, grande parte dos investimentos das empresas de transmissão e distribuição é destinada a fortalecer tecnologicamente sua infraestrutura operacional. Portanto, existe uma crescente necessidade de se caracterizar corretamente o comportamento desses sistemas.

Cerca de duas décadas atrás, devido à desregulamentação do setor elétrico em todo o mundo, usuários e empresas públicas passaram a se preocupar com os impactos causados por problemas de qualidade de energia. Esses problemas surgem como resposta ao uso massivo de cargas não-lineares e equipamentos eletrônicos em residências, centros comerciais e instalações industriais. Além disso, foi percebido que essas deficiências poderiam se intensificar caso não fossem corretamente corrigidas. Isto fez com que a monitoração da qualidade de energia elétrica recebesse muita atenção durante as duas últimas décadas, o que impulsionou e continua impulsionando o desenvolvimento de equipamentos capazes de detectar e classificar distúrbios a fim de analisar a qualidade da energia do sistema. Várias tecnologias têm surgido com o intuito de monitorar o comportamento de sistemas de energia elétrica em diferentes níveis: alta tensão (HV), média tensão (MT) e baixa tensão (LV) (TCHEOU et al., 2014).

No entanto, a gravação de dados brutos do sinal elétrico (tensão e corrente) de forma contínua não é uma tarefa simples, devido à grande quantidade de dados a serem

gravados e, posteriormente, transferidos para uma central de processamento onde os dados poderão ser analisados. Adicionalmente, poucos equipamentos comerciais estão disponíveis no momento para gravação de dados de oscilografia (formas de onda dos sinais) durante um longo período de tempo e em uma taxa de aquisição relativamente alta, visando a recuperação dos sinais de distúrbio (MAASS et al., 2013). Em geral, os equipamentos disponíveis para essa finalidade são orientados a aplicações específicas e são utilizados apenas para a aquisição de um curto período de tempo do sinal de falha ou sinal de perturbação. Dois exemplos de equipamentos comerciais que adquirem dados brutos são o Analisador de Dados de Qualidade de Energia, (do inglês, *Power Quality Data Analyzer*) (PQDA) e o Registrador de Dados de Falha, (do inglês, *Fault Data Recorder*) (FDR). O PQDA é especializado em detectar e registrar os distúrbios de qualidade de energia, enquanto o FDR é projetado para capturar sinais de corrente e tensão devido às faltas ocorridas em linhas de transmissão.

Conforme mencionado, no novo contexto de *Smart-Grids*, onde o comportamento da rede elétrica ainda não é claramente compreendido pelos cientistas e engenheiros, a aquisição de dados brutos e de forma contínua para serem pós-processados pode ser extremamente importante para identificar erros e desvios na operação, proteção e controle do sistema e também podem ser utilizados para encontrar informações aparentemente escondidas, através de técnicas de mineração de dados (HEYDT; GUNTHER, 1996; ZVANOVIC et al., 2004).

1.1 MOTIVAÇÃO

No cenário descrito acima, a gravação dos dados de oscilografia será de grande importância em Sistemas Elétricos de Potência (SEP), especialmente no contexto de redes elétricas inteligentes. Portanto, é esperado que os equipamentos que irão armazenar estes dados estejam munidos de técnicas capazes de reduzir a quantidade de dados que serão armazenados e/ou transmitidos, sem que haja perda de informações relevantes. Isto abre espaço para a pesquisa, desenvolvimento e implementação de novas técnicas de compressão de dados, em especial as que possibilitem uma maior taxa de compressão mesmo que ao custo de uma complexidade computacional maior. Como consequência natural, a utilização de hardware reconfigurável, como *Field Programmable Gate Array* (FPGA) se torna atrativa. Com o uso dessa tecnologia, é possível sintetizar, em *hardware*, algoritmos de processamento digital de sinais eficientes em termos de detecção e compressão, mas que demandam elevado custo computacional.

Adicionalmente, é possível desenvolver e embarcar processadores para realizar tarefas específicas. Portanto, os FPGAs se mostram como uma tecnologia muito promissora para constituir a base que contém a inteligência necessária para um equipamento que armazene as formas de onda de tensão e corrente advindas de SEP.

Esses equipamentos devem fazer uso de técnicas de detecção e compressão, operando em tempo real para que o armazenamento seja eficiente. A maioria dos métodos de compressão de sinais elétricos é baseada em Transformada Wavelet, nas suas mais diversas formas de aplicação. Porém, outras técnicas estão começando a ser utilizadas nessa área. Como exemplo, técnicas de representação esparsa de sinais em dicionários redundantes, largamente utilizadas para compressão de imagens. Uma característica dessas técnicas é a elevada complexidade computacional, que muitas vezes impossibilita sua utilização em tempo real. Portanto, há a necessidade de se realizar um estudo das diversas técnicas de representação esparsa para avaliar sua viabilidade de implementação neste tipo de equipamento.

1.2 OBJETIVOS

O presente trabalho tem como objetivo estudar técnicas de processamento digital de sinais e propor um método eficiente de compressão de sinais elétricos. O método proposto deve ser capaz de ser implementada em tempo real, utilizando plataforma FPGA, a qual constituirá o núcleo principal de processamento de um equipamento capaz de armazenar por um longo período de tempo as formas de onda de tensão e corrente de SEP.

Outro objetivo é estudar e implementar diversos algoritmos de representação esparsa de sinais em dicionários redundantes, para avaliar seu desempenho frente à utilização da Transformada Wavelet para a compressão de sinais elétricos e também sua complexidade computacional. Com essas análises, será possível concluir a respeito da viabilidade de implementá-los em tempo real, na plataforma FPGA, como parte da metodologia utilizada no equipamento citado acima.

1.3 ORGANIZAÇÃO GERAL DO TEXTO

No Capítulo 2 será feita uma revisão sobre os trabalhos publicados na área de compactação de sinais elétricos e, especificamente, de trabalhos que utilizam técnicas de representação esparsa de sinais.

No Capítulo 3 será apresentada a metodologia proposta para a compressão de sinais elétricos baseada em detecção de novidade e transformada Wavelet.

No Capítulo 4 serão mostradas as técnicas utilizadas para a obtenção da melhor árvore de decomposição wavelet, aplicada no sistema de compressão proposto, bem como o processo de limiarização mais adequado e o número ideal de bits a serem utilizados na quantização dos seus coeficientes.

No Capítulo 5 serão apresentados dois detectores baseados na energia do sinal e uma comparação será feita entre eles para que se defina qual é o mais adequado a ser utilizado como base para o sistema de compressão proposto.

No Capítulo 6 serão apresentados resultados de compressão obtidos para o sistema de compressão proposto, quando implementado offline, bem como para uma versão simplificada do mesmo implementada online em FPGA, e esses resultados serão comparados com os resultados obtidos por um equipamento analisador de Qualidade de Energia Elétrica (QEE) comercial, que possui a função de armazenar dados de oscilografia por longos períodos de tempo.

No Capítulo 7 será realizado o estudo de diversas técnicas de representação esparsa de sinais em dicionários redundantes e a será feita uma análise da viabilidade destas serem implementadas em tempo real.

Por fim, o Capítulo 8 apresentará conclusões gerais deste trabalho e algumas propostas para a continuidade desta pesquisa serão feitas.

2 REVISÃO BIBLIOGRÁFICA

Neste capítulo será feita uma revisão bibliográfica a respeito dos principais temas que constituem o foco deste trabalho: compactação de sinais elétricos e representação esparsa de sinais.

2.1 COMPACTAÇÃO DE SINAIS ELÉTRICOS

Técnicas de compressão para sinais advindos de sistemas de potência têm sido largamente estudadas nas últimas duas décadas. Técnicas de compressão sem perdas, como os codificadores Lempel-Ziv e Huffman (SAYOOD, 2012) são utilizadas em (LORIO; MAGNAGO, 2004). Em (KRAUS; TOBISKA; BUBLA, 2009) é apresentada uma revisão de vários métodos de compressão sem perdas, analisando diversos fatores como: taxa de compressão, estabilidade, confiabilidade e a capacidade desses algoritmos se adequarem a uma plataforma embarcada. Um dos principais formatos de armazenamento para formas de onda de sistemas elétricos de potência é o *Power Quality Data Interchange Format* (PQDIF) que é definido pelo IEEE1159 (IEEE1159, 2004) e também proporciona uma compressão sem perdas. Outras técnicas ainda são encontradas na literatura, como a proposta por (ZHANG; BI; ZHAO, 2009), baseada em modulação delta de alta ordem. Esta possui baixo custo computacional e produz uma alta taxa de compressão.

A fim de se conseguir taxas de compressão maiores, é necessária a utilização de técnicas de compressão com perdas. Nesta abordagem, quanto mais informação é perdida, maior será a taxa de compressão. Porém, vale ressaltar que o sinal reconstruído deve preservar suas principais características para proporcionar posteriores análises e diagnósticos (TCHEOU et al., 2012). A maioria das técnicas propostas utilizam as transformadas ortogonais, tais como: a Transformada Discreta de Fourier, (do inglês, *Discrete Fourier Transform*) (DFT), Transformada Discreta de Cosseno, (do inglês, *Discrete Cossine Transform*) (DCT) e a Transformada Wavelet de Tempo Discreto, (do inglês, *Discrete Wavelet Transform*) (DWT), seguidas por um processo de limiarização dos coeficientes no domínio da respectiva transformada. Este processo de limiarização

tem por objetivo eliminar informações de pouca relevância do sinal. Para isso, os coeficientes de baixa energia são zerados ou descartados.

Encontram-se na literatura alguns trabalhos relevantes que fazem uso de transformadas ortogonais. Em (NASCIMENTO, 1997) o sinal é dividido em janelas e transformadas ortogonais são aplicadas. O processo de limiarização é baseado na energia dos coeficientes transformados e um codificador do tipo *Run-Length* é aplicado. A metodologia apresentada em (QING et al., 2011) utiliza a DCT em duas dimensões. Para isso, o dado monitorado é truncado e recomposto em forma matricial, e então, a DCT-2D é aplicada. A DCT e a DFT são úteis na representação de sinais que possuem componentes periódicos e estacionários. Porém, os sinais de distúrbios elétricos possuem componentes transitórios, e estes são melhor representados pela DWT ou então pela Transformada *Wavelet Packet*, (do inglês, *Wavelet Packet Transform*) (WPT) devido à sua capacidade em representar sinais que apresentem variações temporais em seus componentes de frequência (PILLAY; BHATTACHARJEE, 1996).

Os trabalhos que são baseados em Wavelets seguem a mesma metodologia básica: o sinal é decomposto em seus componentes de aproximação e detalhes, e apenas os coeficientes acima de um determinado limiar são utilizados na reconstrução do sinal. Tratando-se de sinais de qualidade de energia, os coeficientes de aproximação são sempre mantidos, pois nesta banda de frequências encontra-se a informação mais relevante do sinal, que é o seu componente fundamental. Em (SANTOSO; POWERS; GRADY, 1997), após a aplicação da DWT, os coeficientes de detalhe que são menores que o limiar são descartados. Esse limiar é diferente para cada nível de detalhe e é escolhido como sendo uma porcentagem do valor máximo absoluto dos coeficientes daquele nível. Os coeficientes que são mantidos são armazenados juntamente com sua localização temporal para posterior reconstrução. Alguns trabalhos propõem zerar os coeficientes que estão abaixo do limiar e aplicar algum tipo de codificador no vetor de coeficientes resultante. Por exemplo: o codificador de Huffman utilizado em (HSIEH; HUANG, 2003) é aplicado em um sinal que foi decomposto em três bandas de frequência por filtros de quatro coeficientes baseados em uma wavelet mãe Daubechies; em (HUANG; JOU, 2004) o sinal decomposto por uma WPT é aplicado a um codificador aritmético para eliminar a redundância presente nos dados; e em (LITTLER; MORROW, 1999) o algoritmo de codificação utilizado é o *Lempel-Ziv-Welch* (LZW).

Enquanto em alguns trabalhos, como os já citados (SANTOSO; POWERS; GRADY, 1997), (HSIEH; HUANG, 2003) e (HUANG; JOU, 2004), os limiares são obtidos em função da energia dos coeficientes ou em relação ao máximo absoluto de cada nível, existem

alguns critérios, como o *Minimum Description Length* (MDL) (SAITO, 1994) que determinam não somente o número de coeficientes que devem ser armazenados, como também auxiliam na seleção do melhor filtro wavelet para determinado tipo de sinal. A utilização dessa técnica aplicada em sinais de distúrbios elétricos está mostrada em (HAMID; KAWASAKI, 2002).

Transformadas wavelet modificadas também têm sido utilizadas para comprimir sinais elétricos. Entre elas pode-se citar a *Slantlet Transform* e a wavelet Spline. A primeira é utilizada em (PANDA et al., 2002), onde apresenta resultados superiores a DCT e a DWT utilizadas, no que diz respeito à energia mantida e ao erro médio quadrático do sinal reconstruído em relação ao sinal original. A outra, proposta em (DASH et al., 2003), é utilizada para a compressão e reconstrução dos sinais, que são analisados por uma transformada wavelet modificada conhecida como transformada S (STOCKWELL; MANSINHA; LOWE, 1996).

Outra abordagem bastante frequente na literatura é a de se dividir o sinal em componentes periódicos e transitórios, em que os parâmetros dos componentes estacionários são estimados e a DWT é aplicada na parcela referente aos transitórios. Em (RIBEIRO; ROMANO; DUQUE, 2004) os autores propõem estimar, com a utilização de Filtro de Kalman, os parâmetros (amplitude, fase e frequência) do componente fundamental. Este componente é subtraído do sinal para gerar a parcela que contenha somente o transitório, e então a DWT é aplicada nesta parcela. A grande desvantagem desse método é considerar como estacionário somente o componente fundamental do sinal, incluindo na parcela relativa aos transitórios os componentes harmônicos e interharmônicos. Uma melhoria é proposta em (RIBEIRO et al., 2007) onde é utilizada a técnica denominada *Notch Filtering-Warped Discrete Fourier Transform* (NF-WDFT) (RIBEIRO; MITRA; ROMANO, 2004) para estimar a amplitude, a fase e a frequência de cada componente harmônico, aumentando a taxa de compressão atingida pela DWT. Estratégia similar é proposta por (ZHANG; LI; HU, 2011), porém esta faz uso de uma transformada de Fourier interpolada e estima somente a amplitude e a fase do componente fundamental e dos harmônicos, considerando a frequência de cada um desses componentes como sendo a frequência nominal.

Alguns trabalhos mais recentes utilizam técnicas de representação esparsa em dicionários redundantes. O algoritmo mais utilizado é o *Matching Pursuit* (MP) proposto por (MALLAT; ZHANG, 1993) ou alguma das variações do mesmo. Com a utilização dessa técnica, os autores em (LOVISOLO et al., 2005) propõem realizar uma representação coerente de sinais elétricos através de uma decomposição adaptativa dos mesmos em com-

ponentes senoidais exponencialmente amortecidas. Para isto, utilizam o algoritmo MP para representar o sinal em um dicionário de Gabor (GABOR, 1946), e a partir do átomo selecionado inicializa os parâmetros da senoide amortecida, aplicando um método de otimização para encontrar os melhores parâmetros do componente. Em (LOVISOLO et al., 2007) os mesmos autores apresentam a utilização da mesma técnica, porém, neste trabalho, o dicionário utilizado é constituído por átomos senoidais exponencialmente amortecidos, dispensando assim a utilização do dicionário de Gabor.

2.2 REPRESENTAÇÃO ESPARSA DE SINAIS ATRAVÉS DE DICIONÁRIOS REDUNDANTES

Antes de introduzir a representação esparsa, deve-se compreender o conceito de decomposição atômica de sinais, que consiste em utilizar formas de onda pré-definidas para expressar sinais. Essas formas de onda são chamadas de átomos e são elementos de um conjunto denominado dicionário. Essa decomposição é considerada adaptativa pois os elementos do dicionário são escolhidos de acordo com o sinal que se deseja representar. Matematicamente falando, tem-se uma matriz $\mathbf{A} \in \mathbb{R}^{N \times M}$, chamada de dicionário, um vetor de coeficientes $\mathbf{x} \in \mathbb{R}^M$ e o sinal $\mathbf{b} \in \mathbb{R}^N$ é representado como uma combinação linear das M colunas (átomos) de $\mathbf{A}$. Portanto, tem-se a seguinte equação:

$$\mathbf{Ax} = \mathbf{b} \tag{2.1}$$

Técnicas de decomposição atômica de sinais são utilizadas em trabalhos nas mais diversas áreas, tais como: para remoção de ruídos em (KRIM et al., 1999); análise harmônica (GRIBONVAL; BACRY, 2003; DONOHO et al., 1998); extração de parâmetros (JAGGI et al., 1998); decomposição tempo frequência (GOODWIN; VETTERLI, 1999; VERA-CANDEAS et al., 2004); entre outras.

Em problemas de representação atômica, a matriz $\mathbf{A}$ é considerada um dicionário redundante pois possui mais elementos, ou funções, do que as necessárias para se estabelecer uma base. Dessa forma, a matriz $\mathbf{A}$ possui mais colunas do que linhas ($M > N$), e portanto o sistema mostrado na equação (2.1) possui várias soluções. A solução que utiliza o menor número de elementos do dicionário é considerada a representação mais esparsa do sinal. Portanto, técnicas de representação atômica podem também ser utilizadas em compressão de sinais, em que o problema é justamente encontrar uma solução para (2.1) que seja esparsa.

Dessa maneira, as técnicas que se utilizam de representação esparsa apresentam os seguintes problemas: (i) dada uma matriz dicionário, como encontrar a solução da equação (2.1) com o menor número de elementos; e (ii) como construir a matriz dicionário.

Tratando-se do primeiro problema, tem-se um sistema de equações indeterminado e procura-se uma solução específica deste sistema, portanto deve-se estabelecer um critério que consiga expressar as características desejadas dessa solução. Uma forma de se introduzir esse critério é através de uma função custo $J(\cdot)$. E, então, um problema de otimização generalizado pode ser escrito da seguinte forma:

$$(P_J) : \min_{\mathbf{x}} J(\mathbf{x}) \text{ sujeito a } \mathbf{b} = \mathbf{A}\mathbf{x} \quad (2.2)$$

A Equação (2.2) significa que deseja-se minimizar a função $J(\mathbf{x})$, em relação à $\mathbf{x}$, e esse $\mathbf{x}$ deve estar sujeito à equação $\mathbf{b} = \mathbf{A}\mathbf{x}$. Vale a pena ressaltar então que essa função custo $J(\mathbf{x})$ determinará que tipo de solução será obtida para o problema. Uma função custo muito utilizada é a norma Euclidiana, ou norma l_2 , elevada ao quadrado $\|\mathbf{x}\|_2^2$. O problema que resulta dessa escolha é chamado de P_2 , definido pela Equação (2.3), e possui solução única (ELAD, 2010) como mostrada em (2.4):

$$(P_2) : \min_{\mathbf{x}} \|\mathbf{x}\|_2^2 \text{ sujeito a } \mathbf{b} = \mathbf{A}\mathbf{x} \quad (2.3)$$

$$\hat{\mathbf{x}}_{opt} = \mathbf{A}^+ \mathbf{b} \quad (2.4)$$

em que, $\mathbf{A}^+$, é a pseudo inversa de $\mathbf{A}$, dada por $\mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^{-1}$. A escolha pela norma l_2 é fundamentada pelo fato de possuir uma solução fechada, e por se assemelhar a técnicas de minimização de erro médio quadrático, que são muito difundidas em algoritmos populares de processamento de sinais, como Filtro de Wiener, Filtro de Kalman e *Least Squares*. Porém, em situações onde se requer uma solução esparsa, deve-se escolher uma função custo que promova esparsidade em $\mathbf{x}$. Em (ELAD, 2010) é matematicamente demonstrado que, dado um problema de minimização da norma l_p , em que:

$$\|\mathbf{x}\|_p = \sum_i |x_i|^p \quad (2.5)$$

quanto menor o valor de p , mais esparsa é a solução. Desta forma, uma possível escolha para a função custo que tende a gerar soluções esparsas é: $J(\mathbf{x}) = \|\mathbf{x}\|_1$. A utilização da norma l_1 tende a promover a esparsidade já que esta é dada pela soma dos valores absolutos dos elementos de $\mathbf{x}$. O problema de otimização se torna então:

$$(P_1) : \min_{\mathbf{x}} \|\mathbf{x}\|_1 \text{ sujeito a } \mathbf{b} = \mathbf{A}\mathbf{x} \quad (2.6)$$

Diferentemente de (P_2) , não é possível minimizar l_1 analiticamente, por possuir uma descontinuidade, e portanto necessita ser resolvido por algum método numérico de otimização. Uma técnica bastante utilizada é a de se transformar (P_1) em um problema de Programação Linear (PL). Para isto, escreve-se $\mathbf{x} = \mathbf{u} - \mathbf{v}$, em que $\mathbf{u}$ é um vetor que contenha somente os elementos positivos, e $\mathbf{v}$ somente o módulo dos elementos negativos do vetor $\mathbf{x}$. Pode-se então criar o vetor $\mathbf{z} = [\mathbf{u}^T, \mathbf{v}^T]$ que é a concatenação dos vetores $\mathbf{u}$ e $\mathbf{v}$. Pode-se verificar que a norma l_1 de $\mathbf{x}$ pode ser escrita da seguinte forma: $\|\mathbf{x}\|_1 = \mathbf{1}^T (\mathbf{u} + \mathbf{v})$ e que $\mathbf{A}\mathbf{x} = \mathbf{A}(\mathbf{u} - \mathbf{v}) = [\mathbf{A}, -\mathbf{A}]\mathbf{z}$. Este artifício matemático elimina a operação de módulo do processo de minimização, eliminando assim, a descontinuidade. Portanto o problema (P_1) pode ser reescrito como mostrado na Equação (2.7) e ser solucionado por técnicas de PL conhecidas na literatura.

$$\min_{\mathbf{z}} \mathbf{1}^T \mathbf{z} \text{ sujeito a } \mathbf{b} = [\mathbf{A}, -\mathbf{A}]\mathbf{z}, \mathbf{z} \geq \mathbf{0} \quad (2.7)$$

É sabido que normas l_p , para $p < 1$, geram soluções ainda mais esparsas. Porém estas não são ditas normas formais, visto que algumas propriedades podem não ser satisfeitas. Entre as normas l_p , para $p < 1$, a norma l_0 é a que melhor descreve esparsidade, já que seu valor é o número de elementos não nulos contidos no vetor. O problema (P_J) se transforma agora em (P_0) e é mostrado na seguinte equação:

$$(P_0) : \min_{\mathbf{x}} \|\mathbf{x}\|_0 \text{ sujeito a } \mathbf{b} = \mathbf{A}\mathbf{x} \quad (2.8)$$

A solução para o problema mostrado em (2.8) apresenta alguns desafios devido à natureza discreta e descontínua da norma l_0 . A solução de (P_0) é um problema clássico de busca combinatória, em que deve-se gerar todos os possíveis subsistemas esparsos $\mathbf{b} = \mathbf{A}_S \mathbf{x}_S$, em que $\mathbf{A}_S$ é uma matriz que contenha apenas as $|S|$ colunas da matriz $\mathbf{A}$ com índices contidos em S e testar se cada um desses subsistemas podem ser resolvidos. A complexidade dessa solução é exponencial em m (número de colunas da matriz $\mathbf{A}$),

portanto, (P_0) é classificado como um problema NP-Hard (LEEUWEN, 1990).

Já que a solução direta do problema (P_0) é inviável em termos computacionais, deve-se buscar outras possíveis soluções confiáveis. É observado que a tarefa de encontrar a variável $\mathbf{x}$ pode ser dividida em duas etapas: encontrar o seu suporte, ou seja, os índices dos elementos não nulos e determinar o valor desses elementos. Então, uma maneira de se atacar esse problema é focar na obtenção do suporte, pois uma vez obtido, os valores de seus coeficientes podem ser encontrados com a aplicação da Equação (2.4), para $\mathbf{A}^+ = \mathbf{A}_S$ (ELAD, 2010). Este raciocínio leva à família dos algoritmos *greedy* ou gulosos.

Esses algoritmos são inicializados com o vetor de solução $\mathbf{x}^0 = \mathbf{0}$ e com um resíduo inicial dado por $\mathbf{r}^0 = \mathbf{b} - \mathbf{A}\mathbf{x}^0 = \mathbf{b}$. A cada iteração k , é executado um estágio de varredura, cujo objetivo é encontrar a coluna da matriz $\mathbf{A}$ que mais se assemelha ao resíduo obtido na iteração anterior $\mathbf{r}^{k-1}$. Essa coluna é então adicionada ao suporte de $\mathbf{x}$ e uma solução provisória para o problema é encontrada. O novo resíduo $\mathbf{r}^k = \mathbf{b} - \mathbf{A}\mathbf{x}^k$ é, então, calculado e algum critério de parada é avaliado. Caso a aproximação ainda não seja suficientemente boa, volta-se ao estágio de varredura e adiciona-se mais um elemento ao suporte de $\mathbf{x}$.

Em processamento de sinais, destaca-se o algoritmo denominado *Matching Pursuit* (MP), proposto em (MALLAT; ZHANG, 1993), em que após o estágio de varredura apenas o coeficiente do elemento adicionado é calculado. Algumas variações desse método foram propostas na literatura, tais como: o *Orthogonal Matching Pursuit* (OMP) que a cada iteração todos os coeficientes do vetor de suporte são atualizados (PATI; REZAIIFAR; KRISHNAPRASAD, 1993); o LS-OMP em que a solução provisória é obtida através da aplicação de um *Least Squares*; o *Weak Matching Pursuit* (WMP) que realiza uma escolha sub-ótima na etapa de varredura; e o *Thresholding Algorithm*, que, na verdade, é uma simplificação do OMP, em que j elementos são selecionados simultaneamente na etapa de varredura (ELAD, 2010).

Outra classe de algoritmos destinada a resolver o problema da Equação (2.8) relaxam a norma l_0 substituindo-a por uma aproximação contínua ou mais suave. Dentre esses pode-se destacar o *FOcal Undetermined System Solver* (FOCUSS) que se utiliza de um método chamado *Iterative-Reweighed-Least-Squares* (IRLS) para representar a norma l_p (para um valor fixo $p \in (0, 1]$). O algoritmo FOCUSS consiste em uma maneira prática de se solucionar o problema, porém nem sempre converge para a solução ótima (ELAD, 2010). Na literatura, encontram-se ainda muitas outras variações e adap-

tações desses algoritmos, sejam com intuito de melhorar seu desempenho, acelerar sua convergência ou diminuir seu esforço computacional.

A escolha do dicionário é um ponto fundamental, pois impacta diretamente na esparsidade da aproximação. A utilização de dicionários pré-definidos geralmente levam a transformações mais rápidas, porém são limitados para representar esparsamente e satisfatoriamente a classe de sinais para a qual foram projetados. Uma maneira de superar essa limitação é a utilização de dicionários adaptativos. Para isso, é necessário um conjunto de dados de treinamento que contenha sinais parecidos com os sinais que se deseja representar. A escolha por um dicionário adaptativo acarreta um custo computacional adicional e significativo. Existem na literatura vários métodos que adaptam os dicionários fazendo uso de um conjunto de dados de treinamento $\mathbf{Y} = \{\mathbf{y}_i\}_{i=1}^N$, o qual é constituído de exemplos dos sinais que se deseja representar, e partindo do pressuposto que existe uma matriz dicionário $\mathbf{A}$ capaz de fornecer uma representação esparsa para cada elemento $\mathbf{y}_i$ desse conjunto. A tarefa é então encontrar qual é essa matriz $\mathbf{A}$.

Pode-se citar alguns métodos como os utilizados em (LEWICKI; OLSHAUSEN, 1999; OLSHAUSEN; FIELD, 1997), em que dado o conjunto de treinamento $\mathbf{Y}$, procuram o dicionário que maximize a razão de verossimilhança $P(\mathbf{Y}|\mathbf{A})$. O método denominado *Method of Optimal Directions* (MOD) apresentado em (ENGAN; AASE; HUSOY, 1999) é mais próximo do *K-means*, utilizado em problemas de clusterização de vetores (FORGY, 1965), e se utiliza de um estágio de aproximação esparsa que utiliza OMP ou FOCUSS por exemplo, seguido de um estágio de atualização do dicionário. Uma maneira de aliar a eficiência do MOD com a maneira natural de se considerar preferências no dicionário é a utilização da maximização da probabilidade a posteriori $P(\mathbf{A}|\mathbf{Y})$ (KREUTZ-DELGADO; RAO, 2000). Uma técnica para a atualização de dicionários constituídos por uma união de bases ortonormais é proposta em (LESAGE et al., 2005). Dessa forma, uma de suas maiores vantagens é a relativa simplicidade do algoritmo de busca para realizar a representação esparsa. Este algoritmo é mais simples dos que os outros mostrados devido a duas características: utiliza um dicionário estruturado e realiza sua atualização de forma estruturada. Uma generalização direta do algoritmo *K-means* é o K-SVD proposto por (AHARON; ELAD; BRUCKSTEIN, 2006). Esse algoritmo apresenta elevada eficiência devido à sua etapa de representação esparsa eficiente e seu método de atualização do dicionário que é do tipo Gauss-Seidel.

2.3 CONCLUSÕES PARCIAIS

Foram descritas diversas técnicas utilizadas para compressão com e sem perdas de sinais advindos de sistemas elétricos de potência, dentre elas pode-se destacar a utilização de transformadas ortogonais. As principais transformadas utilizadas são a DWT ou a WPT, essas transformadas são muito úteis pois elas dividem o sinal em bandas de frequência, possibilitando assim a aplicação de thresholds para eliminar a informação indesejada do sinal.

Através das técnicas analisadas pode-se perceber que uma metodologia interessante é a de se dividir o sinal em componentes periódicos e não periódicos, estimando os parâmetros dos componentes periódicos e aplicando a DWT na parcela referente aos transitórios, sendo possível desta maneira atingir melhores taxas de compressão.

Uma abordagem muito utilizada na compressão de imagens, porém ainda pouco explorada no âmbito de sinais elétricos é a utilização de técnicas de representação esparsa de sinais. Encontram-se poucos trabalhos na literatura, podendo-se destacar (LOVISOLO et al., 2005) e (LOVISOLO et al., 2007), em que os sinais são decompostos em elementos senoidais exponencialmente amortecidos. Nesses trabalhos, os autores conseguem excelente taxas de compressão a um custo computacional muito elevado.

3 SISTEMA DE COMPRESSÃO E DESCOMPRESSÃO DE DADOS DA REDE ELÉTRICA

Neste capítulo será apresentado o sistema proposto para a compressão e descompressão de sinais de tensão e corrente advindos da rede elétrica. O sistema opera de forma independente para cada canal de entrada e, atualmente, possui uma versão implementada em tempo real em plataforma FPGA.

O sistema proposto é baseado no fato de que somente as novidades presentes no sinal necessitam ser salvas (DUQUE et al., 2005). Dessa forma, o sinal é segmentado em *frames* e somente os *frames* que apresentarem novidades serão efetivamente armazenados. Para os *frames* que não apresentam novidade, apenas informações relativas à frequência do componente fundamental serão utilizadas. O sistema de descompressão, por sua vez, é capaz de reconstruir o sinal em todo o intervalo, baseado nas informações armazenadas.

3.1 SISTEMA DE COMPRESSÃO

O sistema de compressão proposto é composto de seis blocos principais, como mostrado na Figura 1: Segmentação; Detecção de Novidades; Estimação da Frequência; Compressão com Perdas; Montador de Pacotes; e Compressão sem Perdas.




Figura 1: Diagrama de blocos do sistema de compressão proposto.

No sistema mostrado na Figura 1, o sinal é segmentado em *frames* e processado simultaneamente por três blocos: (i) Detecção de Novidades; (ii) Estimação de Frequência; e (iii) Compressão com Perdas. O bloco Montador de Pacotes é o responsável por,

a partir do resultado da Detecção de Novidades, empacotar corretamente as informações vindas da Estimação de Frequência e da Compressão com Perdas. Os pacotes de dados são ainda comprimidos pelo bloco Compressão sem Perdas e posteriormente armazenados na memória.

3.1.1 SEGMENTAÇÃO

A segmentação é o processo de dividir o sinal em *frames* consecutivos sem que haja sobreposição. O tamanho de cada segmento, ou *frame*, pode ser fixo ou variável (adaptativo), dependendo do comportamento do sinal e da técnica de processamento.

Segmentação adaptativa é largamente utilizada no processamento de sinais biomédicos e de áudio (AZAMI et al., 2014). O principal objetivo é encontrar o comprimento do segmento em que o sinal pode ser representado pelo mesmo conjunto de parâmetros. Um conceito similar é introduzido em (BOLLEN; GU, 2006) para analisar distúrbios em sistemas de potência. A segmentação adaptativa requer processamento extra para identificar o tamanho de cada *frame*, antes da aplicação do processamento para extrair as informações.

Neste trabalho, a segmentação fixa é utilizada devido a sua simplicidade, e o tamanho da janela utilizada será de 4 ciclos do componente fundamental. Um estudo a respeito da utilização da segmentação adaptativa precisa ser feito para avaliar o seu impacto nos algoritmos de detecção e compressão, e será proposto como um trabalho futuro desta pesquisa.

3.1.2 DETECÇÃO DE NOVIDADE

O bloco Detecção de Novidade é a base da metodologia de compressão de sinais. Este consiste em um bloco de processamento que compara dois *frames* do sinal de entrada e gera um *flag* de saída que indica se o *frame* atual apresenta novidade ou não em relação ao *frame* de referência. Variações na frequência do componente fundamental do sinal não devem ser consideradas novidades para o sistema. Para estes casos será utilizada uma metodologia especial para a reconstrução do sinal.

Os testes que fundamentam a escolha do detector proposto estão mostrados no Capítulo 5, onde o mesmo é descrito de forma detalhada. Resumidamente, este detector é formado por dois ramos: um voltado para a detecção de distúrbios com espectro de frequência de banda larga, formado por um filtro passa-altas seguido por um bloco

que compara a energia de dois *frames*; o outro ramo, é baseado no cálculo da DFT, centrada na frequência fundamental, e é voltado para a detecção de distúrbios de baixa frequência (flicker e sub-harmônicos), e também auxilia na não detecção de sinais com frequência variante. A lógica de detecção do ramo inferior é baseada na comparação, ciclo a ciclo, do módulo $|Y_{f1}|$ e da fase $\angle Y_{f1}$ do componente fundamental, calculados através da DFT. O diagrama de blocos do detector é mostrado na Figura 2.




Figura 2: Diagrama de blocos do detector proposto.

A métrica utilizada para a detecção é a Diferença de Energia entre Frames (DEF), que é o valor absoluto da diferença entre a energia do *frame* atual e de um *frame* de referência. A escolha do parâmetro energia foi baseada na teoria da detecção de sinais, que maximiza a relação sinal-ruído para a detecção de distúrbios genéricos (os quais não se tem informação *a priori*) em um sinal imerso em ruído (KAY, 1998; VAN TREES, 2004). A métrica DEF foi comparada com outra, também baseada na energia e os testes realizados mostraram que a primeira apresenta melhor desempenho.

No Capítulo 5 serão mostrados os resultados dos testes que justificam a escolha da métrica DFE, bem como o cálculo do patamar ótimo para a detecção. Esse cálculo foi baseado na curva ROC (*Receiving Operation Characteristics*) (VAN TREES, 2004) do detector, que por sua vez foi construída utilizando sinais normalizados. Porém, na prática, essa escolha do patamar ótimo pode não satisfazer a necessidade de detecção de alguns distúrbios que apresentem pouca variação de energia, como pequenos afundamentos por exemplo. Além disso, podem existir cenários com sinais em diversas faixas de energia (amplitude) e portanto, uma estratégia inteligente e adaptativa deve ser implementada para a escolha do patamar de detecção, pois este é dependente da energia do sinal de entrada e também do nível de ruído presente neste sinal. Para solucionar essa questão, foram realizados testes com sinais em várias faixas de energia, e para cada uma delas, foi obtido, um valor de patamar, e o patamar aplicado na detecção é o relativo à faixa de energia em que se encontra o sinal.

Para ilustrar o efeito supressão da detecção de sinais que apresentem variações suaves na frequência foi gerado um sinal com amplitude fixa e frequência variando senoidalmente com a amplitude da variação igual a 0.25 Hz e período igual a 2s. A Figura 3 mostra o resultado da detecção sem a utilização dessa lógica, e a Figura 4 o resultado utilizando a lógica. Nessas figuras, os *frames* do sinal mostrados em linhas mais grossas são os *frames* em que foram detectadas novidades, e os *frames* mostrados em linha fina são os *frames* em que não foram detectadas novidades.




Figura 3: Exemplo de resultado da detecção sem a utilização da lógica para evitar a detecção de sinais com frequência variante.




Figura 4: Exemplo de resultado da detecção com a utilização da lógica para evitar a detecção de sinais com frequência variante.

Através das Figuras 3 e 4, pode ser percebido que, quando a lógica não é utilizada, o resultado da detecção é diretamente afetado pela variação da frequência, mesmo que essa variação se dê de forma suave. Como consequência da não utilização da lógica tem-se que vários *frames* de novidade são detectados no intervalo, enquanto que, quando a lógica é utilizada novidades são detectadas somente no início e no fim do intervalo. É importante lembrar que quanto mais *frames* de novidade forem detectados maior é a quantidade de informação que precisa ser armazenada, e portanto, pior será a taxa de compressão.

3.1.3 ESTIMAÇÃO DA FREQUÊNCIA

O valor da frequência estimada do sinal é necessário para a reconstrução dos *frames* que não apresentaram novidade. Estes então, são reconstruídos baseados na forma do sinal do *frame* de referência e das frequências médias dos *frames* que não apresentaram novidade. O diagrama de blocos do algoritmo de estimação de frequência utilizado está mostrado na Figura 5.




Figura 5: Estimação da frequência média.

O algoritmo *Zero Crossing* foi escolhido devido à sua simplicidade de implementação, visto que é baseado na contagem das amostras do sinal de entrada entre duas passagens por zero na mesma direção. Sendo T_{sc} o período de tempo entre dois cruzamentos por zero no mesmo sentido, a frequência do sinal pode ser estimada como sendo:

$$\hat{f}_1 = \frac{1}{T_{sc}} = \frac{1}{N \times T_s} \quad (3.1)$$

em que, N é o número de pontos entre dois cruzamentos por zero e T_s é o período de amostragem.

A precisão do cálculo da frequência é diretamente dependente da taxa de amostragem do sinal. Quanto maior a taxa de amostragem, mais próximas estarão as amostras do sinal e por consequência, o ponto de cruzamento por zero será mais bem localizado. Para melhorar a estimativa da frequência, pode-se implementar uma interpolação linear utilizando as amostras imediatamente antes e após o cruzamento, como mostrado

na Figura 6.

Figura 6: Amostras no cruzamento por zero: interpolação linear.

Na ilustração da Figura 6 $v_{60}[n-1]$ e $v_{60}[n]$ são, respectivamente, as amostras anterior e posterior ao cruzamento por zero. N_a e N_b são as estimações das distâncias relativas entre essas amostras e o cruzamento (N_a e $N_b < 1$; $N_a + N_b = 1$). Utilizando-se uma interpolação linear, os valores de N_a e N_b podem ser obtidos com as seguintes relações:

$$N_a = \frac{v_{60}[n-1]}{v_{60}[n-1] - v_{60}[n]} \quad (3.2)$$

$$N_b = \frac{v_{60}[n]}{v_{60}[n] - v_{60}[n-1]} \quad (3.3)$$

Os valores de N_b calculados para cada cruzamento por zero podem ser utilizados para corrigir o valor de T_{sc} de modo a obter uma estimativa mais precisa para a frequência. A Figura 7 ilustra este processo. De acordo com esta figura, a frequência estimada é obtida por:

$$\hat{f}_1 = \frac{1}{T_{sc}} = \frac{1}{(N + N_{b1} - N_{b2}) \cdot T_s} = \frac{F_s}{N + N_{b1} - N_{b2}} \quad (3.4)$$

em que, $N_{b1} - N_{b2}$ são os valores mostrados na Figura 7.

Figura 7: Correção da estimação do período entre dois cruzamentos por zero.

A cada ciclo do componente fundamental, um valor de frequência é estimado. Desta forma, quatro valores de frequência são armazenados para cada *frame* do sinal, para serem posteriormente utilizados pelo algoritmo de reconstrução. O algoritmo *Zero Crossing* utilizado neste trabalho está descrito em (RIBEIRO et al., 2013).

3.1.4 COMPRESSÃO COM PERDAS

O bloco que executa a compressão com perdas é baseado na DWT e é executado paralelamente aos dois blocos anteriores. Este bloco é responsável por comprimir o sinal, descartando informações redundantes, ou julgadas irrelevantes. A árvore de decomposição wavelet utilizada é baseada na wavelet mãe bior3.1 (nomenclatura utilizada pelo software Matlab) e possui 5 níveis de decomposição. Os critérios utilizados para a escolha da wavelet mãe, número de níveis de decomposição, bem como do processo de limiarização e quantização dos coeficientes serão discutidas no Capítulo 4.

A Figura 8 mostra a árvore de decomposição wavelet utilizada.




Figura 8: Árvore de decomposição wavelet.

Nessa figura, $v[n]$ é o sinal a ser decomposto; $H_d[n]$ e $L_d[n]$ são, respectivamente, os filtros passa-altas e passa-baixas da decomposição, ambos de 4ª ordem; C_{D1} , C_{D2} , C_{D3} , C_{D4} e C_{D5} são os coeficientes de detalhe, e C_{A5} os coeficientes de aproximação. Essa estrutura de decomposição divide o sinal de entrada em bandas de frequência, e a compressão é realizada aplicando-se uma limiarização nos coeficientes da saída. Em se tratando de sinais advindos de sistemas de potência, as informações mais relevantes estão contidas nas bandas de menor frequência, na qual o componente fundamental está localizado. Portanto, a limiarização só é feita nos coeficientes de detalhe e todos os coeficientes de aproximação são preservados. O processo de obtenção do limiar é baseado na estimação do nível de ruído presente no sinal, e é descrito no Capítulo 4. Os coeficientes de aproximação, e os coeficientes de detalhe após a limiarização, são ainda quantizados, para que o armazenamento seja mais eficiente.

É importante ressaltar que, apesar deste trabalho utilizar a DWT para a compressão com perdas, qualquer outra técnica desse tipo que atenda os requisitos para ser executada online pode ser aplicada neste bloco.

3.1.5 MONTADOR DE PACOTES

O bloco Montador de Pacotes é o responsável por organizar as informações provenientes dos blocos anteriores de maneira padronizada para que o sistema de descompressão possa interpretá-las de forma correta. Este bloco é executado ao final de cada *frame* e as informações que ele deve enviar são determinadas pelo status de novidade do *frame* atual e do *frame* anterior. As situações possíveis estão mostradas na Figura 9.

Figura 9: Informações que devem ser empacotadas de acordo com o status do *frame* atual e do *frame* anterior.

Na Figura 9 pode ser visto um sinal que apresenta o primeiro e o último *frames* detectados como sendo *frames* de novidade e um intervalo de N *frames* consecutivos que não apresentam novidade. Através dessa figura fica claro o impacto da detecção de novidades na compressão do sinal, visto que para um longo intervalo de *frames* não detectados, apenas 4 words por *frame* são armazenadas em vez das 512 words necessárias para armazenar um *frame* de novidade. O termo words é utilizado aqui para representar um conjunto de bits, mais detalhes a respeito do número de bits utilizado por cada parâmetro serão vistos adiante.

O sistema de descompressão deve reconhecer em qual das quatro situações possíveis foi enquadrado o *frame* que será reconstruído. Para isso, é necessário que cada uma deles seja marcado com um *flag* diferente. As quatro situações e seus *flags* são:

- 1) O *frame* atual apresenta novidade, assim como o *frame* anterior (*flag* = 0).
- 2) O *frame* atual não apresenta novidade, assim como o *frame* anterior (*flag* = 1).
- 3) O *frame* atual não apresenta novidade, mas o *frame* anterior sim (*flag* = 2).
- 4) O *frame* atual apresenta novidade, e o anterior não (*flag* = 3).

O fluxograma na Figura 10 ilustra os passos do algoritmo do Montador de Pacotes e quais são as informações que ele precisa enviar em cada uma das quatro situações descritas anteriormente. As informações que serão enviadas dependem não somente do *frame* atual, mas também do *frame* anterior, por dois motivos: o primeiro é devido ao efeito de borda causado pelos filtros da wavelet. Para reconstruir os quatro ciclos de um *frame* de novidade, são necessários coeficientes relativos a mais do que quatro ciclos do sinal; e o segundo é devido a metodologia de reconstrução que necessita de dois pontos do sinal real para reconstruir perfeitamente o intervalo de *frames* de não novidade.

Se o *frame* atual é um *frame* de novidade, existem duas possibilidades: a de que o *frame* anterior também apresentou novidade, e nesse caso todas as informações relativas a ele já foram enviadas, sendo necessário, portanto, enviar apenas os coeficientes da wavelet do *frame* atual; ou a de que o *frame* anterior não foi um *frame* de novidade, sendo necessário, assim enviar a amostra do sinal no instante de tempo anterior $x[n-1]$ e a amostra do sinal dez instantes de tempo passados $x[n-10]$, antes dos coeficientes da wavelet do *frame* atual. A necessidade dessas duas amostras se tornará clara na explicação da descompressão do sinal.




Figura 10: Fluxograma dos passos executados pelo Montador de Pacotes.

Se o *frame* atual não apresenta novidade, também existem duas possibilidades: a de que o *frame* anterior também não apresentou novidade, portanto as únicas informações que devem ser enviadas são as frequências médias de cada ciclo do *frame* atual; ou a de que o *frame* anterior apresentou novidade. Nesse caso, antes de enviar as quatro frequências médias do *frame* atual, é necessário enviar os coeficientes da wavelet relativos ao primeiro ciclo após o *frame* anterior.

O bloco Montador de Pacotes fornece em sua saída um *stream* de bits relativos às informações quantizadas. É importante saber que cada tipo de informação é quantizada com um número diferente de bits. Para os flags, já que são apenas quatro valores distintos, utilizam-se 2 bits. Já para os coeficientes da wavelet, foram utilizados 10 bits, como será mostrado no Capítulo 4. Finalmente, para os valores de frequência média e os pontos do sinal foram utilizados 16 bits. Esses valores de números de bits precisam ser de conhecimento do algoritmo de descompressão, para que o processo ocorra de forma correta.

3.1.6 COMPRESSÃO SEM PERDAS

O bloco Compressão sem Perdas é responsável por adquirir os dados ordenados pelo Montador de Pacotes e comprimi-los com um algoritmo de compressão sem perdas, ou seja, depois de descomprimido o dado retorna ao que era originalmente, antes dessa última compressão. O algoritmo escolhido foi o LZW e nele foram feitas algumas modificações, como restrição do tamanho do dicionário, com o intuito de que o mesmo possa ser executado online (NANDI; MANDAL, 2012). Depois de comprimido, o dado é salvo em uma memória de massa, que no caso do protótipo implementado, é um cartão SD.

3.2 SISTEMA DE DESCOMPRESSÃO

O sistema de descompressão é o responsável por, a partir do arquivo codificado e compactado, reconstruir o sinal original. Para tanto, deve-se percorrer a sequência de passos que está mostrada na Figura 11. Vale a pena ressaltar que somente os *frames* que apresentaram novidade é que estão efetivamente armazenados no arquivo, e os outros *frames* serão reconstruídos a partir destes.




Figura 11: Fluxograma a ser seguido para reconstruir um sinal a partir do arquivo compactado.

O primeiro passo de todo este processo é aplicar a descompressão do arquivo através do algoritmo LZW. Desta forma, obtém-se um arquivo de texto estruturado de acordo com a operação do Montador de Pacotes, em que cada informação enviada foi escrita em uma linha do arquivo. O próximo passo a ser realizado é a decodificação desse arquivo. Nessa etapa, o objetivo é encontrar, no arquivo, quais são os *frames* que apresentaram novidade e os valores das frequências médias estimadas. A decodificação do arquivo é realizada através do algoritmo mostrado na Figura 12.

```

indice = 1;
while (indice < n° de linhas do arquivo) do
    flag = arquivo(indice);
    if flag == 1 then
        Sinaliza a ocorrência de um frame de novidade;
        Armazena as frequências médias;
        Armazena os coeficientes da wavelet;
        indice = indice + 516;
    end
    if flag == 2 then
        Sinaliza a ocorrência de um frame de não novidade;
        Armazena as frequências médias;
        indice = indice + 4;
    end
    if flag == 3 then
        Armazena os coeficientes do ciclo extra da wavelet;
        indice = indice + 128;
    end
    if flag == 4 then
        Armazena os pontos  $x[n - 1]$  e  $x[n - 10]$ ;
        indice = indice + 2;
    end
end
end

```

Figura 12: Algoritmo de decodificação do arquivo.

Na etapa de Decodificação deve-se percorrer o arquivo até o fim para extrair as informações necessárias para reconstruir o sinal. O processo se inicia com a leitura da primeira linha. Esta linha contém um dos *flags* provenientes do Montador de Pacotes. Testa-se então este *flag*, pois o seu valor indica qual é a sequência de informações que está a seguir. O *flag* pode possuir quatro valores: se o valor do *flag* for 0, as próximas linhas contêm quatro valores de frequência e 512 coeficientes da wavelet relativos à este *frame*. Nesse caso, então deve-se extrair essas informações do arquivo e sinalizar a ocorrência de um *frame* de novidade. Se o *flag* for 1, deve-se sinalizar a ocorrência de um *frame* de não novidade e extrair o valor das quatro frequências deste *frame*. Se o *flag* for 2, deve-se extrair os coeficientes do ciclo extra da wavelet relativos ao *frame* atual. Finalmente, se o *flag* for 3, deve-se extrair os valores dos pontos $x[n - 1]$ e $x[n - 10]$ relativos ao *frame* atual. É importante ressaltar que a cada *flag* lido, o índice deve ser atualizado para apontar para a posição do próximo *flag* no arquivo e também que apenas os *flags* 0 e 1 significam a ocorrência de um *frame* do sinal. Os *flags* 2 e 3 indicam apenas a existência de informações extras no arquivo.

Com o arquivo completamente decodificado, disponibiliza-se uma interface com o

usuário. Essa interface contém as seguintes informações: o valor ou gráfico da frequência média para cada *frame* do sinal (esse valor é obtido fazendo-se a média das frequências médias de cada ciclo do *frame*) e a sinalização de quais *frames* do sinal apresentaram novidade. De posse dessas informações, o usuário pode escolher quais *frames* do sinal ele deseja reconstruir. O próximo passo é descobrir, no intervalo escolhido pelo usuário, quais *frames* apresentaram e quais não apresentaram novidade para a devida reconstrução do sinal.

Como a reconstrução dos *frames* que não apresentaram novidade é baseada em algum *frame* de referência anterior, reconstrói-se primeiro os *frames* de novidade pertencentes ao intervalo selecionado. Se o intervalo não possuir nenhum *frame* de novidade, encontra-se qual foi o último *frame* que apresentou novidade antes do intervalo selecionado e o reconstrói. Com esses *frames* reconstruídos, pode-se então reconstruir os *frames* que não apresentaram novidade. Após a reconstrução de todos os *frames* do intervalo selecionado pelo usuário, os mesmos são concatenados em um vetor e gera-se o gráfico do sinal reconstruído.

3.2.1 RECONSTRUÇÃO DOS FRAMES DE NOVIDADE

A reconstrução dos *frames* de novidade é baseada na Transformada Wavelet Inversa de Tempo Discreto, (do inglês, *Inverse Discrete Wavelet Transform*) (IDWT) e é feita seguindo-se os passos do fluxograma mostrado na Figura 13. O primeiro passo é inicializar o índice com o número do primeiro *frame* que deve ser reconstruído e concatenar, em um vetor de coeficientes (que inicialmente encontra-se vazio), os valores dos coeficientes relativos a este *frame*. O objetivo é reunir, nesse vetor, os coeficientes relativos a um intervalo de *frames* de novidade consecutivos. Então, testa-se se o próximo *frame* também apresentou novidade: se sim, incrementa-se o índice e concatena-se no vetor os coeficientes relativos ao próximo *frame*; se não, concatena-se os coeficientes do ciclo extra. Com o vetor de coeficientes completo, aplica-se a IDWT para reconstruir o sinal nesse intervalo. Se houver mais algum *frame* de novidade para ser reconstruído, atualiza-se o índice com o número desse *frame* e repete-se o processo. Se não houver outra novidade, retorna-se os *frames* reconstruídos.

3.2.2 RECONSTRUÇÃO DOS FRAMES DE NÃO NOVIDADE

A reconstrução de um *frame* de não novidade é baseada em um *frame* de referência e nas frequências médias estimadas de cada ciclo do sinal. O *frame* de referência é




Figura 13: Fluxograma que descreve a reconstrução dos *frames* que são de novidade.

o último *frame* de novidade anterior ao *frame* a ser reconstruído, ou ao conjunto de *frames* de não novidade. Este processo obedece o fluxograma mostrado na Figura 14.




Figura 14: Fluxograma que descreve a reconstrução dos *frames* que não são de novidade.

A reconstrução dos *frames* que não apresentaram novidade é baseada nas seguintes informações: o *frame* de referência, as frequências médias do intervalo que se deseja reconstruir e os pontos $x[n-1]$ e $x[n-10]$ do sinal real. O algoritmo base para a reconstrução desses *frames* é a Transformada Discreta de Fourier Recursiva de Janela Deslizante, (do inglês, *Sliding Window Recursive Discrete Fourier Transform*) (SWRDFT) proposto em (FABRI et al., 2010). Como este algoritmo requer que o sinal possua amos-

tragem síncrona, é necessário interpolar o sinal do *frame* de referência antes de aplicá-lo ao algoritmo. A utilização da SWRDFT se dá em duas etapas: uma de decomposição e outra de reconstrução.

A etapa de decomposição é conforme na Figura 15. O objetivo dessa etapa é a obtenção dos componentes em quadratura (Y_{S_h} e Y_{C_h}) de cada harmônico até o de ordem 50, e também do componente CC. Esses valores são obtidos executando-se este diagrama de bloco 51 vezes, variando o valor de h de 0 até 50. Ao final tem-se 51 valores de Y_{S_h} e 51 valores de Y_{C_h} com cada par relativo a um componente harmônico e ao componente CC. Esses valores de Y_{S_h} e Y_{C_h} possuem as informações de amplitude e fase de cada componente e portanto, serão a base para a etapa de reconstrução.




Figura 15: Decomposição SWRDFT.

Na Figura 15, N é o número de pontos contidos em um ciclo do sinal $x[n]$, e ω_1 é sua frequência fundamental em rad/s. Os valores de Y_{S_h} e Y_{C_h} obtidos na etapa de decomposição são a entrada para a etapa de reconstrução, como está mostrado na Figura 16. Esta estrutura utiliza os componentes em quadratura do *frame* de referência e as frequências médias dos *frames* que serão utilizados para reconstruir o sinal. O valor das frequências médias ω_{med} estimadas interfere diretamente na reconstrução destes *frames*, portanto, a eficiência da reconstrução está diretamente relacionada ao erro presente nessas estimativas.

Quando ocorre um erro na estimação da frequência, a reconstrução do sinal não se dá perfeitamente, podendo acontecer alguma descontinuidade, no momento em que se inicia um *frame* de novidade, após um intervalo em que só houveram *frames* de não novidade. A Figura 17 ilustra essa situação. Como não pode-se garantir que a estimação da frequência não apresente erros, foi necessário desenvolver uma metodologia que




Figura 16: Reconstrução SWRDFT.

possa corrigir este erro e proporcionar uma reconstrução (ou casamento) perfeita do sinal.

Figura 17: Exemplo de sinal reconstruído sem correção na frequência.

A metodologia proposta para a correção de frequência utiliza-se do fato de que um sinal que possua frequência constante, igual à frequência média do sinal original durante um certo intervalo, atinge o mesmo ponto (coordenada do eixo vertical) que o sinal original no fim desse intervalo. Por isso, são necessários que se conheça os pontos $x[n - 1]$ e $x[n - 10]$ do sinal original.

Para corrigir a frequência, deve-se executar a seguinte sequência de operações.

1. Calcular a frequência média do intervalo que será reconstruído utilizando as frequências médias estimadas de cada ciclo deste intervalo.
2. Através da metodologia descrita acima, projetar o último ponto do sinal reconstruído para uma faixa de frequências próximas do valor da frequência média do intervalo.
3. Escolher os pontos projetados que mais se aproximam de $x[n - 1]$.
4. Com cada uma dessas frequências, deve-se projetar o ponto de dez amostras anteriores.
5. Escolher o ponto que mais se aproxima de $x[n - 10]$.
6. Com o valor da frequência desse ponto, calcular Δf e aplicar este valor na correção de cada uma das frequências médias dos ciclos pertencentes ao intervalo que será reconstruído.

O valor de Δf pode ser calculado como:

$$\Delta f = f_{mp} - f_{me} \quad (3.5)$$

em que, f_{mp} é a frequência média utilizada para a projeção dos pontos e f_{me} é a frequência média do intervalo obtida através das frequências médias estimadas.

A frequência é corrigida de acordo com a equação (3.6).

$$f_{1c} = f_1 + \Delta f \quad (3.6)$$

Com a utilização desta metodologia, consegue-se então fazer com que o sinal não apresente erro de reconstrução entre um *frame* de não novidade e um *frame* de novidade. Um exemplo de sinal reconstruído com essa metodologia está mostrado na Figura 18, onde pode-se perceber o perfeito casamento no ponto em que se inicia um *frame* em que uma novidade foi detectada.

Figura 18: Exemplo de sinal reconstruído com a frequência corrigida.

3.3 CONCLUSÕES PARCIAIS

Este capítulo apresentou a metodologia proposta para compressão de sinais elétricos de sistemas de potência. Essa metodologia apresenta três níveis de compressão do sinal: o primeiro nível é baseado no conceito de novidade (só os *frames* que apresentam novidade precisam ser armazenados); o segundo nível de compressão é baseado na DWT; e o último consiste na aplicação do algoritmo LZW. As duas primeiras etapas consistem numa compressão com perdas e a última numa compressão sem perdas.

Foi apresentada também a metodologia de reconstrução do sinal comprimido, que é capaz de reconstruir todo o sinal utilizando as formas de onda dos *frames* de novidade armazenados e as frequências médias de cada ciclo do intervalo, evitando que haja descontinuidades no sinal reconstruído.

É importante ressaltar que a metodologia proposta apresenta grande flexibilidade e fácil aprimoramento, pois seu funcionamento é independente para cada canal de aquisição e os blocos principais (Detecção de Novidade, Compressão com Perdas e Compressão sem Perdas), descritos na Figura 1 também são independentes. Dessa forma, cada bloco pode ter seu algoritmo substituído sem afetar o funcionamento global do Sistema de Compressão.

4 CRITÉRIOS UTILIZADOS PARA A SELEÇÃO DA MELHOR ÁRVORE DE DECOMPOSIÇÃO WAVELET, LIMARIZAÇÃO E QUANTIZAÇÃO DOS COEFICIENTES

Neste capítulo serão mostradas as técnicas e análises utilizadas para a seleção do melhor sistema de compressão utilizando wavelet. Esse sistema consiste em um banco de filtros wavelet, o processo de limiarização que será utilizado e o número de bits utilizado na quantização dos coeficientes. A obtenção desse sistema deve seguir a seguinte sequência de passos:

1. Obtenção do melhor banco de filtros wavelet (Seção 4.1):
 - (a) Obtenção do número de níveis para a decomposição (Subseção 4.1.1);
 - (b) Obtenção da melhor wavelet mãe (Subseção 4.1.2).
2. Escolha do processo de limiarização e valor de limiar (Seção 4.2);
3. Escolha do número de bits para quantização dos coeficientes (Seção 4.3).

4.1 *SELEÇÃO DO BANCO DE FILTROS PARA COMPRESSÃO DOS DISTÚRBIOS ELÉTRICOS*

A escolha do banco de filtros mais indicado para a compressão dos sinais de distúrbios elétricos foi realizada em duas etapas: a primeira consiste em escolher o melhor número de níveis de decomposição utilizando cada uma das wavelet mãe pré-selecionadas; e a segunda em selecionar dentre os bancos de filtros obtidos na primeira etapa qual é capaz de representar com qualidade, com menor número de coeficientes não nulos os sinais em questão. Para isso, foram utilizadas wavelets mãe de diversas famílias, são elas:

- **Daubechies** : db2, db3, db4, db5, db6, db7, db8, db9 e db10;
- **Symlets**: sym2, sym3, sym4, sym5, sym6, sym7, sym8, sym9 e sym10;

- **Coiflets:** coif1, coif2, coif3, coif4 e coif5;
- **Biortogonais:** bior1.1, bior1.3, bior1.5, bior2.2, bior2.4, bior2.6, bior2.8, bior3.1, bior3.3, bior3.5, bior3.7, bior3.9, bior4.4, bior5.5 e bior6.8;
- **Biortogonais Reversas:** rbio1.1, rbio1.3, rbio1.5, rbio2.2, rbio2.4, rbio2.6, rbio2.8, rbio3.1, rbio3.3, rbio3.5, rbio3.7, rbio3.9, rbio4.4, rbio5.5 e rbio6.8.

A nomenclatura utilizadas para as Wavelets seguem à nomenclatura da *Wavelet Toolbox* do software Matlab.

Cada uma das análises foram feitas com as seguintes classes de distúrbios: Transitórios Oscilatórios, Notches, Harmônicos Estacionários, Harmônicos Variantes, Sags e Swells, segundo à descrição contida em (SANTOSO et al., 2002). Foram gerados 100 sinais de cada uma das classes e os parâmetros analisados são os valores médios considerado os 100 sinais de cada grupo. Os sinais gerados possuem taxa de amostragem de 7680 Hz e comprimento de 512 amostras, ou quatro ciclos da frequência fundamental de 60 Hz.

4.1.1 OBTENÇÃO DO NÚMERO DE NÍVEIS DE DECOMPOSIÇÃO

O processo utilizado para a obtenção do número ótimo de níveis de decomposição para a DWT é baseado na entropia dos coeficientes, e segue a metodologia proposta em (COIFMAN; WICKERHAUSER, 1992): a cada nível de decomposição, são calculadas as entropias dos vetores de coeficientes de aproximação e detalhe. Se as duas somadas forem menores do que a entropia dos coeficientes de aproximação do nível anterior, esta decomposição é mantida, caso contrário deve-se parar no nível anterior. A Figura 19 apresenta um fluxograma que ilustra melhor essa metodologia.

Na figura 19, $CA[i]$ e $CD[i]$ representam os coeficientes de aproximação e detalhe, respectivamente, para o nível de decomposição i .

A entropia é calculada segundo a equação (4.1) e é conhecida com Entropia de Shannon não normalizada (WICKERHAUSER, 1994).

$$H(\mathbf{x}) = - \sum_{n=1}^{N-1} |x_n|^2 \cdot \log_2(|x_n|^2) \quad (4.1)$$

em que, x_n é o n -ésimo ponto do vetor $\mathbf{x}$ e N é o comprimento do vetor.




Figura 19: Fluxograma do algoritmo implementado para a obtenção do número de níveis de decomposição.

A análise da entropia foi realizada para cada uma das wavelets mãe citadas acima e para cada uma das classes de sinais. Na média, o resultado obtido para o número de níveis de decomposição foi de 4 níveis para distúrbios do tipo Harmônicos Estacionários e 5 para os distúrbios das outras classes. Sendo assim, serão utilizados 5 níveis de decomposição. O Apêndice A contém as tabelas que apresentam o número de níveis de decomposição ótimo encontrado para cada tipo de distúrbio utilizando cada uma das wavelet mãe descritas acima.

A Figura 20 ilustra a árvore de decomposição wavelet que será utilizada.




Figura 20: Árvore de decomposição wavelet.

Na Figura 20, $x[n]$ é o sinal de entrada; $H_d[n]$ e $L_d[n]$ são, respectivamente, os filtros passa-altas e passa-baixas de decomposição; C_{D1} , C_{D2} , C_{D3} , C_{D4} e C_{D5} são os coeficientes de detalhe de cada um dos níveis de decomposição; e C_{A1} , C_{A2} , C_{A3} , C_{A4} e C_{A5} são os coeficientes de aproximação.

4.1.2 SELEÇÃO DA WAVELET MÃE

A escolha da wavelet mãe é de fundamental importância para o desempenho do sistema, visto que ela afeta diretamente a reconstrução do sinal, bem como a taxa de compressão obtida. Um critério utilizado para otimizar essa escolha é o chamado *Minimum Description Length* (MDL), proposto por (SAITO, 1994). O critério MDL visa minimizar a relação entre o número de coeficientes utilizados e o erro da representação. Em linhas gerais, este critério permite a escolha da wavelet mais adequada e do número de coeficientes que deve ser utilizado para representar um determinado sinal. O critério MDL é descrito pela seguinte equação:

$$\text{MDL}(k, m) = \min \left\{ \frac{3}{2}k \log_2(N) + \frac{N}{2} \log_2 \left(\|(\mathbf{I} - \Theta^{(k)}) \mathbf{W}_m^T \mathbf{d}\|^2 \right) \right\} \quad (4.2)$$

$$0 \leq k < N; 1 \leq m \leq M$$

em que k é o número de coeficientes utilizados na representação, m é o índice relativo a wavelet mãe utilizada, N é o comprimento do vetor $\mathbf{d}$ que deseja-se representar, $\mathbf{W}_m$ é base wavelet utilizada e $\Theta^{(k)}$ é um operador de limiarização dos coeficientes.

A equação (4.2) mostra que a função custo possui duas parcelas, a primeira delas $\left(\frac{3}{2}k \log_2(N)\right)$ é sempre linearmente crescente, pois depende apenas do número k de coeficientes, já a segunda $\left(\frac{N}{2} \log_2 \left(\|(\mathbf{I} - \Theta^{(k)}) \mathbf{W}_m^T \mathbf{d}\|^2 \right)\right)$ é decrescente pois é relativa ao erro da reconstrução. A Figura 21 mostra essas duas parcelas, como linhas tracejadas e a curva da função custo do MDL como uma linha sólida, para uma wavelet mãe específica.

A técnica de seleção da melhor wavelet tem como objetivo construir a curva da função custo, calculando suas parcelas iterativamente, adicionando a cada iteração o coeficiente de maior energia da decomposição. De posse dessa curva, deve-se, então, encontrar o mínimo (MDL), e o número de coeficientes que o gerou é o número de coeficientes ideal para se utilizar na reconstrução do sinal. Deve-se destacar que a função custo tende para o seu valor mínimo quando k tende ao comprimento N do




Figura 21: Gráfico ilustrativo da curva da função custo do MDL (SAITO, 1994).

sinal, porém, tratando-se de uma aplicação de compressão de sinais, não é interessante utilizar todos os coeficientes da representação, então, o que é feito, é procurar o MDL num intervalo $k_1 \leq k \leq k_2$, em que $k_1 = 0$ e $k_2 = N/2$ (SAITO, 1994). De posse dessas informações pode-se então, obter o MDL para diversos tipos de wavelet e selecionar a mais indicada.

A partir das wavelets mãe apresentadas na Seção 4.1 foram gerados bancos de filtros wavelet com 5 níveis de decomposição, de acordo com os resultados obtidos com o critério de entropia. Cada um dos sinais de distúrbio foram submetidos a cada um dos bancos de filtros e o critério MDL foi empregado, obtendo-se o número de coeficientes indicado para cada sinal. Como foram gerados 100 sinais de cada tipo de distúrbio, uma média foi feita e foi obtido um número de coeficientes médio para cada distúrbio e cada banco de filtros.

Os filtros produzidos a partir de wavelets mãe da mesma família se comportaram de maneira muito semelhante, por isso, os resultados mostrados nas Tabelas 1 e 2 são os resultados para o melhor banco de filtros de cada uma das famílias testadas. A Tabela 1 apresenta o percentual de coeficientes a ser utilizado na reconstrução e a Tabela 2 a qualidade da reconstrução, utilizando como métrica a relação entre a correlação cruzada entre o sinal e a reconstrução e a autocorrelação do sinal como mostrado em (4.3).

$$\text{COR} = \frac{\mathbf{x}^T \hat{\mathbf{x}}}{\mathbf{x}^T \mathbf{x}} \quad (4.3)$$

em que, $\mathbf{x}$ é o vetor que representa o sinal original e $\hat{\mathbf{x}}$ é o vetor que representa o sinal reconstruído. Através dos testes realizados utilizando essa métrica percebeu-se que devem ser considerados satisfatórias reconstruções que apresentem resultados superiores a 0.990.

Tabela 1: Percentual de coeficientes necessários para reconstrução dos sinais.

	db4	sym4	coif2	bior3.1	rbio2.6
Transitórios	16.46	16.84	17.88	13.07	21.37
Sag	10.63	11.85	13.06	7.82	14.88
Swell	11.46	12.05	13.71	8.38	15.62
Harmônicos Variantes	21.32	18.04	19.30	17.72	18.17
Harmônicos Estacionários	10.98	9.13	9.81	21.73	8.10
Notches	6.46	8.68	6.26	24.65	5.77
Média	11.14	12.77	13.34	15.56	13.99

Tabela 2: Correlação entre o sinal original e o sinal reconstruído.

	db4	sym4	coif2	bior3.1	rbio2.6
Transitórios	1.000	1.000	1.000	0.998	1.000
Sag	1.000	1.000	1.000	0.997	1.000
Swell	1.000	1.000	1.000	0.998	1.000
Harmônicos Variantes	0.998	0.997	0.995	0.997	0.993
Harmônicos Estacionários	0.977	0.964	0.965	0.994	0.944
Notches	0.984	0.986	0.980	0.998	0.987

Analisando os resultados da Tabela 1 e da Tabela 2, pode-se perceber que a wavelet mãe que foi capaz de representar todos os distúrbios com qualidade foi a bior3.1. Sendo assim, esta é a wavelet mãe que será adotada. Inspeccionando a Tabela-1 observa-se que para os distúrbios do tipo transitório, sag, swell e harmônicos variantes, esta wavelet mãe fornece também o menor número de elementos dentre todas as outras, e para os distúrbios harmônicos estacionários e nothces isto não acontece, isto é devido ao fato de que para a reconstrução, com qualidade, desses distúrbios, são necessários realmente muitos elementos da base wavelet.

A escolha do melhor banco de filtros então se deu baseada na qualidade da representação proporcionada pela wavelet mãe, onde a wavelet mãe bior3.1 apresentou melhor desempenho na compressão desses sinais.

A Figura 22 ilustra a resposta em frequência do banco de filtros selecionado, destacando a resposta em frequência do filtro equivalente para cada uma das cinco bandas

dos coeficientes de detalhe e para a banda dos coeficientes de aproximação.




Figura 22: Resposta em frequência do banco de filtros wavelet selecionado.

A Tabela 1 e da Tabela 2 apresentam os resultados obtidos para a melhor wavelet mãe de cada uma das famílias testadas. O Apêndice A contém tabelas que apresentam os resultados para cada uma das wavelet mãe.

4.2 LIMIAÇÃO DOS COEFICIENTES

O processo de limiarização dos coeficientes consiste em eliminar o ruído ou informações de baixa relevância presentes no sinal. É baseado no fato de que a energia do sinal se concentra em apenas alguns coeficientes no domínio da transformada enquanto que a energia do ruído se espalha por todos os coeficientes. Desta forma, uma função de limiarização aplicada nas bandas onde o ruído é predominante é capaz de reduzir significativamente sua influência na reconstrução do sinal, e contribuindo assim para a compressão do mesmo, visto que irá aumentar a quantidade de coeficientes nulos.

No processo de limiarização existem duas principais questões, são elas: qual a função de limiarização a ser utilizada; e qual o valor de limiar ótimo a ser escolhido. Uma vasta literatura que trata dessas duas questões pode ser encontrada, visto que o processo de limiarização está na essência das técnicas de remoção de ruído utilizando wavelets.

Quanto a seleção do valor do limiar, as técnicas podem ser divididos em três grupos: o primeiro utiliza um limiar universal, em que o valor de limiar aplicado é o mesmo para todas os coeficientes; o segundo trabalha com limiares diferentes para cada sub-

banda de decomposição; e o terceiro trabalha com limiares adaptativos (DONOHO; JOHNSTONE, 1995; CHANG; YU; VETTERLI, 2000; MIHCAK et al., 1999).

Um método para se obter um valor de limiar é descrito por (DONOHO; JOHNSTONE, 1994), onde o valor do limiar é dado por:

$$\lambda_u = \sigma \sqrt{2 \log(N)} \quad (4.4)$$

em que, N é o comprimento do sinal e σ é o seu desvio padrão, que pode ser estimado utilizando os coeficientes da sub-banda de menor escala da wavelet.

Um estimador descrito em (DONOHO; JOHNSTONE, 1994) utiliza o Desvio Absoluto Mediano, (do inglês, *Median Absolute Deviation*) (MAD) dividido por um fator de escala q . Este estimador é descrito pela seguinte equação:

$$\sigma = \frac{MAD(\omega_{d_1})}{q} \quad (4.5)$$

em que, ω_{d_1} são os coeficientes da sub-banda de mais alta frequência, o fator q é uma constante igual a 0,6745 (DONOHO; JOHNSTONE, 1994) e $MAD(\omega_{d_1})$ é dado por:

$$MAD(\mathbf{x}) = \text{Me}(|\mathbf{x} - \text{Me}(\mathbf{x})|) \quad (4.6)$$

em que, $\text{Me}(\mathbf{x})$ é a mediana do vetor $\mathbf{x}$.

Para determinadas situações é possível obter resultados mais robustos realizando a estimação do desvio padrão do ruído para cada sub-banda de decomposição em que deseja-se eliminá-lo e obtendo um valor distinto de limiar para cada sub-banda. Neste caso, a estimação do ruído é dada por (4.7) e o valor do limiar por (4.8).

$$\sigma_j = \frac{MAD(\omega_j)}{q} \quad (4.7)$$

$$\lambda_{u_j} = \sigma_j \sqrt{2 \log(N_j)} \quad (4.8)$$

em que, N_j é o comprimento do vetor de coeficientes de detalhe da escala j e σ_j é o desvio padrão para a mesma escala.

Em sinais de Sistemas Elétricos de Potência, a energia do sinal se concentra mais nas sub-bandas de menor frequência, portanto, na sub-banda de mais alta frequência o ruído é predominante e dessa forma é mais indicado a utilização desta para a estimação do desvio padrão do ruído.

Em se tratando de aplicações em tempo real, o cálculo da mediana de um conjunto de dados não é uma tarefa trivial, visto que para realizá-lo é necessário ordenar o vetor dos dados. Supondo que o ruído presente no sinal possui distribuição gaussiana, é possível, dado sua simetria, utilizar a média em vez da mediana. Sendo assim, a equação (4.9) pode ser substituída por:

$$MAD(\mathbf{x}) = \overline{|\mathbf{x} - \bar{\mathbf{x}}|} = \frac{1}{N} \sum_{i=1}^N |x_i - \bar{x}| \quad (4.9)$$

No que diz respeito a função de limiarização a ser aplicada, são encontrados na literatura dois tipos principais: a limiarização suave (*soft thresholding*), descrita pela equação (4.10) e a limiarização abrupta (*hard thresholding*), descrita pela equação (4.11).

$$\omega_{soft}(\omega_j, \lambda_j) = \begin{cases} \text{sign}(\omega_j) \cdot (|\omega_j| - \lambda_j) & , |\omega_j| > \lambda_j \\ 0 & , |\omega_j| \leq \lambda_j \end{cases} \quad (4.10)$$

$$\omega_{hard}(\omega_j, \lambda_j) = \begin{cases} \omega_j & , |\omega_j| > \lambda_j \\ 0 & , |\omega_j| \leq \lambda_j \end{cases} \quad (4.11)$$

em que ω_{soft} são os coeficientes modificados pela função de limiarização suave e ω_{hard} são os coeficientes modificados pela função de limiarização abrupta. A Figura 23 mostra graficamente a aplicação dessas duas funções de limiarização para um valor de limiar igual a 0,4. É interessante perceber que a função de limiarização suave reduz o valor dos coeficientes com valores acima do limiar, enquanto que a limiarização abrupta não altera seus valores, sendo por isso, mais indicada para aplicação em problemas de compressão de sinais elétricos (JIE, 2009).

O processo de limiarização baseado no ruído presente no sinal foi adotado, visto que o ruído não é relevante para as análises dos fenômenos ocorridos em sinais advindos de sistemas de potência, além do que, sua eliminação contribui para a compressão dos sinais. Outro fator importante que influenciou na escolha da técnica de obtenção do limiar é que a mesma pode ser implementada online, fazendo com que o limiar se adapte ao ruído presente no sinal que pode variar ao longo do tempo.




Figura 23: Funções de Limiarização: (a) limiarização suave; (b) limiarização abrupta.

Para confirmar a eficiência do processo de limiarização, foram realizados testes com os distúrbios. O banco de filtros wavelet utilizado é constituído a partir da wavelet mãe bior3.1 e possui 5 níveis de decomposição como especificado nas seções anteriores. O valor do limiar é calculado segundo a equação (4.9), utilizando os coeficientes de detalhe do primeiro nível de decomposição. Essa banda de frequência foi escolhida para o cálculo do limiar visto que os sinais de sistemas de potência concentram maior parte da sua energia nas baixas frequências, e portanto, a energia presente na banda de mais alta frequência é geralmente relativa ao ruído, ou a algum distúrbio transitório presente na rede. O processo de limiarização abrupta foi utilizado segundo a equação (4.11) e o valor de limiar obtido é utilizado para todas as bandas de detalhe. Os resultados estão mostrados na Tabela 3 para o percentual de coeficientes utilizados e na Tabela 4 para a energia mantida na reconstrução.

Tabela 3: Percentual de coeficientes que ficaram acima do limiar.

	20 dB	30 dB	40 dB	60 dB	100 dB
Transitórios	10.38	11.02	11.50	11.87	12.20
Sag	9.18	9.93	11.34	16.93	27.92
Swell	9.30	10.30	12.07	18.26	29.82
Harmônicos Variantes	13.47	18.59	25.21	28.26	29.04
Harmônicos Estacionários	17.79	26.08	37.56	41.64	41.29
Notches	9.56	12.98	15.52	15.40	15.27

A Tabela 3 mostra o percentual de coeficientes utilizados na reconstrução dos sinais para diferentes Relação Sinal Ruído, (do inglês, *Signal to Noise Ratio*) (SNR). Inspeccionando essa tabela, percebe-se que quanto maior for a SNR, ou seja, quanto menor for a energia do ruído, mais coeficientes tendem a ser mantidos após a limiarização, o que já era esperado, visto que o nível do limiar depende diretamente da energia, ou variância do ruído e, para baixas energias, o limiar é muito pequeno fazendo com que

mais coeficientes sejam mantidos.

Os resultados obtidos com o processo de limiarização adotado são condizentes com os apresentados na Tabela 1 obtidos com o critério MDL, o que valida a escolha do banco de filtros de acordo com esse critério. Pode ser percebido também, que como foi comentado na Seção 4.1 os distúrbios do tipo harmônicos necessitam de muitos coeficientes para sua reconstrução, podendo chegar a necessitar de por volta de 40% dos coeficientes dependendo da energia do ruído presente. O percentual de coeficientes para distúrbios do tipo notch está bem abaixo do ideal para uma reconstrução satisfatória, isso se dá pois a energia desse distúrbio aparece significativamente em todas as bandas de detalhe em que a limiarização é aplicada. Esse problema será discutido com mais detalhes adiante.

Tabela 4: Percentual de energia do sinal reconstruído em relação ao sinal original.

	20 dB	30 dB	40 dB	60 dB	100 dB
Transitórios	98.34	98.96	99.27	99.92	99.25
Sag	99.13	99.65	99.85	99.97	99.99
Swell	99.07	99.72	99.88	99.98	100.0
Harmônicos Variantes	98.96	99.59	99.82	99.90	99.90
Harmônicos Estacionários	98.94	99.57	99.86	99.87	99.87
Notches	99.13	99.18	99.38	99.39	99.48

Pela inspeção da Tabela 4 percebe-se que os sinais reconstruídos retêm quase toda a energia dos sinais originais. O processo de limiarização tende a eliminar o ruído presente no sinal, por isso, quanto menor for a SNR menor será a relação da energia do sinal reconstruído e o sinal original, e em alguns casos, juntamente com o ruído, informações relevantes do sinal podem ser descartadas. As Figuras 24, 26 e 25 ilustram o efeito da limiarização dos coeficientes para sinais com distúrbios do tipo Transitórios, Harmônicos e Notch respectivamente.

Pode ser observado na Figura 24 que o processo de limiarização elimina boa parte dos coeficientes de detalhe da decomposição de um distúrbio do tipo transitório. Os coeficientes de aproximação não são submetidos à limiarização, pois é nessa banda que encontra-se o componente fundamental do sinal que deve ser reconstruído perfeitamente. Deve ser ressaltado, que alguns coeficientes relativos ao distúrbio, e não ao ruído também são limiarizados, porém, essa limiarização não causa grandes malefícios na reconstrução como pode ser visualmente observado, e comprovado numericamente, visto que a correlação entre o sinal original e a reconstrução é de 0.9998 e a energia mantida foi de 99.64% com a utilização de aproximadamente 14% dos coeficientes.




Figura 24: Limiarização dos coeficientes para um sinal com transitório.

Para distúrbios do tipo harmônicos, como exemplificado na Figura 26, pode ser percebido que a melhor escolha é realmente obter o valor do limiar a partir dos coeficientes de detalhe do nível 1, já que os harmônicos se espalham com energia significativa pelos outros níveis de detalhe e um valor de limiar obtido em cada nível geraria perda de informação significativa para a reconstrução. Para o caso ilustrado nessa figura, foram utilizados 40% dos coeficientes e uma reconstrução mantendo 99.88 da energia do sinal original, com uma correlação de 0.9999 foi obtida.

Nos casos de distúrbios do tipo notch, a obtenção do valor do limiar é seriamente comprometida. Isto é devido ao fato de que esse distúrbio se espalha com energia significativa por todas as bandas de frequência, inclusive nos coeficientes de detalhe do nível 1, fazendo com que o valor do limiar obtido seja maior do que o ideal para eliminar somente o ruído do sinal. Sendo assim, informações relevantes para a reconstrução do distúrbio são perdidas. Esse fato pode ser observado através da reconstrução apresentada na Figura 25, em que os *notches* presentes no sinal não são reconstruídos perfeitamente. Para este caso aproximadamente 15% dos coeficientes foram utilizados, obtendo-se uma reconstrução mantendo 98.70% da energia com uma correlação de 0.9982 em relação ao sinal original.




Figura 25: Limiarização dos coeficientes para um sinal com notches.




Figura 26: Limiarização dos coeficientes para um sinal com harmônicos.

4.3 QUANTIZAÇÃO DOS COEFICIENTES

Os coeficientes limiarizados precisam ainda passar por um processo de quantização antes de serem transmitidos e/ou armazenados. Esse processo é necessário em aplicações de compressão para diminuir a quantidade de bits necessária para o armazenamento, melhorando assim a taxa de compressão. Os coeficientes são quantizados de acordo com a seguinte equação:

$$c_Q = \text{round} \left(\frac{c}{\Delta} \cdot 2^{N_b} \right) \quad (4.12)$$

em que: c é o valor coeficiente, Δ é um fator de normalização, que depende da amplitude do sinal de entrada, N_b é o número de bits que será utilizado para a quantização e $\text{round}(x)$ representa a função arredondamento, que fornece número inteiro que é mais próximo do que x . O processo de quantização consiste então em normalizar o valor de c , escalá-lo de acordo com o número de bits escolhido e, posteriormente, utilizar somente com o valor inteiro do resultado.

Para encontrar o número de bits ideal para a quantização do sinal, partiu-se dos mesmos princípios do que nos outros testes, 100 sinais de cada distúrbio foram gerados e os parâmetros obtidos são uma média para esses 100 sinais. Os sinais foram decompostos em seus coeficientes pelo banco de filtros wavelet e posteriormente quantizados. Utilizando os coeficientes quantizados, os sinais foram reconstruídos e as métricas de Erro Médio Quadrático, (do inglês *Mean Squared Error*) (MSE) e SNR foram escolhidas para medir a qualidade da quantização. Essas métricas são definidas pelas equações (4.13) e (4.14) respectivamente.

$$\text{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} \|x[n] - \hat{x}[n]\|^2 \quad (4.13)$$

$$\text{SNR(dB)} = 10 \log_{10} \frac{\sum_{n=0}^{N-1} \|x[n]\|^2}{\sum_{n=0}^{N-1} \|x[n] - \hat{x}[n]\|^2} \quad (4.14)$$

em que: $x[n]$ são as amostras do sinal original e $\hat{x}[n]$ são as amostras do sinal reconstruído utilizando os coeficientes quantizados e N é o número de amostras do sinal.

Os testes foram feitos utilizando 2, 4, 6, 8, 10, 12, 14, 16, 18, 20, 22, 24, 26, 28, 30 e 32 bits. A Figura 27 mostra o MSE e a Figura 28 mostra a SNR em função do número de bits utilizado para a quantização, para todas as classes de distúrbios testadas.




Figura 27: Erro médio quadrático entre o sinal quantizado e o sinal não quantizado.

Pode-se perceber, através da Figura 27 que o erro cai para um valor muito pequeno quando utiliza-se a partir de 8 bits na quantização do sinal. Pode-se concluir então que 8 bits é o valor ideal a ser utilizado, pois favorecerá a compressão do sinal, mantendo a qualidade da reconstrução.




Figura 28: Relação sinal ruído, calculada de acordo com a equação (4.14).

Analisando também a Figure 28 é percebido que quanto mais bits são utilizados na quantização, maior é o valor da SNR, visto que mais perfeita será a reconstrução do sinal. Porém, a partir de 8 bits a SNR supera o valor de 80 dB, o que já é bastante

satisfatório.

4.4 CONCLUSÕES PARCIAIS

Neste capítulo foram apresentadas as técnicas e a metodologia utilizada para a obtenção do banco de filtros wavelet. Foi visto que: segundo o critério da entropia, o melhor número de níveis de decomposição é igual a 5; de acordo com o critério do MDL utilizado, a melhor wavelet mãe que origina o banco é a wavelet bior3.1; que a estratégia de se utilizar (4.9) para se obter o valor do limiar e a aplicação da limiarização abrupta funciona satisfatoriamente no cenário proposto e que a utilização de 8 para a quantização dos coeficientes é suficiente para a obtenção de uma boa reconstrução.

No que diz respeito à quantização, métodos mais otimizados precisam ser implementados e testados, como um quantizador do tipo *deadzone quantizer*, que alia a limiarização e a quantização de forma a otimizar o número de bits a ser utilizado. Uma outra estratégia que se pode pensar é utilizar alocação ótima de bits por banda de decomposição, que poderá melhorar o desempenho da compressão.

5 DETECTOR DE NOVIDADES

Neste capítulo será apresentada a proposta de um detector de novidades a ser aplicado em sinais advindos de Sistemas de Potência, e que será utilizado como base da metodologia de compressão de sinais apresentada no Capítulo 3. Serão apresentados dois detectores baseados na energia do sinal e uma análise comparativa entre eles será feita para escolher qual é o mais indicado para essa aplicação.

5.1 DETECÇÃO DE NOVIDADE

O termo Detecção de Novidade, do inglês *Novelty Detection* pode ser definido como a tarefa de se detectar que um determinado dado de teste é diferente dos dados disponíveis durante o treinamento. Métodos de detecção de novidade são geralmente empregados em situações onde muitas amostras de dados ditos normais estão disponíveis para o treinamento enquanto só existem poucas amostras disponíveis dos dados ditos anormais (PIMENTEL et al., 2014). O sistema então é treinado com esse conjunto de dados normais e aplicados para reconhecer os dados que são diferentes ou anormais.

Existem na literatura diversos trabalhos que utilizam esse conceito de Detecção de Novidade nas mais diversas áreas, tais como: biomédica (QUINN; WILLIAMS, 2007; CLIFTON et al., 2011); em detecção de falhas na indústria (SURACE; WORDEN, 2010); em monitoramentos de vídeo (DIEH; HAMPSHIRE et al., 2002; MARKOU; SINGH, 2006); em redes de sensores (ZHANG; MERATNIA; HAVINGA, 2010); e várias outras.

Neste trabalho, o conceito de Detecção de Novidade é utilizado de uma maneira um pouco diferente. A principal diferença é que não existe uma etapa de treinamento como foi dito anteriormente. O objetivo da Detecção de Novidade empregada é sinalizar, em um sinal segmentado em *frames* de tamanho fixo, se um determinado *frame* é diferente de um *frame* de referência, de acordo com alguma métrica e um limiar pré-estabelecidos.

O processo então se dá da seguinte maneira: (i) o sinal é segmentado em janelas, ou *frames* de tamanho fixo; (ii) o *frame* atual é comparado com o *frame* de referência;

e (iii) se ele forem diferentes uma novidade é detectada, e o *frame* atual passa a ser o novo *frame* de referência.

5.2 PROPOSTA DE UM DETECTOR DE NOVIDADES

O objetivo deste detector é detectar os *frames* que, relacionados a alguma métrica pré-estabelecida, sejam diferentes de um *frame* de referência. Essa diferença é relacionada à alguma distorção na forma de onda, embora, variações suaves na frequência fundamental do sinal não devam ser consideradas como novidade. O detector de novidades proposto é composto por dois ramos como mostrado na Figura 29. A resposta desses dois ramos é combinada para gerar o resultado final da detecção.




Figura 29: Diagrama de blocos do detector proposto.

O ramo superior é responsável por detectar as novidades com um conteúdo espectral de banda larga. Neste ramo, o sinal é filtrado por um filtro passa-altas e na saída desse filtro é calculada uma métrica e aplicado um limiar. O filtro passa-altas é responsável por atenuar a influência do componente fundamental e dos harmônicos de menor frequência (e maior energia), melhorando assim a resolução para a detecção de eventos de mais alta frequência (geralmente de baixa energia). A atenuação dos componentes de baixa frequência ainda é benéfica pois evita detecções por variações suaves na frequência do sinal, porém, prejudica a detecção de distúrbios de baixa frequência tais como flicker e interharmônicos de baixa frequência, incluindo os sub-harmônicos. Os harmônicos, quando aparecem ou desaparecem do sinal, ou quando apresentam variações de amplitude, são detectados devido ao transitório que eles causam na saída do filtro passa-altas, e quando estão presentes permanentemente, sem variações de amplitude, não causam nenhuma detecção. Esse transitório é significativo no caso dos harmônicos pois eles geralmente apresentam energia mais elevada do que os interharmônicos e sub-harmônicos. O filtro passa-altas utilizado é um filtro FIR de

10ª ordem, com frequência de corte igual a 720 Hz. Este valor para a frequência de corte foi escolhido empiricamente através de testes de simulação.

Para suprir a deficiência do ramo superior com componentes de baixa frequência, o ramo inferior foi adicionado ao detector. Este ramo é composto por uma DFT centrada na frequência do componente fundamental, que é calculada para cada ciclo do sinal, fornecendo o fasor Y_{f1} . O módulo $|Y_{f1}|$ e a fase $\angle Y_{f1}$ desse fasor são calculados, uma lógica de detecção baseada na comparação, ciclo a ciclo, desses valores é aplicada e o resultado é combinado com o resultado do ramo superior para gerar a resposta final do detector. A lógica de detecção utilizada no ramo inferior é baseada no fato de que a presença de flicker, sub-harmônicos ou variação de frequência no sinal causará um espalhamento espectral causando um erro na estimação de Y_{f1} . Os valores de módulo e fase de Y_{f1} são comparados ciclo a ciclo e quando há a presença de um distúrbio (flicker ou sub-harmônico) é observado uma diferença entre os valores de $|Y_{f1}|$ enquanto que $\angle Y_{f1}$ se mantém quase constante. Por outro lado, quando o sinal apresenta somente variação de frequência uma diferença significativa em $\angle Y_{f1}$ é observada.

Para a detecção dos distúrbios do tipo flicker e sub-harmônicos é realizada a subtração do módulo do fasor do componente fundamental entre dois ciclos adjacentes, e o resultado é comparado com um valor de limiar, como mostrado em (5.1). Se o valor dessa subtração for maior do que o patamar, isto significa que há a presença de flicker e/ou sub-harmônico no sinal.

$$|Y_{f1}|_C - |Y_{f1}|_{C1} > \lambda_{flick} \quad (5.1)$$

Na Equação (5.1) $|Y_{f1}|_C$ é o modulo do fasor no ciclo atual, e $|Y_{f1}|_{C1}$ é o modulo do fasor no ciclo anterior. O valor do patamar λ_{flick} foi obtido empiricamente, da seguinte maneira: foi gerado um sinal puramente senoidal, com a adição de um ruído branco e a DFT foi calculada para cada ciclo desse sinal, centrada na frequência de 60 Hz. Realizou-se a subtração ciclo a ciclo dos valores dos módulos da DFT, obtendo-se um conjunto de dados. O valor do patamar escolhido foi definido como o triplo do valor do desvio padrão calculado para este conjunto de dados.

Para a sinalização da presença de frequência variante a lógica é parecida. A fase do fasor do componente fundamental é subtraída ciclo a ciclo e o módulo dessa diferença é comparado com um patamar igual a 0,01, como mostrado em (5.2). Se a diferença entre as fases for maior que o patamar, é sinalizado que o sinal possui frequência variante.

$$\angle Y_{f1C} - \angle Y_{f1C1} > 0.01 \quad (5.2)$$

Na Equação (5.2) $\angle Y_{f1C}$ é a fase do fasor no ciclo atual, e $\angle Y_{f1C1}$ é a fase do fasor no ciclo anterior. O valor do patamar foi escolhido como 0.01, pois a fase é muito sensível à variação de frequência, e desta forma o detector será capaz de sinalizar a presença de suaves variações na frequência do sinal.

Vale lembrar que quando a presença de flicker ou sub-harmônicos é detectada em algum ciclo, o *frame* ao qual este ciclo pertence é detectado como *frame* de novidade pelo detector, independente do resultado do ramo superior. Já quando uma variação de frequência é detectada ela inibirá uma possível detecção desnecessária realizada pelo ramo superior. Dessa forma, a lógica de detecção serve para aumentar a taxa de detecção do detector, sinalizando a ocorrência de distúrbio de baixa frequência e também para diminuir a taxa de falso alarme, sinalizando a presença de frequência variante. Resultados do detector com e sem a utilização do ramo inferior serão mostrados mais adiante.

Os distúrbios que ocorrem nos sinais de sistemas de potência possuem natureza aleatória, além do fato de estarem corrompidos por ruídos aleatórios relativos ao sistema de aquisição. É sabido da literatura, que a energia é o parâmetro mais indicado para a detecção de sinais aleatórios (KAY, 1998; VAN TREES, 2004). Porém, a utilização desse parâmetro pode ser implementada de várias maneiras. A seguir serão descritas duas formas de implementar detectores baseados na energia e seus desempenhos serão comparados para se obter qual das formas de implementação é a mais adequada.

5.2.1 DIFERENÇA DE ENERGIA ENTRE FRAMES (DEF)

A Diferença de Energia entre Frames (DEF) é calculada como o valor absoluto da subtração da energia do *frame* atual pela energia do *frame* de referência, como mostrado em (5.3).

$$DEF = |EF_A - EF_R| \quad (5.3)$$

em que a energia do *frame* é calculada de acordo com (5.4).

$$EF = \sum_{n=0}^{M-1} |x[n]|^2 \quad (5.4)$$

em que, $x[n]$ é a n -ésima amostra do *frame*, e M é o número de amostras contidas em um *frame*. É importante ressaltar que $x[n]$ é a saída do filtro passa-altas da Figura 29.

5.2.2 ENERGIA DO RESÍDUO (ER)

O resíduo consiste no sinal resultante da subtração, amostra a amostra, entre o *frame* atual e o *frame* de referência. A Energia do Resíduo (ER) então, é calculada como mostrado em (5.5).

$$ER = \sum_{n=0}^{M-1} |x_A[n] - x_R[n]|^2 \quad (5.5)$$

em que, $x_A[n]$ é a n -ésima amostra do *frame* atual e $x_R[n]$ é a n -ésima amostra do *frame* de referência. Novamente, é importante ressaltar que tanto $x_A[n]$ como $x_R[n]$ são sinais de saída do filtro passa-altas da Figura 29.

5.3 COMPARAÇÃO ENTRE AS MÉTRICAS DE DETECÇÃO

Os sinais utilizados para os testes do detector são constituídos por dois *frames* e foram divididos em duas classes: a denominada classe de sinais é composta somente por dois *frames* de sinais em estado permanente, tais como sinais puramente senoidais e harmônicos estacionários, podendo haver variação de frequência; e a denominada classe de distúrbios composta por um *frame* de sinal puramente senoidal e outro *frame* contendo distúrbios (Transitórios Oscilatórios, Harmônicos Variantes no Tempo, Notches, Sags/Swells, Flicker e Interharmônicos).

Os resultados serão comparados em termos da Curva ROC (*Receiving Operation Characteristics*) (VAN TREES, 2004) e o limiar ótimo para a detecção foi calculado utilizando o índice Soma-Produto (SP) (FILHO; SEIXAS; CALÔBA, 2009). O cálculo do índice SP é dado pela equação (5.6).

$$SP = \sqrt{\sqrt{S \times E} \times \frac{S + E}{2}} \quad (5.6)$$

em que, S é a sensibilidade do detector e é definida como sendo a probabilidade de detecção (P_D) e E é a especificidade do detector definida como sendo o complemento da probabilidade de falso alarme ($1 - P_{FA}$). Para se encontrar o limiar ótimo, é necessário variar o seu valor em toda faixa de excursão e calcular o índice SP correspondente. O valor de limiar que maximiza o índice SP é o valor ótimo, que apresenta a melhor relação entre probabilidade de detecção e probabilidade de falso alarme.

O detector utilizando somente o ramo superior e utilizando os dois ramos foi testado em dois cenários, um contendo sinais com frequência fixa e o outro sinais com variação na frequência, ambos com adição de ruído branco gaussiano, dando origem aos seguintes casos:

5.3.1 CASO1

Neste caso o detector é composto apenas pelo ramo superior e a classe de sinais possui somente sinais com frequência fixa. Para SNRs superiores a 30 dB as duas métricas apresentaram resultados quase idênticos e bem satisfatórios. Para SNR igual a 30 dB, a comparação das curvas ROC está mostrada na Figura 30.




Figura 30: Comparação entre as curvas ROC dos detectores para o Caso1.

Observando as curvas ROC para este cenário, é possível notar que as duas mé-

tricas apresentaram um comportamento semelhante, com uma ligeira vantagem para a métrica DFE, que se mostrou um pouco mais eficiente. Utilizando o limiar ótimo calculado, obtém-se probabilidade de detecção igual a 81,4% e probabilidade de falso alarme igual a 1,6%

5.3.2 CASO2

Neste caso o detector ainda é composto somente pelo ramo superior, porém a classe de sinais possui somente sinais com frequência variante. A Figura 31 apresenta a comparação entre as curvas ROC para SNR igual a 30 dB.




Figura 31: Comparação entre as curvas ROC dos detectores para o Caso2.

Para este caso percebe-se que a métrica ER não apresentou comportamento satisfatório e que a métrica DFE mostrou melhor desempenho, atingindo, segundo o limiar ótimo uma probabilidade de detecção igual a 78,6% com 2,0% de probabilidade de falso alarme.

Analisando os dois primeiros casos mostrados percebe-se que a probabilidade de detecção não é muito satisfatória, sendo em torno de 80%, isso se deve à deficiência do ramo superior do detector em detectar corretamente distúrbios de baixa frequência. Para esses casos, a escolha de um patamar que aumente a detecção implica em um aumento do número de falsos alarmes, o que deterioraria o desempenho do sistema de compressão.

5.3.3 CASO3

Para melhorar o desempenho do detector o segundo ramo é adicionado com dois objetivos: melhorar a detecção dos distúrbios do tipo flicker e sub-harmônicos; e diminuir o número de detecções devidas à variações suaves de frequência no sinal (falso alarme). Para o primeiro cenário em que o sinal possui frequência fixa e SNR de 30dB, a comparação das curvas ROC está mostrada na Figura 32.




Figura 32: Comparação entre as curvas ROC dos detectores para o Caso3.

Pode ser percebido visualmente, através da Figura 32, que o detector DFE é ligeiramente superior ao ER. Utilizando o valor ótimo de limiar, obtém-se 85,4% de probabilidade de detecção e 2,0% para probabilidade de falso alarme.

É interessante salientar que a probabilidade de detecção é superior a do Caso 1, o que já era esperado, pois a detecção de distúrbios de baixa frequência foi melhorada. A probabilidade de falso alarme não muda significativamente em relação à do Caso 1, isto porque os sinais utilizados neste caso possuem frequência fixa e desse modo, o ramo inferior não interfere para sinais estacionários.

5.3.4 CASO4

Para o cenário em que os sinais apresentam frequência variante, e também para SNR de 30 dB, a comparação das curvas ROC está mostrada na Figura 33.




Figura 33: Comparação entre as curvas ROC dos detectores para o Caso4.

Pode-se perceber que o desempenho dos detectores que utilizam o segundo ramo (Figura 33) é bem superior ao dos detectores compostos somente pelo primeiro ramo (Figura 31). Esse fato é devido à habilidade do segundo ramo em suprimir detecções que contenham somente variações suaves de frequência, possibilitando assim a escolha de um patamar mais adequado para a detecção dos distúrbios de menor energia. Novamente o detector DFE apresentou melhor desempenho e com a utilização do patamar ótimo a probabilidade de detecção é 99%, com 1,0% de probabilidade de falso alarme.

5.4 CONCLUSÕES PARCIAIS

Neste capítulo foi mostrada a proposta de dois detectores baseados na energia e uma comparação entre eles foi realizada. Pôde ser percebido que a métrica denominada DFE apresentou melhores resultados para todos os cenários testados, sendo assim a mais indicada para ser utilizada na metodologia de compressão proposta no Capítulo 3. Foi mostrado também, que o acréscimo de um segundo ramo, baseado na DFT centrada na frequência fundamental, melhorou bastante o desempenho do detector, de acordo com o cálculo do patamar ótimo calculado através do índice SP .

6 RESULTADOS

Neste capítulo serão apresentados os resultados obtidos para o Sistema de Compressão proposto e os mesmos serão comparados com os resultados obtidos por um equipamento comercial voltado para aquisição e compressão de sinais elétricos de sistemas de potência por um longo período de tempo. Os resultados serão divididos em duas partes, primeiro serão mostrados os resultados obtidos em testes *offline* e posteriormente os testes realizados online com a implementação em tempo real do sistema.

6.1 SINAIS DE TESTE

Para a validação e comparação do desempenho do Sistema de Compressão proposto foram gerados alguns sinais de longa duração (aproximadamente 10 minutos), contendo variados distúrbios de QEE. Cada sinal de teste é composto por um sinal puramente senoidal com a frequência fixa em 60 Hz, intercalado com os seguintes distúrbios:

- S1:** afundamento, elevação, harmônicos pares, harmônicos ímpares, interharmônicos e variação de amplitude em rampa.
- S2:** variação de amplitude em rampa.
- S3:** harmônicos pares e harmônicos ímpares.
- S4:** variações de frequência e amplitude.
- S5:** variações de frequência.

A descrição detalhada dos sinais, para que sua reprodução seja possível está apresentada no Apêndice B.

Algumas métricas foram escolhidas para avaliar a qualidade do sinal reconstruído após a descompressão. São elas: o Erro Médio Quadrático Normalizado, (do inglês, *Normalized Mean Squared Error*) (NMSE), definido em (6.1); a correlação cru-

zada (COR) entre o sinal reconstruído e o sinal original, definida em (6.2); e a porcentagem de energia mantida (RTE(%)), definida em (6.3)

$$\text{NMSE} = \frac{\| \mathbf{x} - \hat{\mathbf{x}} \|^2}{\| \mathbf{x} \|^2} \quad (6.1)$$

$$\text{COR} = \frac{\mathbf{x}^T \cdot \hat{\mathbf{x}}}{\mathbf{x}^T \cdot \mathbf{x}} \quad (6.2)$$

$$\text{RTE}(\%) = \frac{\sum_{n=0}^{N-1} x[n]^2}{\sum_{n=0}^{N-1} \hat{x}[n]^2} \quad (6.3)$$

em que, $\mathbf{x}$ representa a notação vetorial para o sinal original $x[n]$, $\hat{\mathbf{x}}$ é a notação vetorial do sinal reconstruído $\hat{x}[n]$ e N é o comprimento do sinal.

A frequência de amostragem utilizada tanto nos testes offline quanto nos testes online é de 7680 Hz (128 amostras por ciclo do componente fundamental). Nos testes online é utilizado um conversor Analógico para Digital (A/D) de 16 bits, e portanto, nos testes offline o sinal gerado foi também quantizado utilizando 16 bits.

O tamanho dos arquivos gerados pelo sistema de compressão proposto será comparado com o tamanho dos arquivos gerados por um equipamento comercial com funcionalidade semelhante. O equipamento utilizado para a comparação é o Elspec G4000 BLACKBOX, que além de ser um analisador de Qualidade de Energia Classe A, é capaz de armazenar dados de oscilografia contínua, a uma taxa de amostragem de 1024 amostras por ciclo para os canais de tensão, e 256 amostras por ciclo para os canais de corrente, durante um ano em sua memória interna de 8 GB (ELSPEC, 2007).

6.2 TESTES OFFLINE

Nesta seção, as informações a respeito dos resultados de compressão e qualidade da reconstrução dos sinais serão mostrados individualmente durante a análise de cada um dos casos descritos acima, e ao final da seção uma tabela sumará os resultados para uma análise global.

As figuras utilizadas para enfatizar o comportamento da Detecção de Novidades mostram todo o intervalo (aproximadamente 10 min) dos sinais testados, e portanto, não é possível visualizar a forma de onda dos sinal. Então o seguinte padrão de cores

foi adotado: a cor preta representa os *frames* que foram detectados, e cor cinza os *frames* que não foram detectados.

Os erros mostrados em algumas figuras são os Erros Absolutos Normalizados (EAN). A normalização é feita em relação à tensão RMS nominal, seguindo a seguinte equação:

$$EAN = \frac{|x[n] - \hat{x}[n]|}{V_{RMS}} \times 100(\%) \quad (6.4)$$

6.2.1 CASO S1

Para o armazenamento do sinal S1 descrito anteriormente, que possui duração de aproximadamente 13 minutos, a uma taxa de amostragem 128 amostras por ciclo e com uma resolução de 16 bits, são necessários aproximadamente 11,6 MB (128 amostras $\times$ 47484 ciclos $\times$ 2 bytes). O tamanho do arquivo comprimido pelo método proposto é de 99,8 kB, constituindo uma taxa de compressão de 119 : 1. O tamanho do arquivo gerado pelo Elspec para o mesmo sinal é de 254,34 kB. Um fato que é interessante mencionar é que para este sinal de teste apenas 12% dos *frames* foram detectados como *frames* de novidade.

A qualidade da reconstrução pelo método proposto é verificada pelos seguintes valores para as métricas definidas anteriormente: NMSE = 0,0343, COR = 0,991 e RTE(%) = 98,37%. A Figura 34 e a Figura 35 apresentam duas janelas da comparação entre as reconstruções do sinal realizadas pelo método proposto e pelo Elspec.

Os sinais reconstruídos mostrados na Figura 34, são comparados com o sinal original. Pode-se perceber que para esta situação, que é o momento do retorno de um afundamento, tanto o método proposto quanto o Elspec foram capazes de reconstruir o sinal perfeitamente, visto que o erro mostrado no gráfico é inferior à 5% do valor RMS.

A Figura 35 apresenta a reconstrução de uma janela em que o sinal está corrompido por interharmônicos. Para este caso, pode ser percebido que ambas as reconstruções apresentam erros. Observando-se o gráfico inferior, pode-se perceber que o comportamento dos erros é muito semelhante. Isso se deve ao fato de que ambos os métodos de reconstrução são baseados na transformada de Fourier. O erro apresentado pelo método proposto é devido ao fato de que a resolução espectral do processo de reconstrução é 15 Hz, visto que o mesmo é baseado na DFT e a janela utilizada possui 4 ciclos do componente de 60 Hz.




Figura 34: Reconstrução do sinal durante o retorno de um afundamento.




Figura 35: Reconstrução do sinal durante presença de inter-harmônicos

6.2.2 CASO S2

O sinal do Caso S2 é um sinal puramente senoidal que apresenta variação na sua amplitude. A amplitude cresce e decresce linearmente entre os valores de 127 V de pico e 180 V de pico, permanecendo constante, durante um intervalo, nesses valores extremos. Para armazenar todo o sinal, que possui 10 minutos de duração, seriam necessários 9,1 MB. A compressão realizada pelo método proposto, dá origem a um arquivo de 20,22 kB, atingindo uma taxa de compressão de 448 : 1. O tamanho do arquivo gerado pelo Elspec é de 22,67 kB, que para este caso, é bem próximo do tamanho do arquivo gerado pelo método proposto.

As métricas relativas à qualidade da reconstrução são: $NMSE = 0,0277$, $COR = 0,990$ e $RTE(\%) = 97,80\%$. A maior parcela relativa ao erro da reconstrução é proveniente da detecção de novidades, que é a não detecção de alguns *frames* durante as rampas de subida e descida presentes no sinal. A Figura 36 ilustra essa situação.




Figura 36: Frames de novidade detectados para o sinal do Caso S2.

Como pode ser percebido na Figura 36, durante as rampas as detecções ocorreram espaçadas, de forma que os *frames* de não novidade foram reconstruídos com a amplitude do último *frame* de referência. Porém, apesar desta falha, o comportamento da variação de amplitude do sinal pode ser analisado de forma clara. Em aplicações onde essas pequenas variações de amplitude forem importantes para a análise, o usuário deve configurar um valor de patamar mais baixo para a detecção, lembrando que dessa forma mais *frames* serão detectados o que comprometerá a taxa de compressão do sistema.

6.2.3 CASO S3

Neste caso o sinal é composto por intervalos de 1 min de sinais puramente senoidais, intercalados com intervalos de 2 min de sinais possuindo componentes harmônicos (ora somente harmônicos pares e ora somente harmônicos ímpares). Para armazenar aproximadamente 10 min deste sinal, são necessários 9,25 MB. O tamanho do arquivo gerado pelo sistema de compressão proposto é 16,2 kB, e portanto, a taxa de compressão obtida é de 570 : 1. Para esse sinal, tamanho do arquivo gerado pelo Elspec é de 36,0 kB.

As métricas relativas à qualidade da reconstrução são: $NMSE = 0,0277$, $COR = 0,992$ e $RTE(\%) = 98,54\%$.

Neste caso a alta taxa de compressão obtida é devido ao fato de que o sinal é composto por componentes praticamente estacionários, e portanto, apenas 1,15% dos *frames* foi detectado como *frames* de novidade. Os *frames* detectados são aqueles que se encontram no entorno das transições entre sinais puramente senoidais e sinais com distorção harmônica, como mostrado na Figura 37, em que a entrada ou saída dos componentes harmônicos podem ser percebidas pelas variações dos valores máximos e mínimos do sinal.




Figura 37: Frames de novidade detectados para o sinal do Caso S3.

6.2.4 CASO S4

O sinal de teste utilizado no Caso S4 é constituído por um componente senoidal que apresenta variação de frequência e amplitude. A cada intervalo de 20 s a amplitude

varia em degrau de aproximadamente 5 V, partindo de 140 V e atingindo 210 V. Simultaneamente, a frequência também varia em degrau de 0,1 Hz, partindo de 59 Hz chegando até 61 Hz. Após atingir estes valores máximos a amplitude e a frequência decaem até os valores de origem com o mesmo comportamento.

O sinal gerado possui duração de aproximadamente 10 min e são necessários 9,96 MB para armazenar todos os seus pontos. O sistema proposto gerou um arquivo de 107 kB enquanto o Elspec gerou um arquivo de 111 kB. Como dito anteriormente, uma das maiores vantagens do método proposto é a maneira de trabalhar em cenários de frequência variante. Portanto, era esperado para este caso que o método proposto apresentasse desempenho superior ao Elspec, porém, como a amplitude e a frequência variam simultaneamente, a cada variação de frequência (e amplitude) são detectados *frames* de novidade, o que piora o desempenho da compressão.

As métricas relativas à qualidade da reconstrução são: NMSE = 0,05, COR = 0,993 e RTE(%) = 98,13%.

Na Figura 38 podem ser percebidas as detecções sempre que a amplitude do sinal aumenta ou diminui, este sinal é útil para demonstrar que a presença de frequência variante no sinal nem sempre inibe a detecção pela diferença de energia. Quando a diferença de energia é muito significativa novidades são detectadas pois sinalizam a presença de um distúrbio.




Figura 38: Frames de novidade detectados para o sinal do Caso S4.

6.2.5 CASO S5

O sinal de testes do Caso S5, é um sinal puramente senoidal, de amplitude constante, em que a frequência do componente fundamental varia entre 59 Hz e 61 Hz. A duração do sinal é de 86 s, e o tamanho necessário para armazená-lo sem compressão seria de 1,32 MB. O arquivo gerado pelo sistema proposto possui 28,3 kB, constituindo uma taxa de compressão de 47 : 1. O tamanho do arquivo gerado pelo Elspec foi de 122,2 kB, que é bem maior do que o tamanho do arquivo comprimido pelo sistema proposto. As métricas relativas à qualidade da reconstrução são: $NMSE = 0,07$, $COR = 0,992$ e $RTE(\%) = 98,85\%$.

Este caso ilustra uma das vantagens do método proposto que é proporcionar grandes taxas de compressão para sinais que apresentem variações suaves na frequência e reconstruí-los com boa qualidade. Essa característica é decorrente do fato de que a metodologia de reconstrução é baseada na frequência estimada de cada ciclo e na utilização da SWRDFT.




Figura 39: Reconstrução do sinal com variação de frequência

A qualidade da reconstrução pelo método proposto pode ser percebida observando

a parte destacada no zoom da Figura 39, onde é possível perceber uma descontinuidade na reconstrução do Elspec e que a reconstrução pelo método proposto se aproxima mais do sinal real. O gráfico inferior da Figura 39, deixa ainda mais evidente o fato de que o método proposto é capaz de reconstruir o sinal sem inserir as descontinuidades.

A Tabela 5 apresenta os resultados obtidos para os casos testados.

Tabela 5: Resultados Compressão Offline.

	Caso S1	Caso S2	Caso S3	Caso S4	Caso S5
Tamanho do Arquivo Original (MB)	11,6	9,1	9,25	9,96	1.32
Tamanho do Arquivo Comprimido (kB)	99,8	20,22	16,2	107	28.3
Tamanho do Arquivo Elspec (kB)	254,3	22,67	36,0	111	122.2
NMSE	0,0343	0,0277	0,0277	0,0500	0,0700
COR	0,991	0,990	0,992	0,993	0,992
RTE(%)	98,37	97,80	98,54	98,13	98,85

6.2.6 CASO S6 - SINAL REAL

O sinal utilizado no Caso S6 foi adquirido de um gerador eólico. Foram adquiridos oito canais, sendo quatro de corrente e quatro de tensão. O sinal tem duração de 34 horas. A Tabela 6 mostra os resultados obtidos para os canais de tensão e corrente separadamente para o Método Proposto e a compressão total obtida pelo Elspec.

Tabela 6: Resultados para o Caso 6.

	Tensão	Corrente	Total
CR - Método Proposto	749:1	372:1	533:1
CR - Elspec	-	-	651:1
File Size - Método Proposto	9.8 MB	17.2 MB	27 MB
File Size - Elspec	-	-	22 MB
NMSE - Método Proposto	0.0093	0.0174	
COR - Método Proposto	0.996	0.990	
ENE(%) - Método Proposto	99.14	97.97	

Observando a Tabela 6, pode ser percebido que as métricas de qualidade foram satisfatórias. Pode ser percebido também que a taxa de compressão obtida para os canais de tensão foram maiores do que a obtida para os canais de corrente. Isso se deve ao fato de que os sinais de corrente apresentam mais variações de que os de tensão. Uma ilustração de um período de uma hora do sinal de corrente está mostrada na Figura 40.




Figura 40: Reconstrução do sinal com variação de frequência

6.3 TESTES ONLINE - IMPLEMENTAÇÃO EM TEMPO REAL

O sistema de compressão proposto é a base de um equipamento construído em parceria com a empresa KRON Medidores. Esse equipamento deve comprimir os sinais de tensão e corrente da rede elétrica e armazená-los em um cartão SD para posterior reconstrução. Os sinais devem ser armazenados por um longo período de tempo e, posteriormente, reconstruídos integralmente.

Essa implementação em tempo real foi realizada no trabalho de mestrado do aluno Eder Barboza Kapisch e possui um protótipo que conta com dois módulos, um de condicionamento de sinais analógicos e outro de processamento. A Figura 41, mostra uma bancada de testes para o módulo de processamento.

O módulo de processamento é constituído por duas plataformas: um FPGA (ALTERA, 2010), e um processador ARM Cortex M4 (INSTRUMENTS, 2013). Os algoritmos dos blocos Detecção de Novidade, Estimação de Frequência, Compressão com Perdas e Montador de Pacotes estão implementados na plataforma FPGA. Dessa forma, é res-

Figura 41: Bancada montada para testes do protótipo.

ponsabilidade do ARM, executar o algoritmo de Compressão sem Perdas e realizar a interface como cartão SD e com o software de controle e parametrização pelo usuário.

A parte de processamento de sinais, implementada em FPGA, é baseada em processadores customizados, especialmente desenvolvidos para essa aplicação. Todo o processamento é dividido em um pipeline de três estágios. No primeiro estágio, são executados, em paralelo, os blocos Detecção de Inovação, Estimação da Frequência e Compressão com Perdas. A implementação de cada um desses blocos foi realizada em um processador exclusivo. No segundo estágio do pipeline está o bloco Montador de pacotes, que a partir da informação vinda dos outros três blocos, empacota os dados que serão enviados para o ARM. O terceiro estágio é executado pelo ARM e consiste no algoritmo do bloco de Compressão com Perdas.

Os processadores desenvolvidos e implementados no FPGA, são baseados na arquitetura *Reduced Instruction Set Computer* (RISC) e possui memórias separadas para dados e instruções (Arquitetura de Harvard) (KAMAL, 2011). Apenas recursos internos do FPGA são utilizados, como memórias e blocos de DSP. Além disso, a ALU (Unidade Lógica e Aritmética) de cada processador contém somente os recursos necessários para o algoritmo nele implementado. A ALU utiliza de aritmética de ponto flutuante, permitindo, simultaneamente, rápido desenvolvimento de software (não é necessário se preocupar com quantização) e resultados precisos.

Para o desenvolvimento dos softwares que serão executados pelos processadores, um compilador específico foi desenvolvido utilizando-se as ferramentas de análise léxica da GNU: o Flex (PAXSON, 2015) e o Bison (DONNELLY; STALLMAN, 2015). O compilador

implementa um subconjunto da linguagem C, em que somente os comandos necessários para controle de fluxo e manipulação de vetores é incluída. O compilador gera dois arquivos binários que são copiados para as memórias de dados e instruções do processador, durante a compilação do hardware e não podem ser modificadas durante a execução. Essa filosofia de trabalho permite a economia dos recursos do FPGA de acordo com as necessidades dos algoritmos que precisam ser implementados.

O protótipo vêm sendo testado com o auxílio de uma fonte Omicron CMC-256-6 *plus* (OMICRON., 2013), específica para gerar sinais de QEE. Com essa fonte, é possível gerar sinais de tensão de até 500 V entre fases e corrente de até 25 A numa configuração trifásica. Dessa forma o protótipo pode ser testado por completo, incluindo a placa de condicionamento de sinais analógicos. A Figura 42 mostra uma bancada de testes onde podem ser vistos os dois módulos do sistema, juntamente com a fonte.

Figura 42: Bancada montada para testes do protótipo. A fonte Omicron ao fundo, o módulo de condicionamento à direita e o módulo de processamento à esquerda.

O FPGA utilizado para a implementação do sistema de compressão proposto é um FPGA com capacidade de processamento limitada, portanto, a metodologia sofreu algumas simplificações, tais como: o Detector de Novidades foi implementado sem a utilização do ramo inferior, responsável pela detecção de distúrbios de baixa frequência; e no bloco de Compressão com Perdas foi implementada uma árvore de decomposição wavelet de três níveis. Outra diferença é que no sistema online em relação ao offline é que no online os coeficientes estão sendo quantizados com 16 bits, enquanto que no offline estão quantizados com 10 bits.

O protótipo desenvolvido foi testado com os mesmos sinais utilizados nos testes

offline. A fonte Omicron foi utilizada para gerar os sinais para os testes do protótipo, bem como do Elspec. A Tabela 7 mostra os resultados de compressão e qualidade para os testes online.

Tabela 7: Resultados Compressão Online

	Caso S1	Caso S2	Caso S3	Caso S4	Caso S5
Tamanho do Arquivo Original (MB)	11,6	9,1	9,25	9,96	1.32
Tamanho do Arquivo Comprimido (kB)	485	735	114	1007	152
Taxa de Compressão	25:1	13:1	83:1	10:1	9:1
NMSE	0,0269	0,0136	0,0257	0,0098	0,0141
COR	0,996	0,995	0,998	0,997	0,995
RTE(%)	99,16	99,10	99,16	99,15	99,05

Por inspeção na Tabela 7 pode ser percebido que a metodologia online também é capaz de comprimir os sinais de entrada e reconstruí-los com qualidade bastante satisfatória. Comparando-se com a metodologia offline, os arquivos ainda são maiores (ocupam mais espaço) em disco, porém este fato é devido às simplificações necessárias para a implementação em um FPGA com capacidade limitada. Uma nova versão, em um FPGA mais poderoso, está sendo implementada de acordo com as especificações da metodologia online e seus resultados serão assunto de um trabalho futuro.

6.4 CONCLUSÕES PARCIAIS

Os sinais utilizados para testes neste capítulo abrangem os distúrbios mais característicos encontrados em Sistemas Elétricos de potência. Os resultados obtidos mostram a capacidade do Sistema de Compressão proposto comprimi-los e reconstruí-los de forma satisfatória. Foi mostrado também que o sistema proposto é capaz de ser implementado em tempo real, com algumas simplificações, mas ainda assim, reconstruir os sinais com alta qualidade.

Os resultados de compressão, foram ainda comparados com os resultados de um equipamento comercial, o Elspec G4000 BLACKBOX e estão sumarizados na Tabela 8.

Observando os dados apresentados na Tabela 8 pode ser percebido que o Sistema de Compressão proposto, quando implementada offline, obtém resultados semelhantes ao Elspec para alguns casos, e superiores para outros. Os casos em que o método proposto apresenta as melhores taxas de compressão são aqueles em que o sinal possui

Tabela 8: Comparação entre os tamanhos dos arquivos comprimidos.

	Caso S1	Caso S2	Caso S3	Caso S4	Caso S5
Online (kB)	485	735	114	1007	152
Offline (kB)	99,8	20,22	16,2	107	28,3
Elspec (kB)	254,3	22,67	36	111	122,2

comportamento mais estacionário, pois dessa forma, poucos *frames* de novidade são detectados e isso favorece bastante a compressão.

A maior vantagem em relação ao Elspec, é a habilidade em trabalhar com sinais de amplitude fixa, mas com frequência variante, como ilustrado pelo Caso S5, em que a taxa de compressão do método proposto é bem superior à obtida pelo Elspec. E a maior deficiência do método proposto, esta ilustrada no caso S1, é reconstruir sinais com a presença de inter-harmônicos, que é devido à SWRDFT utilizada e a resolução de 15 Hz dado o tamanho do *frame* ser de 4 ciclos do componente fundamental.

7 REPRESENTAÇÃO ESPARSA PARA COMPRESSÃO DE SINAIS ELÉTRICOS

Neste capítulo será mostrado o uso de técnicas de representação esparsa de sinais através de dicionários redundantes aplicado à compressão de sinais de sistemas elétricos de potência. Será discutida a maneira como o dicionário utilizado foi construído. Algoritmos utilizados para representação esparsa serão mostrados, e uma análise do desempenho de cada um deles será realizada com o objetivo de encontrar qual deles é o mais indicado para uma operação *online*.

7.1 REPRESENTAÇÃO ESPARSA UTILIZANDO DICIONÁRIOS REDUNDANTES

Técnicas de representação esparsa de sinais em dicionários redundantes têm sido muito utilizadas recentemente. O problema solucionado por essas técnicas é encontrar a representação mais compacta (esparsa) de um sinal em termos de uma combinação linear de elementos pertencentes a um dicionário redundante. Devido a sua capacidade de modelagem do sinal, apresentam desempenho superior quando comparadas a transformadas ortogonais (HUANG; AVIYENTE, 2006).

Obter a representação esparsa de um sinal $\mathbf{b}$, consiste em computar os coeficientes $\mathbf{x}$ da sua representação em uma matriz dicionário $\mathbf{A}$ que seja redundante, ou seja, possua mais elementos (colunas) do que o necessário para representar o sinal. Dessa forma, o sistema $\mathbf{b} = \mathbf{Ax}$ é um sistema linear indeterminado, ou seja, possui infinitas soluções. A representação desejada é, então, aquela que apresentar o menor número de coeficientes não nulos.

Como dito anteriormente, encontrar a solução mais esparsa de um sistema linear indeterminado é um problema de otimização baseado em restrições impostas por uma função custo. Uma função custo que favorece a esparsidade é a norma l_0 do vetor de coeficientes $\mathbf{x}$, dando origem ao problema (P_0) mostrado novamente na Equação (7.1) ou, na presença de ruído, ao problema $(P_{0,\epsilon})$ mostrado na Equação (7.2).

$$(P_0) : \min_{\mathbf{x}} \|\mathbf{x}\|_0 \text{ sujeito a } \mathbf{b} = \mathbf{Ax} \quad (7.1)$$

$$(P_{0,\epsilon}) : \min_{\mathbf{x}} \|\mathbf{x}\|_0 \text{ sujeito a } \|\mathbf{b} - \mathbf{Ax}\|_2 \leq \epsilon \quad (7.2)$$

em que $\|\mathbf{x}\|_0$ representa a norma l_0 do vetor $\mathbf{x}$, que é o número de elementos não nulos deste vetor.

A solução deste problema não se dá de maneira direta. Como pode ser observado, o vetor de coeficientes $\mathbf{x}$ pode ser visto como sendo composto por duas partes: o suporte (índice dos elementos não nulos) e o valor dos elementos do suporte. Dessa forma, uma maneira de resolver o problema é focar no suporte, tendo em mente que posteriormente os valores dos elementos não-nulos de $\mathbf{x}$ podem ser encontrados via Regressão Linear. Essa linha de raciocínio dá origem aos algoritmos ditos vorazes ou gulosos.

Em aplicações de remoção de ruído (*denoising*) e também em aplicações de compactação, o problema mais relaxado, mostrado em (7.2) é mais interessante, visto que algumas informações presentes no sinal, tais como o ruído por exemplo, não são desejadas em sua representação.

Uma outra forma muito difundida para obtenção da esparsidade é utilizar, como função custo, a norma l_1 . Dessa forma, o problema a ser resolvido torna-se (P_1) mostrado novamente na Equação 7.3 ou então a sua forma mais relaxada $(P_{1,\epsilon})$ mostrado na Equação (7.4).

$$(P_1) : \min_{\mathbf{x}} \|\mathbf{x}\|_1 \text{ sujeito a } \mathbf{b} = \mathbf{Ax} \quad (7.3)$$

$$(P_{1,\epsilon}) : \min_{\mathbf{x}} \|\mathbf{x}\|_1 \text{ sujeito a } \|\mathbf{b} - \mathbf{Ax}\|_2 \leq \epsilon \quad (7.4)$$

em que $\|\mathbf{x}\|_1$ representa a norma l_1 do vetor $\mathbf{x}$, que é a soma dos valores absolutos dos coeficientes deste vetor.

O problema $(P_{1,\epsilon})$ mostrado acima pode ser escrito como um problema de otimização com uma função custo linear e com restrições quadráticas. Tais problemas são bem solucionados com algoritmos provenientes da teoria de otimização moderna. Em algumas situações, esses algoritmos de otimização de propósito geral podem se mostrar demasiado lentos e algumas técnicas especiais são necessárias para solucionar esse

problema. Através da escolha de um multiplicador de Lagrange λ apropriado, pode-se transformar o problema $(P_{1,\epsilon})$ no problema de otimização sem restrições mostrado na Equação (7.5).

$$(Q_1^\lambda) : \min_{\mathbf{x}} \lambda \|\mathbf{x}\|_1 + \frac{1}{2} \|\mathbf{b} - \mathbf{Ax}\|_2^2 \quad (7.5)$$

em que o multiplicador de Lagrange λ é função de $\mathbf{A}$, $\mathbf{b}$ e ϵ . Nota-se, nesta função custo, a presença das normas l_2 e l_1 . A primeira lida com a representação dos dados em meio ao ruído, enquanto a segunda busca a esparsidade. O multiplicador de Lagrange atua como peso para ponderar entre as duas normas e é obtido experimentalmente através da escolha do desvio ϵ .

Nas próximas seções serão discutidos alguns algoritmos especializados para a minimização de (Q_1^λ) , baseados no processo de redução iterativo.

7.2 CONSTRUÇÃO DO DICIONÁRIO

Em representação esparsa de sinais, um dos dicionários mais conhecidos e utilizados é o dicionário de Gabor (GABOR, 1946), devido a sua capacidade de representar bem qualquer tipo de sinal, que contenha tanto componentes estacionários quanto transitórios. Entretanto, é necessário um dicionário com muitos elementos para que se tenha uma boa representação, o que afeta diretamente o desempenho dos algoritmos utilizados para encontrá-la. Dessa forma, quando busca-se um dicionário que seja capaz de ser aplicado em tempo real, o dicionário de Gabor mostra-se não ser o mais eficiente.

Em sistemas elétricos de potência, as ferramentas mais utilizadas em representação de sinais são a transformada de Fourier, que utiliza como base funções senoidais, e a transformada Wavelet, que utiliza funções com suporte temporal finito. A decomposição linear de um sinal em somente uma dessas bases não é muito flexível (MALLAT; ZHANG, 1993). A base de Fourier representa bem sinais estacionários no tempo e a base de Wavelet é mais indicada para sinais com suporte temporal finito.

Sabe-se que os sinais de tensão e corrente em um sistema elétrico de potência possuem tanto componentes estacionários, ou quase estacionários (componente fundamental, harmônicos e interharmônicos) quanto componentes não estacionários amortecidos, como é o caso dos transitórios oscilatórios. Os primeiros são bem representados pela base de Fourier e os últimos pela base Wavelet. Sendo assim, um dicionário formado pela união dessas duas bases seria capaz de fornecer uma boa representação para esse

tipo de sinal.

O fato de que o dicionário é constituído pela união de duas bases ortogonais implicará diretamente no desempenho dos algoritmos utilizados neste trabalho. Como será visto mais à frente, alguns algoritmos de representação esparsa possuem uma etapa de ortogonalização, que é custosa computacionalmente. Devido à característica mencionada do dicionário utilizado, o desempenho desses algoritmos com e sem essa etapa não são muito diferentes, possibilitando assim a sua utilização na forma mais simples e menos complexa.

Um dos fatores que pesaram na escolha desse dicionário foi o seu tamanho reduzido, já que o número de elementos no dicionário influi diretamente no tempo de busca e, para uma operação *online*, é necessária uma busca rápida. Para os testes que serão mostrados nas seções subsequentes, o dicionário possui a seguinte composição: 100 elementos da base de Fourier, ou seja, 50 senóides e 50 cossenóides nas frequências harmônicas múltiplas de 60 Hz; e 512 funções de base wavelet, construídas a partir da wavelet mãe Daubechies 3, formando assim um dicionário com 612 elementos com 512 amostras cada. O valor de 512 amostras foi escolhido para que seja feita a comparação com a utilização de Wavelets como no Capítulo 3.

7.3 ALGORITMOS PARA REPRESENTAÇÃO ESPARSA

Uma maneira de se encontrar a solução para os problemas descritos em (7.1) e (7.2) é através de busca exaustiva. Porém, essa solução se mostra inviável em quase todas as situações. Por exemplo, supondo que a matriz $\mathbf{A}$ possua n linhas e m colunas, e que o vetor $\mathbf{b}$ seja uma combinação linear de no máximo k_0 elementos dessa matriz, é necessário enumerar todas as possíveis combinações de k_0 elementos de $\mathbf{A}$ e testá-las. Para isso, são necessárias $O(m^{k_0} n k_0^2)$ flops, o que torna o algoritmo extremamente lento (ELAD, 2010).

Para solucionar esse problema, diversos algoritmos têm sido desenvolvidos. Esses algoritmos podem ser classificados em três principais classes: i) os algoritmos gulosos, que têm como o objetivo minimizar as funções (P_0) ou $(P_{0,\epsilon})$; ii) os algoritmos que relaxam a norma l_0 e têm como objetivo minimizar as funções (P_1) ou $(P_{1,\epsilon})$; e iii) os algoritmos iterativos de redução (*Iterative Shrinkage ALgorithm*) que minimizam uma forma mais geral de (Q_1^λ) mostrada em (7.5).

Neste trabalho não foram utilizados algoritmos pertencentes à classe ii, devido ao

seu elevado custo computacional, o que inviabiliza sua aplicação online. Os algoritmos pertencentes às outras classes, que serão utilizados, estão descritos nas próximas seções.

7.3.1 ALGORITMOS GULOSOS

Um algoritmo guloso abandona a busca exaustiva e trabalha com uma série de atualizações termo a termo, iniciando com a aproximação $\mathbf{x}^0 = \mathbf{0}$ e adicionando elementos iterativamente para construir uma aproximação $\mathbf{x}^k$ contendo k elementos não nulos. Um algoritmo dessa classe, largamente utilizado em processamento de sinais, é o OMP (PATI; REZAIIFAR; KRISHNAPRASAD, 1993) descrito na próxima seção.

7.3.1.1 ORTHOGONAL MATCHING PURSUIT - OMP

O OMP é um algoritmo guloso em que a cada iteração seleciona o elemento do dicionário que possui maior projeção ortogonal no sinal residual (assumindo que os elementos do dicionário estejam normalizados). O elemento selecionado é adicionado ao suporte da solução e o coeficiente de todos os elementos do vetor são atualizados via Regressão Linear. Uma descrição deste algoritmo está mostrada na Figura 43.

O algoritmo funciona da seguinte maneira: no estágio de varredura, os produtos internos entre o resíduo $\mathbf{r}^{k-1}$ e cada elemento (coluna) $\mathbf{a}_j$ da matriz $\mathbf{A}$ são calculados; no estágio de atualização do suporte, o índice j_0 do elemento $\mathbf{a}_{j_0}$ que apresentou maior valor de produto interno é adicionado ao suporte; a atualização da solução provisória é feita via Least-Squares, utilizando somente os elementos da matriz $\mathbf{A}$ relativos ao suporte de $\mathbf{x}$; por fim o novo resíduo $\mathbf{r}^k$ é calculado e o critério de parada é avaliado.

A obtenção dos coeficientes no estágio de atualização da solução provisória é feita através da minimização da expressão $\|\mathbf{A}_{S^k}\mathbf{x}_{S^k} - \mathbf{b}\|_2^2$ em que $\mathbf{x}_{S^k}$ é a parte não nula do vetor $\mathbf{x}$ e $\mathbf{A}_{S^k}$ é uma matriz formada somente pelas colunas de $\mathbf{A}$ que foram escolhidas até o momento. A solução desse problema é obtida igualando-se a derivada dessa expressão quadrática a zero, como mostrado em (7.6).

$$\mathbf{A}'_{S^k} (\mathbf{A}_{S^k}\mathbf{x}_{S^k} - \mathbf{b}) = -\mathbf{A}'_{S^k}\mathbf{r}^k = 0 \quad (7.6)$$

em que $\mathbf{r}^k = \mathbf{b} - \mathbf{A}\mathbf{x}^k$. A equação (7.6) mostra que as colunas da matriz $\mathbf{A}$ que fazem parte do suporte S^k são necessariamente ortogonais ao resíduo $\mathbf{r}^k$, e portanto, não serão escolhidas novamente nas futuras iterações. Esse processo de ortogonalização é que dá o nome ao algoritmo.

Objetivo: Aproximar a solução de $(P_0) : \min_{\mathbf{x}} \text{sujeito a } \mathbf{Ax} = \mathbf{b}$

Inicialização:

- Número de elementos do vetor $\mathbf{x}$: $k = 0$
- Solução inicial: $\mathbf{x}^0 = \mathbf{0}$
- Resíduo inicial: $\mathbf{r}^0 = \mathbf{b} - \mathbf{Ax}^0 = \mathbf{b}$
- Suporte da solução inicial: $S^0 = \text{Suporte}\{\mathbf{x}^0\} = \emptyset$

Iteração principal: $k = k + 1$ e em seguida realizar os seguintes estágios:

- **Varredura:** Calcular os erros $\epsilon(j) = \min_{z_j} \|\mathbf{a}_j z_j - \mathbf{r}^{k-1}\|_2^2$ utilizando o valor ótimo $z_j^* = \mathbf{a}_j' \mathbf{r}^{k-1} / \|\mathbf{a}_j\|_2^2$
- **Atualização do suporte:** Encontrar o índice j_0 relativo tal que $\epsilon(j_0) \leq \epsilon(j)$ e atualizar o suporte $S^k = S^{k-1} \cup j_0$
- **Atualização da solução provisória:** Computar $\mathbf{x}^k$ que minimize $\|\mathbf{Ax} - \mathbf{b}\|_2^2$ sujeito a S^k
- **Atualização do resíduo:** Calcular $\mathbf{r}^k = \mathbf{b} - \mathbf{Ax}^k$
- **Critério de Parada:** Se $\|\mathbf{r}^k\|_2 \geq \epsilon_0$, realizar outra iteração.

Saída: Apos k iterações tem-se o vetor de coeficientes $\mathbf{x}^k$

Figura 43: OMP - Orthogonal Matching Pursuit (ELAD, 2010).

A complexidade computacional do algoritmo OMP, supondo que a solução possua k_0 elementos, é igual a $O(k_0 mn)$ flops, o que, em geral, é bem menor do que as $O(m^{k_0} n k_0^2)$ flops necessárias para a busca exaustiva pela solução.

7.3.1.2 MATCHING PURSUIT - MP

O algoritmo MP é similar ao OMP descrito na seção anterior. A diferença é que no estágio de atualização da solução provisória os coeficientes que já faziam parte do suporte S^{k-1} são mantidos inalterados e o novo coeficiente, referente a j_0 é escolhido como sendo z_j^* , que é o valor do produto interno entre o elemento j_0 da matriz $\mathbf{A}$ e o resíduo $\mathbf{r}^{k-1}$. Essa diferença faz do MP um algoritmo menos custoso computacionalmente, porém, menos preciso do que o OMP. Uma descrição deste algoritmo é mostrada na Figura 44.

Objetivo: Aproximar a solução de $(P_0) : \min_{\mathbf{x}}$ sujeito a $\mathbf{Ax} = \mathbf{b}$

Inicialização:

- Número de elementos do vetor $\mathbf{x}$: $k = 0$
- Solução inicial: $\mathbf{x}^0 = \mathbf{0}$
- Resíduo inicial: $\mathbf{r}^0 = \mathbf{b} - \mathbf{Ax}^0 = \mathbf{b}$
- Suporte da solução inicial: $S^0 = \text{Suporte}\{\mathbf{x}^0\} = \emptyset$

Iteração principal: $k = k + 1$ e em seguida realizar os seguintes estágios:

- **Varredura:** Calcular os erros $\epsilon(j) = \min_{z_j} \|\mathbf{a}_j z_j - \mathbf{r}^{k-1}\|_2^2$ utilizando o valor ótimo $z_j^* = \mathbf{a}_j' \mathbf{r}^{k-1} / \|\mathbf{a}_j\|_2^2$
- **Atualização do suporte:** Encontrar o índice j_0 relativo tal que $\epsilon(j_0) \leq \epsilon(j)$ e atualizar o suporte $S^k = S^{k-1} \cup j_0$
- **Atualização da solução provisória:** Fazer $\mathbf{x}^k = \mathbf{x}^{k-1}$ e atualizar o elemento $x^k(j_0) = x^{k-1}(j_0) + z_j^*$
- **Atualização do resíduo:** Calcular $\mathbf{r}^k = \mathbf{b} - \mathbf{Ax}^k$
- **Critério de Parada:** Se $\|\mathbf{r}^k\|_2 \geq \epsilon_0$, realizar outra iteração.

Saída: Apos k iterações tem-se o vetor de coeficientes $\mathbf{x}^k$

Figura 44: MP - Matching Pursuit (ELAD, 2010).

Existem ainda diversas outras modificações nesses algoritmos, com o intuito de simplificá-los ou melhorar seu desempenho que não serão mencionadas neste trabalho. A seguir serão descritas algumas variantes desta técnica que obtiveram um bom desempenho na representação esparsa de sinais em sistemas de potencia, visando aplicações online.

7.3.1.3 STAGewise ORTHOGONAL MATCHING PURSUIT - StOMP

O *Stagewise Orthogonal Matching Pursuit* (StOMP) (DONOHO et al., 2012) é um algoritmo baseado no OMP, em que a principal diferença entre os dois é que o StOMP constrói a solução adicionando vários elementos a cada iteração enquanto que o OMP

adiciona apenas um. O método é esquematizado na Figura 45 após o cálculo dos produtos internos entre o resíduo $\mathbf{r}^k$ e cada elemento da matriz $\mathbf{A}$, todos os elementos que apresentaram o valor do produto interno superior a um limiar pré-selecionado são escolhidos para fazer parte da solução. Como no caso do OMP, os valores dos coeficientes de cada um desses elementos são obtidos via *Least-Squares*.

Objetivo: Aproximar a solução de $(P_0) : \min_{\mathbf{x}} \text{sujeito a } \mathbf{Ax} = \mathbf{b}$

Inicialização:

- Número de elementos do vetor $\mathbf{x}$: $k = 0$
- Solução inicial: $\mathbf{x}^0 = \mathbf{0}$
- Resíduo inicial: $\mathbf{r}^0 = \mathbf{b} - \mathbf{Ax}^0 = \mathbf{b}$
- Suporte da solução inicial: $S^0 = \text{Suporte}\{\mathbf{x}^0\} = \emptyset$
- Escolha do valor do limiar T .

Iteração principal: $k = k + 1$ e em seguida realizar os seguintes estágios:

- **Varredura:** Calcular os produtos internos $z_j = \mathbf{a}_j' \mathbf{r}^{k-1}$
- **Atualização do suporte:** Encontrar o conjunto J formado pelos índices dos elementos que apresentarem produto interno superior a T e atualizar o suporte $S^k = S^{k-1} \cup J$
- **Atualização da solução provisória:** Computar $\mathbf{x}^k$ que minimize $\|\mathbf{Ax} - \mathbf{b}\|_2^2$ sujeito a S^k
- **Atualização do resíduo:** Calcular $\mathbf{r}^k = \mathbf{b} - \mathbf{Ax}^k$
- **Critério de Parada:** Se $\|\mathbf{r}^k\|_2 \geq \epsilon_0$, realizar outra iteração.

Saída: Apos k iterações tem-se o vetor de coeficientes $\mathbf{x}^k$

Figura 45: StOMP - Stagewise Orthogonal Matching Pursuit.

Uma grande vantagem desse método é o fato de que ele é capaz de produzir uma boa aproximação do resultado com poucas iterações, já que vários elementos podem ser adicionados numa única iteração. A maior dificuldade, porém, é o estabelecimento do valor do limiar T , visto que a cada iteração a faixa de valores dos produtos internos do resíduo $\mathbf{r}^k$ com os elementos da matriz $\mathbf{A}$ é diferente. Quando um limiar grande demais é escolhido, a aproximação resultante pode não ser boa o suficiente. Por outro lado, quando o limiar é escolhido de forma a priorizar a qualidade da aproximação, o método tende a adicionar muitos elementos, o que, para aplicações de compressão, não é algo desejável.

7.3.1.4 REGULARIZED ORTHOGONAL MATCHING PURSUIT - ROMP

Um outro algoritmo baseado no OMP, e muito parecido com o StOMP, é denominado *Regularized Orthogonal Matching Pursuit* (ROMP) (NEEDELL; VERSHYNIN, 2009). A grande diferença entre esse método e o StOMP é que ele não utiliza um valor fixo de limiar, solucionando assim o grande problema do StOMP. O ROMP utiliza o limiar T como sendo a metade do maior valor absoluto entre os produtos internos do resíduo $\mathbf{r}^k$ com os elementos da matriz $\mathbf{A}$. Assim, o limiar se adapta a cada iteração com o intuito de escolher somente os elementos que realmente são significantes para a aproximação. Como resultado, tem-se uma aproximação de boa qualidade e com menos elementos do que no caso da utilização do StOMP. O algoritmo ROMP está descrito na Figura 46.

Objetivo: Aproximar a solução de $(P_0) : \min_{\mathbf{x}}$ sujeito a $\mathbf{Ax} = \mathbf{b}$

Inicialização:

- Número de elementos do vetor $\mathbf{x}$: $k = 0$
- Solução inicial: $\mathbf{x}^0 = \mathbf{0}$
- Resíduo inicial: $\mathbf{r}^0 = \mathbf{b} - \mathbf{Ax}^0 = \mathbf{b}$
- Suporte da solução inicial: $S^0 = \text{Suporte}\{\mathbf{x}^0\} = \emptyset$
- Escolha do valor do limiar T .

Iteração principal: $k = k + 1$ e em seguida realizar os seguintes estágios:

- **Varredura:** Calcular os produtos internos $z_j = \mathbf{a}'_j \mathbf{r}^{k-1}$
- **Calculo do Limiar:** Encontrar o valor máximo entre os produtos internos calculados no estágio anterior $z_{j_{max}} = \max(|z_j|)$ e fazer $T = z_{j_{max}}/2$.
- **Atualização do suporte:** Encontrar o conjunto J formado pelos índices dos elementos que apresentarem produto interno superior a T e atualizar o suporte $S^k = S^{k-1} \cup J$
- **Atualização da solução provisória:** Computar $\mathbf{x}^k$ que minimize $\|\mathbf{Ax} - \mathbf{b}\|_2^2$ sujeito a S^k
- **Atualização do resíduo:** Calcular $\mathbf{r}^k = \mathbf{b} - \mathbf{Ax}^k$
- **Critério de Parada:** Se $\|\mathbf{r}^k\|_2 \geq \epsilon_0$, realizar outra iteração.

Saída: Apos k iterações tem-se o vetor de coeficientes $\mathbf{x}^k$

Figura 46: ROMP - Regularized Orthogonal Matching Pursuit.

7.3.2 ALGORITMOS ITERATIVOS DE REDUÇÃO - ITERATIVE SHRINKAGE ALGORITHMS

A técnica de limiarização ou *Shrinkage*, desenvolvida por Donoho em (DONOHO, 1995) é uma técnica simples, porém muito eficiente em aplicações de remoção de ruído. Avanços recentes mostram que essas técnicas de limiarização auxiliam na busca por uma representação esparsa de um determinado sinal. Os algoritmos baseados nessa técnica formam uma outra categoria, denominada Algoritmos Iterativos de Redução (*Iterative Shrinkage Algorithms*).

Os algoritmos que serão descritos nesta seção têm o objetivo de minimizar uma função do tipo da que está mostrada em (7.7), que é uma forma generalizada de (7.5):

$$f(\mathbf{x}) = \lambda \mathbf{1}^T \rho(\mathbf{x}) + \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 \quad (7.7)$$

Nesta equação, a função $\rho(\mathbf{x})$ opera ponto a ponto no vetor $\mathbf{x}$, e deve ser escolhida de forma a promover a esparsidade. Um exemplo é $\rho(\mathbf{x}) = |\mathbf{x}|^p$, desta forma $\mathbf{1}^T \rho(\mathbf{x}) = \|\mathbf{x}\|_p^p$.

Diversos algoritmos iterativos têm sido desenvolvidos para solucionar o problema posto em (7.7). De forma simplificada, cada iteração desses métodos consiste em uma multiplicação pela matriz $\mathbf{A}$ e sua transposta, seguido por uma etapa de limiarização do resultado obtido.

Para um melhor entendimento do procedimento da obtenção de um algoritmo que minimize $f(\mathbf{x})$ descrita em (7.7), mostra-se que para o caso em que $\mathbf{A}$ é uma matriz unitária ($\mathbf{A}\mathbf{A}^T = \mathbf{I}$), $f(\mathbf{x})$ pode ser facilmente manipulada de forma a dar origem a um conjunto de tarefas de otimização unidimensionais e independentes. Com essa premissa, a função $f(\mathbf{x})$ pode ser reescrita da seguinte forma:

$$\begin{aligned} f(\mathbf{x}) &= \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \mathbf{1}^T \rho(\mathbf{x}) \\ &= \frac{1}{2} \|\mathbf{A}(\mathbf{A}^T \mathbf{b} - \mathbf{x})\|_2^2 + \lambda \mathbf{1}^T \rho(\mathbf{x}) \\ &= \frac{1}{2} \|\mathbf{A}^T \mathbf{b} - \mathbf{x}\|_2^2 + \lambda \mathbf{1}^T \rho(\mathbf{x}) \end{aligned} \quad (7.8)$$

Fazendo $\mathbf{A}^T \mathbf{b} = \mathbf{x}_0$, temos:

$$\begin{aligned}
f(\mathbf{x}) &= \frac{1}{2} \|\mathbf{x}_0 - \mathbf{x}\|_2^2 + \lambda \mathbf{1}^T \rho(\mathbf{x}) \\
&= \sum_{k=1}^m \left[\frac{1}{2} (x_0[k] - x[k])^2 + \lambda \rho(x[k]) \right] = \sum_{k=1}^m g(x[k], x_0[k])
\end{aligned} \tag{7.9}$$

A minimização de uma função escalar do tipo $g(x, a) = 0.5(x - a)^2 - \lambda \rho(x)$, em relação a x , pode ser solucionada analiticamente para alguns casos e numericamente para outros, dando origem à expressão $\hat{x}_{opt} = S_{\rho, \lambda}(a)$. A função $S_{\rho, \lambda}(a)$ mapeia os elementos próximos à origem em zero ($S_{\rho, \lambda}(a) = 0$, se $|a| \leq T$) e os outros elementos são *shrunked*. Portanto, esta é conhecida como uma função de *shrinkage* (ELAD, 2010).

Quando a matriz $\mathbf{A}$ deixa de ser unitária e quadrada, pode-se partir do mesmo princípio para obter a função de *shrinkage*, porém para obter o resultado desejado, várias iterações deverão ser feitas. Um método desenvolvido que trata de casos como esse é o método que se utiliza de funções substitutas (surrogate), que está descrito na próxima subseção.

7.3.2.1 SEPARATE SURROGATE FUNCTIONALS METHOD - SSF

Considerando a função $f(\mathbf{x})$ descrita em (7.7), é adicionado a ela o seguinte termo:

$$d(\mathbf{x}, \mathbf{x}_0) = \frac{c}{2} \|\mathbf{x} - \mathbf{x}_0\|_2^2 - \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{A}\mathbf{x}_0\|_2^2 \tag{7.10}$$

em que a constante c deve ser escolhida de forma que a função $d(\cdot)$ seja estritamente convexa, implicando que sua matriz Hessiana deve ser positiva definida, ou seja, $c\mathbf{I} - \mathbf{A}^T \mathbf{A} > \mathbf{0}$. Dessa forma, $c > \|\mathbf{A}^T \mathbf{A}\|_2 = \lambda_{max}(\mathbf{A}^T \mathbf{A})$. A nova função objetivo é então:

$$\tilde{f}(\mathbf{x}) = \lambda \mathbf{1}^T \rho(\mathbf{x}) + \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2 + \frac{c}{2} \|\mathbf{x} - \mathbf{x}_0\|_2^2 - \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{A}\mathbf{x}_0\|_2^2 \tag{7.11}$$

Abrindo os vários termos da Equação (7.11) e reorganizando-os, tem-se:

$$\begin{aligned}
\tilde{f}(\mathbf{x}) &= \frac{1}{2} \|\mathbf{b}\|_2^2 + \frac{1}{2} \|\mathbf{A}\mathbf{x}_0\|_2^2 + \frac{c}{2} \|\mathbf{x}_0\|_2^2 - \mathbf{b}^T \mathbf{A}\mathbf{x} + \lambda \mathbf{1}^T \rho(\mathbf{x}) \\
&+ \frac{c}{2} \|\mathbf{x}\|_2^2 - c\mathbf{x}^T \mathbf{x}_0 + \mathbf{x}^T \mathbf{A}^T \mathbf{A}\mathbf{x}_0 \\
&= \text{Const}_1 - \mathbf{x}^T [\mathbf{A}^T (\mathbf{b} - \mathbf{A}\mathbf{x}_0) + c\mathbf{x}_0] + \lambda \mathbf{1}^T \rho(\mathbf{x}) + \frac{c}{2} \|\mathbf{x}\|_2^2
\end{aligned} \tag{7.12}$$

em que o termo Const_1 contém todos os termos independentes de $\mathbf{x}$. Definindo:

$$\mathbf{v}_0 = \frac{1}{c} \mathbf{A}^T (\mathbf{b} - \mathbf{A}\mathbf{x}_0) + \mathbf{x}_0 \tag{7.13}$$

dividindo (7.12) por c e substituindo (7.13) em (7.12) tem-se:

$$\begin{aligned}
\tilde{f}(\mathbf{x}) &= \text{Const}_2 - \mathbf{x}^T \mathbf{v}_0 + \lambda \mathbf{1}^T \rho(\mathbf{x}) + \frac{c}{2} \|\mathbf{x}\|_2^2 \\
&= \text{Const}_3 + \lambda \mathbf{1}^T \rho(\mathbf{x}) + \frac{c}{2} \|\mathbf{x} - \mathbf{v}_0\|_2^2
\end{aligned} \tag{7.14}$$

que possui a mesma forma de (7.9) e portanto a solução é dada por:

$$\hat{\mathbf{x}}_{opt} = S_{\rho, \lambda/c}(\mathbf{v}_0) = S_{\rho, \lambda/c} \left(\frac{1}{c} \mathbf{A}^T (\mathbf{b} - \mathbf{A}\mathbf{x}_0) + \mathbf{x}_0 \right) \tag{7.15}$$

Desta forma, é possível minimizar a função $\tilde{f}(\mathbf{x})$ utilizando (7.15). Essa minimização pode ser feita através de um processo iterativo em que $\mathbf{x}_0$ é substituído por $\mathbf{x}_k$, e é comprovado que esse processo, na iteração $k+1$ converge para o mínimo local da função original $f(\mathbf{x})$ (ELAD, 2010). Portanto, o algoritmo proposto é constituído simplesmente pela aplicação da Equação (7.15) de forma iterativa como mostrado abaixo:

$$\mathbf{x}_{k+1} = S_{\rho, \lambda/c} \left(\frac{1}{c} \mathbf{A}^T (\mathbf{b} - \mathbf{A}\mathbf{x}_k) + \mathbf{x}_k \right) \tag{7.16}$$

Esse algoritmo é conhecido como método das Funções Substitutas Separáveis (do inglês, *Separable Surrogate Functionals* (SSF)) e está descrito na Figura 47.

A opção da escolha do μ ótimo, no passo **Line Search**, acelera a convergência do algoritmo (LUENBERGER; YE, 2008), a um custo de aumentar significativamente a complexidade computacional do método, pois envolve multiplicação de vetores e matrizes de elevada ordem.

Objetivo: Encontrar o vetor $\mathbf{x}$ que minimize $f(\mathbf{x}) = \lambda \mathbf{1}^T \rho(\mathbf{x}) + \frac{1}{2} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2^2$

Inicialização:

- Solução inicial: $\mathbf{x}^0 = \mathbf{0}$
- Resíduo inicial: $\mathbf{r}^0 = \mathbf{b} - \mathbf{A}\mathbf{x}^0 = \mathbf{b}$

Iteração principal: $k = k + 1$ e em seguida realizar os seguintes estágios:

- **Projeção:** Computar $\mathbf{e} = \mathbf{A}^T \mathbf{r}_{k-1}$
- **Shrinkage:** Computar $\mathbf{e}_s = \text{Shrink}(\mathbf{x}_{k-1} + \mathbf{e}/c)$
- **Line Search (Opcional):** Escolha de um μ que minimize a função real $f(\mathbf{x}_{k-1} + \mu(\mathbf{e}_s - \mathbf{x}_{k-1}))$
- **Atualização a Solução:** Computar $\mathbf{x}_k = \mathbf{x}_{k-1} + \mu(\mathbf{e}_s - \mathbf{x}_{k-1})$
- **Atualização do resíduo:** Calcular $\mathbf{r}^k = \mathbf{b} - \mathbf{A}\mathbf{x}^k$
- **Critério de Parada:** Se $\|\mathbf{r}^k\|_2 \geq \epsilon_0$, realizar outra iteração.

Saída: Após k iterações tem-se o vetor de coeficientes $\mathbf{x}^k$

Figura 47: SSF - Separable Surrogate Functionals Iterative-shrinkage.

7.4 ANÁLISE DE DESEMPENHO DOS ALGORITMOS

O objetivo deste trabalho é encontrar uma técnica de representação esparsa para ser implementada online em uma aplicação de compressão de sinais advindos de sistemas elétricos de potência. A técnica escolhida deve possuir uma boa capacidade de representar esses sinais, apresentando um baixo erro na reconstrução e um custo computacional condizente com a plataforma na qual será implementada. Esta seção tem, portanto, o objetivo de analisar diversos parâmetros dessas técnicas para que a possibilidade de implementação de alguma delas seja avaliada.

Os algoritmos testados foram: os algoritmos gulosos MP, OMP, StOMP, ROMP e uma variação do ROMP que não utiliza o *Least-Squares* na atualização dos coeficientes e se assemelha ao MP, sendo assim denominado de RMP; e os algoritmos de *Shrinkage* SSF com e sem a etapa de *Line Search*.

Os testes foram conduzidos da seguinte maneira: foram gerados 100 sinais de um determinado distúrbio de QEE, com parâmetros aleatórios e cada um destes foi submetido à 100 iterações de cada um dos algoritmos, com o objetivo de se avaliar a qualidade da aproximação e o número de elementos utilizados em cada iteração. Os gráficos fo-

ram gerados com as médias de cada um dos parâmetros analisados (erro, correlação e número de elementos) dos 100 sinais.

7.4.1 QUALIDADE DA APROXIMAÇÃO

Com o objetivo de se avaliar a qualidade da aproximação foram gerados dois gráficos, um que mostra o erro médio quadrático entre o sinal e a aproximação e outro que mostra o coeficiente de correlação entre os dois. Para distúrbios do tipo transitório oscilatório, a Figura 48 mostra o erro, e a Figura 49 a correlação em cada iteração.




Figura 48: Erro Médio Quadrático para sinais contendo transitórios.

Na Figura 48 pode ser observado que todos os algoritmos (menos o RMP) testados convergem para um valor de erro considerado satisfatório, porém alguns métodos convergem mais rápido, com menos iterações, que outros. Como já era esperado, os métodos que adicionam somente um elemento por iteração (MP e OMP) apresentam convergência mais lenta em relação aos outros métodos que incluem mais de um elemento a cada iteração.

Um algoritmo que merece uma análise mais cuidadosa é o StOMP. Apesar do mesmo convergir rapidamente, seu erro não decai com o passar das iterações. Esse fato se deve a sua característica de trabalhar com um valor de limiar fixo, como foi explicado anteriormente. Essa característica, juntamente com a “quase ortogonalidade” do dicionário, faz com que nenhum elemento que tenha ficado de fora da representação na primeira iteração apresente valor de produto interno com o resíduo superior ao

limiar nas próximas iterações e, portanto, a qualidade da aproximação não varia com o número de iterações do algoritmo.

Durante os testes, foi observado, através de inspeção visual nos sinais reconstruídos, que o MSE não descrevia muito bem a qualidade da aproximação para alguns casos, e outro parâmetro que descrevesse melhor a qualidade da aproximação foi buscado. Percebeu-se então, que o coeficiente de correlação entre o sinal e a aproximação é o parâmetro mais indicado para essa análise. A correlação foi calculada em relação à autocorrelação do sinal, ou seja, para uma reconstrução perfeita o valor de correlação deve ser igual a 1.

Na Figura 49 podem ser notadas diferenças entre a convergência dos algoritmos. Como já era esperado, os algoritmos MP e OMP possuem convergência mais lenta, visto que eles adicionam somente um elemento por vez. Quanto aos algoritmos de *Shrinkage*, o desempenho do algoritmo que utiliza a etapa de *Line Search* é superior ao desempenho do algoritmo que não a utiliza. Porém, a representação gerada por ambos não é satisfatória visto que o valor de correlação para o qual eles convergiram não é suficiente. Os algoritmos RMP e ROMP apresentam comportamento bem diferente para a representação dos distúrbios transitórios, onde o desempenho do ROMP merece destaque pois o mesmo converge em poucas iterações para um valor de correção satisfatório.




Figura 49: Correlação para sinais contendo transitórios.

Vale a pena ressaltar que, tanto na Figura 48 quanto na Figura 49, o algoritmo ROMP apresentou um comportamento superior aos outros algoritmos, seja na velocidade de convergência ou no valor de correlação atingido. Sua superioridade em relação ao RMP se dá devido à etapa de ortogonalização no cálculo dos coeficientes, que afeta diretamente a qualidade da representação utilizando o dicionário proposto.

Análises semelhantes foram realizadas para representação de outros distúrbios típicos de QEE. A Figura 50 apresenta a correlação para distúrbios do tipo harmônicos estacionários e a Figura 51 para harmônicos variantes no tempo.




Figura 50: Correlação para sinais contendo harmônicos estacionários.

Analisando essas duas figuras, pode-se notar que, para o caso dos harmônicos variantes no tempo, os algoritmos que possuem etapa de ortogonalização desempenham melhor do que os seus equivalentes que não possuem essa etapa. Por exemplo: na Figura 50 os algoritmos ROMP e RMP têm um desempenho quase idêntico, e o mesmo pode ser observado para o OMP e o MP. Já na Figura 51 pode ser notado que o ROMP converge mais rápido do que o RMP, e que o OMP é sutilmente mais rápido do que o MP. Essa diferença pode ser explicada pelo fato de que, no caso dos harmônicos estacionários, o resíduo é naturalmente ortogonal em relação aos componentes já escolhidos, e portanto a ortogonalização não faz diferença, enquanto que no caso variante no tempo isso não é verdade.




Figura 51: Correlação para sinais contendo harmônicos variantes no tempo.

O mesmo comportamento pode ser observado na Figura 52 em que os resultados são mostrados para a representação de distúrbios do tipo Sag e Swell. Neste caso ocorre também que o resíduo não é naturalmente ortogonal aos elementos selecionados, ficando evidente uma diferença de desempenho entre o ROMP e o RMP.




Figura 52: Correlação para sinais contendo Sags e Swells.

Como conclusão das análises de comparação entre os diferentes métodos analisados,

pode-se notar que, de forma geral, o algoritmo que se comportou melhor, tanto em relação ao tempo de convergência quanto ao valor final da correlação, para os sinais testados e o dicionário proposto, foi o ROMP.

7.4.2 NÚMERO DE ELEMENTOS UTILIZADOS

Em se tratando de uma aplicação de compressão de sinais, o objetivo é encontrar uma aproximação que seja fiel e ao mesmo tempo compacta, ou seja, que utilize poucos elementos do dicionário. Portanto, em conjunto com a qualidade da aproximação, o número de elementos utilizado também deve ser avaliado. A Figura 53 mostra o número de elementos a cada iteração dos algoritmos utilizados para representação de distúrbios do tipo transitório oscilatório.




Figura 53: Número de elementos para sinais contendo transitórios.

Pode ser percebido que o comportamento do OMP e do MP é exatamente o mesmo quanto ao número de elementos, já que os dois métodos sempre adicionam um elemento a cada iteração. Como já mencionado anteriormente, o número de elementos não varia para o algoritmo StOMP, já que o mesmo trabalha com um valor de limiar fixo.

Um comportamento interessante é observado nos algoritmos de *Shrinkage*, em que muitos elementos são adicionados nas primeiras iterações e depois esse número vai diminuindo gradativamente. Fica evidenciada também a influência da etapa de *Line-Search*, fazendo com que o número de elementos a cada iteração decresça de maneira

mais agressiva, obtendo um resultado, em termos de compactação, bem melhor do que o seu equivalente sem essa etapa.

Novamente, o destaque positivo fica por conta do algoritmo ROMP, que apresentou um nível de compactação bem interessante, sendo capaz de representar bem o sinal (vide Figuras 48 e 49), com o menor número de elementos em relação aos outros algoritmos testados e com o menor número de iterações. A rápida convergência se dá devido ao fato de o algoritmo adicionar vários elementos a cada iteração de acordo com um limiar adaptativo, que é relativo ao valor máximo de produto interno entre os elementos e o resíduo, na respectiva iteração.

Pode ser percebido também que a etapa de ortogonalização faz muita diferença quanto ao número de elementos, visto que o RMP adiciona muito mais elementos a cada iteração do que o ROMP. Este fato ocorre devido a uma característica dos elementos do dicionário proposto, baseados na Wavelet mãe bior3.1, que apresentam forte correlação negativa entre pares vizinhos. A Figura 54 mostra alguns elementos do dicionário proposto, que são pertencentes a base wavelet. Pode-se notar que, devido a esta forte anti-correlação, dois elementos vizinhos serão selecionados com equivalente energia (e sinais opostos) em algoritmos que não realizam a etapa de regressão linear. Por outro lado, a etapa de ortogonalização anula uma das componentes anti-simétricas, reduzindo o número de sinais na representação dos dados.




Figura 54: Alguns elementos do dicionário proposto pertencentes a base wavelet.

A Figura 55 apresenta os resultados dos algoritmos, quanto ao número de elementos por eles utilizados, para a representação dos distúrbios do tipo harmônicos estacionários. Nesta figura pode ser observado também a superioridade do algoritmo ROMP, que

também apresentou convergência mais rápida e utilizou o menor número de elementos para a representação. O comportamento dos outros algoritmos é similar ao do caso dos transitórios oscilatórios, em que o StOMP apresenta número de elementos constante e os algoritmos de shrinkage apresentam convergência mais lenta em relação aos outros métodos.




Figura 55: Número de elementos para sinais contendo harmônicos estacionários.

A Figura 56 e a Figura 57 mostram, respectivamente, o número de elementos para cada iteração na representação de harmônicos variantes no tempo e distúrbios do tipo Sag e Swell. Na análise dessas figuras fica refletido o comportamento apresentado nos gráficos da correlação (Figura 51 e Figura 52) em que pode ser notada uma diferença no comportamento dos algoritmos com e sem etapa de ortogonalização. Essa diferença fica mais evidente nos algoritmos ROMP e RMP, já que, quanto ao número de elementos, tanto o MP quanto o OMP se comportam sempre da mesma maneira: adicionando um elemento a cada iteração.

De posse dessas análises, pode-se concluir que o algoritmo mais indicado para a implementação online, com a utilização do dicionário proposto, é o ROMP devido a sua rápida convergência e boa qualidade de aproximação para os distúrbios testados. Outro fato que justifica a escolha do ROMP é que o número de elementos é sempre pequeno quando comparado aos outros algoritmos, o que é imprescindível para uma boa compressão.




Figura 56: Número de elementos para sinais contendo harmônicos variantes no tempo.




Figura 57: Número de elementos para sinais contendo sags e swells.

7.5 COMPARAÇÃO COM A COMPRESSÃO UTILIZANDO WAVELETS

Uma outra análise que foi realizada foi a comparação de desempenho entre o algoritmo de representação esparsa ROMP e a técnica utilizada pela metodologia apresentada no Capítulo 3 que faz uso da Transformada Discreta de Wavelet. Os métodos

foram comparados segundo a qualidade da aproximação gerada e ao número de elementos utilizados. Os resultados estão mostrados na Tabela 9. Para o número de elementos utilizados são mostrados os valores médios e de desvio padrão.

Tabela 9: Comparação entre os métodos de compressão.

	Método	Distúrbio			
		Transitório	Harmônicos Estacionários	Harmônicos Variantes	Sag e Swell
MSE	Wavelet	$4,58 \times 10^{-4}$	$3,41 \times 10^{-3}$	$6,90 \times 10^{-4}$	$1,41 \times 10^{-5}$
	ROMP	$6,69 \times 10^{-5}$	$4,01 \times 10^{-5}$	$8,55 \times 10^{-5}$	$4,77 \times 10^{-5}$
Correlação	Wavelet	0,9925	0,9917	0,9928	0,9931
	ROMP	0,9951	0,9957	0,9946	0,9957
Número de Elementos	Wavelet	50 ± 9	93 ± 10	53 ± 5	31 ± 3
	ROMP	18 ± 10	11 ± 7	34 ± 15	12 ± 4

Analisando o Erro Médio Quadrático (MSE) e a Correlação, que são os parâmetros relativos à qualidade da aproximação obtida, pode-se perceber que os dois métodos foram capazes de encontrar uma boa aproximação para o sinal, o que já era esperado dado os resultados mostrados anteriormente.

Com relação à compressão, pode-se perceber, através do número de elementos, que o método de representação esparsa mostra relativa superioridade em relação a Transformada Wavelet, fato que já era esperado devido à característica construtiva do dicionário proposto, que une duas bases com características complementares: a base Wavelet, que representa de forma compacta sinais transitórios no domínio do tempo; e a base de Fourier, mais indicada para sinais estacionários. A Tabela 10 apresenta o valor percentual do número de elementos selecionados de cada base para a representação de cada tipo de distúrbio.

Tabela 10: Percentual de elementos selecionados de cada uma das bases que compõem o dicionário.

	Transitório	Harmônicos Estacionários	Harmônicos Variantes	Sag e Swell
Base Wavelet	80%	2%	75%	87%
Base de Fourier	20%	98%	25%	13%

Observando a Tabela 10 pode ser percebido que a utilização da base de Fourier contribui bastante com a compressão, principalmente para o caso de harmônicos estacionários, onde já é conhecido o desempenho ruim da Wavelet e que a maioria dos elementos selecionados pertence a base de Fourier. Para o caso dos transitórios, que são constituídos por um componente de alta frequência amortecido somado ao componente fundamental, os componentes selecionados são quase totalmente da base wavelet. Porém, os poucos componentes selecionados da base de Fourier são suficientes para representar bem o componentes fundamental e, dessa forma, menos componentes da base wavelet são necessários para representar a parte transitória do sinal. Nos casos de harmônicos variantes no tempo, Sags e Swells, embora não haja uma senoide em regime permanente para ser representada com poucos elementos da base de Fourier, a utilização da mesma contribui para a compressão

7.6 CONCLUSÕES PARCIAIS

Esse capítulo mostrou a utilização de técnicas de representação esparsa de sinais utilizando dicionários redundantes aplicadas à compressão de sinais advindos de sistemas elétricos de potência. Foi mostrada a construção do dicionário que será utilizado, em que priorizou-se além da qualidade da aproximação, o tamanho do mesmo para agilizar a busca que deverá ser realizada em tempo real.

Diversos algoritmos de representação esparsa foram apresentados e seus desempenhos foram analisados, tanto quanto a qualidade da representação, quanto ao número de elementos utilizados frente aos mais comuns distúrbios de QEE. Nessa avaliação, constatou-se uma superioridade do algoritmos ROMP, principalmente quanto à convergência, já que o mesmo sempre converge para um resultado satisfatório com menos iterações do que os outros.

Quando comparados com a técnica de compressão baseada na Transformada Wavelet Discreta, o algoritmo de representação esparsa mostrara relativa superioridade para os casos testados, provando ser atrativo para aplicações de compressão de sinais elétricos, embora apresente complexidade computacional mais elevada.

Com as análises feitas, chega-se a conclusão de que existe a possibilidade de que a técnica de representação esparsa, utilizando o dicionário proposto e o algoritmo de busca ROMP seja implementado na metodologia apresentada no Capítulo 3, substituindo o bloco de “Compressão com Perdas” da Figura 1.

8 CONCLUSÃO

O presente trabalho apresentou um sistema de compressão e descompressão de sinais elétricos (tensão e corrente) advindos de Sistemas de Potência, constituído por três níveis de compressão: a Detecção de Novidade; a Transformada Wavelet; e o algoritmo LZW. Os dois primeiros estágios são de compressão com perdas e o último de compressão sem perdas. A principal característica desse sistema é de ser capaz de armazenar os sinais por um longo período de tempo. Isto é possível devido à alta taxa de compressão obtida.

O sistema proposto é baseado no conceito de novidade, em que, o sinal é segmentado em *frames*, e apenas os *frames* que apresentarem novidade, ou seja, forem diferentes de um *frame* de referência necessitam ser armazenados, pois neles está contida a informação necessária para a reconstrução do sinal em todo o intervalo. Quando o sinal apresenta variação de frequência, a metodologia de reconstrução necessita também do valor da frequência de cada ciclo para gerar a forma de onda dos *frames* que não foram detectados. Portanto, esses valores também são armazenados.

O Detector de Novidade é a parte mais importante do sistema proposto, e uma das contribuições deste trabalho foi desenvolver um detector capaz de comparar dois *frames* do sinal e sinalizar se os mesmos apresentam alguma diferença em sua forma de onda, mas que ignore diferenças relativas à variações suaves na frequência do sinal. Foi utilizado então um detector baseado na diferença entre as energias dos frames que possui como estágio de entrada um filtro passa-altas que atenua o efeito da variação da frequência. Um segundo ramo do detector foi necessário para tornar possível a detecção de distúrbios como flicker e subarmônicos. Este segundo ramo é baseado na DFT e também auxilia na sinalização da presença de frequência variante.

Com respeito a detecção, o sistema é adequado para a aplicação em cenários de *smart grids*, haja visto sua habilidade de detectar qualquer variação no sinal, e não somente os distúrbios clássicos de QEE. Outro fato é que variações suaves na frequência do sinal não causam detecções, contribuindo assim para manter uma alta taxa de

compressão, já que os sinais advindos das redes possuem sempre variações suaves na frequência.

A Transformada Wavelet é aplicada nos *frames* que foram detectados para reduzir o número de informação a ser armazenada. Nesta etapa são mantidos apenas os coeficientes relevantes à reconstrução do sinal. Estes ainda são quantizados para diminuir o número de bits necessários para o armazenamento. O número de níveis de decomposição e a wavelet mãe utilizados, foram obtidos utilizando os critérios de entropia e MDL, respectivamente. Os coeficientes mantidos da wavelet e os valores das frequências são ainda comprimidos utilizando o algoritmo LZW.

Uma vantagem do sistema proposto é apresentar grande flexibilidade de implementação, visto que seus blocos principais funcionam de maneira independente, podendo ter seus algoritmos substituídos sem afetar o funcionamento global do sistema. Outra vantagem é que cada canal de aquisição funciona também de forma independente, sendo assim o sistema pode ser implementado facilmente com o número de canais adequado a aplicação.

O desempenho do sistema proposto foi testado e comparado com o desempenho de um equipamento comercial (Elspec G4000 BLACKBOX), que possui a mesma funcionalidade. Os resultados do sistema proposto são no mínimo equivalentes aos do Elspec, mostrando-se superior em alguns casos específicos, o que motiva a continuação da pesquisa e desenvolvimento do sistema.

O sistema proposto foi implementado em tempo real, em plataforma FPGA dando origem ao protótipo de um equipamento desenvolvido em parceria com a empresa KRON Medidores, o qual está patenteado e encontra-se em fase final de implementação para ser lançado no mercado. A versão implementada sofreu algumas simplificações dadas as restrições da plataforma utilizada e por isso seu desempenho não se equipara ao desempenho obtido com a utilização do sistema implementado offline e nem ao desempenho do Elspec. Uma nova versão deste protótipo esta sendo desenvolvida onde o sistema proposto será utilizado na sua versão completa.

Uma outra contribuição do trabalho foi o estudo e implementação de técnicas de representação esparsa em dicionários redundantes, para avaliar a possibilidade de substituir a utilização da Transformada Wavelet no bloco de Compressão com Perdas do sistema proposto. Um dicionário composto pela união de duas bases ortogonais (Wavelet e Fourier) foi utilizado e diversos algoritmos de busca foram implementados e seus desempenhos foram comparados quanto compressão e reconstrução dos principais

distúrbios de QEE.

O dicionário proposto foi pensado não somente para proporcionar uma elevada taxa de compressão e boa qualidade da reconstrução, mas também para permitir uma rápida execução dos algoritmos de busca, que dependem do número de elementos contidos no dicionário. Com a união das bases de Fourier e Wavelet conseguiu-se resultados interessantes, visto que o dicionário é composto por 612 elementos. Além disso, às principais características das duas bases são complementares, a base de Fourier representa bem, utilizando poucos elementos, os sinais estacionários no tempo enquanto que a base wavelet representa melhor os sinais transitórios. Com isso então, conseguiu-se uma boa qualidade da representação utilizando poucos elementos do dicionário.

Analisando os resultados obtidos percebeu-se que dentre os algoritmos testados o que se destacou foi o ROMP, principalmente quanto à convergência, já que o mesmo sempre convergiu para um resultado satisfatório com menos iterações do que os outros. Quando comparada com a utilização da Transformada Wavelet, o desempenho da técnica de representação esparsa utilizando o dicionário e o algoritmo ROMP, apresentou resultados satisfatórios, mostrando ser atrativo para aplicações de compressão de sinais elétricos, apesar de apresentar complexidade computacional mais elevada.

8.1 TRABALHOS FUTUROS

Como possíveis temas para futuros trabalhos baseados nessa pesquisa são sugeridos:

- i estudar métodos de segmentação adaptativa e seus impactos na Detecção de Novidades e na Compressão do Sinal;
- ii estudar uma maneira de melhorar a resolução em frequência do algoritmo de reconstrução dos sinais;
- iii implementar a técnica de representação esparsa em dicionários redundantes como parte do sistema de compressão proposto e avaliar o seu desempenho;
- iv utilizar a técnica de representação esparsa em dicionários redundantes não só para comprimir os sinais, mas também para detectar e classificar os distúrbios.

REFERÊNCIAS

- AHARON, M.; ELAD, M.; BRUCKSTEIN, A. K-svd: An algorithm for designing overcomplete dictionaries for sparse representation. *IEEE Transactions on Signal Processing*, IEEE, v. 54, n. 11, p. 4311–4322, 2006.
- ALTERA. *Cyclone IV Device Handbook*. [S.l.], 2010.
- AZAMI, H. et al. An intelligent approach for variable size segmentation of non-stationary signals. *Journal of Advanced Research*, Elsevier, 2014.
- BOLLEN, M. H.; GU, I. *Signal processing of power quality disturbances*. [S.l.]: John Wiley & Sons, 2006.
- CHANG, S. G.; YU, B.; VETTERLI, M. Adaptive wavelet thresholding for image denoising and compression. *IEEE Transactions on Image Processing*, IEEE, v. 9, n. 9, p. 1532–1546, 2000.
- CLIFTON, L. et al. Identification of patient deterioration in vital-sign data using one-class support vector machines. In: IEEE. *Federated Conference on Computer Science and Information Systems (FedCSIS)*. [S.l.], 2011. p. 125–131.
- COIFMAN, R. R.; WICKERHAUSER, M. V. Entropy-based algorithms for best basis selection. *IEEE Transactions on Information Theory*, IEEE, v. 38, n. 2, p. 713–718, 1992.
- DASH, P. et al. Power quality disturbance data compression, detection, and classification using integrated spline wavelet and s-transform. *IEEE Transactions on Power Delivery*, 2003. ISSN 0885-8977.
- DIEH, C. P.; HAMPSHIRE, J. B. et al. Real-time object classification and novelty detection for collaborative video surveillance. In: IEEE. *Proceedings of the 2002 International Joint Conference on Neural Networks. IJCNN'02*. [S.l.], 2002. v. 3, p. 2620–2625.
- DONNELLY, C.; STALLMAN, R. *Bison: The YACC-Compatible Parser Generator*. 2015. Disponível em: <<http://www.gnu.org/software/bison/>>.
- DONOHO, D. et al. Sparse solution of underdetermined systems of linear equations by stagewise orthogonal matching pursuit. *IEEE Transactions on Information Theory*, v. 58, n. 2, p. 1094–1121, Feb 2012. ISSN 0018-9448.
- DONOHO, D. et al. Data compression and harmonic analysis. *IEEE Transactions on Information Theory*, 1998. ISSN 0018-9448.
- DONOHO, D. L. De-noising by soft-thresholding. *IEEE Transactions on Information Theory*, IEEE, v. 41, n. 3, p. 613–627, 1995.

DONOHOU, D. L.; JOHNSTONE, I. M. Adapting to unknown smoothness via wavelet shrinkage. *Journal of the american statistical association*, Taylor & Francis Group, v. 90, n. 432, p. 1200–1224, 1995.

DONOHOU, D. L.; JOHNSTONE, J. M. Ideal spatial adaptation by wavelet shrinkage. *Biometrika*, Biometrika Trust, v. 81, n. 3, p. 425–455, 1994.

DUQUE, C. A. et al. Power quality event detection based on the divide and conquer principle and innovation concept. *IEEE Transactions on Power Delivery*, IEEE, v. 20, n. 4, p. 2361–2369, 2005.

ELAD, M. *Sparse and redundant representations: from theory to applications in signal and image processing*. [S.l.]: Springer, 2010.

ELSPEC, E. L. *Elspec G4000 BLACKBOX*. [S.l.], 2007.

ENGAN, K.; AASE, S. O.; HUSOY, J. H. Method of optimal directions for frame design. In: IEEE. *IEEE International Conference on Acoustics, Speech, and Signal Processing, 1999. Proceedings., 1999*. [S.l.], 1999. v. 5, p. 2443–2446.

FABRI, D. F. et al. Time-varying harmonic analyzer prototype. In: IEEE. *14th International Conference on Harmonics and Quality of Power (ICHQP), 2010*. [S.l.], 2010. p. 1–7.

FILHO, E. F. S.; SEIXAS, J. M.; CALÔBA, L. P. Optimized calorimeter signal compaction for an independent component based atlas electron/jet second-level trigger. *Proceedings of Science*, p. 1–10, 2009.

FORGY, E. W. Cluster analysis of multivariate data: efficiency versus interpretability of classifications. *Biometrics*, v. 21, p. 768–769, 1965.

GABOR, D. Theory of communication. part 1: The analysis of information. *Journal of the Institution of Electrical Engineers-Part III: Radio and Communication Engineering*, IET, v. 93, n. 26, p. 429–441, 1946.

GOODWIN, M.; VETTERLI, M. Matching pursuit and atomic signal models based on recursive filter banks. *IEEE Transactions on Signal Processing*, 1999. ISSN 1053-587X.

GRIBONVAL, R.; BACRY, E. Harmonic decomposition of audio signals with matching pursuit. *IEEE Transactions on Signal Processing*, 2003. ISSN 1053-587X.

HAMID, E.; KAWASAKI, Z.-I. Wavelet-based data compression of power system disturbances using the minimum description length criterion. *IEEE Transactions on Power Delivery*, 2002. ISSN 0885-8977.

HEYDT, G.; GUNTHER, E. Post-measurement processing of electric power quality data. *IEEE Transactions on Power Delivery*, 1996. ISSN 0885-8977.

HSIEH, C.; HUANG, S. Disturbance data compression of a power system using the huffman coding approach with wavelet transform enhancement. *IEE Proceedings-Generation, Transmission and Distribution*, 2003. ISSN 1350-2360.

- HUANG, K.; AVIYENTE, S. Sparse representation for signal classification. In: *Advances in neural information processing systems*. [S.l.: s.n.], 2006. p. 609–616.
- HUANG, S.-J.; JOU, M.-J. Application of arithmetic coding for electric power disturbance data compression with wavelet packet enhancement. *IEEE Transactions on Power Systems*, 2004. ISSN 0885-8950.
- IEEE1159. Ieee recommended practice for the transfer of power quality data. *IEEE Std 1159.3-2003*, 2004.
- INSTRUMENTS, T. *Tiva TM4C123GXL Microcontroller Datasheet*. [S.l.], 2013.
- JAGGI, S. et al. High resolution pursuit for feature extraction. *Applied and Computational Harmonic Analysis*, Elsevier, v. 5, n. 4, p. 428–449, 1998.
- JIE, G. Wavelet threshold de-noising of power quality signals. In: *Fifth International Conference on Natural Computation, 2009. ICNC '09*. [S.l.: s.n.], 2009. v. 6, p. 591–597.
- KAMAL, R. *Microcontrollers: Architecture, Programming, Interfacing and System Design*. [S.l.]: Pearson Education India, 2011.
- KAY, S. M. *Fundamentals of statistical signal processing: Detection theory, vol. 2*. [S.l.]: Prentice Hall Upper Saddle River, NJ, USA:, 1998.
- KRAUS, J.; TOBISKA, T.; BUBLA, V. Lossless encodings and compression algorithms applied on power quality datasets. In: *20th International Conference and Exhibition on Electricity Distribution - Part 1, 2009. CIRED 2009*. [S.l.: s.n.], 2009. ISSN 0537-9989.
- KREUTZ-DELGADO, K.; RAO, B. D. Focuss-based dictionary learning algorithms. In: INTERNATIONAL SOCIETY FOR OPTICS AND PHOTONICS. *International Symposium on Optical Science and Technology*. [S.l.], 2000. p. 459–473.
- KRIM, H. et al. On denoising and best signal representation. *IEEE Transactions on Information Theory*, 1999. ISSN 0018-9448.
- LEEUWEN, J. V. *Handbook of theoretical computer science: Algorithms and complexity*. [S.l.]: Elsevier, 1990.
- LESAGE, S. et al. Learning unions of orthonormal bases with thresholded singular value decomposition. In: IEEE. *IEEE International Conference on Acoustics, Speech, and Signal Processing, 2005. Proceedings.(ICASSP'05)*. [S.l.], 2005. v. 5, p. v–293.
- LEWICKI, M. S.; OLSHAUSEN, B. A. Probabilistic framework for the adaptation and comparison of image codes. *JOSA A*, Optical Society of America, v. 16, n. 7, p. 1587–1601, 1999.
- LITTLER, T.; MORROW, D. Wavelets for the analysis and compression of power system disturbances. *IEEE Transactions on Power Delivery*, 1999. ISSN 0885-8977.
- LORIO, F.; MAGNAGO, F. Analysis of data compression methods for power quality events. In: *Power Engineering Society General Meeting, 2004. IEEE*. [S.l.: s.n.], 2004.

LOVISOLO, L. et al. Efficient coherent adaptive representations of monitored electric signals in power systems using damped sinusoids. *IEEE Transactions on Signal Processing*, 2005. ISSN 1053-587X.

LOVISOLO, L. et al. Modeling of electric disturbance signals using damped sinusoids via atomic decompositions and its applications. *EURASIP Journal on Applied Signal Processing*, Hindawi Publishing Corp., v. 2007, n. 1, p. 168–168, 2007.

LUENBERGER, D. G.; YE, Y. *Linear and nonlinear programming*. [S.l.]: Springer Science & Business Media, 2008.

MAASS, H. et al. First evaluation results using the new electrical data recorder for power grid analysis. *IEEE Transactions on Instrumentation and Measurement*, 2013. ISSN 0018-9456.

MALLAT, S.; ZHANG, Z. Matching pursuits with time-frequency dictionaries. *IEEE Transactions on Signal Processing*, 1993. ISSN 1053-587X.

MARKOU, M.; SINGH, S. A neural network-based novelty detector for image sequence analysis. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE, v. 28, n. 10, p. 1664–1677, 2006.

MIHCAK, M. K. et al. Low-complexity image denoising based on statistical modeling of wavelet coefficients. *IEEE Signal Processing Letters*, IEEE, v. 6, n. 12, p. 300–303, 1999.

NANDI, U.; MANDAL, J. A compression technique based on optimality of lzw code (olzw). In: *Third International Conference on Computer and Communication Technology (ICCCCT), 2012*. [S.l.: s.n.], 2012. p. 166–170.

NASCIMENTO, F. Assis de O. Data compression algorithm for transient recording system. In: IEEE. *Proceedings of the IEEE International Symposium on Industrial Electronics, 1997. ISIE'97*. [S.l.], 1997. p. 1126–1130.

NEEDEL, D.; VERSHYNIN, R. Uniform uncertainty principle and signal recovery via regularized orthogonal matching pursuit. *Foundations of computational mathematics*, Springer, v. 9, n. 3, p. 317–334, 2009.

OLSHAUSEN, B. A.; FIELD, D. J. Sparse coding with an overcomplete basis set: A strategy employed by v1? *Vision research*, Elsevier, v. 37, n. 23, p. 3311–3325, 1997.

OMICRON. *Omicron CMC 256plus Brochure*. [S.l.], 2013.

PANDA, G. et al. Data compression of power quality events using the slantlet transform. *IEEE Transactions on Power Delivery*, 2002. ISSN 0885-8977.

PATI, Y.; REZAIIFAR, R.; KRISHNAPRASAD, P. Orthogonal matching pursuit: recursive function approximation with applications to wavelet decomposition. In: *Record of The Twenty-Seventh Asilomar Conference on Signals, Systems and Computers, 1993*. [S.l.: s.n.], 1993. ISSN 1058-6393.

PAXSON, V. *Flex, Version 2.5: A Fast Scanner Generator*. 2015. Disponível em: <<https://www.gnu.org/software/flex/>>.

- PILLAY, P.; BHATTACHARJEE, A. Application of wavelets to model short-term power system disturbances. *IEEE Transactions on Power Systems*, Nov 1996. ISSN 0885-8950.
- PIMENTEL, M. A. et al. A review of novelty detection. *Signal Processing*, Elsevier, v. 99, p. 215–249, 2014.
- QING, A. et al. A compression approach of power quality monitoring data based on two-dimension dct. In: *Third International Conference on Measuring Technology and Mechatronics Automation (ICMTMA), 2011*. [S.l.: s.n.], 2011.
- QUINN, J. A.; WILLIAMS, C. K. Known unknowns: Novelty detection in condition monitoring. In: *Pattern Recognition and Image Analysis*. [S.l.]: Springer, 2007. p. 1–6.
- RIBEIRO, M.; MITRA, S.; ROMANO, J. A novel approach for spectral analysis of monitored power systems. In: *11th International Conference on Harmonics and Quality of Power, 2004*. [S.l.: s.n.], 2004.
- RIBEIRO, M. et al. A novel mdl-based compression method for power quality applications. *IEEE Transactions on Power Delivery*, 2007. ISSN 0885-8977.
- RIBEIRO, M.; ROMANO, J. M. T.; DUQUE, C. An improved method for signal processing and compression in power quality evaluation. *IEEE Transactions on Power Delivery*, 2004. ISSN 0885-8977.
- RIBEIRO, P. F. et al. *Power systems signal processing for smart grids*. [S.l.]: John Wiley & Sons, 2013.
- SAITO, N. Simultaneous noise suppression and signal compression using a library of orthonormal bases and the minimum-description-length criterion. In: INTERNATIONAL SOCIETY FOR OPTICS AND PHOTONICS. *SPIE's International Symposium on Optical Engineering and Photonics in Aerospace Sensing*. [S.l.], 1994. p. 224–235.
- SANTOSO, S. et al. *Electrical power systems quality*. McGraw-Hill Professional, 2002.
- SANTOSO, S.; POWERS, E.; GRADY, W. Power quality disturbance data compression using wavelet transform methods. *IEEE Transactions on Power Delivery*, 1997. ISSN 0885-8977.
- SAYOOD, K. *Introduction to data compression*. [S.l.]: Newnes, 2012.
- STOCKWELL, R. G.; MANSINHA, L.; LOWE, R. P. Localization of the complex spectrum: the s transform. *IEEE Transactions on Signal Processing*, 1996. ISSN 1053-587X.
- SURACE, C.; WORDEN, K. Novelty detection in a changing environment: a negative selection approach. *Mechanical Systems and Signal Processing*, Elsevier, v. 24, n. 4, p. 1114–1128, 2010.
- TCHEOU, M. et al. The compression of electric signal waveforms for smart grids: State of the art and future trends. *IEEE Transactions on Smart Grid*, 2014. ISSN 1949-3053.

TCHEOU, M. P. et al. How far can one compress digital fault records? analysis of a matching pursuit-based algorithm. *Digital Signal Processing*, Elsevier, 2012.

VAN TREES, H. L. *Detection, estimation, and modulation theory*. [S.l.]: John Wiley & Sons, 2004.

VERA-CANDEAS, P. et al. Transient modeling by matching pursuits with a wavelet dictionary for parametric audio coding. *IEEE Signal Processing Letters*, 2004. ISSN 1070-9908.

WICKERHAUSER, M. V. Adapted wavelet analysis from theory to software. AK Peters Ltd., 1994.

ZHANG, D.; BI, Y.; ZHAO, J. A new data compression algorithm for power quality online monitoring. In: *International Conference on Sustainable Power Generation and Supply, 2009. SUPERGEN 09*. [S.l.: s.n.], 2009.

ZHANG, M.; LI, K.; HU, Y. A high efficient compression method for power quality applications. *IEEE Transactions on Instrumentation and Measurement*, 2011. ISSN 0018-9456.

ZHANG, Y.; MERATNIA, N.; HAVINGA, P. Outlier detection techniques for wireless sensor networks: A survey. *IEEE Communications Surveys & Tutorials*, IEEE, v. 12, n. 2, p. 159–170, 2010.

ZVANOVIC, R. et al. Identification of the resonant-grounded system parameters by evaluating fault measurement records. *IEEE Transactions on Power Delivery*, 2004. ISSN 0885-8977.

APÊNDICE A – TABELAS REFERENTES AOS RESULTADOS OBTIDOS NAS ANÁLISES REFERENTES À OBTENÇÃO DA MELHOR ÁRVORE DE DECOMPOSIÇÃO WAVELET

A.1 TABELAS UTILIZADAS NA ANÁLISE RELATIVA À ESCOLHA DO NÚMERO DE NÍVEIS DE DECOMPOSIÇÃO

Nesta Seção serão mostradas as tabelas relativas à análise realizada utilizando o critério da entropia descrito no Capítulo 4. As tabelas mostram o número ótimo de níveis de decomposição encontrado para cada wavelet mãe testada.

Tabela 11: Número de níveis de decomposição para wavelets mãe da família das Daubechies.

	db2	db3	db4	db5	db6	db7	db8	db9	db10
Transitórios	6	5	5	5	5	5	5	5	5
Notches	5	5	5	5	5	5	5	5	5
Harmonicos Estacionários	5	4	4	4	3	3	3	3	3
Harmonicos Variantes	5	5	5	5	5	5	5	5	5
Sag	5	5	5	5	5	5	5	5	5
Swell	4	5	5	5	5	5	5	5	5

Tabela 12: Número de níveis de decomposição para wavelets mãe da família das Symlets.

	sym2	sym3	sym4	sym5	sym6	sym7	sym8	sym9	sym10
Transitorios	6	5	5	5	5	5	5	5	6
Notches	5	5	5	5	5	5	5	5	5
Harmonicos Estacionários	5	4	4	4	4	4	3	3	3
Harmonicos Variantes	5	5	5	5	5	5	5	5	5
Sag	4	5	5	5	5	5	6	5	6
Swell	4	5	5	5	5	5	5	5	6

Tabela 13: Número de níveis de decomposição para wavelets mãe da família das Coiflets.

	coif1	coif2	coif3	coif4	coif5
Transitorios	5	5	5	5	5
Notches	5	5	5	5	5
Harmonicos Estacionários	4	4	3	3	3
Harmonicos Variantes	5	5	5	5	5
Sag	4	5	5	5	6
Swell	3	5	5	5	5

Tabela 14: Coiflets

Tabela 15: Número de níveis de decomposição para wavelets mãe da família das Biortogonais.

	bior1.1	bior1.3	bior1.5	bior2.2	bior2.4	bior2.6	bior2.8	bior3.1	bior3.3	bior3.5	bior3.7	bior3.9	bior4.4	bior5.5	bior6.8
Transitorios	6	5	5	6	5	5	5	6	5	5	5	5	5	5	5
Notches	6	5	5	5	5	5	5	5	5	5	5	5	5	5	5
Harmonicos Estacionários	5	4	3	4	4	4	3	5	4	4	4	4	4	4	3
Harmonicos Variantes	5	4	4	5	5	5	5	5	5	5	5	5	5	5	5
Sag	2	2	2	4	4	4	5	5	5	5	5	5	5	5	5
Swell	2	2	2	4	4	4	5	5	5	5	5	5	5	5	5

Tabela 16: Número de níveis de decomposição para wavelets mãe da família das Biortogonais Reversas.

	rbio1.1	rbio1.3	rbio1.5	rbio2.2	rbio2.4	rbio2.6	rbio2.8	rbio3.1	rbio3.3	rbio3.5	rbio3.7	rbio3.9	rbio4.4	rbio6.8
Transitorios	6	5	5	5	5	5	5	5	5	5	5	5	5	5
Notches	6	5	5	5	5	5	5	3	5	5	5	5	5	5
Harmonicos Estacionarios	5	4	4	4	4	4	3	4	3	3	3	3	4	4
Harmonicos Variantes	5	5	5	5	5	5	5	4	5	5	5	5	5	5
Sag	2	5	5	4	5	5	5	1	4	5	5	5	5	5
Swell	2	5	5	3	5	5	5	1	4	5	5	5	5	5

A.2 TABELAS UTILIZADAS NAS ANÁLISES RELATIVAS À ESCOLHA DA MELHOR WACELET MÃE

Nesta Seção serão mostradas as tabelas relativas às análises realizadas utilizando o critério MDL descrito no Capítulo 4.

As Tabelas 17 e 18 são relativas às wavelet mãe da família das Daubechies.

Tabela 17: Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Daubechies.

	db2	db3	db4	db5	db6	db7	db8	db9	db10
Transitorios	17.43	19.82	16.46	18.07	18.96	20.02	21.12	22.41	22.93
Notches	6.20	7.53	6.46	5.43	5.34	6.30	6.96	7.26	7.95
Harmonicos Estacionários	7.89	9.39	10.98	10.86	11.09	9.59	10.18	10.98	11.44
Harmonicos Variantes	15.32	17.37	18.95	21.32	20.96	19.13	20.31	21.16	22.21
Sag	12.67	13.07	10.63	11.49	12.04	13.44	14.07	15.04	15.92
Swell	13.04	13.97	11.46	11.76	12.73	13.99	14.71	15.79	17.06
Mean	12.09	13.53	12.49	13.15	13.52	13.74	14.56	15.44	16.25

Tabela 18: Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Daubechies.

	db2	db3	db4	db5	db6	db7	db8	db9	db10
Transitorios	0.999	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Notches	0.981	0.987	0.984	0.982	0.981	0.985	0.985	0.984	0.983
Harmonicos Estacionários	0.962	0.970	0.977	0.975	0.971	0.963	0.965	0.959	0.955
Harmonicos Variantes	0.995	0.997	0.998	0.998	0.998	0.995	0.996	0.995	0.996
Sag	0.999	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Swell	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Mean	0.989	0.992	0.993	0.992	0.992	0.990	0.991	0.989	0.989

As Tabelas 19 e 20 são relativas às wavelet mãe da família das Symlets.

Tabela 19: Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Symlets.

	sym2	sym3	sym4	sym5	sym6	sym7	sym8	sym9	sym10
Transitorios	17.45	19.21	16.84	17.37	19.10	19.88	20.50	21.34	21.39
Notches	6.46	6.83	8.68	6.37	5.62	6.29	6.59	6.74	7.80
Harmonicos Estacionários	7.79	9.50	9.13	9.90	9.53	10.66	10.04	10.92	11.12
Harmonicos Variantes	13.25	16.33	18.04	19.66	19.30	21.46	18.34	17.67	18.02
Sag	12.80	13.23	11.85	12.01	13.80	14.33	15.57	15.78	16.82
Swell	13.39	13.87	12.05	12.32	13.66	14.32	15.64	16.15	17.10
Mean	11.86	13.16	12.76	12.94	13.50	14.49	14.45	14.77	15.37

Tabela 20: Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Symlets.

	sym2	sym3	sym4	sym5	sym6	sym7	sym8	sym9	sym10
Transitorios	0.999	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Notches	0.982	0.986	0.986	0.986	0.983	0.986	0.986	0.986	0.986
Harmonicos Estacionários	0.967	0.965	0.964	0.974	0.966	0.973	0.961	0.967	0.966
Harmonicos Variantes	0.991	0.996	0.997	0.998	0.996	0.998	0.995	0.995	0.994
Sag	0.999	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Swell	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Mean	0.990	0.991	0.991	0.993	0.991	0.993	0.990	0.991	0.991

As Tabelas 21 e 22 são relativas às wavelet mãe da família das Coiflets.

Tabela 21: Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Coiflets.

	coif1	coif2	coif3	coif4	coif5
Transitorios	17.95	17.88	20.87	24.41	25.55
Notches	6.38	6.26	6.82	8.68	9.86
Harmonicos Estacionários	8.90	9.81	10.38	10.99	10.95
Harmonicos Variantes	13.86	19.30	20.48	20.76	20.42
Sag	13.36	13.06	15.65	19.59	21.26
Swell	13.73	13.71	16.33	20.25	22.10
Mean	12.36	13.34	15.09	17.45	18.36

Tabela 22: Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Coiflets.

	coif1	coif2	coif3	coif4	coif5
Transitorios	1.000	1.000	1.000	1.000	1.000
Notches	0.980	0.980	0.981	0.983	0.982
Harmonicos Estacionários	0.971	0.965	0.964	0.951	0.939
Harmonicos Variantes	0.992	0.995	0.995	0.991	0.989
Sag	1.000	1.000	1.000	1.000	1.000
Swell	1.000	1.000	1.000	1.000	1.000
Mean	0.990	0.990	0.990	0.987	0.985

As Tabelas 23 e 24 são relativas às wavelet mãe da família das Biortogonais.

Tabela 23: Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Biortogonais.

	bior1.1	bior1.3	bior1.5	bior2.2	bior2.4	bior2.6	bior2.8	bior3.1	bior3.3	bior3.5	bior3.7	bior3.9	bior4.4	bior5.5	bior6.8
Transitorios	11.53	12.25	13.08	17.58	19.32	22.01	24.65	13.07	14.93	18.10	19.84	22.98	16.52	17.69	21.92
Notches	8.67	9.38	9.38	11.07	7.85	8.15	8.67	24.65	25.71	15.75	6.79	8.12	15.41	6.35	6.54
Harmonicos Estacionários	7.67	8.18	8.29	12.30	11.18	10.79	10.85	21.73	20.43	21.68	16.91	17.89	10.49	9.24	10.40
Harmonicos Variantes	9.86	10.69	10.98	16.76	16.38	15.53	16.82	17.72	19.44	22.94	23.09	25.07	18.72	17.41	21.37
Sag	9.73	10.41	10.89	13.03	15.22	18.29	20.70	7.82	9.85	13.15	15.19	18.26	11.29	12.23	16.93
Swell	9.91	10.41	11.19	13.36	15.29	18.48	20.93	8.38	10.43	13.42	15.32	18.27	11.39	12.40	17.04
Mean	9.56	10.22	10.63	14.02	14.21	15.54	17.11	15.56	16.80	17.51	16.19	18.43	13.97	12.55	15.70

Tabela 24: Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Biortogonais.

	bior1.1	bior1.3	bior1.5	bior2.2	bior2.4	bior2.6	bior2.8	bior3.1	bior3.3	bior3.5	bior3.7	bior3.9	bior4.4	bior5.5	bior6.8
Transitorios	0.982	0.996	0.997	0.999	1.000	1.000	1.000	0.998	0.999	1.000	1.000	1.000	1.000	1.000	1.000
Notches	0.967	0.987	0.987	0.987	0.988	0.988	0.987	0.998	0.999	0.988	0.983	0.985	0.990	0.983	0.985
Harmonicos Estacionários	0.933	0.961	0.960	0.979	0.975	0.973	0.967	0.994	0.992	0.993	0.981	0.974	0.971	0.967	0.967
Harmonicos Variantes	0.969	0.988	0.990	0.996	0.997	0.995	0.995	0.997	0.998	0.999	0.999	0.999	0.998	0.996	0.996
Sag	0.984	0.999	0.999	0.999	1.000	1.000	1.000	0.997	0.999	1.000	1.000	1.000	1.000	1.000	1.000
Swell	0.984	0.999	0.999	1.000	1.000	1.000	1.000	0.998	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Mean	0.970	0.988	0.989	0.993	0.993	0.993	0.991	0.997	0.998	0.997	0.994	0.993	0.993	0.991	0.991

As Tabelas 25 e 26 são relativas às wavelet mãe da família das Biortogonais Reversas.

Tabela 25: Percentual de coeficientes necessários para reconstrução dos sinais utilizando wavelets mãe da família das Biortogonais Reversas.

	rbio1.1	rbio1.3	rbio1.5	rbio2.2	rbio2.4	rbio2.6	rbio2.8	rbio3.1	rbio3.3	rbio3.5	rbio3.7	rbio3.9	rbio4.4	rbio5.5	rbio6.8
Transitorios	11.69	19.80	17.89	17.77	18.50	21.37	22.49	9.27	22.05	20.04	21.98	23.75	18.85	20.49	22.63
Notches	8.01	9.64	5.03	6.51	8.63	5.77	6.58	8.68	7.98	8.72	6.43	7.34	7.11	7.35	6.67
Harmonicos Estacionários	7.45	9.19	9.74	7.32	8.19	8.10	8.22	5.33	6.55	6.72	6.95	7.27	9.63	10.20	9.08
Harmonicos Variantes	9.66	16.44	18.68	12.80	15.68	18.17	17.43	8.59	13.91	17.22	18.42	16.76	18.19	20.55	20.45
Sag	9.41	13.12	11.58	13.93	13.03	14.88	16.26	9.06	15.50	13.92	15.77	17.85	13.53	14.87	16.71
Swell	9.67	14.29	12.19	16.09	15.75	15.62	17.25	9.37	16.11	14.87	16.61	18.73	15.99	17.07	17.55
Mean	9.31	13.75	12.52	12.40	13.30	13.98	14.71	8.38	13.68	13.58	14.36	15.28	13.88	15.09	15.51

Tabela 26: Correlação entre o sinal original e o sinal reconstruído utilizando wavelets mãe da família das Biortogonais Reversas.

	rbio1.1	rbio1.3	rbio1.5	rbio2.2	rbio2.4	rbio2.6	rbio2.8	rbio3.1	rbio3.3	rbio3.5	rbio3.7	rbio3.9	rbio4.4	rbio5.5	rbio6.8
Transitorios	0.982	0.999	0.999	0.999	1.000	1.000	1.000	0.957	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Notches	0.962	0.983	0.964	0.981	0.987	0.974	0.980	0.967	0.987	0.988	0.981	0.983	0.985	0.985	0.983
Harmonicos Estacionários	0.929	0.964	0.962	0.949	0.952	0.944	0.942	0.753	0.943	0.939	0.928	0.920	0.967	0.970	0.952
Harmonicos Variantes	0.968	0.995	0.996	0.991	0.995	0.993	0.993	0.946	0.992	0.992	0.990	0.989	0.997	0.998	0.996
Sag	0.984	0.999	0.999	1.000	1.000	1.000	1.000	0.988	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Swell	0.984	1.000	0.999	1.000	1.000	1.000	1.000	0.991	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Mean	0.968	0.990	0.987	0.987	0.989	0.985	0.986	0.934	0.987	0.986	0.983	0.982	0.992	0.992	0.988

APÊNDICE B – DESCRIÇÃO DOS SINAIS UTILIZADOS NOS TESTES

Este apêndice apresenta a descrição detalhada dos sinais utilizados para os testes tanto do método proposto, online e offline, bem como do Elspec. Para gerar os sinais para os testes online, a fonte Omicron CMC-256-6 *plus* (OMICRON., 2013) foi utilizada. Essa fonte é utilizada para gerar sinais de tensão e/ou corrente, contendo distúrbios característicos de QEE e pode ser configurada para gerar uma sequência de estados, em que cada estado pode conter ou não um distúrbio. A Figura 58 mostra uma fonte Omicron CMC-256-6 *plus*.



Figura 58: Fonte Omicron modelo CMC-256-6 *plus*.

Para os estados que contém distúrbio, devem ser configurados os tempos de pré-evento, evento e pós-evento, sendo que o pré e o pós evento são constituídos de um sinal puramente senoidal de frequência e amplitudes fixas. Para os estados em que o sinal é puramente senoidal e durante os tempos de pré e pós-eventos, a amplitude é fixa em 180 V e a frequência em 60 Hz. Os valores de tensão mostrados em Volts (V) são valores de pico, os valores RMS são mostrados em V_{rms} .

B.1 CASO S1:

O sinal do Caso S1 é constituído por uma sequência de distúrbios descritos pelos estados mostrada na Tabela 27, que descreve a temporização de cada um dos estados, e como pode ser percebido a duração aproximada deste sinal é de 13 min. Os valores dos componentes que compõem o sinal em cada estado estão descritos abaixo.

Tabela 27: Descrição temporal do sinal do caso S1.

Estado	Descrição	Tempo (s)			
		Pré-Evento	Evento	Pós-Evento	Total
1	Senoidal				60
2	Afundamento	10	1	9	20
3	Elevação	10	1	9	20
4	Harmônicos Ímpares	10	120	10	140
5	Senoidal				60
6	Notches	10	20	10	40
7	Afundamento Rampa	10	5	10	25
8	Elevação Rampa	10	5	10	25
9	Senoidal				60
10	Harmônicos Pares	10	120	10	140
11	Senoidal				30
12	Interharmônico	10	120	10	140
13	Senoidal				30

Estado 1: Puramente senoidal.

Estado 2: Afundamento para 70.7 V

Estado 3: Elevação para 282.8 V

Estado 4: Harmônicos: $3^{\circ} = 5\%$, $5^{\circ} = 2\%$ e $7^{\circ} = 2\%$

Estado 5: Puramente senoidal.

Estado 6: Notches: Afundamentos periódicos de 30V, com duração de 2 ms e ângulo de início em 30°.

Estado 7: Afundamento em rampa para 70.7 V. Tempo das rampas de descida e subida igual a 2 s e tempo de permanência de 1 s.

Estado 8: Elevação em rampa para 282.8 V. Tempo das rampas de descida e subida igual a 2 s e tempo de permanência de 1 s.

Estado 9: Puramente senoidal.

Estado 10: Harmônicos: 2° = 5%, 4° = 3% e 6° = 2%

Estado 11: Puramente senoidal.

Estado 12: Interharmônico com frequência de 400 Hz e amplitude de 10 V

Estado 13: Puramente senoidal.

B.2 CASO S2:

O sinal do Caso S2 é constituído por um sinal senoidal que possui variações de amplitude em rampa, como mostrado na Tabela 28, que descreve a temporização de cada um dos estados, e como pode ser percebido a duração aproximada deste sinal é de 9.8 min. Os valores da amplitude do sinal estão descritos abaixo.

Tabela 28: Descrição temporal do sinal do caso S2.

Estado	Descrição	Tempo (s)			
		Pré-Evento	Evento	Pós-Evento	Total
1	Senoidal				40
2	Afundamento Rampa	20	300	20	340
3	Senoidal				10
4	Afundamento Rampa	10	150	10	170
5	Senoidal				30

Estado 1: Puramente senoidal.

Estado 2: Afundamento em rampa para 140.4 V. Tempo das rampas de descida e subida igual a 2 min e tempo de permanência de 1 min.

Estado 3: Puramente senoidal.

Estado 4: Afundamento em rampa para 140.4 V. Tempo das rampas de descida e subida igual a 1 min e tempo de permanência de 30 s.

B.3 CASO S3:

O sinal do Caso S3 é constituído por um sinal senoidal intercalado com um sinal que possui distorção harmônica, de acordo com a temporização mostrada na Tabela 29, e como pode ser percebido a duração aproximada deste sinal é de 10 min. Os valores dos componentes que compõem o sinal em cada estado estão descritos abaixo.

Tabela 29: Descrição temporal do sinal do caso S3.

Estado	Descrição	Tempo (s)			
		Pré-Evento	Evento	Pós-Evento	Total
1	Senoidal				60
2	Harmônicos Pares		120		120
3	Senoidal				60
4	Harmônicos Ímpares		120		120
5	Senoidal				60
6	Harmônicos Pares e Ímpares		120		120
7	Senoidal				60

Estado 1: Puramente senoidal.

Estado 2: Harmônicos: $2^{\circ} = 5\%$, $4^{\circ} = 4\%$, $6^{\circ} = 3\%$, $8^{\circ} = 2\%$ e $10^{\circ} = 1\%$

Estado 3: Puramente senoidal.

Estado 4: Harmônicos: $3^{\circ} = 5\%$, $5^{\circ} = 4\%$, $7^{\circ} = 3\%$, $9^{\circ} = 2\%$ e $11^{\circ} = 1\%$

Estado 5: Puramente senoidal.

Estado 6: Harmônicos: $2^{\circ} = 7\%$, $3^{\circ} = 5\%$, $5^{\circ} = 3\%$ e $7^{\circ} = 1\%$

Estado 7: Puramente senoidal.

B.4 CASO S4:

O sinal do Caso S4 consiste em um sinal puramente senoidal que possui amplitude e frequência variantes com o comportamento mostrado na Figura 59. A amplitude começa em 100 Vrms e sobe até 150 Vrms em degraus de 3.125 Vrms a cada 20 s e retorna da mesma forma para os 100 Vrms. A frequência varia da mesma forma começando em 59 Hz subindo até 61 Hz e retornando para 59 Hz.




Figura 59: Variação da amplitude e da frequência do sinal do Caso S4.

B.5 CASO S5:

O sinal do Caso S5 é um sinal puramente senoidal com amplitude fixa em 180 V e com a frequência variando como mostrado na Figura 60. A frequência parte do valor de 59 Hz sobe em degraus de 20.5 mHz a cada 20 ms, até atingir o valor de 61 Hz e retorna para o valor de 59 Hz, da mesma maneira. Esse comportamento é repetido várias vezes.




Figura 60: Variação da frequência do sinal do Caso S5.

APÊNDICE C – PRODUÇÃO BIBLIOGRÁFICA

C.1 ARTIGOS EM CONGRESSOS NACIONAIS

KAPISCH, Eder Barboza; Silva, Leandro R. M.; Martins, Carlos H. N.; Filho, Luciano M. de A.; Duque, Carlos A., “Implementação em FPGA de Transformada Wavelet para Compactação De Sinais Elétricos de Sistemas de Potência Utilizando Processador Embarcado”. Anais do XX Congresso Brasileiro de Automática (CBA), 2014, Belo Horizonte, Minas Gerais.

Resumo: Este trabalho tem como objetivo apresentar uma implementação da Transformada Wavelet em FPGA (*Field Programmable Gate Array*). Através dessa ferramenta, é possível a compactação rápida de sinais elétricos, suavizando ou realçando os detalhes dos mesmos. Além disso, compara-se essa ferramenta embarcada em processador com uma implementação direta, denominada de método paralelo, cujos diversos blocos lógicos compõem a estrutura não-processada. Essa comparação é feita considerando-se a quantidade de blocos lógicos utilizada e a velocidade despendida em cada caso. Um protótipo desenvolvido foi capaz de implementar os dois métodos e de realizar esta tarefa de compressão, na qual mais de 85% das amostras adquiridas a uma taxa de 7,68 kHz puderam ser substituídas por zero, mantendo-se mais de 99,9% da energia do sinal original. O erro na reconstrução limitou-se à ordem de $10^{-2}\%$.

C.2 ARTIGOS EM CONGRESSOS INTERNACIONAIS

KAPISCH, Eder Barboza; Silva, Leandro R. M.; Martins, Carlos H. N.; Barbosa, Alexander S.; Duque, Carlos A.; Filho, Luciano M. de A.; Cerqueira, Augusto S., “An Electrical Signal Disturbance Detector and Compressor Based on FPGA Platform”. Proceedings of the 16th IEEE International Conference on Harmonics and Quality of Power (ICHQP).

Abstract: This paper presents a prototype system used to detect and compress disturbances commonly found in electrical signal, on both voltage and current. The algorithm for detecting and compressing the disturbances are synthesized in FPGA

platform. The compression algorithm operates in three different stages: the innovation stage, the wavelet stage and the bit compression stage. These three stages provide efficient compression rate. Beside the algorithm description, the paper presents details of the hardware implementation and results obtained from synthesized and real signals.

SILVA, Leandro R. M.; Duque, Carlos A.; Ribeiro, Paulo F., “Recent Developments on Signal Processing for Smart Grids”. Power and Energy Society General Meeting 2015.

Abstract: with the growing complexity of the electric grid, signal processing has a fundamental importance in characterization, diagnoses and protection. In this paper a brief review of digital signal processing techniques will be done. These techniques are focused in power systems applications, such as: signal compression, harmonic estimation and characterization of load and generation profiles.

C.3 ARTIGOS ACEITOS PARA PUBLICAÇÃO EM PERIÓDICOS

SILVA, Leandro R. M.; Duque, Carlos A.; Ribeiro, Paulo F., “Smart Signal Processing for an Evolving Electric Grid”. EURASIP Journal on Advances in Signal Processing (2015).

Abstract: Electric grids are interconnected complex systems consisting of generation, transmission, distribution, and loads (consumers). Additionally, these encompass a vast array of equipment such as machines, power transformers, capacitor banks, power electronic devices, motors, etc., that are continuously evolving. In this context, the smart grid has contributed even further to the complexity and a better understanding of their operation is required. Given these conditions, signal processing is becoming an essential assessment tool to enable the engineer and researcher to understand, plan, design and operate the complex and smart electronic grid of the future. This paper focuses on recent developments associated with signal processing applied to power system analysis in terms of characterization and diagnostics. The following techniques are reviewed and their characteristics and applications discussed: active power system monitoring, sparse representation of power system signal, real-time resampling and time-frequency (i.e. wavelets) applied to power fluctuations.

KAPISCH, Eder Barboza; Silva, Leandro R. M.; Martins, Carlos H. N.; Barbosa, Alexander S.; Duque, Carlos A.; Filho, Luciano M. de A.; Tavi, Andres E.; de Souza, Luiz A. R., “An Implementation of a Power System Smart Data Recorder using FPGA and ARM cores”. Measurement, 2015.

Abstract: In this paper, the design and the prototype implementation of a power-quality (PQ) disturbance detector and compressor are described. This instrument, named Power System Smart Data Recorder (PSSDR), is able to acquire the samples of the power system signals and process them in order to detect the disturbances, compress the data and store it in an micro SD card, from which it can be reconstructed and analyzed offline with a suitable computer application. It uses, among other devices, Field Programmable Gate Array (FPGA) and ARM platforms to work with the electrical power system signals in a smart way. Algorithms of Digital Signal Processing with a high level of complexity are implemented in a low cost and small FPGA chip due the utilization of an embedded processor, developed for this purpose, which can be programmed by customized compilers that use Assembly language and an subset of the C language.

SILVA, Leandro R. M.; Kapisch, Eder Barboza; Martins, Carlos H. N.; Filho, Luciano M. de A.; Cerqueira, A. S.; Duque, Carlos A.; “A Gapless Power Quality Disturbance Recorder”. IEEE Transactions on Power Delivery, 2016.

Abstract: This paper presents a Gapless Power Quality Disturbance Recorder based on the concept of novelty detection. Initially, the signal is divided into disjoint and sequential frames and the difference of the energies is used to compare the actual frame with the previously stored reference frame. If the current frame is different from the reference frame, according a previously setup threshold, it will be stored, becoming the new reference frame; otherwise the frame is discarded and only the information of the frequency of fundamental component is stored to allow the offline reconstruction of the entire signal. The new detector is insensitive to slow variations in the frequency of the fundamental component, which can increase the compression ratio. The novelty frames are processed using DWT in order to generate a sparse signal and thus further increase the compression ratio. Finally, all the information is concatenated and a lossless compressor runs. The paper describes the whole process of detection and compression and compares the performance of the proposed method with the one obtained by a commercial Power Quality Data Recorder. Also some prototype implementation details are presented.

C.4 PATENTES

KAPISCH, Eder Barboza; Silva, Leandro R. M.; Martins, Carlos H. N.; Duque, Carlos A.; Filho, Luciano M. de A.; Cerqueira, Augusto S., “Registrador Eficiente De Distúrbios Elétricos”, 2014, Brasil.

Resumo: A presente invenção diz respeito à descrição de um sistema utilizado para detectar distúrbios em sinais elétricos (tanto na corrente, quanto na tensão) e compactar de maneira eficiente estes distúrbios. O sistema utiliza técnicas de detecção, compactação de distúrbio e hardware reconfigurável para implementar os algoritmos de processamento digital de sinais. Além disso, aplica simultaneamente três conceitos fundamentais, o que lhe confere eficiência para registrar e compactar os distúrbios de sinais elétricos em tempo real: (a) detecção utilizando o conceito de novidade e limites adaptativos; (b) Compactação do sinal em 3 níveis; (c) utilização de hardware reconfigurável em FPGA (*Field-Programmable Gate Array*), onde além de sintetizar máquinas de estados de dimensão finitas, são implementados processadores customizados para tarefas específicas do sistema.