

UNIVERSIDADE FEDERAL DE JUIZ DE FORA
PROGRAMA DE PÓS-GRADUAÇÃO EM
ENGENHARIA ELÉTRICA

Tiago Motta Quirino

**Aprendizado *Online* de Redes Neurais Artificiais Aplicadas à Reconstrução de Energia
no Calorímetro Hadrônico do ATLAS**

Juiz de Fora
2022

Tiago Motta Quirino

**Aprendizado *Online* de Redes Neurais Artificiais Aplicadas à Reconstrução de Energia
no Calorímetro Hadrônico do ATLAS**

Exame de Qualificação apresentado ao
Programa de Pós-graduação em Engenharia
Elétrica, área de concentração: Sistemas
Eletrônicos, da Faculdade de Engenharia da
Universidade Federal de Juiz de Fora como
requisito parcial à obtenção do grau de Doutor.

Orientador: Prof. Luciano Manhães de Andrade Filho, D.Sc.

Juiz de Fora

2022

Tiago Motta Quirino

**Aprendizado online de redes neurais artificiais aplicadas à reconstrução de energia no calorímetro
hadrônico do ATLAS**

Tese apresentada ao
Programa de Pós-
Graduação de Engenharia
Elétrica da Universidade
Federal de Juiz de Fora
como requisito parcial à
obtenção do título de
Doutor em Engenharia
Elétrica. Área de
concentração: Sistemas
Eletrônicos

Aprovada em 15 de dezembro de 2022.

BANCA EXAMINADORA

Prof. Dr. Luciano de Manhães Andrade Filho - Orientador

Universidade Federal de Juiz de Fora

Prof. Dr. Eduardo Pestana de Aguiar

Universidade Federal de Juiz de Fora

Prof. Dr. Leandro Rodrigues Manso Silva

Universidade Federal de Juiz de Fora

Prof. Dr. Jorge Luís Machado do Amaral

Pontifícia Universidade Católica do Rio de Janeiro

Prof. Dr. Bernardo Sotto Maior Peralva

Universidade do Estado do Rio de Janeiro

Juiz de Fora, 21/11/2022.



Documento assinado eletronicamente por **Bernardo Sotto-Maior Peralva, Usuário Externo**, em 15/12/2022, às 12:03, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Luciano Manhaes de Andrade Filho, Professor(a)**, em 15/12/2022, às 13:07, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Leandro Rodrigues Manso Silva, Professor(a)**, em 15/12/2022, às 13:23, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Jorge Luís Machado do Amaral, Usuário Externo**, em 15/12/2022, às 14:44, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Eduardo Pestana de Aguiar, Professor(a)**, em 15/12/2022, às 15:17, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



A autenticidade deste documento pode ser conferida no Portal do SEI-Ufjf (www2.ufjf.br/SEI) através do ícone Conferência de Documentos, informando o código verificador **1046674** e o código CRC **9DA07AFF**.

Agradecimentos

A Deus por ter me guiado e me enchido de sentido e esperança, quando os meus próprios falharam.

À minha esposa Nainalisa Sousa da Veiga Quirino, que ouviu novas ideias sem mesmo entender, colaborou como pode de forma ativa, mas superou as expectativas na paciência, pois apoiou este trabalho na distância, frustração e abdicação pessoal.

Aos meus pais Eliezer Quirino, Lilian Motta e Dalva Margareth, meus irmãos Jonatas Quirino e Lília Quirino, que se mantiveram ao meu lado, mesmo com o excesso de drama do último minuto e emoções fortes na expectativa dos resultados. Devo muito daquilo que conquistei a minha família, pois sem eles não conseguiria nem começar a minha carreira acadêmica.

Agradeço também meus cunhados Hellen Teixeira Barbosa Quirino e Raphael Athayde, bem como minha sogra Maria Marta Gomes de Sousa, que sempre mostraram carinho e compreensão para mim.

Aos meus amigos que pacientemente ouviram as novas ideias e descobertas, participando comigo do crescimento, corrigiram textos e fizeram críticas. Em especial meu grande amigo Filipe Costa Machado, Marcos Guilherme, Calos Filho, Victor Hugo, Caio Cesar, Pedro Macedo e Pedro Lisboa. Também agradeço meu amigo Jorge, por quem tenho muito respeito e apreço, pelas orientações e indicações que me forneceu, bem como os momentos descontraídos.

Aos meus professores da UFJF, e de maneira muito especial meu orientador, Prof. Luciano Manhães de Andrade Filho pelo auxílio, companheirismo, amizade e as performances musicais que fizeram parte das nossas trocas.

"Ao escrever o meu pensamento, ele às vezes me escapa; mas, isso me faz lembrar-me da minha fraqueza, que a todo instante esqueço; isso me instrui tanto quanto o meu pensamento esquecido, pois minha tendência consiste apenas em conhecer o meu nada".

(Blaise Pascal)

Resumo

A tarefa principal desenvolvida neste trabalho é a de recuperar informações de partículas subatômicas incidentes em calorímetros. Especificamente, trata-se os sinais da eletrônica de leitura do TileCal, o calorímetro hadrônico instalado no ATLAS, que por sua vez, é um dos principais experimentos do maior e mais potente colisionador de partículas construído, o LHC (*Large Hadron Collider*). Há um planejamento de atualizações do LHC que considera o aumento da luminosidade, havendo maior probabilidade de colisões de partículas em intervalos fixos e definidos de tempo, o que, no contexto do tempo de resposta do TileCal, ocasiona o efeito de empilhamento dos sinais, prejudicando a estimação da amplitude deles, grandeza essa que está relacionada à energia das partículas detectadas. Sugere-se o aprendizado online de Redes Neurais Artificiais, devido às não-linearidades intrínsecas do canal de leitura, para estimação de energia em condições de alta luminosidade, comparando seu desempenho a métodos lineares. Para tanto, aproveita-se o sistema de seleção de eventos do ATLAS, que consiste no conhecimento especialista do sinal de aceitação no primeiro nível de trigger (L1A), que discrimina os dados válidos para serem armazenados, ou os dados descartados, e assim possibilita a aplicação ou aprendizado online da Rede Neural Artificial, respectivamente. O aprendizado é definido pela simulação de um sinal central de amplitude conhecida, somado aos sinais ordinários que caracterizam o efeito empilhamento. Logo, com os padrões de empilhamento aprendidos, os mesmos podem ser retirados do sinal, recuperando a amplitude de sinais de interesse na etapa de aplicação da Rede Neural Artificial. A eficiência do método proposto apresenta resultados competitivos em relação aos métodos utilizados no contexto de recuperação de energia do calorímetro hadrônico do ATLAS.

LISTA DE ILUSTRAÇÕES

FIGURA 1 – REPRESENTAÇÃO DOS ELEMENTOS DO MODELO PADRÃO DE PARTÍCULAS.	18
FIGURA 2 – O LHC, SEUS DETECTORES E A SEDE DO CERN.	19
FIGURA 3 – CRONOGRAMA DE ATUALIZAÇÕES DO LHC.	21
FIGURA 4 – DETECTOR ATLAS E SEUS SUBDETECTORES.	23
FIGURA 5 – CORTE TRANSVERSAL DOS SUBDETECTORES DO ATLAS EM CAMADAS.	24
FIGURA 6 – PERSPECTIVA DAS CAMADAS DO ATLAS.	24
FIGURA 7 – MÓDULO DO TILECAL	26
FIGURA 8 – REPRESENTAÇÃO DO PROCESSO DA ELETRÔNICA DE LEITURA NO TILECAL.	26
FIGURA 9 – FORMA DE PULSO DO TILECAL E AMPLITUDE DE ENERGIA DEPOSITADA NA CÉLULA.	27
FIGURA 10 – FORMA DO PULSO DE REFERÊNCIA DO TILECAL COMPARADA A DADOS REAIS.	28
FIGURA 11 – ARQUITETURA ATUAL DA ELETRÔNICA DE LEITURA DO TILECAL.	28
FIGURA 12 – ELETRÔNICA DE LEITURA DO TILECAL ATUALIZADA PARA A FASE II.	30
FIGURA 13 – VISÃO ESQUEMÁTICA DO SISTEMA DE <i>TRIGGER</i> E AQUISIÇÃO DE DADOS DA FASE I.	31
FIGURA 14 – FLUXOGRAMA DO <i>TRIGGER</i> DA FASE I.	33
FIGURA 15 – FLUXOGRAMA DO <i>TRIGGER</i> DA FASE II.	35
FIGURA 16 – REPRESENTAÇÃO DE EMPILHAMENTO DO SINAL NO TILECAL.	37
FIGURA 17 – RUÍDO SIMULADO NAS CÉLULAS DO TILECAL EM FUNÇÃO DO NÚMERO MÉDIO DE INTERAÇÕES POR CRUZAMENTO DE FEIXES.	39
FIGURA 18 – FLUXO DA SIMULAÇÃO COMPLETA DO ATLAS.	40
FIGURA 19 – FLUXOGRAMA DA SIMULAÇÃO TMC, COM EXEMPLO.	44
FIGURA 20 – FLUXOGRAMA DE PROCESSAMENTO E ARMAZENAMENTO DE DADOS <i>ONLINE</i>	46

FIGURA 21 – DIFERENÇA ENTRE OS PROCEDIMENTOS DE DECONVOLUÇÃO E RECONSTRUÇÃO DE ENERGIA.	48
FIGURA 22 – MODELO DO CANAL DESCONHECIDO DO TILECAL E FILTRO DE ESTIMAÇÃO DE ENERGIA.	48
FIGURA 23 – MODELO DO CANAL DESCONHECIDO DO TILECAL E FILTRO DE ESTIMAÇÃO DE ENERGIA.	52
FIGURA 24 – ESTIMAÇÃO DA ENERGIA POR REPRESENTAÇÃO ESPARSA PELA FUNÇÃO SHRINKAGE.....	59
FIGURA 25 – MODELO DE EQUALIZAÇÃO CEGA POR TEORIA DA ESPARSIDADE.	59
FIGURA 26 – FILTRO FIR (A) E FILTRO NEURAL (B) EM APLICAÇÃO <i>ONLINE</i>	61
FIGURA 27 – PERFORMANCE DA BUSCA EXAUSTIVA DA CONFIGURAÇÃO DA RNA.....	62
FIGURA 28 – REDE NEURAL COM RESPOSTA FINITA AO IMPULSO.	63
FIGURA 29 – COMPARAÇÃO DOS COEFICIENTES DO FILTRO FIR E DE UM NEURÔNIO DA RNA.	64
FIGURA 30 – MAPEAMENTO DE ENTRADA E SAÍDA DE CADA NEURÔNIO.	64
FIGURA 31 – MODELO DE TREINAMENTO E APLICAÇÃO <i>ONLINE</i> DO FILTRO NEURAL PARA RECONSTRUÇÃO DE ENERGIA.	68
FIGURA 32 – GERAÇÃO DO RUÍDO ELETRÔNICO PARA FORMAÇÃO DO BANCO DE DADOS DE TESTE.....	78
FIGURA 33 – DISTRIBUIÇÕES DE DADOS DA DEPOSIÇÃO DE ENERGIA PARA O BANCO DE DADOS DE TESTE.....	80
FIGURA 34 – EXEMPLOS DOS SINAIS DE DEPOSIÇÃO DE ENERGIA DO BANCO DE DADOS PARA TESTE.....	80
FIGURA 35 – DISTRIBUIÇÕES DE DADOS DO SINAL MEDIDO PARA FORMAÇÃO DO BANCO DE DADOS DE TESTE.....	81
FIGURA 36 – EXEMPLOS DOS SINAIS DE DEPOSIÇÃO DE ENERGIA PARA BANCO DE DADOS DE TESTE.....	82
FIGURA 37 – EXEMPLO DO SINAL DE ENERGIA GERADO <i>ONLINE</i> PELO SIMULADOR.	83
FIGURA 38 – EXEMPLO DOS VALORES DE MEDIÇÃO GERADOS <i>ONLINE</i> PELO SIMULADOR.	84
FIGURA 39 – DISTRIBUIÇÕES DE PROBABILIDADE DE $y + y$ POR OCUPAÇÃO.	85

FIGURA 40 – EXEMPLOS DAS SOMAS $y + y$ POR OCUPAÇÃO.	85
FIGURA 41 – RELAÇÃO DA OCUPAÇÃO DO CANAL COM A RAZÃO SINAL RUÍDO.	87
FIGURA 42 – RELAÇÃO DA OCUPAÇÃO DO CANAL COM O DESVIO PADRÃO DO SINAL.	87
FIGURA 43 – DEFINIÇÃO DOS INTERVALOS DE OCUPAÇÃO PARA O CONJUNTO DE TREINAMENTO.	89
FIGURA 44 – PROCEDIMENTO DE EXPERIMENTO DO MÉTODO.	90
FIGURA 45 – AVALIAÇÃO DOS MÉTODOS DE RECONSTRUÇÃO DE ENERGIA.	91
FIGURA 46 – AVALIAÇÃO DOS MÉTODOS DE DECONVOLUÇÃO.	93

SUMÁRIO

1 INTRODUÇÃO	12
1.1 Motivação	12
1.2 Objetivos.....	15
1.3 Principais Contribuições.....	16
1.4 Organização do Texto	17
2 AMBIENTE DE EXPERIMENTAÇÃO DE FÍSICA DE PARTÍCULAS	18
2.1 O LHC	19
2.2 Plano de atualizações do LHC.....	21
2.3 O experimento ATLAS	22
2.3.1 Calorimetria Hadrônica do ATLAS	25
2.3.2 Sistema de Seleção e Aquisição de Dados	31
2.4 Efeito <i>Pile-Up</i>	36
2.5 Simulação do Sinal	40
2.6 Conclusões Parciais do Capítulo	44
3 PROCESSAMENTO DE SINAIS NO TILECAL.....	46
3.1 Filtros de Reconstrução de Energia no Sistema de Leitura	48
3.1.1 Filtro Ótimo	49
3.1.2 Filtro de Wiener.....	50
3.2 Filtros de Deconvolução no Primeiro nível de Trigger	52
3.2.1 Aproximação do Sistema Inverso.....	53
3.2.2 Filtro de Mínimos Quadrados.....	55
3.2.3 Filtro Adaptativo Bussgang-Sparse	56
3.2.4 Filtro Neural	60
3.3 Conclusões Parciais do Capítulo	65
4 MÉTODO PROPOSTO.....	66
4.1 Filtro Neural Aplicado ao Método Bussgang-Sparse	66
4.2 Método de Parametrização Online do Filtro Neural.....	67
4.2.1 Aprendizado Contínuo.....	69
4.2.2 Adição de Ruído ao Conjunto de Treinamento	71
4.2.3 Técnicas de Generalização de Redes Neurais Artificiais	72
4.2.4 Estimação do Canal de Medição	75
4.3 Conclusões Parciais do Capítulo	76
5 RESULTADOS	77
5.1 Banco de Dados.....	77
5.2 Dados Simulados <i>Online</i>	82

5.3 Análise dos Dados	86
5.3.1 Divergência dos Dados Simulados <i>Online</i> com banco de Dados.....	86
5.3.2 Razão Sinal Ruído	86
5.3.3 Desvio Padrão do Sinal	87
5.4 Medidas de Desempenho.....	88
5.5 Procedimento do Experimento e Avaliação do Método Proposto.....	88
5.7 Conclusões Parciais do Capítulo	94
6 CONCLUSÃO.....	95
6.1 Trabalhos Futuros	96
7 BIBLIOGRAFIA	98
APÊNDICE A – Produção Bibliográfica.....	104

1 INTRODUÇÃO

Existe amplo interesse na medição apurada das grandezas para monitoramento ou controle dos processos físicos. Isso estimula o desenvolvimento de sistemas de instrumentação eletrônica e processamento de sinais. Nos sistemas de instrumentação eletrônica mais modernos há predominância de processamento digital de sinais. Nesses sistemas, os transdutores convertem as grandezas físicas em sinais elétricos, que por sua vez são condicionados para níveis de amplitude e faixa de frequências controlados por circuitos de condicionamento, para serem digitalizados por conversores analógico-digitais (ADC, do inglês *analog-digital converter*) e, assim, ser realizada a aquisição dos sinais, seguida, por fim, do processamento de dados para extração dos parâmetros relacionados à grandeza física de interesse.

Em algumas aplicações, muitos canais de medição, com alta taxa de aquisição, são utilizados. Nesse contexto é quase inevitável que os sinais relevantes estejam misturados a sinais desprezíveis, pois podem ocorrer interferência eletromagnética, cross-talk, ruído térmico etc. Para evitar a quantidade de informação armazenada e o excesso de processamento de sinais, também se utiliza, nos sistemas de instrumentação, o sistema de seleção de amostras (ou sistema de *trigger*).

1.1 Motivação

Muitas limitações tecnológicas das áreas de instrumentação eletrônica e processamento digital de sinais têm sido superadas graças aos esforços empregados em ambientes de experimentação de física de altas energias. Isso, devido às complexas exigências impostas ao sistema de instrumentação, por utilizar altas taxas de operação e quantidade extensiva de canais de sensores. Para tanto, técnicas sofisticadas de processamento e seleção de sinais são implementadas nos equipamentos dos colisionadores.

Os colisores de partículas são projetados para acelerar feixes de partículas a alta velocidade e a elevados níveis de energia, para colidirem em um alvo fixo ou com outros feixes. Nos locais onde ocorrem as colisões são instalados experimentos com várias camadas de sensores para medir as interações ocasionadas pelas novas partículas que surgem após as colisões.

O Grande Colisionador de Hádrons (LHC do inglês *Large Hádron Collider*) foi elaborado pelo CERN (Centro Europeu de Pesquisa Nuclear, do francês, *Conseil Européen pour la Recherche Nucléaire*), com intuito de pesquisar a constituição da matéria. É o acelerador de partículas que, nos últimos anos, tem permitido as mais novas descobertas das propriedades de partículas fundamentais, além de ter possibilitado a descoberta efetiva da partícula Bóson de Higgs, que levou ao prêmio Nobel de Física em 2013.

No LHC dois feixes de prótons são acelerados em sentidos contrários para colidirem entre si a uma taxa de 40MHz, ou 40 milhões de cruzamento de feixes por segundo (BC, do inglês *Bunch Crossing*). Em uma das regiões de colisão se encontra o experimento de interesse neste trabalho, o ATLAS (*A Toroidal LHC ApparatuS*).

Há um sistema de calorimetria no ATLAS que é fundamental para o estudo da física de partículas, pois por ele observa-se o padrão espacial de depósito de energia das partículas subatômicas oriundas das colisões. Tal padrão de deposição reflete o processo de decaimento de partículas fundamentais, em outras mais estáveis, à medida que elas penetram no material do calorímetro. Entender este processo é de suma importância para o estudo das partículas fundamentais e das forças de interação entre elas.

Os pulsos elétricos oriundos dos sensores dos calorímetros possuem a amplitude proporcional à energia depositada, mas são condicionados em uma forma específica no canal de medição, que é referido como pulso característico do canal (denominado aqui por $h[n]$). Por isso, deve ser realizado o processamento digital desses sinais, de forma a reconstruir a energia depositada nas células, através de um processo de estimação da amplitude destes pulsos.

No processo de digitalização dos sinais, a taxa de amostragem é síncrona ao *clock* do LHC, que é correspondente a taxa de cruzamento de feixes, logo considera-se o período de 25 ns. Por outro lado, o pulso característico do canal possui duração maior que o período de *clock* do LHC, pois há um compromisso de projeto entre a duração do pulso e a quantidade de amostras sequenciais de digitalização. A maior quantidade de amostras torna a reconstrução de energia mais eficiente. No entanto, quanto mais amostras, maior o tempo de processamento, acarretando, também, uma maior possibilidade de sobreposição de sinais. Especificamente, o circuito de condicionamento do calorímetro em estudo foi projetado para representar o pulso característico, com duração de sete amostras, síncronas ao *clock* do LHC, configurando 150 ns para medição da deposição de energia.

O fato de o período de medição ser maior que o intervalo mínimo entre eventos não caracterizou um problema nas operações iniciais do LHC, pois a probabilidade de medições consecutivas era pequena, em consequência do baixo valor do parâmetro Luminosidade, que é um grau de concentração de prótons nos feixes para colisão.

As atualizações previstas ao LHC visam aumentar a luminosidade do colisionador de forma a aumentar a probabilidade de colisão de partículas no mesmo encontro de feixes. Neste novo contexto, ainda não comum a calorimetria, evidencia-se a discrepância dos intervalos de cada medição e das colisões, aumentando a probabilidade do empilhamento ou sobreposição de sinais (do inglês, *pile-up*).

Uma consideração importante é que apenas algumas amostras são selecionadas para reconstrução de energia, pois nem todas as medições carregam informações interessantes à análise física. Para essa tarefa, o ATLAS conta com um sistema de seleção de dados dividido em dois níveis de *trigger*. O primeiro nível de *trigger* utiliza informação de padrões espaciais de deposição de energia para avaliar as colisões que são consideradas relevantes e consequentemente ativar o comando L1A (do inglês, *Level 1 Acceptance*), para que assim a próxima camada do sistema de *trigger* (o *trigger* de alto nível, do inglês *High Level Trigger* – HLT) possa decidir mais criteriosamente quanto ao armazenamento permanente ou não.

Quando o sinal L1A é ativado, no primeiro nível de *trigger*, o sistema de aquisição de dados do calorímetro deve recortar uma janela de 7 amostras sequenciais de conversão do ADC (em cada um dos milhares de canais do calorímetro), para que possa ser realizada uma estimativa da amplitude do pulso contido nesta janela e cujo pico é localizado na amostra central (quarta amostra). No entanto, para o cenário de alta luminosidade previsto, a operação dos algoritmos convencionais de estimativa de amplitude se torna subótima na presença de *pile-up*, pois eles se fundamentam no modelo em que um único pulso, de formato determinístico, é imerso em ruído eletrônico gaussiano, o que deixa de ser realidade por ocasião do *pile-up*.

Considerando uma mesma janela, definida pelo L1A, as amostras adjacentes à amostra central de interesse são interpretadas como ruído não gaussiano, fortemente correlacionado à amostra central. Tais características do ruído originado pelo *pile-up* fazem surgir componentes de não lineares nas medições, por isso, os métodos lineares de estimativa operam de forma sub-ótima na presença *pile-up*.

Foram projetados, em trabalhos anteriores, filtros fundamentados em Redes Neurais Artificiais (RNA), referidos como filtros neurais, pois elas são capazes de realizar a estimativa

não-linear, e assim indiretamente acessar a informação da estatística de ordem superior do ruído, voltando a realizar uma estimação ótima de amplitude da energia depositada, o que não era considerado em nenhum dos métodos antecessores.

O método dos filtros neurais exige dados de aprendizado com padrões de empilhamento conhecidos previamente. Então, para treinamento da RNA foram utilizados dados fornecidos por uma simulação *Toy Monte Carlo* (TMC) do calorímetro. No entanto, tal simulação não apresenta garantias de representar adequadamente o efeito de empilhamento, por se tratar de um ambiente de experimentação ainda desconhecido, consequentemente os dados estatísticos ainda não estão disponíveis para confirmação do modelo. Isso faz surgir certa objeção na utilização de RNA no calorímetro do ATLAS, apesar do seu desempenho em simulação demonstrar maior eficiência quando comparado aos métodos baseados em filtros lineares.

1.2 Objetivos

Diante do desafio apresentado pelo efeito de empilhamento de sinais e a carência de métodos convencionados para sua solução, propõe-se a utilização de RNA para a estimação da amplitude da energia depositada no calorímetro hadrônico do ATLAS, considerando o aprendizado *online*. Tal método, deve utilizar amostras reais com as características de empilhamento, para treinamento, ou seja, dados coletados durante o tempo de execução. Desta maneira busca-se proporcionar maior confiança na utilização de RNA em calorimetria.

O método proposto consiste na utilização do conhecimento especialista do sistema de *trigger* pelo comando L1A, de forma a aumentar a capacidade de generalização do filtro neural. Em eventos nos quais este comando não é ativado, está caracterizada a presença apenas de ruído de fundo nas amostras temporais digitalizadas. Em outras palavras, não há um sinal de interesse na amostra central da janela de leitura, contendo apenas ruído com dois componentes: o ruído eletrônico; e os sinais de interações físicas irrelevantes que caracterizam o empilhamento. Os sinais rejeitados pelo L1A são antes combinados a um pulso simulado, com uma amplitude de energia conhecida, para aprendizado do filtro neural. Quando o comando L1A seleciona algum sinal, o aprendizado é interrompido e o filtro neural é utilizado para reconstrução da energia (estimação da amplitude da amostra central), com os parâmetros que foram ajustados durante o aprendizado.

1.3 Principais Contribuições

Inicialmente, foram estudados métodos de processamento de sinais para aumentar a eficiência na geração do comando L1A, pelo primeiro nível de *trigger*, no cenário de *pile-up* elevado. Para tal, propôs-se, a utilização de métodos neurais de deconvolução não supervisionados, no intuito de remover, sequencialmente, o empilhamento causado pelo canal do calorímetro.

O pré-processamento por deconvolução tem por objetivo a identificação correta da janela com deposição de energia, sem implementar qualquer tipo de *trigger*, mas permitir um maior desempenho do sistema de *trigger* na identificação dos eventos de interesse, assim, atinge-se maior assertividade ao sistema na geração do comando L1A.

Foi estudada a implementação computacional de um algoritmo de aprendizado *online* do filtro neural que utiliza o conhecimento especialista do L1A, este se propõe a aumentar a eficiência no processo de reconstrução da energia em ambiente de alto *pile-up*. O método proposto apresenta resultados melhores que os métodos de filtros lineares, mas, como esperado, não supera o filtro neural supervisionado, treinado com dados do simulador, pois os dados de teste também são gerados pelo mesmo simulador, o que caracteriza tendência nos resultados. Portanto, graças ao trabalho realizado nesta tese, o filtro neural com aprendizado *online*, pode considerar o ruído real, aumentar a capacidade de generalização e é factível para reconstrução de energia *online* em calorimetria.

A dificuldade de acesso aos dados pela utilização de uma plataforma própria do CERN impediu testes com dados reais nesta tese. Por isso, um simulador foi desenvolvido para este trabalho e os testes do método proposto foram realizados utilizando-se tal simulador, além de ser desenvolvido o arcabouço teórico-matemático para utilização do método.

Portanto, algumas contribuições alcançadas neste trabalho podem ser ressaltadas:

- Aperfeiçoamento de um simulador *toy* Monte Carlo dos canais de medição do calorímetro hadrônico do experimento ATLAS.
- Desenvolvimento de um método de parametrização de filtros utilizando o paradigma do aprendizado contínuo;
- Generalização no aprendizado e regularização da complexidade de redes neurais artificiais pela adição de ruído ao conjunto de dados;
- Desdobramento de um filtro neural aplicável nos contextos de reconstrução de energia e deconvolução dos sinais oriundos dos canais do TileCal;

- Aumento da capacidade de generalização de Redes Neurais Artificiais aplicadas nos contextos de reconstrução de energia e deconvolução;

1.4 Organização do Texto

O capítulo 2 é empregado para apresentar o ambiente de experimentação de física de partículas e assim ser possível a contextualização dos sistemas de calorimetria do ATLAS, em um panorama geral. O sistema de seleção de eventos do ATLAS é apresentado para explicação mais profunda do sinal de comando L1A, assim como as técnicas de simulação do ATLAS, que inspira o simulador *Toy Monte Carlo*, utilizado neste trabalho, para geração de dados *online*. Também é apresentada a questão do *pile-up*, que compõe a problematização que motiva esse trabalho.

No capítulo 3 é realizada uma revisão do estado da arte das técnicas relacionadas a técnica proposta neste texto. Aquelas técnicas que possuam bom desempenho são apresentadas, para serem tomadas como referência comparativa.

O capítulo 4 é dedicado a apresentação da técnica proposta, bem como os conceitos que fundamentam a sua utilização, seguido dos resultados parciais para comprovação do desempenho da técnica.

No capítulo 5 são apresentadas as características dos dados gerados pelos simuladores, bem como as discussões sobre os resultados parciais e os conceitos propostos.


As sugestões de propostas futuras são elencadas no capítulo 6, a partir do estudo bibliográfico realizado para elaboração deste texto.

Finalmente, no capítulo 7, são apresentados os comentários sobre os resultados e os métodos implementados, com um cronograma de planejamento para execução das próximas tarefas.

2 AMBIENTE DE EXPERIMENTAÇÃO DE FÍSICA DE PARTÍCULAS

Descobrir a estrutura fundamental da matéria tem sido uma tarefa importante para a ciência. Os pressupostos das partículas fundamentais evoluíram a partir do conceito inicial do átomo, que não é uma partícula fundamental, por ter sido descoberto que os átomos são formados por elétrons, prótons e nêutrons. Por sua vez, essas ainda não são as partículas elementares, pois são formadas por partículas menores ainda, a saber, os quarks, léptons e os bósons (GAGNON, 2016), que então definem a estrutura da matéria, conforme o modelo padrão de partículas apresentado na Figura 1.

Figura 1 – Representação dos elementos do Modelo Padrão de Partículas.



Fonte: GAGNON, 2016


A detecção das partículas fundamentais depende da utilização de colisionadores, em que esses fornecem energia a partículas estáveis (geralmente elétrons e prótons), acelerando-as em rota de colisão. As colisões são realizadas com o intuito de dividi-las nas partículas fundamentais, e, então, são finalmente medidas por sistemas de instrumentação eletrônica instalados em detectores de partículas (ANDRADE FILHO, 2009). O principal colisionador de partículas é o LHC, o qual tem colaborado com a confirmação experimental das partículas teorizadas pelo modelo padrão, sendo o único colisionador que permitiu a observação do Bóson de Higgs (CERN, 2013), partícula responsável por gerar a massa das outras partículas.

Nesse sentido, em relação ao objetivo desse trabalho, são descritos o LHC e o seu plano de atualizações, descrevendo também o detector ATLAS e os subsistemas relevantes. Apresenta-se ainda o efeito *pile-up* nos canais de medição, o qual surge diante das atualizações do LHC. Por fim, são descritas as técnicas de simulação de *pile-up*.

2.1 O LHC

O colisionador de partículas com maior capacidade energética e de maiores dimensões do mundo é o LHC, capaz de acelerar, colidir e então fissionar prótons extraídos de átomos de hidrogênio. Os prótons são um tipo de hádron, o que inspirou o nome do colisionador. O LHC foi adicionado ao complexo de aceleradores do CERN em 2008, na região de fronteira franco-suíça, conforme apresentado na Figura 2. O CERN é uma organização internacional cuja principal proposta é a compreensão da matéria, e que graças a implementação do LHC alavancou tal investigação.

Figura 2 – O LHC, seus detectores e a sede do CERN.



Fonte: HAFFNER, 2013

O LHC possui o formato de um anel circular com aproximadamente 27 km de circunferência, onde feixes de prótons circulam no sentido horário e anti-horário em dois tubos distintos. Cada feixe atinge a energia de $6,5 \text{ TeV}$ e é possível gerar o entrelcho dos feixes em momentos e posições específicas atribuindo a energia total de colisão igual a 13 TeV (CERN, 2018). Os níveis de energia são elevados, pois quanto maior a energia

concedida às partículas, maior se torna a eficiência de geração das partículas que se deseja estudar (FERREIRA, 2009).

São quatro pontos de colisão no LHC onde estão posicionados os detectores que recolhem informações provenientes das colisões, a saber: O ALICE (*A Large Ion Collider Experiment*) é o detector destinado para o estudo de íons pesados; o LHCb (*Large Hadron Collider beauty experiment for precision measurements of CP-violation and rare decays*) é designado principalmente para estudo do desbalanceamento entre matéria e antimatéria presentes no universo visível; os detectores CMS (*Compact Muon Solenoid*) e ATLAS (*A Toroidal LHC Apparatus*) possuem propósito geral (CERN, 2014), ou seja, foram projetados para uma ampla gama de estudos em física de partículas.

A trajetória circular do feixe de partículas é sustentada por eletroímãs de supercondutores. Além disso, eles possuem a função de aumentar a concentração do feixe de partículas em uma área de seção transversal. O aumento da densidade dos feixes de partículas em entrecchoque aumenta a probabilidade de eventos de colisão, esse parâmetro é definido como a luminosidade ($\mathcal{L}$), utilizado para análise de desempenho dos aceleradores de partículas, regido pela Equação 1 (CERN, 2019). Sendo n_{bunch} a quantidade de prótons dos dois feixes contrapostos, Δt_c o tempo da colisão e S_c a área da seção transversal da região de colisão (CLEMENT e KLIMEK, 2011).

$$\mathcal{L} \approx \frac{n_{bunch}^2}{\Delta t_c \cdot S_c} \quad (1)$$

A taxa média de colisões por cruzamento (μ) é a média probabilística da taxa de ocorrência de colisões, logo, possui uma relação diretamente proporcional à luminosidade, conforme a Equação 2. Onde S_{inel} denota a área da seção transversal não elástica próton-próton ($S_{inel} = 71,5 \text{ mb}$) e f_r representa a frequência de revolução do LHC, que é de 40 MHz (NOVAKOVA, 2013).


$$\mu = \frac{\mathcal{L} \cdot S_{inel}}{n_{bunch} \cdot f_r} \quad (2)$$

Conforme será apresentado no plano de atualizações, ocorrerão modificações significativas nos valores de luminosidade do LHC, o que exigirá a atualização de diversos componentes do equipamento.

2.2 Plano de atualizações do LHC

Um panorama geral das atualizações no LHC é apresentado para contextualização do ambiente em que este trabalho se desenvolve, conforme o plano de atualizações dos experimentos definido pelo CERN e apresentado na Figura 3 (CERN, 2019).

Figura 3 – Cronograma de atualizações do LHC.



Fonte: CERN, 2019.

Nos anos iniciais de utilização do LHC, 2011 e 2012, não foi utilizada toda a energia que o sistema seria capaz de oferecer, assim como não foi fornecida a luminosidade máxima do sistema. Na primeira rodada de experimentos (*Run 1*) as colisões são quantificadas por $7\sim 8\text{ TeV}$ de energia, utilizando 75% da luminosidade instantânea projetada para o equipamento, o que em termos numéricos significa a luminosidade de $0,75 \cdot 10^{34} \text{ cm}^{-2} \text{ s}^{-1}$ na *Run 1*, acarretando a quantidade média de colisões por cruzamento entre 0 e 12 (ATLAS, 2011).

Aprimoramentos iniciais foram realizados na primeira parada (do inglês *Long Shutdown* - LS1) do LHC, entre 2013 e 2015. A partir de meados de 2015, executou-se a segunda rodada de experimentos (*Run 2*) encerrada no final de 2018. A *Run 2* foi caracterizada pela energia das colisões de 13 TeV e com aumento progressivo da luminosidade instantânea até o valor de $2 \cdot 10^{34} \text{ cm}^{-2} \text{ s}^{-1}$. Na *Run 2* o valor de projeto da luminosidade foi ultrapassado alcançando o dobro do projetado. Por isso observou-se a taxa média de colisões por cruzamento no intervalo de 25 a 50 (ATLAS, 2011).

A segunda parada do LHC (LS2) começou em 2019, marcando o início do período da fase I do LHC, e tratou principalmente das atualizações nos detectores ALICE, LHCb, CMS e

ATLAS. A terceira execução de experimentos (*Run 3*) iniciou-se em junho de 2022 com energia de 14 TeV. A luminosidade instantânea será mantida em $2 \cdot 10^{34} \text{ cm}^{-2}\text{s}^{-1}$, isso pelo excelente desempenho do acelerador, permitindo alcançar a taxa média de colisões por cruzamento na faixa de 55 a 80 (ATLAS, 2011).

A terceira parada (LS3), planejada para iniciar em 2024, pretende atualizar todos os sistemas do LHC para um aumento significativo da luminosidade, caracterizando a fase II do LHC. Isso se deve ao fato do conselho do CERN decidir explorar completamente o potencial físico do LHC. As implementações de atualização para aumento da luminosidade do equipamento converterão o LHC em HL-LHC (*High Luminosity Large Hadron Collider*) para produzir maior taxa de eventos, e assim, mais dados experimentais permitirão a observação de processos raros. A luminosidade instantânea estimada é de até $7,5 \cdot 10^{34} \text{ cm}^{-2}\text{s}^{-1}$, no contexto da fase II, e, portanto, há expectativa da taxa média de colisões por cruzamento inicial ser de 140, podendo chegar até 200 em rodadas sucessivas (ATLAS, 2019).

As rodadas de experimento são discriminadas na tabela 1 com os respectivos parâmetros de interesse, ressaltando o aumento da taxa média de colisões por cruzamento em cada período.

Rodada	$\sqrt{s}$	Luminosidade Máxima	Colisões por Cruzamento
<i>Run 1</i>	8 TeV	$0,75 \cdot 10^{34} \text{ cm}^{-2}\text{s}^{-1}$	0 - 12
<i>Run 2</i>	13 TeV	$2 \cdot 10^{34} \text{ cm}^{-2}\text{s}^{-1}$	25 - 50
<i>Run 3</i>	13 - 14 TeV	$2,5 \cdot 10^{34} \text{ cm}^{-2}\text{s}^{-1}$	55 - 80
<i>Run 4+</i>	14 TeV	$5 \cdot 10^{34} - 7,5 \cdot 10^{34} \text{ cm}^{-2}\text{s}^{-1}$	140 - 200

Tabela 1 – Características de funcionamento do LHC por período.

Fonte: ATLAS, 2018b adaptado.

2.3 O experimento ATLAS


O tratamento dos dados oriundos do detector ATLAS é o interesse neste trabalho, por isso são apresentados os sistemas que influenciam os dados que se deseja adquirir e processar. Sendo também descrito o problema previsto no sistema de medição do detector.

O ATLAS é o maior dos quatro detectores, em termos de dimensões, com 44 metros de comprimento e 25 metros de diâmetro, como ilustrado na Figura 4. O detector foi projetado para medir a maior quantidade possível de fenômenos físicos das colisões do LHC, e caracterizar as propriedades resultantes das colisões e os seus decaimentos, a saber: constantes

de massa, rotação, paridade e acoplamento do bóson de Higgs; partículas supersimétricas; partículas constituintes da matéria escura; escala de energia eletrofraca; novos cenários com assinaturas muito inclusivas; evidências da física além do modelo padrão; e investigação de novos bósons (CERN, 2019).

Tanto o CMS quanto o ATLAS possuem os mesmos objetivos, mas utilizam tecnologias diferentes, pois assim, a coincidência de resultados em ambos os experimentos reduz a possibilidade de conclusões equivocadas sobre as descobertas.

Figura 4 – Detector ATLAS e seus subdetectores.




Fonte: PEQUENAO, 2008a

Os subsistemas de detecção do ATLAS são dispostos em camadas cilíndricas, conforme representado no corte transversal da Figura 5, referidos como: o detector de trajetórias (do inglês, *Inner Detector*); o calorímetro eletromagnético ou LAr (do inglês *LiquidArgon* – Argônio Líquido); o calorímetro hadrônico ou Tilecal (do inglês *Tile Calorimeter* – Calorímetro de Telhas); e o espectrômetro de múons (ATLAS, 2008).


Por outra perspectiva mais simplificada é possível visualizar as camadas do ATLAS e as partículas que podem ser identificadas em cada camada, conforme a Figura 6.

Figura 5 – Corte transversal dos subdetectores do ATLAS em camadas.



Fonte: PEQUENAO, 2008b.

Figura 6 – Perspectiva das camadas do ATLAS.



Fonte: LENGU, 2010.

Dentre todos os subsistemas do ATLAS, o interesse específico neste trabalho é o processamento de dados do Tilecal, por tanto aprofundam-se suas características. As informações sobre as outras camadas de detecção do ATLAS podem ser encontradas no relatório de projeto técnico produzido pela colaboração do ATLAS (2008).

2.3.1 Calorimetria Hadrônica do ATLAS

Na física de partículas, os calorímetros são utilizados para absorção e amostragem da energia de partículas incidentes. Quanto maiores forem os níveis de energia, maior é a resolução intrínseca dos calorímetros, situação na qual o LHC se enquadra, por utilizar níveis de energia que alcançam até 14TeV (GALLART, 1998).


Os calorímetros são compostos por blocos de material pesado. Estes devem ser espessos o suficiente para que a partir de uma partícula primária seja formado um chuveiro até a deposição total da sua energia no detector, como os chuveiros representados na Figura 6. A possibilidade de segmentar os calorímetros na distribuição de várias células, é uma das vantagens dos calorímetros, pois permite caracterizar o formato geométrico da deposição energética, o que auxilia na identificação da partícula (FERBEL, 2003).

No ATLAS, os calorímetros são estruturados pela técnica de amostragem, consistindo em intercalar material passivo que absorve a energia e material ativo para medição de energia. A maior parte da energia é dissipada na forma de calor no material passivo, mas uma fração de energia é detectada pelo material ativo, permitindo a estimativa energética da partícula original (GALLART, 1998).

O Tilecal é o calorímetro do ATLAS que interage com os hádrons resultantes das colisões, ou seja, píons, nêutrons e prótons, as partículas que estão sob ação da interação forte (FERBEL, 2003). A interação ocorre pela técnica de amostragem por coleção de luz, por isso o calorímetro é formado de aço, como o material passivo, intercalado com o material ativo, que são telhas cintiladoras de plástico, que por sua vez são acopladas a fotomultiplicadores para medição da luz (do inglês, PMTs – *Photomultipliers*) (GALLART, 1998).

A estrutura altamente periódica do sistema permite a construção de um grande detector montando submódulos menores (GALLART, 1998), apresentado na Figura 7. O número de cintiladores é elevado e a leitura é realizada por fibras de deslocamento de comprimento de onda (do inglês *Wavelength-Shifting* – WLS). Estas percorrem e coletam os dados de grupos de cintiladores, formando assim células de leitura. A quantidade de células foi projetada para garantir um rendimento suficiente de luz, bem como, para fornecer redundância, o que pode ser necessário durante o longo período esperado de funcionamento do experimento ATLAS (ATLAS, 2018b).

Figura 7 – Módulo do Tilecal




Fonte: ATLAS, 2018b

São aproximadamente 10.000 canais de medição da luz produzida nos cintiladores (HENRIQUES, 2015), em que cada canal possui um circuito de processamento para detecção da luz e conversão em sinal elétrico.

Os circuitos eletrônicos de leitura serão abordados mais profundamente em seguida, estes condicionam e digitalizam os sinais elétricos de forma a possuir amplitude proporcional à energia medida, conforme o processo apresentado na Figura 8.

Figura 8 – Representação do processo da eletrônica de leitura no TileCal.




Fonte: O Próprio Autor.

Ressalta-se que há um alargamento do pulso pelos componentes de leitura, e idealmente o evento de deposição de energia pela colisão poderia ser aproximado a um impulso discreto, cuja amplitude varia conforme a energia depositada. O sinal resultante da leitura é apresentado em preto, na Figura 9, e o sinal que representa a energia depositada é representado em vermelho. É possível a amostragem do sinal condicionado por 7 amostras,

que são síncronas aos BCs, sabendo-se que o período de amostragem do sistema é de 25ns , logo, a janela de medição é de 150ns (PERALVA, 2013).

Figura 9 – Forma de pulso do Tilecal e amplitude de energia depositada na célula.




Fonte: SÁNCHEZ, 2010.

É importante ressaltar que, utilizando diferentes técnicas, os canais de medição do TileCal são continuamente monitorados e calibrados mantendo a estabilidade da forma do pulso. Por essa razão, as formas dos pulsos em cada canal não apresentam deformações significativas entre si, conforme se representa na Figura 10. Nesta Figura, o pulso de referência, fornecido por um canal calibrado é comparado a dados reais de um canal na parte superior, e o erro relativo padrão é apresentado na parte inferior (PERALVA, 2015). A estabilidade dos pulsos é de suma importância no contexto da proposta inicial desta tese, pois garante que as incertezas geradas no processo de treinamento *online*, que será aqui proposto, está preponderantemente nas características da estatística de empilhamento e não na forma do pulso do calorímetro em si.

Existe interesse no aprofundamento dos circuitos que condicionam e digitalizam o sinal, portanto dedica-se a seção seguinte para apresentação dos componentes da cadeia eletrônica do TileCal, bem como as atualizações planejadas para tais circuitos.

Figura 10 – Forma do pulso de referência do TileCal comparada a dados reais.




Fonte: PERALVA, 2015.

2.3.1.1 Eletrônica de Leitura do TileCal até a fase I

A cadeia eletrônica do TileCal é dividida em eletrônica de *front-end* (FE), ou *on-detector*, e eletrônica de *back-end* (BE), ou *off-detector*. Na arquitetura atual, apresentada na Figura 11, a eletrônica de FE foi projetada para processar dados na taxa de operação do LHC em 40MHz, enquanto a eletrônica de BE pode realizar o processamento na taxa de *trigger* de 100kHz (PERALVA, 2010), sendo esta, a taxa média de eventos aceitos pelo primeiro nível, através do acionamento do comando L1A.

Figura 11 – Arquitetura atual da eletrônica de leitura do TileCal.



Fonte: YUE, 2019.

O primeiro elemento da eletrônica de FE é o PMT, que fornece um sinal elétrico proporcional à intensidade da luz à placa *3-in-1*, que, por sua vez, possui as funções de

condicionar o sinal, amplificá-lo e realizar a soma analógica do sinal de entrada. A soma analógica é útil para validação da detecção de eventos no primeiro nível de *trigger* (CERQUEIRA, 2005). Por isso, a placa é composta por um circuito de conformação ao pulso de referência, que foi apresentado na Figura 8; um circuito amplificador bi-ganho (*low-gain* e *high-gain*); e um circuito somador analógico, que formam torres *trigger* enviadas para o nível 1 do sistema de *trigger*, como será abordado em seguida (YUE, 2019).

O sinal *low-gain* funciona como *backup* do sinal *high-gain*, estes são enviados para placas digitalizadoras, que são equipadas com ADCs para digitalizar os pulsos com o período de amostragem de 25ns. Apenas no caso do sinal *high-gain* saturar o ADC utiliza-se o sinal *low-gain*. O sinal digitalizado é armazenado por memórias *pipeline* que dependem de um sinal de *trigger* (L1A) para serem recortados e enviados aos circuitos consecutivos (PERALVA, 2010).

Os sinais recortados são transmitidos para a Placa de Interface, onde os dados são compactados, formatados e transmitidos aos RODs (*Read-Out Drivers*) na eletrônica de BE. As placas RODs são o núcleo do sistema de aquisição de dados, pois realizam a conexão entre os detectores e o sistema de leitura para a multiplexação e formatação dos dados da FE, bem como, distribuição do sinal TTC (*Timing, Trigger and Control*), que por sua vez sincroniza os subdetectores aos cruzamentos de feixes (FARIA, 2017).


Além disso, a reconstrução de energia (estimação das amplitudes dos pulsos) é realizada por algoritmos em execução *online* nas placas RODs. Para tanto, duas placas FPGA recebem e encaminham os dados para as respectivas unidades de processamento (*Processing Units* – PUs), em que cada PU contém dois processadores digitais de sinais (*Digital Signal Processors* – DSPs), capazes de executar os algoritmos de reconstrução *online* de energia (VALERO et al., 2007; CARRIÓ et al., 2013).

Os circuitos da eletrônica de leitura do TileCal apresentados na Figura 11 foram projetados há aproximadamente 25 anos e por isso apresentam limitações tecnológicas relativas à disponibilidade da época (YUE, 2019), o que incita a modernização do sistema.

2.3.1.2 Eletrônica de Leitura do TileCal na fase II

O plano de atualizações para fase II prevê a substituição dos circuitos de leitura do TileCal para torná-los mais tolerantes a alta radiação; aumentar a precisão dos dados; melhorar os conectores; e adequar as fontes de energia às novas exigências de potência (CERQUEIRA, 2015). A Figura 12 apresenta a arquitetura eletrônica projetada para fase II.

Figura 12 – Eletrônica de leitura do TileCal atualizada para a fase II.



Fonte: YUE, 2019.

Similarmente ao circuito eletrônico atual do TileCal, na nova arquitetura o sinal elétrico oriundo da PMT é enviado à *front-end board 3-in-1*, que é uma placa totalmente baseada no sistema atual, com apenas modificações do ganho e sem a necessidade de formação do sinal de torres de *trigger* (ATLAS, 2017).

A placa consecutiva no fluxo de processamento é a *mainboard* (placa-mãe) que digitaliza os sinais de 12 placas *3-in-1* e roteia os dados para a *daughterboard* (placa-filha). Por sua vez, as *daughterboards* formatam e enviam os dados para a eletrônica de BE via conexões óticas redundantes (YUE, 2019).

A estratégia da nova arquitetura é transferir os dados digitalizados continuamente para o módulo da eletrônica de BE, aumentando a taxa de operação dos módulos de 100kHz para 40MHz. Isso exige a substituição da placa ROD pela placa TilePPr (*Tile PreProcessor*) (ATLAS, 2017), que nos outros subdetectores e em projetos anteriores do TileCal era nomeado como super ROD (sROD) (CARRIO, 2014).

Nessa proposta, as funcionalidades originais da placa ROD são mantidas, implementadas também em FPGA. Por isso, a placa TilePPr continua executando algoritmos de reconstrução *online* de energia, o que interessa neste trabalho. Ao mesmo tempo em que os algoritmos são executados, os dados oriundos da eletrônica de FE são armazenados em uma memória *pipeline*, aguardando o sinal de aceitação (L1A) que avalia a relevância de armazenamento permanente dos dados. Em paralelo, a placa TilePPr realiza o pré-processamento de sinais de *trigger*, enviados por meio do módulo TDAQi (*Trigger and Data Acquisition Interface*), que por sua vez adequa o formato dos sinais entre os módulos (ZAKAREISHVILI, 2020).

Em resumo, além das tarefas pré-definidas em fases anteriores, como a de estimar a amplitude dos sinais recortados pelo primeiro nível, este sistema agora tem também a finalidade de fazer uma estimativa inicial da medida de energia em cada colisão (a cada 25ns), para que esta informação seja utilizada pelo primeiro nível no auxílio da geração do

sinal L1A. A estimativa da energia no primeiro nível é um tema abordado nesta tese e alguns resultados a esse respeito também são apresentados nos próximos capítulos.

Os dados classificados como relevantes são aceitos pelo sistema de *trigger* e então são enviados a rede de dados FELIX (*Front End Link eXchange*), proposta para a fase II, com o objetivo de agregação e armazenamento de eventos, via o módulo TDAQi (YUE, 2019).

2.3.2 Sistema de Seleção e Aquisição de Dados


A taxa de colisão de partículas no LHC é muito elevada e são vários canais de medição no detector ATLAS o que gera uma elevada quantidade de dados, exigindo assim um tamanho de memória impraticável para registrar todas as amostras. No entanto, nem todos os dados medidos são relevantes para descrição dos fenômenos físicos, por isso, um sistema de seleção de eventos *online* ou *trigger* é combinado ao sistema de armazenamento de dados no ATLAS, formando o TDAQ (do inglês *Trigger and Data Acquisition*) (PERALVA, 2010).

O TDAQ é um sistema dividido em níveis para armazenamento de milhares de eventos por segundo dentre os milhões de eventos obtidos por segundo. Ocorre a discriminação *online* das amostras de *bunch-crossings* e naquelas em que existem maior probabilidade de caracterizar uma partícula é atribuído um identificador (BCID) (PASTORE, 2016).

O sistema TDAQ do ATLAS possui um plano de atualizações correspondente à modernização do LHC, para adequação aos novos requisitos do experimento. Interessa as atualizações do TDAQ para a fase I e fase II do LHC, pois tratam um contexto de luminosidade elevada, o que aumenta o número de dados processados pelo TDAQ em duas ordens de magnitude (SANCHES, 2019), e, portanto, exigem soluções correspondentes.

A Figura 13 apresenta a visão geral do TDAQ, relativo a *Run 2*, cujo escopo é idêntico à fase I. São utilizadas informações oriundas da eletrônica de FE dos calorímetros hadrônico e eletromagnético, combinadas às informações originadas pela eletrônicas de FE do espectrômetro de múons para que o sistema de *trigger* possa atuar e realizar a discriminação de dados no ATLAS.

Figura 13 – Visão esquemática do sistema de *trigger* e aquisição de dados da fase I.



Fonte: VAZQUEZ, 2017.

2.3.2.1 Panorama do TDAQ na fase I

A segunda grande parada do LHC (LS2), iniciada em 2019, abrangeu a fase I de atualização do sistema TDAQ do ATLAS. O projeto de atualização consta do tratamento da luminosidade de $\mathcal{L} \simeq 2 - 3 \cdot 10^{34} \text{ cm}^{-2} \text{ s}^{-1}$ com colisões por cruzamento de feixes de $\mu = 80$, previstas para *Run 3*.

Neste contexto, o TDAQ é dividido em dois níveis, tanto no sistema de *trigger*, quanto no sistema de aquisição de dados, que possuem implementações correspondentes, pois o primeiro nível é implementado em *hardware* e o segundo nível é implementado em *software*, para ambos os casos.

Os dados são detectados com a frequência de 40MHz, que pela atuação do *trigger* no primeiro nível (*Level 1 Accept – L1A*) tem a frequência de aquisição de amostras reduzida para 100kHz, isso consequentemente diminui a taxa de armazenamento de dados de 100PB/s para 160GB/s. O valor de latência é mantido em 2.5μs, de outras atualizações, no intuito de evitar modificações no sistema de aquisição de dados (FARIA, 2017).

Um filtro de eventos é compreendido como um *trigger* de alto nível (HLT) e é responsável por reduzir a taxa de eventos de 100kHz para a taxa de armazenamento de dados

de 1kHz , considerando a latência aproximada de 550ms . Em decorrência disso, a taxa de dados é reduzida de 160GB/s para 1.5GB/s , em valores aproximados.


Na ocorrência do sinal de aceitação de *trigger*, L1A, os dados obtidos pela FE são enviados via fibra ótica para os *drivers* de leitura (*Read Out Drivers* – RODs). A transferência de dados continua, dos RODs ao sistema de leitura composto pelos *Readout Buffers* (ROB), de forma a armazenar os fragmentos de eventos temporariamente. Um *hardware* dedicado para reconstrução de trajetórias, o FTK (*Fast Track*), rapidamente age para colaborar com montagem de eventos do HLT para a reconstrução global de traços identificados.

O HLT é elaborado por algoritmos de tempo crítico, para realizar uma análise refinada, de acordo com a latência aproximada de 200ms . Ele utiliza as regiões de interesse (do inglês *Regions of Interest* – RoI) definidas pelo *trigger* de nível 1, a partir dos ROBs, para montar eventos relevantes para análise física das partículas e assim tais eventos são registrados em mídias permanentemente (CARRIÓ, 2014).

O sinal de aceitação do nível 1 de *trigger* L1A necessita de especial atenção nesse trabalho, pois há o interesse de utilizá-lo como conhecimento especialista no algoritmo de reconstrução de energia. Por esse motivo, a formação do sinal é apresentada no fluxograma da Figura 14, caracterizando o circuito L1Calo. São utilizados circuitos eletrônicos dedicados que processam dados oriundos dos calorímetros (L1Calo) e do detector de múons (L1Muon). Eles são responsáveis por conformar os sinais medidos e comparar os níveis de energia absorvida nos detectores aos valores de referência das partículas em análise, sinalizando eventos que provavelmente caracterizam uma partícula a partir de um grau de similaridade.

Sistemas de extração de características energéticas globais (gFEX), jatos (jFEX) e elétrons (eFex) compõem o L1Calo, bem como um pré-processador nMCM (new Multi-Chip-Module), que é constituído por uma FPGA (do inglês, *Field Programmable Gate Array*) e fornece melhor resolução de energia dos sinais oriundos da eletrônica de FE.

Figura 14 – Fluxograma do *trigger* da fase I.



Fonte: CHEN, 2017 modificado.

Associações geométricas dos jatos, elétrons e múons são calculadas no módulo topológico (L1Topo), que seleciona eventos com base no padrão geométrico (PALKA, 2015; ATLAS, 2018b).

Finalizando o nível 1, o processador central de *trigger* (CTP – *Central Trigger Processor*) realiza o cruzamento de dados dos detectores, enviados pelo processador L1Topo, para determinar os dados que tem maior probabilidade de indicar um evento e assim emitir o sinal L1A.


2.3.2.2 Cenários do TDAQ na fase II

Na atualização da fase II busca-se o máximo de integração com o projeto de atualização da fase I e a utilização de interfaces com sistemas comerciais. Mantém-se a estrutura básica apresentada na Figura 14, no entanto o cenário de alta luminosidade estimado exige aumento correspondente das taxas de armazenamento e leitura, bem como latência mais longa do *trigger*. Logo, projeta-se o acréscimo da taxa de leitura na eletrônica de BE para 40MHz, substituindo os RODs pelos sRODs, que executarão o processamento de dados mais refinado na cadeia de DAQ. O sistema FELIX interage com os sRODs (GOFF, 2020), agindo como um roteador entre a eletrônica de FE e uma rede comercial multi-gigabyte (SANCHES, 2019), enviando as regiões de interesse (RoI) ao HLT.

A latência no primeiro nível de *trigger* é quadruplicada para 10 μ s e a taxa final de armazenamento de dados é incrementada para 10kHz, requerendo, por tanto, a atualização do processador FTK, referindo-se ao novo sistema como FTK++ (*Full Event Traking*), que permite encontrar trajetórias de menor momento transversal (CAMPLANI, 2020).

As alterações do circuito de formação do sinal de aceitação do *trigger* na fase II consideram dois cenários, diferenciados pelas cores no fluxograma da Figura 15. A utilização de um nível de *trigger* (L0), equivalente ao primeiro nível de *trigger* da fase I é representada em azul. A variação do esquema compreende dois níveis de *trigger* (L0/L1), caracterizado pelo acréscimo de componentes para formar o nível 1 (L1), representado em rosa.

Figura 15 – Fluxograma do *trigger* da fase II.



Fonte: ATLAS, 2013 modificado.

Os subsistemas de extração de características apresentados em L0Calo foram adaptados do L1Calo da fase I, sendo complementado o novo subsistema de extração de características eletromagnéticas avançadas de jatos (fFEX), projetado para aumentar a eficiência de identificação de elétrons.

O pré-processador nMCM é mantido para melhorar a resolução dos sinais medidos, que por sua vez são enviados aos subsistemas de extração de características das partículas. Para tanto, são implementados algoritmos de deconvolução dos sinais de energia, na placa FPGA do nMCM, de forma a contribuir na formação de sinais de aceitação de *trigger* mais eficientemente.

Também deve-se ressaltar que há a substituição do processador L1Topo pelo *Global Trigger Processor*, pois é um sistema utilizado por todo sistema de *trigger* independente do cenário de aplicação do *trigger*.

No cenário de utilização do nível de *trigger* L0 apenas, o sinal L0A é gerado tal como na fase I, pelo processador de *trigger* central do nível 0 (L0CTP), mas com a diferença da taxa ser de 1MHz, permitindo o fluxo de dados para tratamento pelo HLT e posterior armazenamento permanente dos eventos.

O outro cenário que considera a utilização dos níveis de *trigger* L0 e L1 tem a taxa do sinal de aceitação L0A alterada para 4MHz , controlando apenas o fluxo de dados do detector de trajetórias do ATLAS, com a latência mantida em $10\mu\text{s}$. Nesse contexto, o elemento RoIE (*Regions of Interest Engine*) é incorporado ao *Global Trigger Processor*, com a responsabilidade de calcular as RoIs após o L0 com granularidade máxima (ATLAS, 2015), requerendo a informação de todas as células em que a discriminação do ruído e de energia seja caracterizada por $|E| > 2\sigma_{\text{ruído}}$ (ATLAS, 2018b).

O processador L1Track é agregado ao nível 1, para receber os dados gerados pelo RoIE e reconstruir os traços nas RoIs. O elemento final que compõe o nível 1 para formar o sinal L1A é o processador central de *trigger* do nível 1 (L1CTP), combinando e formatando os dados oriundos do L0CTP e do processador de *trigger* central. Finalmente, o L1A controla o fluxo de dados de todos os detectores (Calorímetros, Muon e Traços), com a taxa de 800kHz considerando a latência de $35\mu\text{s}$ pelo sistema de *trigger* nesse cenário (IZZU, 2020).

Tais propostas estão em análise para estabelecer o cenário que apresenta o armazenamento mais eficiente de dados, isso conforme cada contexto de aumento de eventos do LHC.

2.4 Efeito *Pile-Up*


Genericamente, tanto em detectores de partículas, quanto em detectores de radiação ocorre o efeito sobreposição de medições em um mesmo canal (*pile-up*), pelo fato de os eventos no detector serem espaçados aleatoriamente no tempo, o que faz surgir a possibilidade de pulsos muito próximos, no contexto de alta taxa de eventos, isso combinado ao alargamento do pulso no tempo pela eletrônica de leitura, como representado na Figura 7 (KNOLL, 2010). Especificamente no caso do TileCal, o circuito de condicionamento que compõe eletrônica de leitura fornece pulsos com a duração de 150ns , mas o período entre cruzamento de feixes do LHC é de 25ns (ANDERSON, 1998), ou seja, pode-se esperar, pelo menos, que há *pile-up* no pulso resultante do sistema de medições a partir de 7 colisões diferentes. Ocorre que dos 10.000 canais do TileCal, apenas uma fração dos canais de leitura é utilizado aleatoriamente nos instantes de cruzamentos de feixes, por isso, não se observava o *pile-up* significativamente de forma a alterar as análises.

O aumento da luminosidade na atualização para fase II do LHC implica diretamente no aumento a taxa de eventos por canal, o que aumenta a ocupação da eletrônica de leitura

devido na duração do pulso característico dos canais de medição. Mesmo com o evidente descompasso, não há interesse na diminuição da largura do pulso característico dos canais para não exigir maior resposta em frequência dos componentes do sistema de leitura, principalmente o conversor analógico digital (CERQUEIRA, 2015), logo a tarefa de tratamento de *pile-up* deverá ser realizada via *software*.

O fenômeno de *pile-up* considerado neste trabalho pode ser denominado empilhamento de pico, que ocorre quando dois pulsos estão suficientemente próximos para que sejam tratados como um único pulso pelo sistema de leituras (KNOLL, 2010). Na Figura 16 representa-se o efeito *pile-up* de dois pulsos representados pelas cores preto e vermelho, que combinados formam o pulso representado pela cor lilás.

Figura 16 – Representação de empilhamento do sinal no TileCal.



Fonte: ATLAS, 2017.

A superposição de pulsos forma um pulso combinado de amplitude maior que a anterior e em um caso limite, a amplitude resultante será a soma das amplitudes de cada pulso individual. Descreve-se matematicamente a amplitude (A_c) de um pulso combinado a partir de outros dois pulsos em um intervalo, em função de três parâmetros aleatórios: a amplitude do primeiro pulso (A_1), a amplitude do segundo pulso (A_2) e o intervalo entre o pico dos pulsos (δp). Considerando-se $A_1 < A_2$, pode-se afirmar que a amplitude do pulso combinado está no intervalo apresentado na Equação 3.

$$A_1 \leq A_c(\delta p) \leq A_1 + A_2 \quad (3)$$

Existem algumas possibilidades de surgir o *pile-up* no ambiente de calorimetria do ATLAS, mas em linhas gerais dois tipos de *pile-up* surgem a partir de colisões de cruzamento de feixes, quais sejam *in-time pile-up* e *out-of-time pile-up*; e um tipo de *pile-up* de fundo significativo, que surgem pelas características do LHC. Estima-se o aumento de todos os tipos de *pile-up* com aumento da luminosidade, mas com preponderância do *in-time pile-up*.

O *in-time pile-up* ocorre por medições superpostas da energia depositada por cada partícula no mesmo cruzamento de feixes, como pode-se interpretar da Figura 6, em que dois ou mais chuveiros de partículas podem ser detectados por canais em comum. Já o *out-of-time pile-up* se dá pela sobreposição de leituras de energia de cruzamento de feixes consecutivos, que ocorreram logo antes ou depois, como comentado anteriormente, isso ocorre pela largura do pulso ser maior que a taxa de cruzamento de feixes. Por fim, os eventos de *pile-up* de gás de feixe surgem por pelo menos um dos feixes de prótons se chocar com gás residual que pode haver dentro da linha do feixe, tais eventos geralmente ocorrem em uma posição diferente do centro do detector. Os diferentes motivos para a formação do *pile-up* permitem a interpretação do efeito como sinais de interesse e ruído, assim é possível diferenciar técnicas no tratamento do *pile-up* e sua simulação.

Na medição da deposição de energia, no caso de ocorrer o *in-time pile-up* ou *out-of-time pile-up*, todas as deposições são interessantes para análise preliminar, pois a ativação dos canais permite determinar se surgiu uma região de interesse com um ou mais chuveiros de partículas, logo o ideal é que os sinais sejam separados ou desempilhados para análise. No entanto, após a definição das regiões de interesse, alguns sinais que formam o *in-time pile-up* e o *out-of-time pile-up* podem ser descartados e, nesse sentido, são interpretados como ruído.

Na interpretação do *pile-up* como ruído, independentemente da sua origem, há a alteração do ruído total em função da luminosidade instantânea ($\mathcal{L}$) e consequentemente da taxa média de colisões por cruzamento (μ). Deve-se isso, ao fato do *pile-up* ser diretamente proporcional ao número de interações por cruzamento de feixes de prótons, que por sua vez é dependente da luminosidade instantânea, projetada para elevados valores no HL-LHC.

No contexto de maior luminosidade a presença de *pile-up* aumenta significativamente o ruído total nos canais de leitura, por haver predominância do ruído de *pile-up* em relação ao ruído eletrônico ($\sigma_{pileup} \gg \sigma_{eletrônico}$) em mais de uma ordem de magnitude (CERN, 2017).


É possível modelar o ruído *pile-up* como uma componente do ruído total em quadratura, conforme a Equação 4. Tal hipótese é considerada, pois se entende que o ruído oriundo do *pile-up* e o ruído eletrônico são descorrelacionados (NOVAKOVA, 2013).

$$\sigma_{total} = \sqrt{\sigma_{pileup}^2 + \sigma_{eletrônico}^2} \quad (4)$$

Flutuações sistemáticas ou aleatórias das leituras acarretam o ruído eletrônico. Por exemplo, as flutuações sistemáticas são oriundas do processo de coleta de luz, em que se acumula certa quantidade de carga após a conversão no sinal elétrico. Em relação as flutuações aleatórias, são exemplos os problemas de casamento de impedância e aterramento das fontes de energia. (PEREIRA, 2019).

O ruído eletrônico é invariável em relação a amplitude da medição, isso quer dizer que quanto maior a energia medida, menos o ruído eletrônico corrompe o sinal, assim a relação sinal ruído é atenuada para elevados níveis de energia. No entanto o ruído de *pile-up* possui a probabilidade de corromper as medições da mesma maneira em toda faixa de energia, dependendo do aumento da luminosidade. Na Figura 17 é ilustrado como o aumento da taxa de colisões por cruzamento de feixes acrescenta progressivamente o ruído em diversos canais de leitura do TileCal, devido a componente de ruído *pile-up* (ATLAS, 2011).

Figura 17 – Ruído simulado nas células do Tilecal em função do número médio de interações por cruzamento de feixes.



Fonte: ATLAS, 2017.

Um modelo aproximado permite representar a tendência da relação entre a taxa de colisões por cruzamento e o ruído *pile-up*, como apresentado pela Equação 5. O termo σ_{pileup}^{norm} indica uma constante de *pile-up*, que permite ao modelo boa concordância na quantificação do ruído no caso de condições de deposições de energia em sequências muito próximas e para um alto número de interações (NOVAKOVA, 2013).

$$\sigma_{pileup} = \sigma_{pileup}^{norm} \cdot \sqrt{\mu} \quad (5)$$

Sendo o termo μ a taxa de cruzamento de feixes.

Insurge o desafio de simular o efeito *pile-up*, pois ainda não foram observados os comportamentos dos calorímetros para configurações de luminosidade elevada dos aceleradores de partículas (FABIAN, 2003). Desta maneira deseja-se elaborar projeções para representação do *pile-up*.

2.5 Simulação do Sinal

A natureza estocástica dos eventos estudados no ATLAS exige a utilização de técnicas estatísticas para simulação. Deseja-se simular a energia e direção das partículas produzidas nas colisões entre prótons. Os algoritmos de simulação por métodos Monte Carlo (MC) apresentam desempenho promissor, pois são capazes de gerar variáveis aleatórias regidas por distribuições de probabilidade oriundas do evento que se deseja reproduzir (GUATELLI, 2011).

As simulações são úteis, pois colaboram com o tratamento de dados, gerando modelos geométricos inerentes aos chuveiros de partículas, possibilitando a calibração do calorímetro (BUDAGOV et. al., 2006).

São vários os algoritmos MC utilizados na simulação dos eventos do ATLAS, conforme o fluxo de dados apresentado na visão geral da Figura 18. O fluxo de dados da simulação é dividido em etapas, no intuito de utilizar os recursos computacionais mais efetivamente para a representação dos eventos no ATLAS. A simbologia utilizada na Figura 16 tem os diagramas de borda quadrada referindo-se aos algoritmos e aplicativos, os diagramas de borda arredondada são objetos de dados, enquanto os diagramas pontilhados são etapas opcionais para simular o *pile-up* (AAD, 2010).

As simulações MC no ATLAS constituem uma tarefa ambiciosa, ao requerer uma análise cuidadosa e detalhada de todos os domínios que caracterizam o experimento (RIMOLDI, 2003). Logo, deseja-se utilizar neste trabalho, uma parte da simulação MC, que propõe a síntese da eletrônica de leitura, considerando o pulso característico do canal e o ruído eletrônico. Com este tipo de simulação consegue-se mais controle nos parâmetros dos sinais gerados, para se estudar profundamente a atuação de novos algoritmos. Deve-se isso ao fato de existir conhecimento das distribuições de probabilidade do sinal em função da amplitude de energia depositada no canal.

Figura 18 – Fluxo da simulação completa do ATLAS.

A ocupação em cada canal pode ser definida em função da relação entre a taxa de amostras ocupadas (ν) e a taxa de amostragem (f_s), conforme apresenta-se nas equações 7 e 8, respectivamente. Sendo, então possível, definir ocupação pela relação de taxas na Equação 9.

$$\nu = \frac{\Delta N_{BCID}}{\Delta t} \quad (7)$$

$$f_s = \frac{\Delta N}{\Delta t} \quad (8)$$

$$\gamma_{ocup} = \frac{\nu}{f_s} \quad (9)$$

A ocupação é na realidade uma medida de probabilidade ($P[ocp]$), pois trata a probabilidade de uma amostra estar ocupada, dentre várias, e pode ser obtida também pelo produto da taxa de amostras ocupadas (ν), com o tempo de duração de cada amostra (τ), obtendo-se assim a Equação 10, que mantém coerência com a Equação 8, é reescrita em termo do período de amostragem ($\Delta t = f_s^{-1} = \tau$) (WIELERS, 2015).

$$P[ocp] = \nu \cdot \tau = \gamma_{ocup} \quad (10)$$

Analogamente é calculada a probabilidade de vacância do canal ($P[vac]$), dada pelo complemento da probabilidade de ocupação, expressa na Equação 11.

$$P[vac] = 1 - \nu \cdot \tau = 1 - \gamma_{ocup} \quad (11)$$

A taxa de amostras ocupadas (ν) pode ser relacionada a média de colisões por cruzamento (μ) em uma distribuição espacial (α) e a probabilidade de vacância do canal, conforme a Equação 12 (WIELERS, 2015).

$$\nu = \alpha \cdot \mu \cdot P[vac] \quad (12)$$

O termo de distribuição geométrica de canais pode ser determinado a partir do estudo do sistema de coordenadas do ATLAS e depende apenas da posição do canal no experimento. Ele é sempre o mesmo para cada canal, logo, na análise separada de cada canal o parâmetro é constante.

Combinando-se as equações 9, 11 e 12 encontra-se a relação entre a taxa média de colisões por cruzamento e a ocupação do canal, assim como sua função inversa, respectivamente nas equações 13 e 14. Sendo o termo $\gamma_{ocup}^{norm} = \alpha\tau$ um coeficiente normalizado de ocupação para cada canal.

$$\gamma_{ocup} = \frac{\mu}{\gamma_{ocup}^{norm} + \mu} \quad (13)$$

$$\mu = \gamma_{ocup}^{norm} \frac{\gamma_{ocup}}{1 - \gamma_{ocup}} \quad (14)$$

Percebe-se pela Equação 14, que ao controlar o parâmetro ocupação (γ_{ocup}) o parâmetro físico taxa de ocupação (μ) é reproduzido. Logo, retomando-se a Equação 4, que relaciona o *pile-up* interpretado como ruído a taxa de ocupação, como exposto na Equação 15.

$$\sigma_{pileup} = \sigma_{pileup}^{norm} \cdot \sqrt{\gamma_{ocup}^{norm} \frac{\gamma_{ocup}}{1 - \gamma_{ocup}}} \quad (15)$$

As conclusões da análise matemática para simulação do *pile-up* são utilizadas na elaboração do modelo TMC dos canais dos TileCal. Isto é possível devido ao fato dos sistemas de calibração fornecem alto desempenho aos sinais adquiridos pela eletrônica de leitura, conforme apresentado na Figura 8, visto que um dos objetivos da calibração é verificar se a forma do pulso é fixa, uniformizando a resposta dos milhares de canais que compõe o sistema de calorimetria (PERAVALVA, 2010).

O procedimento da simulação TMC é apresentado no diagrama da Figura 19, com um exemplo de simulação de sinal, em que as amostras representadas por círculos não preenchidos são as sorteadas para receberem energia.


As etapas do simulador são descritas em ordem:

1. Um valor para a taxa de ocupação do sinal (γ_{ocup}) é definido para sortear as amostras que recebem o depósito de energia (BCID¹), seguidos das amostras que não recebem energia (BCID⁰).
2. Os níveis de energia dos BCID¹ são sorteados conforme a distribuição de probabilidades exponencial com valor médio de unidades de conversão ADC igual a 30, para cada evento medido no calorímetro, independentemente da luminosidade, em que tais características são retiradas do banco de dados do LHC (BARBOSA, 2017).
3. Desvios de fase podem deslocar o pulso característico conforme uma distribuição de probabilidade aproximada a uma distribuição de probabilidades gaussiana com média 0ns e desvio padrão 1ns, mesmo com o aumento da luminosidade (FARIA, 2017).
4. Cada amostra de energia é convolvida com o pulso característico normalizado de 7 BC, definido pelo circuito de conformação na placa 3-in-1, de forma a representar a característica dispersiva dos canais dos calorímetros (PERALVA, 2010).

- Finalmente é adicionado ao sinal amostras de ruído gaussiano, para reproduzir o ruído eletrônico existente nos canais dos calorímetros (FARIA, 2017).

Os dados gerados pelo simulador TMC são úteis para avaliação de novas técnicas na presença do *pile-up*, além de permitirem a simulação em campo para sugestões de novas técnicas.

Figura 19 – Fluxograma da simulação TMC, com exemplo.



Fonte: Elaborado pelo autor.

O sinal $x[n]$ apresentado na Figura 19 já está amostrado, mas se relaciona totalmente com o sinal lilás da Figura 16, pois o simulador deve ser capaz de gerar dois sinais de evento que se superpõe.

2.6 Conclusões Parciais do Capítulo

O ambiente a que se propõe este trabalho foi apresentado neste capítulo, abordando os experimentos no LHC e sua atualização para o HL-LHC, denominada fase II. Especificamente abordou-se o experimento ATLAS, com seu sistema de calorimetria, enfatizando-se o sistema de seleção de dados *online* em um contexto de luminosidade elevada, ou seja, com a presença do efeito *pile-up*.


As considerações apresentadas sobre o *pile-up* foram aprofundadas com a análise da simulação desenvolvidas neste trabalho, o que tornou evidente a necessidade de algoritmos de processamento dos sinais no contexto do HL-LHC para reconstrução de energia. Por tanto, o estado da arte das técnicas para reconstrução de energia do TileCal é avaliado.

3 PROCESSAMENTO DE SINAIS NO TILECAL

Os experimentos do LHC inovam o estudo da física de partículas e essa inovação tende a progredir com as atualizações propostas para o HL-LHC, a fase do II do LHC, pois a luminosidade do colisor será aumentada significativamente. Como mencionado no capítulo 2, o aumento da luminosidade representa maior concentração de partículas nos feixes, no intuito de incrementar a probabilidade de interações nas colisões e, portanto, fornecer mais dados estatísticos na observação de processos, com foco em eventos raros.

Nos experimentos iniciais, o sistema de calorimetria do ATLAS não considerava a luminosidade, pois a medição da energia só era corrompida por ruído eletrônico. Algoritmos de processamento de sinais garantiam o armazenamento apenas as amostras úteis à análise física. No entanto, o ambiente de luminosidade elevada faz surgir o efeito *pile-up*, que não é solucionado pelas técnicas iniciais (PERALVA, 2010).

São propostas técnicas de processamento de sinais *online* para os canais do TileCal, de forma a atenuar o efeito *pile-up*, juntamente com o ruído eletrônico. Os algoritmos de processamento devem ser implementados para pré-processamento do primeiro nível de *trigger* e para reconstrução de energia na etapa de armazenamento, como apresentados na Figura 20.




Fonte: Elaborado pelo autor.

A reconstrução da energia do sistema de leitura e armazenamento do TileCal é implementada em FPGA, no sistema referido como TilePPr, tratado no tópico 2.3. O sistema de processamento para reconstrução de energia é caracterizado por utilizar lotes de 7 amostras armazenadas em um *buffer pipeline*, de forma que a janela de amostras forme um vetor de observação ($\mathbf{y}$). É realizada a configuração prévia do vetor de observação para que a amostra central seja correspondente ao valor de amplitude depositada no canal de medição (A), a formação do vetor de observação se dá quando o sistema de *trigger* detecta um sinal de interesse, iniciando a reconstrução da energia ($\hat{A}$) para armazenamento dos dados.

O primeiro nível de *trigger* (L0/L1) tem um sistema de pré-processamento de dados para permitir a operação mais eficiente do sinal de aceitação no primeiro nível de *trigger* (L0A ou L1A). Um algoritmo de filtragem é implementado no pré-processador nMCM, desenvolvido em FPGA, também tratado no tópico 2.3. Nesta aplicação, os algoritmos devem realizar a deconvolução *free-running* do sinal observado ($y[n]$), ou seja, amostra por amostra, estimando o sinal de energia depositada ($\hat{a}[n]$).

Os algoritmos de filtragem do sistema de leitura e do sistema de *trigger* operam paralelamente, isso faz com que o sinal filtrado no sistema de *trigger* não tenha relação direta com o sistema de leitura. No entanto, há uma diferença inerente nestes dois tipos de processamento, como representa-se na Figura 21, em que no sistema de *trigger*, a estimação deve ser feita amostra a amostra, com o objetivo de identificar qual BC apresentou deposição de energia para um determinado canal e dar um valor, ainda que grosseiro, para a energia depositada em cada BC ($\hat{a}[n]$), neste ponto não há conhecimento de qual sinal é desejado e qual é indesejado, logo a deconvolução é aplicada para desempilhar os sinais; já o sistema de leitura precisa estimar a amplitude do sinal recortado, com máxima precisão possível, na qual o pico encontra-se na quarta amostra da janela e todo outro sinal que está imerso na janela de leitura é tratado como ruído e deve ser atenuado o máximo possível. Existe, contudo, uma relação indireta entre ambos os sistemas, pois, como já mencionado, o sinal de aceitação do *trigger* (L1A) define as amostras que são armazenadas no sistema de leitura e, para tal, um processo de estimação da energia depositada também é executado no primeiro nível.

Figura 21 – Diferença entre os procedimentos de deconvolução e reconstrução de energia.




Fonte: Elaborado pelo autor.

3.1 Filtros de Reconstrução de Energia no Sistema de Leitura

Os métodos que têm sido estudados até então para a reconstrução de energia utilizam o modelo para os canais do TileCal, conforme a Equação 16 e a Figura 22. Nesse modelo, o *pile-up* é interpretado como ruído, conforme desenvolvido na seção 2.4.2, pois, interessa apenas o depósito de energia que se relaciona a amostra central da janela de medição, logo as outras medições sobrepostas à amostra de interesse são incluídas no vetor de ruído. Além do ruído *pile-up* ainda existe a influência do ruído eletrônico, em que ambos compõem o ruído total do sistema pela soma em quadratura, conforme já apresentado na Equação 3, perfazendo o ruído total (σ_{Total}).

$$y = h \cdot A + \sigma_{Total} \quad (16)$$

Figura 22 – Modelo do canal desconhecido do TileCal e filtro de estimação de energia.



Fonte: Adaptado de Haykin, 2014.

No modelo matemático comumente proposto para se realizar a estimação da amplitude (A) da amostra central, o vetor que caracteriza o pulso de referência do canal (com amplitude unitária) do TileCal ($\mathbf{h}$) é composto por 7 amostras ($\mathbf{h} = [h_{-3} \ h_{-2} \dots \ h_2 \ h_3]$), que é combinado a amplitude de energia (A) e, então, somado ao ruído total (σ_{Total}). O resultado do canal do TileCal são janelas de medição ($\mathbf{y}$), definidas pelo sinal de aceitação do primeiro nível de *trigger* (L0A/L1A).

A atenuação do ruído eletrônico e ruído *pile-up* por um filtro digital constituem a reconstrução *online* de energia ($\hat{A}$) nos lotes de amostras das janelas de observação. A determinação dos coeficientes do filtro pode ser realizada tanto considerando o conhecimento do pulso de referência do canal, quanto avaliando a relação entrada-saída do canal, logo, os principais métodos para reconstrução de energia são apresentados.

3.1.1 Filtro Ótimo

O método de reconstrução de energia em operação desde 2014, tanto no sistema de leitura, quanto no primeiro nível de *trigger* do TileCal é o Filtro Ótimo (do inglês *Optimal Filter* - OF), o qual dispõe de variações que são apresentadas por Peralva (2010). Este método era utilizado anteriormente em calorímetros de ionização líquida, como o próprio calorímetro LAr do ATLAS, que trabalhava em ambiente de alta luminosidade (DUARTE, 2018), mas seu desempenho estimulou a sua utilização no TileCal.

Apresenta-se a técnica de parametrização do OF fundamentada no melhor estimador linear não tendencioso (BLUE, do inglês *Best Linear Unbiased Estimator*). É utilizada a função de autocorrelação do ruído para minimizar a variância do estimador, o que permite determinar a amplitude e o tempo no qual a energia foi depositada no canal, eliminando o ruído eletrônico e as amostras empilhadas no sinal central (FULLANA, 2006). A estimação da amplitude de energia desejada ($\hat{A}$) é obtida, modelando o filtro $g(y)$ pela Equação 17.

$$\hat{A} = \sum_{k=0}^{M-1} w_k y[k] \quad (17)$$

A janela de medição do sinal observado no TileCal $\mathbf{y}$ possui $M = 7$ amostras que são ponderadas pelos pesos fixos w_k , para $0 \leq k \leq M$ (GONÇALVES, 2018).

O filtro deve ser não tendencioso, logo, segundo o BLUE, a média da amplitude estimada deve ser igual a amplitude de energia original (A):

$$E\{\hat{A}\} = \sum_{k=0}^{M-1} w_k E\{y[k]\} = A \quad (18)$$

A variância da amplitude estimada é definida pela multiplicação da matriz de pesos com a matriz de covariância do ruído de fundo $\mathbf{C}$, dada pela Equação 19.

$$\text{var}\{\hat{A}\} = \mathbf{w}^T \mathbf{C} \mathbf{w} \quad (19)$$

Minimizando a variância obtém-se os valores de pesos, calculados por:

$$\mathbf{w} = \frac{\mathbf{h}^T \mathbf{C}^{-1}}{\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h}} \quad (20)$$

Consequentemente a estimativa da amplitude na amostra central da janela de medição é dada pela expressão:

$$\hat{A} = \frac{\mathbf{h}^T \mathbf{C}^{-1}}{\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h}} \mathbf{y} \quad (21)$$

O desempenho do OF era satisfatório quando o ruído eletrônico era predominante, pela distribuição de probabilidades ser gaussiana com média zero, contudo, o ruído *pile-up* não é gaussiano e a média é diferente de zero, por isso, quando o ruído predominante é o ruído *pile-up*, o desempenho do OF é deteriorado (PERALVA, 2013).

O pressuposto de que os canais podem ser modelados por um pulso característico invariável e idêntico nos 10.000 canais, pode ser equivocada, logo, a limitação da modelagem do ruído combinada a excessiva dependência que o OF tem do pulso característico, motiva a busca por novas técnicas de filtragem (GONÇALVES, 2018).

3.1.2 Filtro de Wiener

Assumindo-se a hipótese que as relações entrada-saída do canal são conhecidas, também é possível equalizar filtros lineares, não sendo mais necessário utilizar diretamente a resposta impulsiva do canal. Em tal abordagem o algoritmo de equalização de Wiener fornece a operação ótima ao filtro, pois satisfaz o princípio da ortogonalidade (HAYKIN, 2014), por isso Gonçalves (2018) propôs a aplicação do filtro de Wiener para reconstrução de energia no sistema de leitura do TileCal.

Os coeficientes ótimos da solução de Wiener ($\mathbf{w}_o$) são calculados pela minimização da função de custo ($\mathcal{J}$), que é definida pelo valor esperado do erro quadrático para o conjunto de amostras disponíveis representando os padrões estatísticos dos sinais (HAYKIN, 1996), conforme a Equação 24.

$$\mathbf{w}_o = \arg \min \mathcal{J} \quad (23)$$

$$\mathcal{J}(\mathbf{w}) = E\{e^2\} = E\{(A - \hat{A})^2\} \quad (24)$$

O procedimento do método consiste em substituir o valor de amplitude estimativa ($\hat{A}$) pela combinação linear dos pesos do filtro ($\mathbf{w}$) com a resposta do calorímetro ($\mathbf{y}$). Em seguida, é calculado o gradiente da função de custo em relação aos pesos. O resultado do gradiente é igualado a zero, de forma a se obter o mínimo da função de custo e consequentemente definir os pesos ótimos, resultando na Equação 25.

$$\begin{aligned} \frac{\partial \mathcal{J}}{\partial \mathbf{w}} &= \nabla \mathcal{J} = \nabla E\{(A - \mathbf{w}^T \mathbf{y})^2\} = 0 \\ E\{\mathbf{y}(A - \mathbf{w}^T \mathbf{y})\} &= 0 \end{aligned} \quad (25)$$

É possível reescrever os termos da Equação 25 como a correlação cruzada entre os sinais de entrada e saída do filtro ($\mathbf{p} = E\{\mathbf{y}A\}$), bem como a autocorrelação da entrada ($\mathbf{R} = E\{\mathbf{y}\mathbf{y}^T\}$):

$$\mathbf{R}\mathbf{w}_o = \mathbf{p} \quad (26)$$

Portanto, assumindo que a matriz de autocorrelação $\mathbf{R}$ seja inversível, calculam-se os pesos ótimos da solução de Wiener pela Equação 27.

$$\mathbf{w}_o = \mathbf{R}^{-1}\mathbf{p} \quad (27)$$

Devido ao fato do ruído de *pile-up* no TileCal não possuir média zero, exige-se que seja acrescentado um elemento igual a 1 ao vetor de entrada ($\mathbf{y}_b = [\mathbf{y} \ 1]$). Com isso, o elemento *bias* é acrescido ao vetor de pesos ($\mathbf{w}_b = [\mathbf{w}_o \ b]$), sendo ajustado exclusivamente para compensação da tendência originada pela média do ruído, tornando o filtro não tendencioso (GONÇALVES, 2018).

Na perspectiva estatística o filtro de Wiener é comparável a um modelo linear de regressão, por isso alguns critérios deveriam ser satisfeitos para sua aplicação no Tilecal em que a distribuição de probabilidade dos dados deve ser normal e o resíduo deve apresentar homoscedasticidade, entre outras (FÁVERO, 2017). Ambos os critérios apresentados não são satisfeitos no contexto do TileCal para a fase II do LHC, como será apresentado no capítulo 5.

No contexto do TileCal a amplitude de energia depositada pelas partículas (A) não está disponível diretamente, apenas a resposta do canal ($\mathbf{y}$) pode ser obtida, o que inviabilizaria a implementação dos algoritmos de filtros adaptativos. Entretanto, os parâmetros estatísticos dos sinais são conhecidos, isso possibilita que simulações TMC forneçam relações de entrada-saída do canal $\{A, \mathbf{y}\}$, que são utilizadas para equalização dos coeficientes dos filtros

(DUARTE, 2019). As propostas iniciais de implementar filtros de Wiener no TileCal consideram a equalização *offline*, isso pela ausência dos valores desejados em tempo real. Logo, uma vez que os coeficientes sejam adaptados na etapa de projeto, o filtro é utilizado com os coeficientes fixos.

Os resultados obtidos por Gonçalves (2018) distinguem o filtro de Wiener do Filtro Ótimo e dos outros métodos que eram utilizados até então para reconstrução de energia no sistema de leitura.


3.2 Filtros de Deconvolução no Primeiro nível de Trigger

A perspectiva sobre o *pile-up* no primeiro nível de *trigger* é diferente do sistema de leitura, pois ainda não se tem informação de quais são os pulsos de interesse. Por isso são estudados algoritmos de deconvolução para remover a combinação entre a resposta ao impulso do canal (h) e a energia depositada (a) (HAYKIN, 1996).

O modelo do canal utilizado para deconvolução consiste em um sistema digital LTI (do inglês, *Linear Time Invariant* – Linear e Invariante no Tempo) seguido de um filtro digital a ser projetado, como representado na Figura 23 e como descrito na Equação 28.

$$y[n] = f(a[n]) + \sigma_E[n] = \sum_{i=-\infty}^{\infty} h[i]a[n-i] + \sigma_E[n] \quad (28)$$

Figura 23 – Modelo do canal desconhecido do TileCal e filtro de estimação de energia.



Fonte: Adaptado de Haykin, 1996.

A saída dos canais de leitura dos calorímetros é representada por $y[n]$, ela é resultado da soma do ruído eletrônico $\sigma_E[n]$ com o resultado da convolução do vetor do sinal de energia a e a resposta ao impulso do canal h .

Aplicações de algoritmos de deconvolução são comuns no processamento digital de sinais para equalização de canais em telecomunicações (PERALVA, 2015), processamento de

imagens e para estimação de estímulos sísmicos (HAYKIN, 1996), havendo excelente desempenho do método nessas aplicações.

No caso da reconstrução de estímulos sísmicos, por exemplo, o estímulo (referido como *seismic wavelet*) não é observável diretamente e, logo, não é conhecido. No entanto, é possível medir as ondas sísmicas de resposta no solo e, além disso, o modelo sísmico em camadas da Terra é conhecido, tornando possível recuperar o estímulo, antes desconhecido, pela deconvolução entre o modelo sísmico e as ondas sísmicas (HAYKIN, 1996).

As especificações dos canais do TileCal se comparam ao contexto de deconvolução sísmica, pois não são conhecidas as amplitudes de energia depositadas pelas partículas, também existem informações sobre o modelo dos canais de medição e os sinais medidos estão disponíveis. Essas condições para o processamento de sinais do TileCal justificam a implementação das técnicas de deconvolução no TileCal por parte da colaboração brasileira do ATLAS, substituindo, assim, um método variante do filtro ótimo utilizado desde 2014. Logo, as propostas de filtros de deconvolução que possuem relação com este trabalho são apresentadas nas seções seguintes.

3.2.1 Aproximação do Sistema Inverso

Os métodos de projeto tradicionais para filtros de deconvolução realizam a aproximação do sistema inverso do canal: pelo domínio da frequência, e pela interpretação de sistemas lineares. Para tanto, deve valer a hipótese que os canais do calorímetro são modelados adequadamente por uma resposta ao impulso conhecida, definida pelo vetor de coeficientes $\mathbf{h}$. Se a hipótese é confirmada, o sinal original de entrada ($a[n]$) é recuperado quando o sinal de saída do canal $y[n]$ passa pelo filtro, caracterizado pelo vetor de pesos $\mathbf{w}$, e gera a resposta $\hat{a}[n]$ que é uma aproximação do sinal de entrada (MITRA, 2006).

3.2.1.1 Inversão no Domínio z

A análise do problema no domínio z facilita a caracterização do sistema inverso para o projeto do filtro, conforme a Equação 29 (MITRA, 2006):

$$W(z) = \frac{1}{H(z)} \quad (29)$$

Em que $H(z)$ e $W(z)$ são respectivamente a transformada z da resposta ao impulso do canal e do filtro de deconvolução.

O problema relacionado ao filtro de aproximação inversa é que, indesejavelmente, o filtro resultante é classificado como um filtro IIR (*Infinite Impulse Response* - Resposta Infinita ao Impulso) de fase não-mínima, surgindo a questão da instabilidade ao filtro (MITRA, 2006), que deve, necessariamente ser estável em quaisquer condições, ao tratar-se de um sistema de instrumentação.

Para que o filtro seja estável faz-se necessária uma série de aproximações convertendo-o em um filtro FIR (*Finite Impulse Response* - Resposta Finita ao Impulso) (DUARTE, 2019). As aproximações degradam o filtro acarretando perdas de desempenho.

3.2.1.2 Método da Pseudo Inversa de Moore-Penrose

Os modelos do canal do TileCal e do filtro podem ser ambos aproximados por sistemas lineares, em que a operação de convolução é a combinação linear do sinal de entrada com uma matriz que representa o sistema (BARBOSA, 2017).

Inicialmente define-se a matriz de convolução $\mathbf{H}$, composta por deslocamentos dos coeficientes do pulso de referência $\mathbf{h}$:

$$\mathbf{H} = \begin{bmatrix} h_{-3} & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & & \vdots \\ h_3 & \cdots & h_{-3} & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & h_3 & \cdots & h_{-3} \\ \vdots & & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & h_3 \end{bmatrix} \quad (30)$$

A definição da matriz de convolução permite que o operador $f(\cdot)$ do canal do TileCal, apresentado na Figura 23, seja interpretado como um operador matricial que multiplica o vetor do sinal de energia $\mathbf{a}$ com a matriz de convolução $\mathbf{H}$, de forma a gerar o vetor de observação $\mathbf{y}$, conforme a Equação 31.

$$\mathbf{y} = \mathbf{H}\mathbf{a} \quad (31)$$

Manipulações pelo método de Moore-Penrose permitem obter a matriz pseudo inversa da matriz de convolução $\mathbf{H}$, comparada a solução analítica da regressão lineal, que se aproxima da matriz de deconvolução $\mathbf{W}$ (VAN LOAN, 1996), conforme a Equação 32.

$$\begin{aligned} \mathbf{H}^T \mathbf{y} &= \mathbf{H}^T \mathbf{H} \mathbf{a} \\ (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} &= (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{H} \mathbf{a} \\ (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y} &= \hat{\mathbf{a}} \\ \hat{\mathbf{a}} &= \mathbf{W} \mathbf{y}, \quad \text{pois} \quad \mathbf{W} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \end{aligned} \quad (32)$$

O procedimento é correspondente a solução dos mínimos quadrados, em que o erro quadrático do modelo é uma função de custo a ser minimizada derivando-se a função de custo e igualando a zero, para que seja obtida a Equação 33.

$$\begin{aligned}
J(\mathbf{a}) &= (\mathbf{y} - \mathbf{H}\mathbf{a})^2 = (\mathbf{y} - \mathbf{H}\mathbf{a})^T (\mathbf{y} - \mathbf{H}\mathbf{a}) \\
J(\mathbf{a}) &= \mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{H}\mathbf{a} - \mathbf{a}^T \mathbf{H}^T \mathbf{y} + \mathbf{a}^T \mathbf{H}^T \mathbf{H}\mathbf{a} \\
\frac{dJ(\mathbf{a})}{d\mathbf{a}} &= -2\mathbf{H}^T \mathbf{y} + 2\mathbf{H}^T \mathbf{H}\mathbf{a} = 0 \\
\hat{\mathbf{a}} &= (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}
\end{aligned} \tag{33}$$

O resultado consequente da solução dos mínimos quadrado é idêntico ao resultado do método inverso de Morre-Penrose, tratando um sistema sobre determinado, em que há mais linha que colunas (VAN LOAN, 1996). As equações 31 e 32 caracterizam que o operador do filtro de deconvolução $g(\cdot)$ também é um operador matricial, como apresentado na Figura 21.

Esse procedimento é muito utilizado em sistemas de processamento de sinais aleatórios (HAYKIN, 2001), mas tem a desvantagem na aplicação do TileCal de gerar o espalhamento da energia entre os componentes da matriz. O espalhamento polariza o resultado, distribuindo incorretamente a amplitude de energia estimada $\hat{\mathbf{a}}$ entre amostras vizinhas (BARBOSA, 2017).

3.2.2 Filtro de Mínimos Quadrados

Foi desenvolvido por Duarte (2016) um filtro linear adaptativo fundamentado no método dos mínimos quadrados (LMS, do inglês *Least Mean Squared*) de forma a minimizar a função de custo do filtro, pois, cogita-se que conjuntos de amostras separadas colaboram com ajustamento global dos pesos, aproximando o filtro da operação ótima (PROAKIS, 2007).

São utilizadas N amostras observadas que caracterizam a função de custo:

$$J(\mathbf{w}) = \sum_{k=0}^{N-1} e[k]^2 = \sum_{k=0}^{N-1} (a[k] - \hat{a}[k])^2 \tag{34}$$

A função de custo pode ser reescrita em sua forma matricial, conforme apresenta-se na Equação 34, em que a matriz de observação $\mathbf{Y}$ é definida por N linhas e $M + 1$ colunas. A quantidade de linhas N corresponde a quantidade de amostras observadas, enquanto o número de colunas é definido pela ordem M do filtro FIR, ou quantidade de pesos, mas que ainda são combinadas a uma coluna de elementos 1, perfazendo $M + 1$ colunas. Tal acréscimo é

realizado devido a tendência do filtro no contexto do TileCal, conforme descrito por Duarte (2016).

$$J(\mathbf{w}) = (\mathbf{a} - \mathbf{Y}\mathbf{w})^T (\mathbf{a} - \mathbf{Y}\mathbf{w}) \quad (35)$$

Aplica-se a propriedade distributiva à função de custo, e em seguida calcula-se o seu gradiente em relação aos pesos do filtro, cujo resultado é igualado a zero, para que seja obtido o mínimo da função, logo, se obtém a Equação 36.

$$\begin{aligned} J(\mathbf{w}) &= \mathbf{a}^T \mathbf{a} - \mathbf{a}^T \mathbf{Y}\mathbf{w} - \mathbf{a}^T \mathbf{Y}\mathbf{w} + \mathbf{w}^T \mathbf{Y}^T \mathbf{Y}\mathbf{w} \\ J(\mathbf{w}) &= \mathbf{a}^T \mathbf{a} - 2\mathbf{a}^T \mathbf{Y}\mathbf{w} + \mathbf{w}^T \mathbf{Y}^T \mathbf{Y}\mathbf{w} \\ \frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} &= -2\mathbf{a}^T \mathbf{Y} + 2\mathbf{Y}^T \mathbf{Y}\mathbf{w} = 0 \end{aligned} \quad (36)$$

Supondo-se que a matriz $\mathbf{Y}^T \mathbf{Y}$ seja invertível é possível definir o vetor de pesos $\mathbf{w}$ do filtro FIR para deconvolução (DUARTE, 2016):

$$\mathbf{w} = (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y} \mathbf{a} \quad (37)$$

O resultado é uma estrutura de um filtro FIR, relativamente simples, com os coeficientes determinados por dados simulados do TileCal. No entanto, o filtro dos mínimos quadrados tem o resultado degradado na presença de *pile-up*, ao não ser capaz de tratar os termos de estatística superior provenientes do *pile-up* e serem tendenciosos aos dados fornecidos pelo simulador.

3.2.3 Filtro Adaptativo Bussgang-Sparse

Duarte (2019) ainda combinou um filtro adaptativo à representação esparsa dos dados por algoritmos gulosos (ELAD, 2010), de forma a evitar a tendência aos dados do simulador do filtro dos mínimos quadrados na aplicação do TileCal. Nessa proposta nem a informação da resposta impulsiva do canal é utilizada, e nem sinais simulados da entrada e saída do canal,

Para essa realização o problema de otimização é formulado em uma única equação sem restrições, estabelecendo-se a função de custo:

$$J(\mathbf{a}) = \lambda \|\mathbf{a}\|_1 + \frac{1}{2} \|\mathbf{H}\mathbf{a} - \mathbf{y}\|_2^2 \quad (38)$$

A função de custo se fundamenta na hipótese que o vetor de energia $\mathbf{a}$ possui a característica mais esparsa que o vetor de observação $\mathbf{y}$. Para favorecer a esparsidade é utilizada a norma l_1 do vetor de energia $\mathbf{a}$ (DUARTE, 2019), sendo sujeita ao erro quadrático entre o vetor de observações $\mathbf{y}$ e o modelo da saída do calorímetro $\mathbf{H}\mathbf{a}$. A minimização da

função de custo é obtida com a escolha do ponderador de penalidade (λ) adequado, o que caracteriza regularização.

O parâmetro λ é basicamente a quantidade de retração, que controla a influência da penalidade da norma l_1 . No caso de $\lambda = 0$, nenhum parâmetro é eliminado. A estimativa é igual à encontrada com a regressão linear. À medida que λ aumenta, mais e mais coeficientes são colocados em zero e eliminados (teoricamente, quando $\lambda = \infty$, todos os coeficientes são eliminados). À medida que λ aumenta, o viés aumenta. À medida que λ diminui, a variância aumenta. Trata-se do dilema bias-variância controlado por um parâmetro.

É possível reescrever a função de custo em termos da aproximação da pseudo inversa de $\mathbf{H}$, fazendo $\mathbf{W} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$, conforme a Equação 39 (Duarte, 2019).

$$\mathcal{J}(\mathbf{a}) = \lambda \|\mathbf{a}\|_1 + \frac{1}{2} \|\mathbf{a} - \mathbf{W}\mathbf{y}\|_2^2 \quad (39)$$

A derivada da função de custo igualada a zero permite determinar o valor mínimo da entrada desconhecida ($\mathbf{a}$), que se relaciona a esparsidade máxima:

$$\frac{d\mathcal{J}(\mathbf{a})}{d\mathbf{a}} = \lambda \mathbf{1} + (\mathbf{a} - \mathbf{W}\mathbf{y}) \frac{d(\mathbf{a} - \mathbf{W}\mathbf{y})}{d\mathbf{a}} = 0 \quad (40)$$

Da Equação 40 é definido o erro $\mathbf{e} = \mathbf{a} - \hat{\mathbf{a}} = \mathbf{a} - \mathbf{W}\mathbf{y}$, como a distorção do modelo (SERACO, 2008). Define-se também o termo residual δ , interpretado como a taxa de variação da distorção do modelo em relação a amplitude:

$$\frac{d(\mathbf{a} - \mathbf{W}\mathbf{y})}{d\mathbf{a}} = \frac{d\mathbf{e}}{d\mathbf{a}} = \delta$$

De onde se calcula:

$$\frac{d(\mathbf{a} - \mathbf{W}\mathbf{y})}{d\mathbf{a}} = 1 - \frac{d(\mathbf{W}\mathbf{y})}{d\mathbf{a}} = 1 - \mathbf{W} \frac{d\mathbf{y}}{d\mathbf{a}} \quad (41)$$

Utiliza-se o modelo da Equação 27 para definir a matriz de convolução como a derivada do vetor de observação pelo vetor de energia:

$$\frac{d\mathbf{y}}{d\mathbf{a}} = \mathbf{H} \quad (42)$$

Combinando-se as Equações 36 e 37, e em seguida substituindo $\mathbf{W}$ pela pseudo inversa $\mathbf{H}^+ = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T$, se obtém:

$$\frac{d(\mathbf{W}\mathbf{y})}{d\mathbf{a}} = \mathbf{W}\mathbf{H} \approx (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{H} = \mathbf{1} \quad (43)$$

Necessariamente tal aproximação não pode ser a igualdade, para não ocasionar uma solução trivial da função de custo da Equação 39. Vale ressaltar que somente com a ordem

infinita do vetor de entrada ($\mathbf{y}$) seria obtida a solução trivial, mas um vetor de observação de entradas infinito é impraticável, por isso, a recuperação da entrada desconhecida é limitada (DUARTE, 2019). Interpreta-se disso que sempre haverá a taxa de variação da distorção do modelo.

$$\frac{d(\mathbf{W}\mathbf{y})}{d\mathbf{a}} = \frac{d g(\mathbf{y})}{d\mathbf{a}} \neq 1$$

Como o termo residual δ ideal é próximo de zero, sem se tornar zero, é possível continuar com o tratamento da derivada da função de custo.

$$1 - \frac{d(\mathbf{W}\mathbf{y})}{d\mathbf{a}} \neq 0$$

$$\delta \neq 0$$

$$\lambda \mathbf{1} + (\mathbf{a} - \mathbf{W}\mathbf{y})\delta = 0$$

$$\lambda \mathbf{1}/\delta + (\mathbf{a} - \mathbf{W}\mathbf{y}) = 0$$

$$\frac{\lambda}{\delta} = \lambda_0$$

Define-se um parâmetro de ajuste modificado (λ_0), que é dependente da taxa de variação da distorção (δ) e do ponderador de penalidade (λ) proposto originalmente. A escolha de valores de λ maiores atribuem maior esparsidade ao modelo, mas devem ser compensados por valores de distorção δ maiores, prejudicando a preservação do modelo. Por outro lado, valores da variação de distorção δ menores, aproximam o modelo da solução trivial, mas, em contrapartida, obrigam a escolha de um valor de λ diminuído, de onde perde-se a capacidade representar a esparsidade do modelo. Caracteriza-se, portanto, um erro aproximativo como a incapacidade do modelo de realizar a regressão adequada, dependente do valor da taxa de variação da distorção (δ), e, também, um erro estimativo, que depende do ponderador de penalidade (λ), representando a não-adequação do modelo ao conjunto de dados disponíveis (HAYKIN, 2008).

Há um compromisso entre escolha do tamanho do conjunto de dados, relativo ao valor de distorção do modelo, e o valor do ponderador de penalidade para garantir que o modelo responda eficientemente. Estes valores foram escolhidos empiricamente por Duarte (2019).

A energia estimada é dada pela Equação 43, esta pode ser entendida como um filtro de convolução, caracterizado pela matriz $\mathbf{W}$, seguido de uma função não linear sem memória, referida como função Shrinkage para representar a esparsidade.


$$\hat{\mathbf{a}} = \mathbf{W}\mathbf{y} - \lambda_0 \mathbf{1} \tag{44}$$

$$\hat{a}[k] = W_{0k}y[k] - \lambda_0, \quad a[k] > 0$$

A função Shrinkage pode ser aproximada para ser utilizada apenas no argumento positivo, pois no contexto de calorimetria não se espera valores negativos, e ela consiste em um mapeamento que zera valores menores que λ_0 , logo reescreve-se a Equação 45 e representa-a na Figura 24.

$$S_{\lambda_0}(a) = \begin{cases} 0, & \text{para } \mathbf{W}\mathbf{y} \leq \lambda_0 \\ \hat{a}, & \text{para } \mathbf{W}\mathbf{y} > \lambda_0 \end{cases} \quad (45)$$


Figura 24 – Estimação da energia por representação esparsa pela função Shrinkage.



Fonte: Duarte, 2019

A abordagem esparsa pela função Shrinkage é útil para ser combinada com o modelo de equalização cega de Bussgang. Isso, pois, a proposta de Bussgang necessita de um estimador não linear sem memória. Nesse sentido, Duarte (2019) propôs a implementação da função Shrinkage como estimador do modelo de equalização cega de Bussgang, nomeando o filtro como *Bussgang-Esparse*, e o modelo do filtro é apresentado na Figura 25.

Figura 25 – Modelo de Equalização Cega por Teoria da Esparsidade.



Fonte: Duarte, 2019

A técnica cega *Bussgang-Esparse* apresenta resultados satisfatórios para a aplicação no TileCal, pois identifica os coeficientes do filtro sem a necessidade de conhecimento prévio

das características de empilhamento (também não necessita o conhecimento do pulso característico). Conhecimento este que não se dispõe ainda com total confiança por simulação, frente às inovações propostas pelo LHC. No entanto, por se tratar de um método linear, esta técnica não é capaz de corrigir não-linearidades intrínsecas do canal. Este fato motivou a busca por adaptações deste método, através da substituição do filtro FIR por estimadores não-lineares baseados em redes neurais, que possam ser treinadas *online* por essa estrutura proposta. Este foi o objetivo inicial da proposta desta tese.


3.2.4 Filtro Neural

A estrutura típica de Redes Neurais Artificiais (RNA) é feita com Alimentação Adiante (do ing. *Feedforward Artificial Neural Network*) e estabelece que os dados fluem paralelamente pelos neurônios da entrada para a saída, camada por camada, por isso, inicialmente o conceito das RNA era denominado Processamento Distribuído Paralelamente (RUMELHART, 1986). Quando o modelo de neurônio utilizado é o perceptron, a RNA é denominada Perceptron Multicamadas (MLP do ing. *Multi Layer Perceptron*). Esta técnica aplicada como filtro de deconvolução no canal do TileCal foi verificada por Faria (2017), que teve como interesse substituir o filtro FIR implementado por Duarte (2016) no modo de treinamento *offline*.

A proposta de Faria (2017) se fundamenta na possibilidade da arquitetura MLP ser utilizada para processamento de sinais através de uma linha de atraso derivada na entrada da RNA (WIDROW, 1988). Por definição os MLP reconhecem padrões estáticos, logo, para que sinais sejam processados são utilizados registradores de deslocamento para atuarem como memórias de curto prazo, de forma a permitir que padrões temporais sejam reconhecidos implicitamente, estabelecendo uma janela de observação. Quando combinados vários neurônios com a linha de memória é estabelecido um filtro não linear referido como Rede Alimentada Adiante Focada Atrasada no Tempo (do ing. FTLFN – *Focused Time Lagged Feedforward Network*) (HAYKIN, 2001).

As linhas de atraso são componentes próprios de filtros digitais, as quais determinam a quantidade de coeficientes do filtro ($p+1$), que também é referida como a ordem do filtro, tal como representado na Figura 26a. Similarmente, a utilização de uma linha de atraso em um MLP estabelece um filtro neural, apresentado na Figura 26b, que no contexto, substitui os pesos do filtro FIR.

Figura 26 – Filtro FIR (a) e Filtro Neural (b) em aplicação *online*.



Fonte: Modificado de FÁRIA, 2017.

No filtro FIR, cada um dos valores da janela de observação ($y[n - p], 0 \leq i \leq p$) é multiplicado por um coeficiente correspondente do filtro ($w_i, 0 \leq i \leq p$), cujos resultados são somados. Tal combinação linear fornece um valor estimado de energia $\hat{a}[n - \frac{p}{2}]$, que é correspondente à amostra central da janela de observação. Isso, pois, devido a forma do pulso característico do canal é mais interessante estimar a amostra central da janela de observação, mas em contrapartida é adicionada latência à filtragem, correspondente a metade da ordem do filtro ($p/2$) (FÁRIA, 2017).

O projeto do MLP depende da escolha de parâmetros do modelo, dentre os quais Faria (2017) investigou experimentalmente a quantidade de neurônios da RNA e o número de atrasos na janela de observação. A quantidade de entradas é um hiperparâmetro, e por isso, no caso do filtro neural o tamanho da janela de observação deve ser escolhido apropriadamente (WIDROW, 1988).

O MLP depende que sejam apresentados os pares de sinais de entrada/saída $\{\mathbf{y}, \mathbf{a}\}$ contendo os padrões a serem aprendidos. Faria (2017) utilizou os dados gerados pelo simulador TMC de forma a apresentar os padrões estatísticos caracterizando diferentes parâmetros ao modelo, similarmente como é realizado com os filtros adaptativos.

Os coeficientes do MLP são ajustados pelo algoritmo de retropropagação do erro (do inglês, *backpropagation*), quando os pares de sinais são fornecidos ao modelo. Comumente é escolhido o método de segunda ordem para otimização Levenberg-Marquardt (FUN, 1998), desenvolvido para resolver iterativamente problemas de minimização do erro de funções não lineares. Este algoritmo propõe uma solução de compromisso entre o algoritmo de gradiente descendente e o método iterativo de Gauss-Newton, de acordo com a Equação 46, como regra de atualização dos coeficientes do MLP (HAYKIN, 2001).


$$W^{i+1} = W^i - (J^T J + \mu I)^{-1} \nabla E^i \quad (46)$$

Sendo W a matriz dos coeficientes e i o índice da iteração no treinamento. A matriz hessiana é aproximada por $J^T J + \mu I$, onde J é o jacobiano do erro, μ é um fator de ajuste, que deve ser bem pequeno, e ∇E é o gradiente do erro médio quadrático entre o valor desejado e o resultado da RNA (HAYKIN, 2001).

É interessante repartir os dados disponíveis para parametrização do modelo, em conjuntos diferentes nomeados como: treino, validação e teste. Os dados de treinamento são utilizados para ajuste dos coeficientes, utilizando o algoritmo de otimização, como já descrito. O conjunto de validação é útil para que o modelo tenha uma boa capacidade de generalização, ou seja, evita-se que sejam obtidos bons resultados apenas para uma partição dos dados, evita-se o treinamento excessivo (*overfitting*), quando se realiza a parada antecipada. Por último o conjunto de teste é apresentado ao modelo e, portanto, é possível reconhecer a performance do modelo (BISHOP, 1995).

Utilizando o conjunto de teste é possível definir a melhor quantidade de neurônios e de nós de entrada. Faria (2017) realizou uma busca exaustiva desses parâmetros pela análise do erro médio quadrático dos dados de teste aplicados ao modelo em cada configuração treinada e validada, conforme a Figura 27 (FARIA, 2017).

Figura 27 – Performance da busca exaustiva da configuração da RNA.



Fonte: FARIA, 2017.

Conclui-se que as quantidades de nós de entrada e neurônios maiores que 4 e 10, respectivamente, aumentam a complexidade do modelo sem fornecer diminuição significativa


do erro, logo a configuração definida para a rede neural MLP foi 10-4-1, correspondentes a 10 nós de entrada, 4 neurônios e 1 neurônio de saída.

A dependência dos dados simulados é a principal desvantagem que o método apresenta, mesmo que em análises comparativas, no contexto, este tenha sido o método de menor erro. Essa desvantagem merece atenção pelo fato de a RNA poder apresentar tendência no seu aprendizado, isso, pois, seria exigido um simulador TMC muito eficiente representando corretamente todos os padrões do processo físico e apenas estes padrões. Ainda não se pode afirmar que o simulador TMC utilizado por Faria (2017) seja tão eficiente quanto a técnica exige, logo, o método de RNA para estimação da energia do TileCal apresentado é mantido em suspenso.

3.2.4.1 Interpretação dos Neurônios como Combinação de Filtros FIR

Vale apresentar uma outra perspectiva para a implementação da RNA na filtragem de sinais, na qual cada neurônio de entrada é considerado um filtro FIR linear e todos são acoplados a uma camada da RNA que os sucede, para atribuir a não linearidade ao modelo (WAN, 1990), conforme a Figura 28. Percebe-se que desta maneira há separação dos componentes lineares dos não lineares. Essa interpretação é referida como Rede Neural com Resposta Finita ao Impulso (FIRNN, do ing. *Finite Impulse Response Neural Network*) (HAYKIN, 2001).


Figura 28 – Rede Neural com Resposta Finita ao Impulso.



Fonte: Modificado de HAYKIN, 2001.

Faria e Duarte (2017) comprovaram experimentalmente tal interpretação ao concluir que os coeficientes de um dos neurônios do filtro neural convergem para os mesmos coeficientes de um filtro FIR (Figura 29), através da utilização dos dados simulados pelo TMC do TileCal. Esse neurônio é o que mais influencia o resultado do filtro neural, conforme é apresentado na tabela 2 e atua em uma região linear, conforme a Figura 30.

Figura 29 – Comparação dos coeficientes do filtro FIR e de um neurônio da RNA.




Fonte: FARIA, 2017.

Neurônio	1	2	3	4
Peso sináptico	-5,05	10,25	-7,48	1.358,23

Tabela 2 – Influência absoluta de cada neurônio representada pelo peso sináptico.

Fonte: FARIA, 2017.

Figura 30 – Mapeamento de entrada e saída de cada neurônio.



Fonte: FARIA, 2017.

Percebe-se que um neurônio realiza a filtragem linear enquanto os outros três neurônios corrigem as não-linearidades intrínsecas dos sinais. É exatamente a correção não-linear que fornece um resultado melhor da RNA quando comparada aos outros métodos de estimação de energia no TileCal.

3.3 Conclusões Parciais do Capítulo

As propostas de solução de tratamento do *pile-up* por filtros lineares, tanto para o sistema de leitura, quanto para o primeiro nível de *trigger*, apresentam menor eficiência, quando comparados aos métodos não lineares descritos.

Sumarizando os métodos apresentados para reconstrução de energia e deconvolução são reconhecidas vantagens e desvantagens. Na perspectiva de reconstrução de energia o filtro OF2 apresenta a vantagem de não depender de um banco de dados simulado e apresenta resultados estáveis, mas ao mesmo tempo apresenta excessiva dependência do pulso característico que pode ser variável e diferente. Enquanto o filtro de Wiener depende de dados simulados e apresenta menor dependência do pulso característico do canal de leitura. Ambos os filtros apresentados são lineares e, por isso, não apresentam resultados aceitáveis na presença de *pile-up*. Na perspectiva de deconvolução, as técnicas de aproximação do sistema inverso e do filtro de mínimos quadrados são sempre aproximadas e apresentam dependência de um simulador, ou do modelo matemático do pulso característico do canal. Já o filtro adaptativo Busgang-Sparse é capaz de realizar a deconvolução sem um modelo ou simulador. No entanto, os métodos de deconvolução de filtro inverso, filtro dos mínimos quadrados ou filtro Busgang-Sparse são lineares e não acessam características desejadas no canal. Por outro lado, o filtro neural é uma técnica não-linear, mas depende de um simulador para ser implementado.

Dessa forma, a possibilidade de tratamento não linear dos dados por RNA é um método relevante, mas ainda recai no problema de dependência do simulador e tem dependência da ocupação e sensibilidade a variação da linha de base do sinal. Por isso, surge o interesse de aplicação da RNA em ambos os sistemas do TileCal com menor dependência dos dados simulados.

4 MÉTODO PROPOSTO

Os algoritmos de processamento que estão sendo propostos tanto para o sistema de armazenamento de dados, quanto para o primeiro nível de *trigger* do TileCal devem considerar características não-lineares e não podem ser tendenciosos ao conjunto de treinamento simulado, conforme foi apresentado. Neste capítulo, portanto, são sugeridas propostas de processamentos não-lineares com treinamento *online*.

4.1 Filtro Neural Aplicado ao Método Bussgang-Sparse

Neste trabalho, implementou-se um filtro neural ao método Bussgang-Sparse, e, substituição ao método linear proposto por Duarte (2019), busca-se aplicar a representação esparsa ao filtro neural, combinando-o à função Shrinkage, de forma a atribuir a competência de aprendizado não supervisionado e não linearidade ao sistema de processamento de dados.

O procedimento é o mesmo desenvolvido na seção 3.2.2, mas como o filtro neural é um sistema não linear, os modelos não podem ser aproximados as matrizes de convolução e deconvolução, respectivamente, portanto, retoma-se a abordagem genérica do canal $\mathbf{y} = f(\mathbf{a})$.

O filtro deve ser a função inversa do canal de medições a partir do vetor de observações ($\mathbf{y}$), conforme a Equação 47.

$$\hat{\mathbf{a}} = f^{-1}(\mathbf{y}) = g(\mathbf{y}) \quad (47)$$

A função de custo pela sua função inversa do canal, apresentada na Equação 39 de forma a privilegiar a esparsidade, é reescrita na forma genérica:

$$\mathcal{J}_o(\mathbf{a}) = \lambda \|\mathbf{a}\|_1 + \frac{1}{2} \|\mathbf{a} - g(\mathbf{y})\|_2^2 \quad (48)$$

Define-se o erro de distorção como:

$$\mathbf{e} = \mathbf{a} - g(\mathbf{y}) = \mathbf{a} - \hat{\mathbf{a}} \quad (49)$$

A esparsidade ocorre para o $\min(\mathbf{a})$, conforme a Equação 49, que é obtida derivando a função de custo pelo vetor de energia e igualando o resultado a zero:

$$\begin{aligned} \frac{d\mathcal{J}_o}{d\mathbf{a}}(\mathbf{a}) &= 0 \\ 0 &= \lambda \mathbf{1} + (\mathbf{a} - g(\mathbf{y})) \cdot \left(1 - \frac{dg(\mathbf{y})}{d\mathbf{y}} \cdot \frac{d\mathbf{y}}{d\mathbf{a}}\right) \end{aligned} \quad (50)$$

Sendo o teorema da derivada da função inversa dado por (LEITHOLD, 1994):

$$\frac{dg(\mathbf{y})}{d\mathbf{y}} \cdot \frac{d\mathbf{y}}{d\mathbf{a}} = 1 \quad (51)$$

O resultado da derivada da função de custo é a solução trivial:

$$0 = \lambda \mathbf{1} + (\mathbf{a} - \hat{\mathbf{a}}) \cdot (1 - 1)$$

$$0 = \lambda \mathbf{1} + (\mathbf{a} - \hat{\mathbf{a}}) \cdot 0$$

$$\lambda = 0$$

Isso determina que a tentativa de aplicar a técnica de Bussgang combinada com o filtro neural não é possível. Conclui-se que, isso se deve ao fato do teorema da aproximação universal das redes neurais artificiais garantir a igualdade entre a função inversa e a função de deconvolução ($g(\cdot) = f^{-1}(\cdot)$) (HAYKIN, 2001), o que na aplicação de Bussgang não pode ocorrer. Nesse sentido, tal técnica não pode ser utilizada, sem que uma aproximação adequada seja encontrada, por isso, outro método é investigado.

4.2 Método de Parametrização Online do Filtro Neural

Conforme as especificações apresentadas, a proposta deste trabalho é desenvolver técnicas de treinamento para os filtros neurais com menor dependência dos dados simulados. Isso, pois, a simulação de sinais com *pile-up* utilizando o TMC ainda não tem sua eficiência comprovada e, combinado a isso, os resultados dos filtros neurais podem ser tendenciosos ao conjunto de treinamento (HAYKIN, 2001).

A energia depositada e o pulso característico do canal podem ser simulados pelo TMC com eficiência admissível, o que permite formar relações conhecidas entre a janela de observação do canal e amplitude de energia correspondente ($\tilde{\mathbf{y}}, \tilde{A}$), sem a simulação do efeito *pile-up*. No entanto, o filtro neural necessita da representação do *pile-up* para a reconstrução adequada de energia, logo adiciona-se a janela de observação do canal ($\tilde{\mathbf{y}}$) a janela de medição *online* ($\mathbf{y}$). Esse procedimento atribui o efeito *pile-up* ao conjunto de treinamento, sem a necessidade de simulá-lo, pois os dados de medição *online* englobam o efeito *pile-up*. Nesse caso, os dados desejados para treinamento do filtro são os dados simulados, enquanto os dados reais, medidos dos canais do calorímetro, são interpretados como ruído de fundo.


O conjunto de dados formado pela técnica proposta possui n amostras nas quais os exemplos de entrada são a soma do sinal medido ($\mathbf{y}^\sigma$), que abrange o ruído *pile-up* e o ruído

eletrônico, com o sinal simulado ($\tilde{y}$), rotulados em correspondência, as amplitudes de energia simulada ($\tilde{A}$), conforme os pares:

$$\mathcal{S} = \{(y_1^\sigma + \tilde{y}_1, \tilde{A}_1), \dots, (y_n^\sigma + \tilde{y}_n, \tilde{A}_n)\} \quad (52)$$

Isso implica que a proposta de treinamento *online* só pode ser realizada na reconstrução de energia para o sistema de aquisição, pois neste contexto a amostra desejada é apenas a amostra central da janela de medição, e as outras amostras são interpretadas como ruído. Daí propõe-se o modelo de treinamento *online* do filtro neural como apresentado na Figura 31.

Figura 31 – Modelo de treinamento e aplicação *online* do filtro neural para reconstrução de energia.



Fonte: Próprio autor.

O sinal L1A oriundo do sistema de *trigger* é utilizado como um discriminante entre a etapa de aprendizado e a atuação do filtro neural para reconstrução de energia. Na ausência do sinal L1A o sistema proposto realiza o treinamento do filtro neural atualizando seus parâmetros, e quando o sistema de *trigger* detecta um sinal de interesse a atualização dos

parâmetros é interrompida pelo sinal L1A para que o filtro neural estime a energia relativa ao sinal de interesse.

O filtro neural utilizado é o mesmo que o projetado por Faria (2017), por se tratar do mesmo contexto e o algoritmo de aprendizado utilizado também é mantido como o algoritmo Levamberg-Marquadt.

O simulador de amplitude TMC é responsável por fornecer o sinal de energia desejado ao processo de treinamento ($\tilde{A}$), isso, para caracterizar a amostra central do sistema de reconstrução de energia. Esse sinal é combinado a estimação da forma do pulso característico dos canais de leitura do TileCal ($\hat{h}$) para constituir a janela de medição correspondente ao sinal de energia simulado ($\tilde{y}$), formando os dados de treinamento *online*.

4.2.1 Aprendizado Contínuo

O método proposto pode ser entendido como um método de Aprendizado Contínuo (CL do inglês *Continual Learning*), que também é denominado por *Lifelong Learning*, *Sequential Learning* ou *Incremental Learning*, isso pois, o modelo possui a capacidade de aprender continuamente a partir de um fluxo de dados sem um fim determinado (ALJUNDI, 2019). Tal perspectiva é interessante, pois em vários problemas os dados estão sendo modificados no tempo, como é o caso das leituras do TileCal, logo o aprendizado contínuo permite o tratamento de novas distribuições de dados (PARISI, 2019).

A discriminação entre retreinamento do modelo de CL e acionamento para predição é o principal desafio para a maioria de aplicações de CL, muitas das soluções utilizadas são por periodicidade no tempo (YOCHZE, 2019). Essa questão foi facilmente solucionada na aplicação do TileCal, pela disponibilidade do sinal de *trigger*.

Define-se o aprendizado contínuo por uma configuração generalizada, em que há um fluxo infinito de dados onde, a cada passo de tempo n , o modelo recebe uma nova amostra $\{\mathbf{y}_n, \tilde{A}_n\}$, extraída de uma distribuição $\mathcal{S}$ que pode experimentar mudanças súbitas ou graduais. O objetivo principal é aprender uma função f com parâmetros θ que minimize uma função de custo $\mathcal{J}$ para as novas amostras interferindo o mínimo possível e ocasionalmente melhorando aquelas que foram aprendidas anteriormente (ALJUNDI, 2019), isso é descrito matematicamente, conforme a Equação 53.

$$\theta^n = \underset{\theta, \epsilon}{\operatorname{argmin}} \left[\mathcal{J}(f(\mathbf{y}_n, \theta^{n-1}), \tilde{A}_n) + \sum \psi_i \right] \quad (53)$$

Sendo ψ_i uma variável de tolerância para abranger um pequeno aumento de algumas perdas das amostras anteriores, que, por sua vez, poderiam afetar o aprendizado de amostras atuais.

Isso pode ser interpretado de tal modo que o custo sempre vai satisfazer a Equação 54.

$$\mathcal{J}(f(\mathbf{y}_i, \theta^i), \tilde{A}_i) \leq \mathcal{J}(f(\mathbf{y}_i, \theta^{i-1}), \tilde{A}_i) + \psi_i, \quad \forall i \in [0, \dots, n-1] \quad (54)$$

Conforme afirma Aljundi (2019) é desejável que os algoritmos de aprendizado contínuo sejam capazes de apresentar as seguintes características: Aprendizado Online, Sem Limites para as Tarefas, Tamanho de Memória Constante, Transferência de Aprendizado Adiante, Adaptabilidade, Esquecimento Seletivo de Padrões, entre outros. A literatura apresenta a principal preocupação no esquecimento de padrões anteriores (LI, 2016; LEE, 2017; KIRKPATRICK, 2017; RUSU, 2016), mas na aplicação do TileCal, pelo estudo realizado até então, não há essa preocupação, pois há uma repetição dos padrões no processo de leitura.

A maioria das aplicações de CL são para a tarefa de classificação e comumente os modelos utilizados são de redes neurais profundas, diferentemente da aplicação deste trabalho.

Craine et al. (2019) mostram a necessidade de rotulagem de agentes autônomos, sendo, portanto, fundamental o aprendizado de objetos que constituem um determinado ambiente. Dessa forma demanda-se um agente especialista externo responsável por avaliar se a representação do objeto aprendida está adequada. Além disso, é necessário ao agente autônomo obter informações sobre os objetivos fornecidos, o que geralmente é feito por uma função de recompensa, ou definido internamente por outras regras. (LAVERSANNE-FINOT et al., 2018) (SCHMIDHUBER, 2010)

Como o processo de classificação exemplificado, embora não obrigatoriamente costuma ser caro, demorado, mas consideravelmente benéficos ao processo de aprendizagem, por isso, buscam-se métodos de CL que possam superar as limitações, tentando aproveitar ao máximo os rótulos disponíveis para o aprendizado.

Para resolver esses problemas, foi proposto por FEI-FEI et al (2006) e posteriormente por LAKE et al. (2011) o método de CL few-shot learning, que consiste na tentativa em apreender um conceito a partir de poucos pontos de dados e o método de CL active learning, proposto por SETTLES (2009), que visa identificar e selecionar os rótulos mais necessários para maximizar a aprendizagem.

4.2.2 Adição de Ruído ao Conjunto de Treinamento

Os métodos de aprendizado das redes neurais artificiais são comumente definidos como aprendizado supervisionado, no qual o objetivo é mapear a relação de um conjunto com n amostras de dados de entrada $\mathbf{y} = (y_1, \dots, y_n)$, para uma saída $\mathbf{A} = (A_1, \dots, A_n)$. Deve-se definir a função de mapeamento $g: \mathcal{X} \rightarrow \mathcal{Y}$, que dê novos pares $(\mathbf{y}, g(\mathbf{y}))$, em que $\hat{\mathbf{A}} = g(\mathbf{y})$ é uma boa aproximação de $\mathbf{A}$, sendo que $g(\mathbf{y})$ foi configurado a partir de um conjunto de treinamento feito por pares $(\mathbf{y}_i, A_i)$. Denomina-se $A_i \in \mathcal{Y}$ como os rótulos (*labels*) ou objetivos, dos exemplos de entrada $\mathbf{y}_i \in \mathcal{X}$ (CHAPELLE, et al., 2009; ROELOFS, 2019).

O aprendizado não supervisionado tem como objetivo descobrir o padrão estrutural dos dados de exemplo $\mathbf{y}_i$, de forma ao aprendizado definir os rótulos A_i , sem que tenham sido apresentados (CHAPELLE, et al., 2009).

No contexto dos canais do TileCal reconhece-se que a situação ideal seria o uso de técnicas não supervisionadas, mas, até então, não foram estabelecidas as técnicas que garantam a eficiência necessária do filtro neural, na aplicação em questão, conforme foi testada e exemplificada a técnica não supervisionada da seção 4.1.

A técnica de aprendizado proposta se enquadra em uma forma intermediária ao treinamento supervisionado e ao não supervisionado, compreendida como supervisão fraca, por valer-se de invariâncias funcionais do conjunto de rótulos ou objetivos (RATNER, et al., 2017). A definição de invariância de rótulos considera que é possível adicionar ruído ao conjunto de dados, sem degradar o resultado de uma máquina de aprendizado (WU, 2020), esta técnica é conhecida na literatura de redes neurais artificiais como um dos métodos de *data augmentation*, muito comum no processamento de imagens. Novas amostras podem ser acrescentadas ao conjunto de dados artificialmente, pois a adição de ruído caracteriza um novo elemento no conjunto de dados (SHORTEN, 2019). Dentre todos métodos de *data augmentation* a adição de ruído é que menos altera o banco de dados, isso é útil no sentido de garantir que os dados sejam preservados (BAYER, 2021).

As redes neurais artificiais podem utilizar tal definição, considerando o resultado estimado $\hat{\mathbf{A}}$, dado em função dos exemplos de treinamento $\mathbf{y}$ e seus respectivos rótulos $\mathbf{A}$:

$$\hat{\mathbf{A}} = g(\mathbf{y}, \tilde{\mathbf{y}}, \tilde{\mathbf{A}}) \quad (55)$$

Sendo uma matriz de transformação linear quadrada Q ela é uma função de transformação com invariância dos rótulos se a Equação 56 for satisfeita.

$$\mathbf{y}^T \hat{\mathbf{A}} = (Q\mathbf{y})^T \hat{\mathbf{A}}, \text{ para todo } \mathbf{y} \in \mathcal{X} \quad (56)$$

Logo, valendo-se da propriedade de composição aditiva (WU, 2020) é possível escolher uma matriz Q , que permite o aumento do conjunto de dados pela adição do ruído ao conjunto, mantendo a invariância dos rótulos:

$$\mathbf{y}^{aumentado} = \tilde{\mathbf{y}} + \mathbf{y}^\sigma \quad (57)$$

Especificamente, trata-se do paradigma de programação de dados para aumento do conjunto de treinamento, ao passo que ruído é adicionado ao conjunto de exemplos sem alterar as distribuições de probabilidade da saída do modelo (RATNER, et al., 2017).

A supervisão fraca é normalmente utilizada para classificação de imagens, o que não apresenta uma relação direta a aplicação deste trabalho. No entanto, é possível afirmar que a tarefa de classificação não se distingue da regressão, quando as classes são interpretadas como contínuas ($\mathcal{Y} = \mathbb{R}$), ou seja, a quantidade de classes é aproximada ao infinito (CHAPELLE, et al., 2009). Além disso, não há dificuldade na comparação do processamento de imagens com o processamento de sinais, pois a diferença entre ambos é em termos de dimensão (COSTA, 2009).

Por esses argumentos é possível aplicar a supervisão fraca em processamento de sinais para regressão, conforme o escopo deste trabalho, e como desenvolvido pelo aumento do conjunto de dados por adição do ruído nas aplicações de separação de fontes musicais (do ing. *Music Source Separation* - MSS) (UHLICH, 2017), no reconhecimento de fala (MA, 2020) e na análise de dados de espectroscopia (SAIZ-ABAJO, 2015).

4.2.3 Técnicas de Generalização de Redes Neurais Artificiais

Um dos principais desafios para implementação das redes neurais artificiais é o *overfitting* (pode ser traduzido como sobre aprendizado, ou sobre ajuste, ou treinamento excessivo), decorrente da capacidade das RNAs aproximarem qualquer mapeamento entrada-saída, pois satisfazem o Teorema da Aproximação Universal (HAYKIN, 2001). Em contrapartida, existem diferentes alternativas para controlar o *overfitting* e garantir a generalização da RNA.

O erro de generalização (G_e) é utilizado como métrica para reconhecer o enviesamento do modelo proposto em relação aos dados do conjunto de treinamento. Adota-se a suposição probabilística de um conjunto de distribuição de dados $\mathcal{D}$ que contenha todos os pares rotulados corretamente $(\mathbf{y}, A)$. O interesse no aprendizado de máquinas é encontrar a função

do modelo (g) que reduza o risco populacional esperado em todo conjunto $\mathcal{D}$ (ROELOFS, 2019):

$$L_{\mathcal{D}}(g) = E \left[(\hat{A} - A)^2 \right] \quad (58)$$

Comumente não é conhecida toda a distribuição de dados em $\mathcal{D}$, por isso calcula-se o risco empírico no conjunto de amostra de treinamento $\mathcal{S}$ (ROELOFS, 2019):

$$L_{\mathcal{S}}(g) = \frac{1}{n} \sum_{i=1}^n (\hat{A}_i - A_i)^2 \quad (59)$$

A minimização do risco empírico ($L_{\mathcal{S}}$) permite que seja definida uma função $\hat{g}_n$, que é parametrizada pelas n amostras do conjunto de treinamento ($\mathcal{S}$). Logo, o erro de generalização é dado pela diferença da função de risco populacional pela função de risco empírico considerando a função de mapeamento $\hat{g}_n$ (ROELOFS, 2019):

$$G_e = L_{\mathcal{D}}(\hat{g}_n) - L_{\mathcal{S}}(\hat{g}_n) \quad (60)$$

Pelo fato de não ser possível avaliar $L_{\mathcal{D}}(\hat{g}_n)$, um outro conjunto de amostras é considerado $\mathcal{S}_{teste} \sim \mathcal{D}$ para estimar a perda populacional. Então é calculado o erro de generalização aproximado $\hat{G}_e$, considerando $L_{\mathcal{D}}(\hat{g}_n) \cong L_{\mathcal{S}_{teste}}(\hat{g}_n)$ (ROELOFS, 2019):

$$\hat{G}_e = L_{\mathcal{S}_{teste}}(\hat{g}_n) - L_{\mathcal{S}}(\hat{g}_n) \quad (61)$$

Devido as redes neurais artificiais aproximarem qualquer função, é possível obter $L_{\mathcal{S}}(\hat{g}_n) \cong 0$, consequentemente o erro de generalização aproximado se torna idêntico a função de risco que estima a perda populacional (ROELOFS, 2019):

$$\hat{G}_e \cong L_{\mathcal{S}_{teste}}(\hat{g}_n) \quad (62)$$

Por isso, devem ser propostas técnicas que reduzam o erro de generalização aproximado, a despeito da degradação do resultado que as RNAs fornecem para o conjunto de treinamento. Existem diferentes alternativas para garantir a generalização da RNA, a saber:

- Parada antecipada do treinamento, segundo a performance de um conjunto de validação (HAYKIN, 2001);
- Regularização da complexidade da rede neural, controlando a quantidade de parâmetros e escolhendo os menores valores para cada um (poda da rede) (HAYKIN, 2001; BISHOP, 1995).
- Adição de ruído aos dados de entrada, como forma de regularização de Tikhonov (BISHOP, 1995);

- *Overfitting* adaptativo, reutilizando dados de teste para novas etapas de treinamento (ROELOFS, 2019);
- Aumento do conjunto de dados, somando ruído ao conjunto de entrada e, portanto, utilizando os dados ruidosos e os não ruidosos (NOVAK, 2018);
- Dropout (HAYKIN, 2001);

A proposta de parametrização *online* do filtro neural utiliza, por definição, a técnica de generalização de ruído aditivo nos dados de entrada. Isso, pois, para treinamento do filtro neural os dados reais de medição são interpretados como ruído, que, por sua vez, são somados aos valores simulados de entrada com os respectivos rótulos. Portanto, percebe-se uma vantagem inerente ao método e, além disso, mais técnicas de generalização ainda podem ser combinadas ao método.

4.2.3.1 Generalização por Adição de Ruído ao Conjunto de Entrada

A generalização pela adição de ruído é considerada uma forma de regularização de Tikhonov, que considera uma função de custo modificada pela adição de um termo de penalidade Ω (BISHOP, 1995):

$$\tilde{\mathcal{J}} = \mathcal{J} + \lambda\Omega \quad (63)$$

O parâmetro λ é um ponderador de penalidade, que controla a compensação bias-variância determinando o quanto Ω afeta a minimização da função (BISHOP, 1995).

A função de custo $\mathcal{J}$, definida como o erro médio quadrático pode ser representada em uma forma geral, dependendo da densidade de probabilidade conjunta da entrada com a saída $p(\mathbf{y}, A) = p(A|\mathbf{y})p(\mathbf{y})$ (BISHOP, 1995), escrita como:

$$\mathcal{J}(g(\mathbf{y}), A) = \frac{1}{2} \sum_{i=1}^n \iint (g(\mathbf{y}_i) - A_i)^2 p(A_i|\mathbf{y}_i) p(\mathbf{y}_i) d\mathbf{y} dA \quad (64)$$

O ruído adicionado a entrada é representado por $\xi = \mathbf{y}^\sigma$, com uma função de probabilidade $\tilde{p}(\xi)$, o que torna a função de custo em:

$$\mathcal{J}(g(\mathbf{y}), A) = \frac{1}{2} \sum_{i=1}^n \iint (g(\mathbf{y}_i + \xi) - A_i)^2 p(A_i|\mathbf{y}_i) p(\mathbf{y}_i) \tilde{p}(\xi) d\mathbf{y} dA d\xi \quad (65)$$

A função da rede neural, com o ruído adicionado a entrada, é expandida em uma série de Taylor em potências de ξ (BISHOP, 1995):

$$g(\mathbf{y}_i + \boldsymbol{\xi}) = g(\mathbf{y}_i) + \sum_{i=1}^n \xi_i \left. \frac{\partial A_i}{\partial y_i} \right|_{\boldsymbol{\xi}=0} + \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \xi_i \xi_j \left. \frac{\partial^2 A_i}{\partial y_i \partial y_j} \right|_{\boldsymbol{\xi}=0} + \mathcal{O}(\boldsymbol{\xi}^3) \quad (66)$$

Por algumas considerações e integrando o ruído $\boldsymbol{\xi}$, obtém-se a expressão:

$$\tilde{\mathcal{J}} = \mathcal{J} + \eta^2 \mathcal{J}_R \quad (67)$$

Dado que η^2 é a variância do ruído adicionado e $\mathcal{J}_R$ é calculado por (BISHOP, 1995):

$$\mathcal{J}_R = \frac{1}{2} \iint \sum_{i=1}^n \sum_{j=1}^n \left[\left(\frac{\partial A_i}{\partial y_j} \right)^2 + \frac{1}{2} (g(\mathbf{y}_i) - A_i) \frac{\partial^2 A_i}{\partial^2 y_j} \right] p(A_i | \mathbf{y}_i) p(\mathbf{y}_i) d\mathbf{y} dA \quad (68)$$

A proposta de adição do ruído não apresentava o interesse de penalizar a complexidade do modelo, mas sim permitir a utilização do padrão de deposição de energia no TileCal de maneira controlada, apenas somando-se o parâmetro conhecido da amplitude energia simulada, mas a pesquisa bibliográfica permitiu concluir que o modelo é penalizar a complexidade do modelo, como uma vantagem adicional.

4.2.4 Estimação do Canal de Medição

O método de parametrização proposto depende diretamente da forma do pulso característico do canal. Há a possibilidade de duas estratégias aplicadas ao método: utilizar o pulso característico do banco de dados do ATLAS, aproximando todos os canais a uma forma geral de resposta dos canais (pulso característico aproximado $\tilde{h}$); ou ainda, aplicar métodos de identificação de sistemas para estimar o pulso característico de cada canal individualmente, como desenvolvido por Duarte (2019) (pulso característico estimado $\hat{h}$).

A utilização do pulso característico aproximado, busca prever todas as possíveis variações do sistema de leitura, e é definido após rigorosa calibração dos canais. Por outro lado, o ambiente de agressividade ao qual o sistema de leitura é exposto e a grande quantidade de canais são características que podem acarretar muita diferença entre a resposta real de cada canal individual e o pulso característico aproximado.

Mesmo com essas possíveis diferenças, a estratégia de utilizar o pulso característico aproximado ainda é válida ao método proposto, pois a vantagem de generalização que o método apresenta, implica no fato do filtro neural não ser tendencioso à forma do pulso apresentado.

As vantagens de se utilizar métodos para identificação do sistema são evidentes, ao haver a reconstituição de cada canal individualmente e a tarefa de generalização é menos

exigida do algoritmo de treinamento, mas pondera-se o aumento do custo computacional por essa estratégia.

O contexto exige a identificação cega do canal, por isso Duarte (2019) utilizou a técnica *Bussgang-Sparse* para estimar um filtro de deconvolução do canal, e sugeriu a inversão do filtro no domínio da frequência, para então obter uma estimativa do pulso característico do canal.

4.3 Conclusões Parciais do Capítulo

Foi pesquisada a técnica de aprendizado não supervisionado, que combina o filtro neural e o método *Bussgang-sparse*, mas não foram encontradas considerações satisfatórias que permitissem tal combinação.

O método proposto utiliza os dados simulados, que são rotulados para supervisão, adicionando-os aos dados fornecidos pelos canais de medição, que neste contexto são interpretados como ruído, por conterem o ruído *pile-up* e o ruído eletrônico e não portam nenhum sinal de interesse, como definido pelo comando L1A. Desta forma, diminui-se a dependência do simulador TMC, que tem menor responsabilidade no processo de treinamento. Além disso, o método ainda se torna mais independente do simulador, por ser caracterizado como uma técnica de regularização do aprendizado de máquinas, garantindo a generalização.

A necessidade de utilizar o pulso característico do canal pode ser tratada tanto utilizando informações dos canais do banco de dados do TileCal ou utilizando técnicas cegas de identificação do canal de medição, especificamente o inverso do filtro FIR obtido pela técnica *Bussgang-Esparse*.

Reconhece-se que o treinamento proposto somente pode ser realizado no sistema de aquisição de dados, pois depende do sinal de aceitação fornecido pelo *trigger* tanto para discriminar a aplicação e treinamento do filtro neural, quanto para caracterizar o ruído de fundo nas janelas de medição.

5 RESULTADOS

No intuito de avaliar o método de reconstrução de energia proposto para o TileCal, foram realizados experimentos com dados que simulam a operação do sistema. Por tanto, foi utilizado o simulador *Toy Monte Carlo*, apresentado na seção 2.5, com interesse de formar a base de dados de avaliação do método proposto.

O método proposto é comparado a outras técnicas, já avaliadas em trabalhos anteriores, para que seu desempenho possa ser confirmado. São escolhidos os métodos de filtro neural treinado com dados simulados, o método de filtros lineares dos mínimos quadrados treinado com dados simulados e o filtro adaptativo *Bussgang-Sparse* como referência comparativa.

Primeiramente são apresentadas as distribuições de probabilidade dos dados utilizados para treino e teste, respectivamente utilizados para os métodos de referência e para o método proposto. Por fim, são apresentados os resultados obtidos em cada um dos métodos.

Utiliza-se o parâmetro D^* da estatística de teste Kolmogorov-Smirnov (KS) para determinar a qualidade de ajuste dos dados gerados pelo simulador TMC, quando estes são comparados com suas distribuições de probabilidade, dos dados de referência. Trata-se de um teste não paramétrico da similaridade entre distribuições de probabilidade. O cálculo do parâmetro D^* é realizado conforme a Equação 69, que consiste na diferença absoluta entre as duas distribuições de probabilidade acumuladas, a hipotética $F(x)$ e a empírica $\hat{F}(x)$ (MASSEY, 1951).

$$D^* = \max_x (|\hat{F}(x)| - F(x)) \quad (69)$$

O valor de D^* se aproxima de zero, quanto mais próximas forem as duas distribuições de probabilidade e quanto mais amostras estiverem disponíveis para comparação (MARSAGLIA, 2003).

5.1 Banco de Dados

O banco de dados é estabelecido através de simulação, para reproduzir as distribuições de probabilidade dos sinais do TileCal, permitindo a comparação dos métodos. Alguns componentes do sinal são representados em contagem ADC negativa, mesmo que isso não seja praticável, pois teoricamente é possível tal representação.


a) Ruído eletrônico

Conforme já mencionado, o ruído eletrônico é modelado por uma distribuição de probabilidades gaussiana, com média zero e variância igual a 1 (em contagens de ADC), caracterizada pela Equação 70. A hipótese do ruído eletrônico é fundamentada no teorema do limite central, valendo-se da existência de inúmeras fontes de interferência eletrônica, logo, a soma de muitas variáveis aleatórias caracterizam a distribuição de probabilidade gaussiana (PERALVA, 2010).

$$f_{\Sigma_{\text{eletrônico}}}(\sigma_{\text{eletrônico}}) \sim N(0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{\sigma_{\text{eletrônico}}^2}{2}} \quad (70)$$

A distribuição de probabilidade gerada pelo simulador é comparada com uma distribuição ideal esperada nesse contexto, conforme é apresentado na Figura 32a, e cuja estatística de teste Kolmogorov-Smirnov obtida foi $D^* \cong 0,001$. O aspecto do sinal estocástico gerado pelo simulador é apresentado na Figura 32b, selecionando-se 100 amostras tomadas aleatoriamente.

Figura 32 – Geração do ruído eletrônico para formação do banco de dados de teste.



Fonte: Próprio autor.

b) Amplitude de energia depositada

Modela-se a energia depositada nos canais de medição ($A = E \cdot \Gamma$), para simulação do TMC, como o produto de duas variáveis aleatórias estatisticamente independentes, os níveis de energia (E) e a ocupação das amostras (Γ).

Os níveis de energia depositados pelas partículas no TileCal apresentam uma distribuição de probabilidades exponencial com média $\lambda_e = 30$ ADC, independentemente da luminosidade do acelerador, de acordo com as informações do banco de dados do LHC

(BARBOSA, 2017), logo, define-se a variável E , dos níveis de energia, com a distribuição de probabilidades:

$$f_E(\varepsilon) \sim \exp(\lambda_e) = \lambda_e e^{-\lambda_e \cdot \varepsilon} \quad (71)$$

A ocupação das amostras é definida por uma variável aleatória Γ , esta pode assumir os valores 0 ou 1, correspondendo respectivamente a vacância ou ocupação de uma amostra. A distribuição de probabilidade da variável Γ é uma distribuição de Bernoulli, cuja probabilidade de ocupação é exatamente o valor taxa de ocupação γ_{ocup} , como tratado na seção 2.4, e que deve ser definida para formar diferentes contextos de *pile-up* no banco de dados:

$$P(\gamma) = \begin{cases} \gamma_{ocup}, & \gamma = 1 \\ 1 - \gamma_{ocup}, & \gamma = 0 \end{cases} \quad (72)$$

Após manipulações matemáticas é obtida a Equação 73, que caracteriza a distribuição de probabilidades do sinal de energia.


$$f_A(a) = \begin{cases} 1 - \gamma_{ocup} \cdot (1 - \lambda_e), & a = 0 \\ \gamma_{ocup} \cdot \lambda_e \cdot e^{-\lambda_e \cdot a}, & a > 0 \end{cases} \quad (73)$$

Um conjunto de 9 gráficos representam as distribuições dos dados obtidos em relação as distribuições ideais da simulação TMC, conforme a Figura 33. Cada gráfico é caracterizado por um grau de ocupação γ_{ocup} , cujos valores de D^* obtidos também são apresentados na Figura 34.

Percebe-se da Figura 33 que a ocorrência de zeros no sinal diminui conforme a ocupação aumenta, tornando a distribuição de probabilidades uma distribuição exponencial apenas.


A Figura 34 apresenta o aspecto do sinal estocástico gerado pelo simulador, selecionando-se 25 amostras tomadas aleatoriamente.

Figura 33 – Distribuições de dados da deposição de energia para o banco de dados de teste.



Fonte: Próprio autor.

Figura 34 – Exemplos dos sinais de deposição de energia do banco de dados para teste.




Fonte: Próprio autor.

c) Amplitude do sinal medido

O canal de medição gera um sinal que é estimulado através de cada deposição de energia, modificando a forma do sinal de energia pela resposta ao impulso do canal, de forma a espalhá-lo em amplitudes menores nas amostras consecutivas, conforme já tratado em seções anteriores. Por isso, o sinal de medição não é necessariamente simulado, mas é a consequência da interação do canal com o sinal de amplitude de energia, o que caracteriza as novas distribuições de probabilidade dependendo da ocupação do sinal, conforme apresentase na Figura 35. A Figura 35 apresenta os trechos dos sinais de exemplo do sinal de medição correspondentes aos sinais de deposição de energia da Figura 36.


Nota-se que para pequenos valores de ocupação, a distribuição de probabilidades é aproximada a uma distribuição exponencial, similar aos sinais de deposição de energia, e com o aumento da ocupação a distribuição de probabilidades se aproxima de uma distribuição de probabilidades gama. O inconveniente do cálculo da distribuição de probabilidade gama teórica é o fato da média das distribuições de probabilidade exponencial serem diferentes, pois cada peso do pulso característico do canal atribui uma nova função exponencial quando há depósito de energia, o que torna o cálculo impraticável.

Figura 35 – Distribuições de dados do sinal medido para formação do banco de dados de teste.



Fonte: Próprio autor.

Figura 36 – Exemplos dos sinais de deposição de energia para banco de dados de teste.



Fonte: Próprio autor.

5.2 Dados Simulados *Online*


O método proposto utiliza o simulador TMC gerando amostras *online*, produzindo sinais que são simulados a partir de menos pressupostos estatísticos, para permitir a parametrização do aprendizado contínuo. Por essa razão, são apresentadas as distribuições de probabilidade de cada sinal do canal do TileCal e ainda os sinais produzidos para o treinamento.

a) Amplitude de energia simulada

A simulação *online* do sinal de energia é diferente da simulação para formação do banco de dados do mesmo sinal, pois no contexto *online* apenas uma amplitude é simulada, sempre na amostra central de uma janela de medição. A janela deve conter no mínimo 7 amostras, mas foi escolhido o tamanho de janela 10, conforme o trabalho desenvolvido por Faria (2017).

A Figura 37 apresenta 30 amostras tomadas aleatoriamente exemplificando 3 janelas de medição, representadas por linhas pontilhadas.

Figura 37 – Exemplo do sinal de energia gerado *online* pelo simulador.



Fonte: Próprio autor.

A preocupação com o enviesamento do método conduz a decisão que a distribuição de probabilidade da amplitude na amostra central seja uma distribuição de probabilidade uniforme, cujo valor de amplitude ($\tilde{a}$) pertence ao intervalo de 0 a 1024 ADC, que é a faixa de contagem do conversor analógico-digital. Todas as outras amostras, que não a central, são zero.

Consequentemente, a função densidade de probabilidade é dada pela Equação 74. O valor de D^* obtido nesse contexto é 0, caracterizando similaridade completa dos valores teóricos e os valores obtidos.

$$f_{\tilde{A}}(\tilde{a}) = \begin{cases} 0.9 + \left(\frac{1}{\max(\tilde{a})}\right), & \tilde{a} = 0 \\ 0.1 \frac{\tilde{a}}{\max(\tilde{a})}, & \max(\tilde{a}) \geq \tilde{a} > 0 \end{cases} \quad (74)$$


A probabilidade de ocorrência de zeros no sinal é aproximadamente 9 vezes mais elevada que a probabilidade de as amostras do sinal estarem no intervalo de zero exclusive até o valor máximo de contagem ADC. Isso ocorre por se tratar de um sinal em que apenas uma amostra de intervalos de 10 amostras terem probabilidade de ser diferente de zero.

b) Sinal de medição simulado

Similarmente ao que foi considerado na formação do banco de dados, não é realizada a análise teórica do sinal de medição simulado. Trata-se do resultado entre o sinal de energia simulado ($\tilde{a}$), em interação com a estimação do canal de leitura ($\mathbf{h}$), que no contexto atual foi

obtido pelas informações do banco de dados do ATLAS. A Figura 38 apresenta o exemplo das mesmas 3 janelas da Figura 37 após interagirem com o canal estimado.

Figura 38 – Exemplo dos valores de medição gerados *online* pelo simulador.




Fonte: Próprio autor.

A soma do sinal de medição simulado com o sinal de medição do banco de dados ($y + \tilde{y}$) e são obtidas novas distribuições de probabilidade para cada valor de ocupação conforme é representado na Figura 39. O resultado da soma é de especial interesse, pois trata-se da composição dos dados utilizados para treinamento do algoritmo de filtragem, relativas aos valores de amplitude simulados.


A Figura 40 apresenta exemplos do sinal resultante da soma, apresentando 3 janelas de medição perfazendo 30 amostras, para cada ocupação do sinal no banco de dados.

Figura 39 – Distribuições de probabilidade de $y + \tilde{y}$ por ocupação.



Fonte: Próprio autor.

Figura 40 – Exemplos das somas $y + \tilde{y}$ por ocupação.



Fonte: Próprio autor.

5.3 Análise dos Dados

No intuito de se reconhecer as características dos dados do simulador, análises são desenvolvidas do conjunto de dados.

5.3.1 Divergência dos Dados Simulados *Online* com banco de Dados

O método proposto utiliza os dados de treinamento como a composição do sinal de medição oriundo do detector e o sinal de medição simulado *online* ($y + \tilde{y}$), no entanto, os dados de treinamento são caracterizados por apenas o sinal (y), ambos os conjuntos de dados são normalizados para a mesma escala. Devido a divergência entre os dados de treino e teste, realiza-se a avaliação da divergência pelo teste KS e os valores de divergência (D^*), obtidos entre os bancos de dados são apresentados na Tabela 3 para as diferentes ocupações.

Tabela 3 – Parâmetro de divergência D^* do teste KS.

Ocupação Teste KS	10%	20%	30%	40%	50%	60%	70%	80%	90%
D^*	0,006	0,005	0,003	0,003	0,004	0,007	0,004	0,006	0,006


Em todas as ocupações aceita-se a hipótese nula com nível de significância de 5%, consequentemente os conjuntos de dados de treino e teste são caracterizados na mesma distribuição de probabilidades, mesmo com as diferentes formações.

5.3.2 Razão Sinal Ruído

A razão sinal ruído (SNR do inglês *signal to noise ratio*) é um parâmetro muito utilizado em processamento de sinais, para relacionar a potência do sinal com o ruído (COLLINS, 2016), neste sentido foi desenvolvido um algoritmo para separar os sinais empilhados e caracterizá-los como ruído.

Percebe-se da Figura 41, que conforme a ocupação do canal aumenta, caracterizando o aumento de *pile-up*, a relação sinal ruído piora.

Figura 41 – Relação da ocupação do canal com a razão sinal ruído.




Fonte: O próprio autor.

5.3.3 Desvio Padrão do Sinal

Outra análise apresenta a variação do desvio padrão em função da ocupação do sinal. A Figura 42 apresenta um gráfico que relaciona tais parâmetros. Pode-se perceber a variação do desvio padrão por ocupação e consequentemente, por nível de *pile-up*, isso caracteriza que os dados apresentam heteroscedasticidade, logo não podem ser representados por modelos lineares (FAVERO, 2018).

Figura 42 – Relação da ocupação do canal com o desvio padrão do sinal.



Fonte: Próprio autor.

5.4 Medidas de Desempenho

O método de parametrização *online* do filtro neural é comparado com os outros métodos adotando-se duas métricas: raiz do erro médio quadrático (do inglês, *Root Mean Square Error* - *RMSE*) e o erro de generalização (do inglês, *Generalization Error* - *GE*).

O RMSE é obtido entre os valores desejados e os valores estimados pelo método usado ($e[k] = A[k] - \tilde{A}[k]$). Isso, de forma a revelar a dispersão do erro com a informação da tendência na sua medida (DUARTE, 2019), sendo, portanto, definido conforme a Equação 75.

$$RMSE = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} |e[k]|^2} \quad (75)$$

O cálculo do *GE* é proposto comparando-se o resultado obtido entre os RMSEs do conjunto de treino e do conjunto de teste. Reconhece-se a existência de erro no conjunto de treino do filtro neural, pois são utilizadas técnicas de generalização no filtro neural, o que não permitiu o sobre aprendizado do conjunto de dados. Logo, é possível estimar o enviesamento dos modelos, aplicando-se a Equação 76.

$$GE = RMSE_{teste} - RMSE_{treino} \quad (76)$$

5.5 Procedimento do Experimento e Avaliação do Método Proposto

O filtro com menos enviesamento e menor erro para reconstrução de energia no sistema de leitura considerado até então é o filtro de Wiener, conforme já avaliado em trabalhos anteriores e como foi apresentado no capítulo 3. Devido ao seu desempenho, este é o filtro mais interessante para ser implementado no sistema em questão, por essa razão o filtro de Wiener é também implementado no método proposto, em substituição ao filtro neural, para que seja possível compará-lo sob as mesmas condições. Ainda é realizada a comparação do método de sintonização *online* dos dois filtros e o método tradicional de sintonização utilizando os dados simulados.

Foram definidos 450.000 pares de amostras $(\mathbf{y} + \tilde{\mathbf{y}}, A)_{treino}$ para formar o banco de dados de treino, em que este simula o funcionamento real do canal de leitura do calorímetro, compostas de 9 subconjuntos 50.000 amostras correspondentes aos graus de ocupação de 10% a 90% com passos de 10%. O conjunto de teste é definido similarmente, mas com 45.000 de

pares de amostras $(\mathbf{y}, A)_{teste}$ divididos em 18 subconjuntos de 2.500 amostras correspondentes aos graus de ocupação de 5% a 90% com passos de 5%.


Manteve-se a RNA projetado por Faria (2017), conforme se observa na Figura 27, pois como desenvolvido na seção 5.2 os conjuntos de dados mantêm as distribuições da análise realizada no seu trabalho. Além disso, neste trabalho também foi realizado o mesmo ensaio para o projeto, logo a configuração definida para a rede neural MLP foi 10-4-1, correspondentes a 10 nós de entrada, 4 neurônios e 1 neurônio de saída.

A ordem do filtro de Wiener foi mantida em 10, conforme o trabalho de Duarte (2019), em que ainda acrescenta-se um peso para caracterização de um valor de viés, cuja entrada correspondente é sempre o valor 1.

Um primeiro experimento consiste em determinar os intervalos de graus de ocupação ideais relacionados aos dados de treinamento. Para tanto, avaliam-se os resultados dos filtros para o conjunto de teste, quando os filtros são sintonizados com diferentes conjuntos de amostras de treino.

Inicialmente, os intervalos de ocupação foram definidos considerando somente amostras com 10% de ocupação, depois as amostras de 10% e 20% de ocupação, seguidas de amostras de 10% a 30% de ocupação, e assim sucessivamente até considerar as amostras de 10% a 90% ocupação. Esses intervalos são representados na Figura 43, representados apenas com o maior valor de ocupação do intervalo, no eixo das abscissas, relacionados, aos valores RMSE e GE, no eixo das ordenadas, respectivamente nas partes (a) e (b).

Figura 43 – Definição dos intervalos de ocupação para o conjunto de treinamento.




Fonte: Próprio autor.

Percebe-se da Figura 43 que é interessante explorar o intervalo de ocupações de 10% a 30%, bem como o intervalo de 10% a 40%, do banco de dados para treinamento, pois obtêm-se os menores RMSE de teste e os menores GE, quando é realizado o treinamento *online* do filtro neural.

Vale ressaltar da análise da Figura 40, que o filtro de Wiener não apresenta variações significativas do RMSE e do GE em relação aos intervalos de ocupação utilizados para sua sintonização. Essa conclusão se deve ao fato de o filtro de Wiener ser linear, mantendo esse comportamento por todo intervalo de ocupações, e com isso degenerando seus resultados linearmente com o aumento da ocupação.

Escolheu-se amostras correspondentes ao intervalo de ocupação de 10% a 30%, do conjunto de treinamento, para que fossem comparadas com os filtros utilizando os métodos de treinamento *offline*, ou seja, valendo-se do simulador.


O segundo experimento para teste do método foi realizado 10 vezes, para devido a característica aleatória de inicialização da RNA e da formação do banco de dados. Para que o paradigma de aprendizado contínuo seja atribuído ao método, o procedimento do experimento consiste na utilização de 100 amostras para treino e 10 para teste, continuamente. As 10 amostras de teste correspondem a dois níveis de ocupação, um idêntico a ocupação do treino e outro 5% menor. Este procedimento é repetido continuamente até que o banco de dados seja esgotado. Busca-se ilustrar o procedimento na Figura 44.



Fonte: Próprio autor.

A Figura 45 apresenta os resultados do filtro neural e do filtro de Wiener, quando implementados no método proposto de treinamento *online* e o método de treinamento *offline*.

Figura 45 – Avaliação dos métodos de reconstrução de energia.



Fonte: Próprio autor.

O filtro neural apresenta os melhores resultados independentemente do método, quando comparado ao filtro de Wiener, para toda faixa de ocupação do conjunto de teste. Percebe-se também que o método *offline* apresenta sempre resultados com menor erro quando se compara os mesmos filtros implementados no método *online*.

Também foi calculado o erro de generalização dos métodos em todo conjunto de dados de teste, de onde se obteve os resultados apresentados na Tabela 4.

Método Filtro	Método	
	Online	Offline
Neural	0.0365	0.2363

Tabela 4 – Valores de GE do Filtro Neural implementado no treinamento *Online* e *Offline*.

Analisando-se os resultados do filtro neural implementado em cada método de treinamento, percebe-se que o filtro neural com treinamento *offline* fornece o menor RMSE, o que permitiria enquadrá-lo como o método ideal, em comparação aos outros métodos, mas por outro lado, apenas a análise do RMSE não é suficiente. Ocorre que o desempenho atingido pelo filtro no método *offline* se deve ao fato das distribuições de treino e teste serem idênticas, o que não vai ocorrer na prática, pois trata-se de experimentos nunca realizados anteriormente

em calorimetria. Diante disso, deve-se considerar atentamente a generalização do método, mas ao contrário do desejado, nota-se que o GE do filtro neural com treinamento *offline* é o mais elevado, ou seja, o método é excessivamente enviesado ao conjunto de treinamento e, por tanto o desempenho desse filtro não é realista.

Continuando a mesma análise no método proposto neste trabalho, o caso do filtro neural com treinamento *online*, ele apresenta o RMSE sempre melhor que as aplicações com filtro de Wiener, com treinamento *online* e *offline*, e ainda é o método com menor GE, o que caracteriza que o enviesamento dessa proposta é pequeno. Essas considerações indicam que este é o melhor método, dentre os métodos analisados. Além disso, na prática, o método proposto será implementado em cada célula de medição do TileCal separadamente, respeitando o valor de ocupação instantâneo na célula, o que aumentará o desempenho do filtro neural treinado de forma *online*. Isso, pois, neste trabalho, a análise foi realizada considerando o conjunto completo de ocupações, como critério de demonstração da eficiência do método.

Os sinais relacionados à reconstrução de energia possuem uma similaridade muito elevada com os sinais relacionados a deconvolução, salvo a exclusão dos sinais não interessantes na janela de amostras para reconstrução de energia, enquanto na deconvolução todos os sinais são interessantes. Ou seja, na reconstrução de energia há a seleção de uma janela de amostras para estimar a amplitude de energia correspondente a amostra central, enquanto, no caso da deconvolução a mesma janela de amostras recebe os valores de todo o sinal incrementalmente, estimando assim, todas as amplitudes de energia do sinal. Por essa razão a distribuição de dados é muito parecida nas duas aplicações.


Devido à similaridade entre os sinais das duas aplicações, motivou-se implementar o filtro neural, que é treinado na etapa de reconstrução de energia, para realizar a deconvolução do sinal do primeiro nível de *trigger*.

Nesse contexto, foi realizada a comparação dos resultados de deconvolução obtidos do filtro neural treinado no sistema de reconstrução de energia, em relação aos resultados do filtro neural cujo treinamento é realizado *offline*, bem como, com o desempenho do filtro adaptativo *Bussgang-Sparse*, e, ainda, com os resultados filtro adaptativo com equalização *online* pelo método dos mínimos quadrados. Esses resultados são apresentados na Figura 46.

Deve-se ressaltar que o filtro adaptativo *Bussgang-Sparse* é o filtro que pode substituir o filtro linear de treinamento *offline*, pois Duarte (2019) comprova a parametrização do filtro linear, sem a necessidade dos pares de entrada e saída do filtro, logo não são mais necessários

os dados do simulador em treinamento *offline*, para que seja obtido o mesmo desempenho, por se tratar de um filtro cego.

Figura 46 – Avaliação dos métodos de deconvolução.



Fonte: Próprio autor.

Apesar de serem apresentados os desempenhos dos quatro métodos diferentes, o método do filtro neural com treinamento *offline* não é factível, pois ainda não há método de treinamento adaptativo disponível para tal contexto. Percebe-se ainda da Figura 46 que os valores RMSE na aplicação de deconvolução são muito parecidos com aqueles obtidos na Figura 45 na aplicação de reconstrução de energia, com diferenças muito pequenas, pois ao que se pode concluir, os dados mantêm o padrão de ruído e de *pile-up*, mesmo com as perspectivas diferentes sobre ambos, logo as considerações anteriores podem ser retomadas neste contexto.

Os métodos de treinamento online e o método Bussgang-Sparse são capazes de tratar as distribuições de *pile-up* que ocorrerão na prática, dentre estes o método proposto é aquele que apresenta menor RMSE, logo sugere-se que é igualmente válido para aplicação de deconvolução e reconstrução de energia.

5.7 Conclusões Parciais do Capítulo

Neste capítulo foi possível caracterizar que o método proposto é uma alternativa válida para os outros métodos apresentados tanto para a aplicação de reconstrução de energia, quanto para a deconvolução do sinal medido, ao alcançar baixos valores de RMSE e garantir uma boa generalização definida pelo baixo valor de GE, quando comparado aos outros métodos.

6 CONCLUSÃO

A proposta inicial deste trabalho foi concentrada no desenvolvimento de uma técnica de reconstrução de energia em contexto de empilhamento nos canais de medição do TileCal, de forma a diminuir a dependência de dados simulados para a parametrização de um modelo. O tema abordado visa um pré-processamento do sistema de leitura, para que os sinais armazenados caracterizem devidamente as informações de tempo e energia depositadas pelos hádrons resultantes das colisões de partículas no interior do detector ATLAS.

O contexto de deconvolução no primeiro nível de *trigger* realiza uma tarefa bastante similar a aplicação de reconstrução de energia, o que motivou a extensão da proposta inicial para este novo contexto.

Os estudos anteriores relacionados à reconstrução de energia consideraram modelos lineares e valeram-se de um simulador para fornecer dados para parametrizar cada modelo. Para a aplicação de deconvolução, foram realizados dois estudos de interesse, em que em um estudo foi considerada a utilização de uma RNA para modelar as características não-lineares dos dados, enquanto em outro estudo foi proposta a eliminação da dependência existente em relação aos dados do simulador, ao ser utilizada a técnica de equalização cega *Bussgang-Sparse*, valendo-se da característica esparsa dos dados.

Buscou-se combinar a utilização de RNA com a técnica *Bussgang-Sparse*, mas conceitualmente não foi encontrada uma adequação aceitável para implementar a combinação das técnicas. Por outro lado, a pesquisa conduziu ao paradigma intermediário entre treinamento supervisionado e não supervisionado: a supervisão fraca.

O método proposto neste trabalho apresentou vantagens interessantes, conforme comprovado matematicamente e experimentalmente, pois considerou-se menos características estatísticas para a simulação, o que torna o método menos dependente do simulador. A adição do ruído também é útil no sentido de aumentar a generalização do aprendizado da rede neural artificial e garantir o aprendizado contínuo.

Reitera-se um sumário de contribuições deste trabalho que podem ser ressaltadas:

- Aperfeiçoamento de um simulador *toy* Monte Carlo dos canais de medição do calorímetro hadrônico do experimento ATLAS.
- Desenvolvimento de um método de parametrização de filtros utilizando o paradigma do aprendizado contínuo;

- Generalização no aprendizado e regularização da complexidade de redes neurais artificiais pela adição de ruído ao conjunto de dados;
- Desdobramento de um filtro neural aplicável nos contextos de reconstrução de energia e deconvolução dos sinais oriundos dos canais do TileCal;
- Aumento da capacidade de generalização de Redes Neurais Artificiais aplicadas nos contextos de reconstrução de energia e deconvolução;

6.1 Trabalhos Futuros

A partir dos resultados e análises obtidos neste trabalho são sugeridas novas investigações para continuação da pesquisa de reconstrução de energia e deconvolução em calorímetros, além de outras aplicações do método desenvolvido.

- Exploração de técnicas de controle de complexidade no contexto de aprendizado contínuo, como a parada de aprendizado antecipada, *dropout*, *concept drift*, entre outros.
- Teste de Estabilidade dos Métodos, pois algumas alterações que ocorrem nas medições reais podem ser simuladas para serem acrescentadas aos conjuntos de treino e teste. Nesse sentido alguns parâmetros de simulação devem ser alterados para testar a estabilidade dos métodos dadas estas variações.
- Atribuir Esparsidade as Redes Neurais Artificiais, como abordado em trabalhos anteriores realizados por Duarte (2019) e Barbosa (2017), é interessante se valer da representação esparsa para o sinal de energia. Seja pela utilização da função de ativação ReLU na camada de saída, seja pelo acréscimo do termo de penalidade na função de custo, apenas na camada de saída da rede neural artificial pela norma L_1 , ou por uma função logarítmica, ou pela divergência de Kullback-Leibler em relação a uma distribuição de probabilidade que represente a esparsidade desejada.
- Desenvolver Redes Neurais Artificiais Autocodificadoras para Deconvolução de maneira a atribuir a característica não supervisionada, que é obtida pela estrutura autoassociativa, ou autocodificadora, em que as redes são referidas apenas como autoencoders. Essa estrutura é utilizada quando são dispostas apenas as amostras de entrada, sem rotulação, o que condiz com o contexto do TileCal.

- Aplicação do método em dados de outros calorímetros para avaliação da sua generalização.
- A análise do desempenho com os dados reais é outra possibilidade que permite avaliar a capacidade de generalização bem como o desempenho do algoritmo, como tem sido o objetivo da pesquisa. Destaca-se, porém, que dados reais com alto índice de empilhamento estarão disponíveis somente após o início da fase II do LHC, prevista para 2026. No entanto, propõe-se o uso de dados já armazenados de 2019 para tentar se obter indícios do aprimoramento do método em relação aos já implementados.

7 BIBLIOGRAFIA

AAD, Georges et al. **The ATLAS simulation infrastructure**. The European Physical Journal C, v. 70, n. 3, p. 823-874, 2010.

ALJUNDI, Rahaf. **Continual learning in neural networks**. arXiv preprint arXiv:1910.02718, 2019.

ANDRADE FILHO, Luciano Manhães de. **Detecção e Reconstrução de Raios Cósmicos Usando Calorimetria de Altas Energias**. 2009. Tese (Doutorado em Engenharia Elétrica) – COPPE, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2009.

ATLAS Collaboration, **Technical Design Report for the Phase-I Upgrade of the ATLAS TDAQ System**, ATLAS TDR 023, CERN-LHCC-2013-018, 2013.

____ **ATLAS Phase II Upgrade**, LHCC-F-166, CERN-LHCC-2015-020, 2015.

____ **Technical Design Report for the Phase-II Upgrade of the ATLAS Tile Calorimeter**, ATLAS TDR 028, CERN/LHCC/96-42, 2018.

____ **Technical Design Report for the Phase-II Upgrade of the ATLAS Trigger and Data Acquisition System**, ATLAS TDR 029, CERN-LHCC-2017-020, 2018.

BARBOSA, Davis Pereira. **Estimação de Energia para Calorimetria em Física de Altas Energias Baseada em Representação Esparsa**. 2017. Tese de Doutorado. Universidade Federal de Juiz de Fora.

BAYER, Markus; KAUFHOLD, Marc-André; REUTER, Christian. **A survey on data augmentation for text classification**. ACM Computing Surveys, 2021.

BRAGA, Antônio de Pádua; CARVALHO, André Carlos Ponce de Leon Ferreira; LUDERMIR, Teresa Bernarda. **Redes neurais artificiais**. 2. ed. [S.l.]: LTC Editora, 2007.

CAMPLANI, Alessandra. **ATLAS Track Trigger: On behalf of the ATLAS TDAQ collaboration**. Common ATLAS CMS Electronics Workshop, 2020.

CARRIÓ, F. et al. **The sROD module for the ATLAS tile calorimeter phase-II upgrade demonstrator**. Journal of Instrumentation, v. 9, n. 02, p. C02019, 2014.

CERN. **New Results Indicate New Particle Higgs Boson**, 2013. Disponível em: <<https://home.cern/news/news/physics/new-results-indicate-new-particle-higgs-boson>>. Acessado em junho de 2020.

CERQUEIRA, A. S.; SEIXAS, J. M.; CALOBA, L. P. **Analog system for building the first-level triggering signal provided by the hadronic calorimeter of ATLAS detector**. Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment, 2007, vol. 570, no 1, p. 117-125.

CERQUEIRA, A.S. **Tile Calorimeter Upgrade Program for the Luminosity Increasing at the LHC**. arXiv preprint arXiv:1509.08994, 2015.

CHAPELLE, Olivier; SCHOLKOPF, Bernhard; ZIEN, Alexander. **Semi-supervised learning** (chappelle, o. et al., eds.; 2006)[book reviews]. IEEE Transactions on Neural Networks, v. 20, n. 3, p. 542-542, 2009.

CHEN, Kai. **BNL Readout & Trigger/DAQ Road Map**. CPAD2017: Novo México, 2017.

COSTA, Marcus VC, João LA Carvalho, Pedro A. Berger, Alexandre Zaghetto, Adson F. Da Rocha, and Francisco AO Nascimento. **Two-dimensional compression of surface electromyographic signals using column-correlation sorting and image encoders**. In 2009 Annual International Conference of the IEEE Engineering in Medicine and Biology Society, pp. 428-431. IEEE, 2009.

CRAYE, Céline et al. Exploring to learn visual saliency: The RL-IAC approach. Robotics and Autonomous Systems, v. 112, p. 244-259, 2019.

DUARTE, João Paulo Bittencourt da Silveira. **Deconvolução Free-running Aplicada à Estimação Online de Energia na Calorimetria do ATLAS**. Tese – Universidade Federal de Juiz de Fora, 2019.

ELAD, Michael. **Sparse and redundant representations: from theory to applications in signal and image processing**. New York: springer, 2010.

FÁVERO, Luiz Paulo; BELFIORE, Patrícia. **Manual de análise de dados: estatística e modelagem multivariada com Excel®, SPSS® e Stata®**. Elsevier Brasil, 2017.

FERREIRA, Bruno Carneiro. **Deteção de Raios Cósmicos com Calorimetria de Altas Energias**. 2009. Tese (Doutorado em Engenharia Elétrica) – COPPE, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2009.

FEI-FEI, Li; FERGUS, Robert; PERONA, Pietro. One-shot learning of object categories. IEEE transactions on pattern analysis and machine intelligence, v. 28, n. 4, p. 594-611, 2006.

FUN, Meng-Hock; HAGAN, Martin T. Levenberg-Marquardt training for modular networks. In: **Proceedings of International Conference on Neural Networks (ICNN'96)**. IEEE, 1996. p. 468-473.

GALLART, Sílvia Bravo i. **Calibration and Light Yield measurements of Steelplastic scintillator calorimeters for the ATLAS detector**. Universitat Autònoma de Barcelona Departament de Física Institut de Física d'Altes Energies Edifici, Bellaterra: Barcelona, 1998.

GOFF, Fabrice Le. **DAQ in ATLAS**. On Behalf of ATLAS TDAQ, 2020. Disponível em:<<http://cds.cern.ch/record/2719417/files/ATL-DAQ-SLIDE-2020-118.pdf>>. Acessado em junho de 2020.

GONÇALVES, Guilherme I.; PERALVA, Bernardo S.; ANDRADE FILHO, Luciano M.; CERQUEIRA, Augusto S.; SEIXAS, José M. **Estimação de Energia para o Calorímetro de Telhas do ATLAS Baseada na Filtragem de Wiener-Hopf**. Anais do XXI ENMC, Búzios, 2018.

HAFFNER, J. **The CERN accelerator complex. Complexe d'accélérateurs du CERN.** Oct 2013. General Photo. Disponível em: <<https://cds.cern.ch/record/1621894>>.

HAYKIN, S. **Neural Networks: A Comprehensive Foudation**, Prentice Hall, 2001. ISBN: 9780780334946.

IZZO, Vincenzo. **ATLAS Upgrades.** The 8th Annual Large Hadron Collider Physics conference, 2020.

JG Proakis e DG Manolakis, **Digital Signal Processing: Principles, Algorithms, and Applications**, Prentice-Hall, 4^a ed., 2007.

KIRKPATRICK, J., PASCANU, R., RABINOWITZ, N., VENESS, J., DESJARDINS, G., RUSU, A. A., MILAN, K., QUAN, J., RAMALHO, T., GRABSKA-BARWINSKA, A., et. al. **Overcoming catastrophic forgetting in neural networks.** Proceedings of the national academy of sciences, 2017.

LAKE, Brenden et al. One shot learning of simple visual concepts. In: Proceedings of the annual meeting of the cognitive science society. 2011.

LAVERSANNE-FINOT, Adrien; PERE, Alexandre; OUDEYER, Pierre-Yves. Curiosity driven exploration of learned disentangled goal spaces. In: Conference on Robot Learning. PMLR, 2018. p. 487-504.

LEE, S.-W., KIM, J.-H., JUN, J., HA, J.-W., AND ZHANG, B.-T. **Overcoming catastrophic forgetting by incremental moment matching.** In Advances in neural information processing systems, 2017, pp. 4652–4662.

LENGO, Paolo. **Heavy Ions Z->ee candidate.** Nov 2010. Disponível em: <https://people.na.infn.it/~elly/TesiAtlas/SeminariAtlas/Detector/IengoAtlasCalo.pdf>. Acesso em: outubro de 2022.

LI, Z., AND HOIEM, D. **Learning without forgetting.** In European Conference on Computer Vision (2016), Springer, pp. 614–629.

LOPEZ-PAZ, David; RANZATO, Marc'Aurelio. Gradient episodic memory for continual learning. Advances in neural information processing systems, v. 30, 2017.

MA, Edward. **Data Augmentation for Audio.** 2019. Disponível em: <https://medium.com/@makcedward/data-augmentation-for-audio-76912b01fdf6>. Acesso em: Outubro de 2020.

MARSAGLIA, G., W. TSANG, and J. WANG. **Evaluating Kolmogorov's Distribution.** Journal of Statistical Software. Vol. 8, Issue 18, 2003.

MASSEY, F. J. **The Kolmogorov-Smirnov Test for Goodness of Fit.** Journal of the American Statistical Association. Vol. 46, No. 253, 1951, pp. 68–78.

MINSKY, Marvin. **Steps toward artificial intelligence.** Proceedings of the IRE, v. 49, n. 1, p. 8-30, 1961.

NOVAKOVA, Jana. **Standard Model Measurements with the ATLAS Detector: Monte Carlo Simulations of the Tile Calorimeter and Measurement of the $Z \rightarrow T T$ Cross Section**. Springer Science & Business Media, 2013.

PALKA, Marek. **Operation of the enhanced ATLAS First Level Calorimeter Trigger at the start of Run-2**. Journal of Instrumentation, v. 11, n. 02, p. C02059, 2016.

PEQUENAO, Joao **Computer Generated image of the ATLAS calorimeter**. Mar 2008. Disponível em: <https://cds.cern.ch/record/1095927>. Acesso em: abril de 2020.

_____. **Computer generated image of the whole ATLAS detector**. Mar 2008. Disponível em: <<http://cds.cern.ch/record/1095924>>. Acesso em: abril de 2020.

_____. **Event Cross Section in a computer generated image of the ATLAS detector**. Mar 2008. Disponível em: <<https://cds.cern.ch/record/1096081>>. Acesso em: abril de 2020.

PARISI, German I. et al. **Continual lifelong learning with neural networks: A review**. *Neural Networks*, v. 113, p. 54-71, 2019.

PERALVA, Bernardo Sotto-Maior. **Deteção de Sinais e Estimacao de Energia para Calorimetria de Altas Energias**. 2012. Dissertação de Mestrado, UFJF, Juiz de Fora, MG, Brasil.

PERALVA, Bernardo Sotto-Maior. **Reconstrução de Energia para Calorímetros Finamente Segmentados**. 2015. Tese de Doutorado. UFJF, Juiz de Fora, MG, Brasil.

RATNER, A. J., DE SA, C. M., WU, S., SELSAN, D., & Ré, C. **Data programming: Creating large training sets, quickly**. In *Advances in neural information processing systems*. pp. 3567-3575, 2016.

REIS, Carlos Henrique; **Otimização de Hiperparâmetros em Redes Neurais Profundas**. 2018. Monografia (Graduação em Engenharia da Computação), Universidade Federal de Itajubá, Itajubá, 2018.

ROELOFS, Rebecca. **Measuring Generalization and Overfitting in Machine Learning**. 2019. Tese de Doutorado. UC Berkeley.

RUSU, A. A., RABINOWITZ, N. C., DESJARDINS, G., SOYER, H., KIRKPATRICK, J., KAVUKCUOGLU, K., PASCANU, R., AND HADSELL, R. **Progressive neural networks**. arXiv preprint arXiv:1606.04671, 2016.

SÁIZ-ABAJO, M. J. et al. **Ensemble methods and data augmentation by noise addition applied to the analysis of spectroscopic data**. *Analytica chimica acta*, v. 533, n. 2, p. 147-159, 2005.

SÁNCHEZ, Carlos Antônio Solans. **Implementation of the ROD Crate DAQ Software for the ATLAS Tile Calorimeter and a Search for a MSSM Higgs Boson decaying into Tau pairs**, 2010. Tese (Doutorado em Física) – Universitat de València – CSIC: Valência, 2010.

_____. **The FELIX detector interface for the ATLAS TDAQ upgrades and its deployment in the ITk demonstrator**: On behalf of the ATLAS Collaboration CERN, 2019. Disponível em: <<https://cds.cern.ch/record/2674293/files/ATL-DAQ-PROC-2019-005.pdf>>. Acesso em: junho de 2020.

SETTLES, Burr. Active learning literature survey. 2009.

SILVA, Ivan Nunes; SPATTI, Danilo Hernane; FLAUZINO, Rogério Andrade. **Redes Neurais Artificiais para engenharia e ciências aplicadas curso prático**. São Paulo: Artliber, 2010.

SHORTEN, Connor; KHOSHGOFTAAR, Taghi M. **A survey on image data augmentation for deep learning**. Journal of big data, v. 6, n. 1, p. 1-48, 2019.

SOUZA, David de Melo; MENEGUIN, Candida A. D.; XAVIER, Fernando M. V.; NÓBREGA, Rafael Antunes. **Desenvolvimento de Algoritmos Computacionais para Identificação de Elétrons para o Experimento Atlas**. Principia, Juiz de Fora, v. 17, p. 107-116, 2013.

UHLICH, Stefan et al. **Improving music source separation based on deep neural networks through data augmentation and network blending**. In: 2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2017. p. 261-265.

VALERO, A. et al. **Installation and Commissioning of the TileCal Read-Out Drivers**. In: 2007 IEEE Nuclear Science Symposium Conference Record. IEEE. p. 490-493.

VAN LOAN, Charles F.; GOLUB, Gene H. **Matrix computations**. Baltimore: Johns Hopkins University Press 3ed, 1996.

VAZQUEZ, William Panduro; on behalf of the ATLAS CollaborationATLAS Experiment. **The ATLAS Data Acquisition System in LHC Run 2**, ATL-DAQ-PROC-2017-007, 2017.

WAN, Eric A., **Temporal Backpropagation: An Efficient Algorithm for Finite Impulse Response Neural Networks**. In: **Connectionist Models**. Morgan Kaufmann, 1991. p.131-137.

WIGMANS, R. **Calorimetry: Energy Measurement in Particle Physics**. 2 ed. Oxford University Press: New York, 2017.

WIELERS, Mônica. **Introduction to Trigger and Data Acquisition**. Out 2015. Disponível em: <<https://indico.cern.ch/event/518474/?print=1>>. Acesso em: junho de 2020.

WU, Sen et al. **On the Generalization Effects of Linear Transformations in Data Augmentation**. arXiv preprint arXiv:2005.00695, 2020.

YNOGUTI, Carlos Alberto. **Probabilidade, Estatística e Processos Estocásticos**. Apostilha. Universidade de São Paulo, 2011.

YUE, Xiaoguang. **Tile TDAQ interface module for the Phase-II Upgrade of the ATLAS Tile Calorimeter**. In: 2019 IEEE Nuclear Science Symposium and Medical Imaging Conference (NSS/MIC). IEEE, 2019. p. 1-4.

ZAKAREISHVILI, Tamar. **Upgrade of the ATLAS Hadronic Tile Calorimeter for the High Luminosity LHC**. ATL-COM-TILECAL-2020-016, 2020.

APÊNDICE A – Produção Bibliográfica

- **Artigos em Congressos Nacionais**

QUIRINO, T. M.; FILHO, L. M. A.; SEIXAS, J. M. **Combinando Redes Neurais Artificiais e Representação Esparsa de Dados para Reconstrução Online de Energia no Calorímetro Hadrônico do ATLAS**. Em: Simpósio Brasileiro de Telecomunicações e Processamento de Sinais 2019, Petrópolis. Simpósio Brasileiro de Telecomunicações e Processamento de Sinais, 2019.

QUIRINO, T. M.; FILHO, L. M. A.; SEIXAS, J. M. **Representação Esparsa de Dados Combinada à Redes Neurais Artificiais para Reconstrução de Energia no Calorímetro Hadrônico do ATLAS**. Em: Encontro Nacional de Física de Partículas e Campos (ENFPC), 2019, Campos do Jordão. XL Encontro Nacional de Física de Partículas e Campos (ENFPC), 2019.

- **Apresentações em grupo de pesquisa do CERN**

QUIRINO, T. M.; et. al. **Free-running Energy Reconstruction Filter Review and Pulse Shaper Circuit Model**. Em: TileCal HL-LHC Meeting, 2023.

PERALVA, B. S.; Silva, A. M.; Cerqueira, A. S. ; Dias, C. D. ; Gonçalves, G. ; SEIXAS, J. M. ; FILHO, L. M. A. ; FILHO, L. E. B. ; FARIA, M. H. M. ; QUIRINO, T. M. **Perspectivas para a Estimação de Energia do Calorímetro de Telhas do ATLAS no HL-LHC**. Em: Workshop da Rede Nacional de Física de Partículas, 2022.

QUIRINO, T. M.; et. al. **Energy Reconstruction for HL-LHC**. Em: TileCal HL-LHC Meeting, 2022.

QUIRINO, T. M.; et. al. **Updates on pedestal variation model for free-running energy deconvolution continuation**. Em: TileCal HL-LHC Meeting, 2022.

QUIRINO, T. M.; et. al. **Update on the pedestal variation model for free-running energy deconvolution**. Em: TileCal HL-LHC Meeting, 2021.

QUIRINO, T. M.; et. al. **Pedestal variation analysis for free-running energy reconstruction**. Em: TileCal HL-LHC Meeting, 2021.

QUIRINO, T. M.; et. al. **Update on free-running energy reconstruction**. Em: TileCal HL-LHC Meeting, 2021.

QUIRINO, T. M.; et. al. **Pedestal variation analysis for free-running energy Reconstruction**. Em: TileCal HL-LHC Meeting, 2021.

QUIRINO, T. M.; et. al. **Wiener filter for free-running reconstruction**. Em: TileCal HL-LHC Meeting, 2021.

QUIRINO, T. M.; et. al. **Energy Estimation in L0 Trigger**. Em: TileCal HL-LHC Meeting, 2021.

QUIRINO, T. M.; FILHO, L. M. A.; FARIA, M. H. M. **Wiener Filter to Free-Running Estimation**. Em: Workshop ATLAS-Brazil, 2021.

QUIRINO, T. M.; FILHO, L. M. A.; FARIA, M. H. M. **Energy Reconstruction in TileCal by Artificial Neural Networks with Online Learning and Application Discriminated by Trigger System**. Workshop ATLAS-Brazil, 2020.

- **Artigos submetidos para Publicação em Periódicos**

QUIRINO, T. M.; FILHO, L. M. A. **Sparse Deconvolution Method for PMTs Signals in Radiation Detectors**. Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment, 2023.