

UNIVERSIDADE FEDERAL DE JUIZ DE FORA
FACULDADE DE ENGENHARIA
PROGRAMA DE PÓS GRADUAÇÃO EM ENGENHARIA ELÉTRICA

Mariana de Souza Oliveira

**Avaliação comparativa de métodos lineares clássicos e baseados em
aprendizado de máquina para estimação de energia em calorimetria de altas
energias no regime de alta luminosidade**

Juiz de Fora

2026

Mariana de Souza Oliveira

**Avaliação comparativa de métodos lineares clássicos e baseados em
aprendizado de máquina para estimação de energia em calorimetria de altas
energias no regime de alta luminosidade**

Dissertação apresentada ao Programa de Pós
Graduação em Engenharia Elétrica da Univer-
sidade Federal de Juiz de Fora como requisito
parcial à obtenção do título de Mestra em
Engenharia Elétrica. Área de concentração:
Sistemas Eletrônicos

Orientador: Prof. Dr. Augusto Santiago Cerqueira

Coorientador: Prof. Dr. Luciano Manhães de Andrade Filho

Juiz de Fora

2026

Ficha catalográfica elaborada através do Modelo Latex do CDC da UFJF
com os dados fornecidos pela autora

Oliveira, Mariana de Souza.

Avaliação comparativa de métodos lineares clássicos e baseados em aprendizado de máquina para estimação de energia em calorimetria de altas energias no regime de alta luminosidade / Mariana de Souza Oliveira. – 2026.

96 f. : il.

Orientador: Augusto Santiago Cerqueira

Coorientador: Luciano Manhães de Andrade Filho

Dissertação (Mestrado) – Universidade Federal de Juiz de Fora, Faculdade de Engenharia. Programa de Pós Graduação em Engenharia Elétrica, 2026.

1. Estimação de Energia. 2. Calorimetria Hadrônica. 3. Aprendizado de Máquina. I. Cerqueira, Augusto Santiago, orient. II. Filho, Luciano Manhães de Andrade, coorient. III. Título.

Mariana de Souza Oliveira

Avaliação comparativa de métodos lineares clássicos e baseados em aprendizado de máquina para estimativa de energia em calorimetria de altas energias no regime de alta luminosidade

Dissertação apresentada ao Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal de Juiz de Fora como requisito parcial à obtenção do título de Mestra em Engenharia Elétrica.
Área de concentração: Sistemas Eletrônicos

Aprovada em 18 de março de 2026.

BANCA EXAMINADORA

Prof. Dr. Augusto Santiago Cerqueira - Orientador

Universidade Federal de Juiz de Fora

Prof. Dr. Luciano Manhães de Andrade Filho - Coorientador

Universidade Federal de Juiz de Fora

Prof. Dr. Rafael Antunes Nóbrega

Universidade Federal de Juiz de Fora

Prof. Dr. Eduardo Furtado de Simas Filho

Universidade Federal da Bahia

Juiz de Fora, 12/03/2026.



Documento assinado eletronicamente por **Augusto Santiago Cerqueira, Professor(a)**, em 18/03/2026, às 17:04, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Eduardo Furtado de Simas Filho, Usuário Externo**, em 18/03/2026, às 17:06, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Luciano Manhaes de Andrade Filho, Professor(a)**, em 18/03/2026, às 17:06, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



Documento assinado eletronicamente por **Rafael Antunes Nobrega, Professor(a)**, em 18/03/2026, às 17:10, conforme horário oficial de Brasília, com fundamento no § 3º do art. 4º do [Decreto nº 10.543, de 13 de novembro de 2020](#).



A autenticidade deste documento pode ser conferida no Portal do SEI-Ufjf (www2.ufjf.br/SEI) através do ícone Conferência de Documentos, informando o código verificador **2902137** e o código CRC **D4F29C24**.

Dedico este trabalho aos meus pais.

AGRADECIMENTOS

Agradeço, primeiramente, a Deus, pela vida, pela força nos momentos de dificuldade e pelas oportunidades que tornaram possível a realização deste trabalho. Em cada etapa desta jornada, Sua presença foi essencial para que eu mantivesse a fé, a coragem e a perseverança necessárias para seguir em frente.

À minha mãe e ao meu pai, Izabel e Luís, pelo amor incondicional, por me incentivarem desde criança e por sempre acreditarem em mim. Mesmo à distância, o carinho e a confiança de vocês foram fundamentais para que eu enfrentasse os desafios desta caminhada com determinação.

À minha irmã, Michele, e ao meu irmão, Luiz Henrique, pelo carinho, pela parceria e pelo incentivo ao longo de toda a minha trajetória. Saber que posso contar com vocês sempre foi uma fonte de segurança e motivação.

Às minhas sobrinhas, Stephany e Yasmin, por trazerem alegria, leveza e inspiração. Mesmo nos períodos mais intensos de trabalho e estudo, o carinho de vocês me lembrava da importância de manter o coração leve e de valorizar os momentos simples.

Ao meu namorado, Leandro, pelo companheirismo, pela paciência e pelo apoio durante esta trajetória. Obrigada por sempre me incentivar e por estar presente, tornando esse percurso mais leve e significativo.

Às minhas amigas, Aline, Paloma e Taís, pela amizade de muitos anos, pelo apoio e pelos momentos de conversa e descontração que ajudaram a equilibrar os desafios.

Aos meus orientadores, pela confiança, pelas valiosas contribuições e pelo incentivo ao longo de todo o desenvolvimento desta pesquisa.

À CAPES (Coordenação de Aperfeiçoamento de Pessoal de Nível Superior), pelo apoio e incentivo à pesquisa.

A realização deste trabalho representou um desafio particular ao exigir a conciliação entre as atividades profissionais e as demandas da pesquisa acadêmica. Ao longo dessa jornada, aprendi também sobre autonomia, disciplina e resiliência. Ainda assim, o apoio, o carinho e a presença de cada um de vocês — mesmo que à distância — foram fundamentais para que esta conquista se tornasse possível.

Por fim, agradeço a todos que, direta ou indiretamente, contribuíram para a realização deste trabalho.

“Paixão e perseverança são essenciais para realizar qualquer coisa que valha a pena.”
(DUCKWORTH, 2016).

RESUMO

Esta dissertação investiga o problema de estimação de energia em calorimetria hadrônica de altas energias no contexto do Calorímetro Hadrônico de Telhas (*Tile Calorimeter* – TileCal) do experimento ATLAS, com ênfase nas condições operacionais associadas ao regime de Alta Luminosidade do Grande Colisor de Hádrons (*High-Luminosity Large Hadron Collider* – HL-LHC). O objetivo do trabalho é avaliar comparativamente o desempenho de métodos lineares clássicos e de modelos baseados em aprendizado de máquina para reconstrução da amplitude de pulsos digitalizados em presença de ruído eletrônico e superposição temporal de sinais (*pile-up*). Para isso, o problema é formulado como uma tarefa de estimação de amplitude a partir de janelas temporais contendo amostras discretizadas do sinal. Foi utilizada uma base sintética gerada por simulador de canal de leitura, com variação controlada da ocupação, formação do sinal por convolução com pulso característico do detector e adição de ruído gaussiano. Sobre essa base, foram implementados e avaliados quatro estimadores: Filtro de Wiener, Perceptron Multicamadas (*Multilayer Perceptron* - MLP), Regressão por Vetores de Suporte (*Support Vector Regression* - SVR) com núcleo radial e Rede Neural Convolucional (*Convolutional Neural Network* - CNN) unidimensional. A comparação foi realizada por meio de métricas de erro, resolução relativa, viés, coeficiente de determinação e análise ROC, considerando diferentes regimes de ocupação. Os resultados mostram que o aumento de *pile-up* degrada sistematicamente o desempenho de todos os métodos avaliados. Em regimes de baixa ocupação, o Filtro de Wiener apresenta desempenho competitivo, com baixa complexidade e boa aderência ao modelo de pulso aproximadamente isolado. Em condições mais severas, os métodos não lineares mostram maior capacidade de adaptação às distorções induzidas pela sobreposição temporal, com destaque para a CNN em regimes mais elevados de ocupação. Conclui-se que a escolha do estimador mais adequado depende do compromisso entre qualidade de reconstrução, robustez estatística e viabilidade computacional, sendo os modelos baseados em aprendizado de máquina alternativas promissoras para cenários de alta luminosidade no TileCal.

Palavras-chave: calorimetria hadrônica; estimação de energia; TileCal; *pile-up*; aprendizado de máquina.

ABSTRACT

This dissertation investigates the problem of energy estimation in high-energy hadronic calorimetry in the context of the ATLAS Tile Calorimeter (TileCal), with emphasis on the operating conditions expected for the High-Luminosity Large Hadron Collider (HL-LHC) regime. The main objective is to comparatively evaluate the performance of classical linear methods and machine-learning-based models for reconstructing pulse amplitudes from digitized samples in the presence of electronic noise and temporal signal superposition (*pile-up*). To this end, the problem is formulated as an amplitude estimation task using short temporal windows of discretized signal samples. A synthetic dataset generated by a readout-channel simulator was employed, with controlled occupancy variation, signal formation through convolution with the characteristic detector pulse, and additive Gaussian noise. Four estimators were implemented and evaluated on this basis: Wiener filter, Multilayer Perceptron (MLP), Support Vector Regression (SVR) with radial basis function kernel, and one-dimensional Convolutional Neural Network (CNN). The comparison was carried out using error metrics, relative resolution, bias, coefficient of determination, and ROC analysis under different occupancy regimes. The results show that increasing *pile-up* systematically degrades the performance of all evaluated methods. In low-occupancy regimes, the Wiener filter remains competitive due to its low complexity and good adherence to the approximately isolated-pulse model. Under more severe conditions, nonlinear methods exhibit greater adaptability to distortions caused by temporal overlap, with the CNN standing out in higher-occupancy regimes. It is concluded that the most suitable estimator depends on the trade-off among reconstruction quality, statistical robustness, and computational feasibility, and that machine-learning-based approaches constitute promising alternatives for high-luminosity TileCal operating scenarios.

Keywords: hadronic calorimetry; energy estimation; TileCal; pile-up; machine learning.

LISTA DE ILUSTRAÇÕES

Figura 1 – Vista aérea com indicação aproximada do anel do LHC e da localização dos principais experimentos.	16
Figura 2 – Ilustração esquemática da superposição temporal de sinais (<i>pile-up</i>) em uma janela de amostragem.	17
Figura 3 – Ilustração conceitual associada ao Modelo Padrão das Partículas Elementares.	22
Figura 4 – Cadeia de aceleradores do CERN, ilustrando os estágios de pré-aceleração até a injeção no LHC.	26
Figura 5 – Diagrama do anel do LHC indicando os principais experimentos instalados nos pontos de interação.	28
Figura 6 – Esquemático do detector ATLAS.	29
Figura 7 – Vista em corte dos principais subsistemas do ATLAS.	29
Figura 8 – Layout das células TileCal.	31
Figura 9 – Vista em corte do TileCal.	32
Figura 10 – Esquema de um módulo do TileCal, ilustrando as placas de aço, as telhas cintiladoras e o sistema de leitura óptica.	33
Figura 11 – Arquitetura do sistema de <i>Trigger</i> e Aquisição de Dados (TDAQ) do ATLAS.	35
Figura 12 – Linha do tempo da operação do LHC, indicando os períodos de <i>Run</i> e as <i>Long Shutdowns</i> , incluindo a transição para o HL-LHC.	36
Figura 13 – Exemplo esquemático de uma janela temporal centrada, composta por $N = 7$ amostras igualmente espaçadas, destacando a amostra central associada ao depósito de energia de referência.	42
Figura 14 – Exemplo conceitual do sinal de referência (<i>truth</i>): depósitos de energia por amostra como sequência esparsa de impulsos com amplitudes aleatórias.	67
Figura 15 – Pulso característico $h[n]$ utilizado na simulação, discretizado a 40 MHz e normalizado no pico.	68
Figura 16 – Trecho ilustrativo do sinal simulado $r[n]$ e do <i>truth</i> $s[n]$ correspondente.	69
Figura 17 – Trecho do sinal simulado no modo de <i>bunch train</i> , mostrando o sinal simulado $r[n]$ e a sequência de depósitos $s[n]$	70
Figura 18 – Comparação da raiz do erro médio quadrático (RMSE) e do tempo de treinamento para diferentes valores do parâmetro ε no SVR com núcleo RBF e $\rho = 60$	78
Figura 19 – Curvas de perda (MSE) durante o treinamento da CNN para o cenário com ocupação de 60%.	79

Figura 20 – Evolução da raiz do erro médio quadrático (RMSE) em função da ocupação para os métodos Wiener, MLP, SVR e CNN. Observa-se degradação global do desempenho com o aumento de <i>pile-up</i> , com diferenças entre os estimadores tornando-se mais pronunciadas em regimes de maior ocupação.	81
Figura 21 – Evolução da resolução relativa em função da ocupação para os métodos Wiener, MLP, SVR e CNN. O aumento da ocupação tende a ampliar a dispersão relativa do erro, refletindo a maior dificuldade de reconstrução sob intensificação do <i>pile-up</i>	82
Figura 22 – Diagramas <i>hexbin</i> da energia estimada em função da energia de referência para os métodos Wiener, MLP, SVR e CNN, considerando ocupações de $\rho = 10\%$ e $\rho = 80\%$. A linha tracejada representa a correspondência ideal entre a energia estimada e a energia de referência.	83
Figura 23 – Distribuições do erro relativo da energia estimada, comparando os métodos de Wiener, MLP, SVR e CNN. O aumento da ocupação de $\rho = 10\%$ para $\rho = 70\%$ provoca alargamento das distribuições, indicando degradação da precisão sob maior <i>pile-up</i>	85
Figura 24 – Curvas ROC obtidas a partir da reinterpretação da tarefa de estimação como problema de detecção binária da presença de depósito de energia na amostra central. As curvas utilizam a energia estimada como escore contínuo de decisão.	87

LISTA DE TABELAS

Tabela 1 – Resumo dos hiperparâmetros selecionados por ocupação para os modelos MLP, SVR e CNN.	80
Tabela 2 – Resumo do desempenho dos estimadores em ocupações representativas.	81

LISTA DE ABREVIATURAS E SIGLAS

CERN	Organização Europeia para a Pesquisa Nuclear
LHC	Large Hadron Collider
HL-LHC	High-Luminosity Large Hadron Collider
ATLAS	A Toroidal LHC ApparatuS
CMS	Compact Muon Solenoid
ALICE	A Large Ion Collider Experiment
LHCb	Large Hadron Collider beauty experiment
LEP	Large Electron-Positron Collider
PMT	Photomultiplier Tube
TileCal	Tile Calorimeter
TDAQ	Trigger and Data Acquisition
OF	Optimal Filter
MLP	Multilayer Perceptron
SVM	Support Vector Machine
SVR	Support Vector Regression
CNN	Convolutional Neural Network
MSE	Mean Squared Error
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
ROC	Receiver Operating Characteristic
AUC	Area Under the Curve
TPR	True Positive Rate

LISTA DE SÍMBOLOS

E	Energia da partícula
m	Massa da partícula
c	Velocidade da luz no vácuo
p_T	Momento transversal
μ	Número médio de interações por cruzamento de feixe (pile-up)
$\mathcal{L}$	Luminosidade instantânea do feixe
σ	Seção de choque de interação
B	Intensidade do campo magnético
R	Raio de curvatura da trajetória
A	Amplitude do pulso reconstruído
$\hat{A}$	Estimativa da amplitude
$r[n]$	Sinal observado digitalizado
$s[n]$	Sinal verdadeiro
σ_n	Desvio padrão do ruído
ε	Parâmetro de insensibilidade do SVR

SUMÁRIO

1	INTRODUÇÃO	16
1.1	MOTIVAÇÃO	17
1.2	OBJETIVOS	19
1.3	ESTRUTURA DA DISSERTAÇÃO	19
2	FUNDAMENTAÇÃO TEÓRICA E O AMBIENTE EXPERIMENTAL	21
2.1	FÍSICA DE PARTÍCULAS	21
2.2	ACELERADORES DE PARTÍCULAS	23
2.3	O CERN E A INFRAESTRUTURA DE GRANDES EXPERIMENTOS	25
2.4	O GRANDE COLISOR DE HÁDRONS - LHC	26
2.5	O EXPERIMENTO ATLAS	28
2.6	O <i>TILE CALORIMETER</i> (TILECAL)	31
2.7	O SISTEMA DE <i>TRIGGER</i> DO ATLAS	34
2.8	ATUALIZAÇÕES DO LHC E DO ATLAS: DA <i>RUN 1</i> AO HL-LHC	36
3	MÉTODOS DE ESTIMAÇÃO DE ENERGIA	39
3.1	MODELAGEM DO SINAL NO TILECAL	39
3.2	RECONSTRUÇÃO JANELADA E DECISÃO POR EVENTO	41
3.3	FILTRO ÓTIMO (OF)	44
3.4	FILTRO DE WIENER	48
3.5	PERCEPTRON MULTICAMADAS (MLP)	52
3.6	MÁQUINAS DE VETORES DE SUPORTE (SVM/SVR)	58
3.7	REDES NEURAIS CONVOLUCIONAIS (CNN)	62
4	METODOLOGIA EXPERIMENTAL E AVALIAÇÃO DE DESEMPENHO	66
4.1	Base de Dados e Configuração Experimental	66
4.2	Implementação dos Estimadores de Energia	70
4.2.1	Filtro de Wiener	71
4.2.2	Perceptron Multicamadas (MLP)	72
4.2.3	Regressão por Vetores de Suporte (SVR)	72
4.2.4	Rede Neural Convolucional	73
4.3	Métricas de Desempenho	75
5	RESULTADOS E DISCUSSÃO	78
5.1	Seleção de hiperparâmetros e comportamento do treinamento	78
5.2	Desempenho global em função da ocupação	80
5.3	Análise qualitativa das estimativas	83
5.4	Síntese dos resultados	85
6	CONCLUSÕES	89


REFERÊNCIAS	92
-----------------------	----

1 INTRODUÇÃO

A reconstrução precisa de grandezas físicas a partir de sinais eletrônicos digitalizados constitui um dos desafios centrais em experimentos modernos de Física de Altas Energias. Em detectores de grande porte, altamente segmentados e operando sob elevadas taxas de eventos, a estimação confiável de parâmetros físicos — como energia, momento e tempo de chegada — depende diretamente da capacidade de modelar e processar sinais complexos, frequentemente afetados por ruído eletrônico e sobreposição temporal de contribuições distintas (HANAGAKI et al., 2023).

No contexto do Grande Colisor de Hádrons (*Large Hadron Collider – LHC*), localizado no CERN, em Genebra (Figura 1), colisões próton–próton ocorrem a intervalos de 25 ns, gerando um volume massivo de dados que deve ser adquirido, processado e filtrado em tempo real. Esse ambiente impõe restrições simultâneas de alta precisão, robustez estatística e eficiência computacional, especialmente nos sistemas responsáveis pela reconstrução *online* e pelas decisões associadas ao *trigger*, que devem operar sob limites estritos de latência e com comportamento temporal determinístico.

Figura 1 – Vista aérea com indicação aproximada do anel do LHC e da localização dos principais experimentos.




Fonte: Adaptado de CERN (2020).

Entre os experimentos instalados no LHC, o ATLAS (*A Toroidal LHC Apparatus*) destaca-se como um detector de propósito geral projetado para medir, com elevada precisão, as propriedades das partículas produzidas nas colisões. Em sua arquitetura, os sistemas de calorimetria desempenham papel central na estimação da energia das partículas incidentes, convertendo depósitos de energia em sinais elétricos cuja amplitude deve ser reconstruída a partir de amostras digitalizadas (ATLAS Collaboration, 2017).

A precisão dessa reconstrução depende não apenas da instrumentação eletrônica, mas também dos métodos de processamento digital de sinais empregados na estimação da amplitude dos pulsos registrados. Em condições ideais, nas quais a contribuição dominante provém de uma única interação por janela de amostragem, métodos lineares clássicos, baseados em propriedades estatísticas de segunda ordem dos sinais, apresentam desempenho satisfatório.

Entretanto, o aumento progressivo da luminosidade do LHC — grandeza que quantifica a taxa de colisões produzidas por unidade de tempo — altera de forma significativa o regime estatístico de operação, elevando a taxa média de interações por intervalo de amostragem e, conseqüentemente, a probabilidade de superposição temporal de sinais provenientes de diferentes eventos. Esse efeito intensifica o fenômeno de empilhamento de sinais (*pile-up*, ilustrado na Figura 2) e impõe novos desafios à reconstrução precisa da energia.

Figura 2 – Ilustração esquemática da superposição temporal de sinais (*pile-up*) em uma janela de amostragem.



Fonte: Extraído de ANDRADE FILHO et al. (2015).

1.1 MOTIVAÇÃO

A transição do LHC para o regime de Alta Luminosidade (*High Luminosity Large Hadron Collider – HL-LHC*) implica um aumento substancial do parâmetro μ , que representa o número médio de interações próton–próton produzidas em um mesmo cruzamento de feixes. Para o HL-LHC, são projetados valores de μ da ordem de 200 (ALONSO et al., 2023).

Esse cenário resulta em uma ocupação média significativamente superior à observada em períodos anteriores de operação do LHC. Neste trabalho, o termo ocupação é utilizado

para indicar a fração de amostras temporais que contêm depósitos de energia não nulos no canal simulado. O aumento dessa ocupação intensifica a probabilidade de superposição temporal entre pulsos, modifica a estrutura de correlação das amostras digitalizadas e pode introduzir vieses na estimação da amplitude.

No Calorímetro Hadrônico de Telhas (*Tile Colorimeter* – TileCal), um dos sub-detectors do experimento ATLAS, a estimação da energia baseia-se na reconstrução da amplitude de pulsos digitalizados a partir de um conjunto discreto de amostras igualmente espaçadas no tempo. Em regimes de baixa ocupação, nos quais a hipótese de pulso isolado é razoável, métodos lineares clássicos de processamento digital de sinais, fundamentados em estatísticas de segunda ordem, apresentam desempenho adequado. Além disso, esses métodos oferecem baixa complexidade computacional e comportamento determinístico, características relevantes para aplicações de reconstrução *online* (GONÇALVES et al., 2022).

Entretanto, em regimes de alta ocupação, a superposição sistemática de múltiplos pulsos dentro da janela de amostragem torna-se a condição nominal de operação. A presença simultânea de contribuições temporais deslocadas modifica a forma efetiva do sinal observado e altera sua estrutura de correlação, reduzindo a eficácia de estimadores formulados sob hipóteses de dominância de um único pulso por janela e linearidade estrita do modelo de reconstrução.

Nesse contexto, o Filtro de Wiener (WIENER, 1949) é adotado como representante da classe de métodos clássicos lineares fundamentados em estatísticas de segunda ordem, tradicionalmente empregados em problemas de reconstrução de sinais em calorimetria. Ao minimizar o erro quadrático médio com base na estrutura de correlação observada, o método permite incorporar explicitamente informações estatísticas do processo de medição. Contudo, sua estrutura permanece restrita a combinações lineares das amostras digitalizadas.

Em cenários caracterizados por forte *pile-up*, a sobreposição temporal de pulsos e possíveis variações instrumentais podem induzir dependências que não são completamente capturadas por modelos lineares. Nesse sentido, métodos baseados em aprendizado de máquina, em particular abordagens supervisionadas treináveis a partir de dados, têm sido investigados na Física de Altas Energias como alternativas para problemas de reconstrução em ambientes estatisticamente complexos (RADOVIC et al., 2018). Ao ampliarem o espaço funcional de estimação, tais abordagens possibilitam modelar relações não lineares entre as amostras temporais e a energia depositada.

A adoção de modelos mais flexíveis deve ser avaliada à luz de restrições operacionais concretas, incluindo estabilidade numérica, interpretabilidade e viabilidade computacional, especialmente quando se considera sua eventual aplicação em cadeias associadas ao sistema de filtragem *online* do ATLAS (*trigger*). Dessa forma, impõe-se a necessidade de uma

avaliação comparativa rigorosa entre um estimador linear estatisticamente fundamentado, representado neste trabalho pelo Filtro de Wiener, e modelos supervisionados não lineares, sob condições compatíveis com o regime operacional previsto para o HL-LHC. Tal análise deve considerar não apenas métricas de erro, mas também robustez sob diferentes níveis de ocupação e custo computacional de inferência.

1.2 OBJETIVOS

O presente trabalho tem como objetivo investigar o desempenho de métodos avançados de estimação de energia aplicados ao TileCal em condições compatíveis com o regime de alta luminosidade previsto para o HL-LHC. A análise concentra-se na comparação entre um estimador linear estatisticamente fundamentado — representado pelo Filtro de Wiener — e modelos supervisionados não lineares, avaliando seu comportamento sob diferentes níveis de ocupação e sobreposição temporal de sinais.

Especificamente, busca-se modelar o problema de reconstrução de energia como um processo de estimação de amplitude a partir de amostras digitalizadas sujeitas a ruído e *pile-up*, implementar o Filtro de Wiener como referência linear para o regime de alta ocupação e desenvolver modelos baseados em aprendizado de máquina capazes de capturar dependências temporais potencialmente não lineares induzidas pela superposição de pulsos.

A avaliação comparativa considera não apenas métricas quantitativas de erro, mas também robustez estatística e custo computacional de inferência, de modo a analisar a viabilidade de aplicação dos métodos estudados em ambientes associados ao sistema de *trigger* do ATLAS. Dessa forma, este trabalho busca identificar em que condições abordagens não lineares oferecem vantagens efetivas em relação ao estimador linear de referência, contribuindo para a discussão sobre estratégias de reconstrução de energia no cenário operacional do HL-LHC.

1.3 ESTRUTURA DA DISSERTAÇÃO

Esta dissertação está organizada de forma a conduzir o leitor desde os fundamentos físicos e instrumentais do problema até a análise comparativa dos métodos de estimação de energia investigados.

O Capítulo 2 apresenta a fundamentação teórica e o ambiente experimental no qual o problema está inserido. Inicialmente, são discutidos aspectos gerais da Física de Partículas e da Física de Altas Energias, seguidos de uma descrição da infraestrutura de aceleração do CERN e das características operacionais do LHC. Logo depois, detalha-se a arquitetura do experimento ATLAS, com ênfase no sistema de calorimetria e no TileCal, incluindo a formação, conformação e digitalização do pulso eletrônico, bem como os efeitos associados ao regime de alta luminosidade.

O Capítulo 3 aborda os fundamentos teóricos dos métodos de estimação considerados neste trabalho. São apresentados os princípios do Filtro de Wiener como estimador linear de referência, bem como os conceitos centrais relacionados aos modelos baseados em aprendizado de máquina não lineares empregados na análise comparativa.

No Capítulo 4 é descrita a metodologia experimental adotada, incluindo a base de dados utilizada, os procedimentos de pré-processamento, a configuração dos modelos implementados e as métricas de avaliação empregadas para a comparação entre as abordagens.

O Capítulo 5 apresenta e discute os resultados obtidos, analisando o desempenho dos métodos sob diferentes níveis de ocupação, avaliando sua robustez estatística e o custo computacional associado.

Por fim, o Capítulo 6 reúne as conclusões do trabalho, sintetiza as principais contribuições e aponta possíveis direções para investigações futuras no contexto da reconstrução de energia em regimes de alta luminosidade.

2 FUNDAMENTAÇÃO TEÓRICA E O AMBIENTE EXPERIMENTAL

A estimação de energia em calorimetria de altas energias está diretamente ligada à capacidade de converter sinais eletrônicos digitalizados em grandezas físicas com precisão e estabilidade, em um ambiente experimental caracterizado por alta taxa de eventos, radiação e limitações estritas de latência. No contexto do ATLAS, e em particular do *Tile Calorimeter* (TileCal), essa tarefa envolve compreender a cadeia completa que vai desde os princípios físicos que motivam os experimentos de colisão até os detalhes instrumentais de formação, conformação e digitalização do pulso, além das restrições impostas pelos sistemas de aquisição e seleção de eventos.

Este capítulo consolida os fundamentos necessários para situar o problema investigado nesta dissertação. Inicia-se com uma síntese de Física de Partículas e com a motivação para explorar regimes de altas energias, estabelecendo a conexão com experimentos de colisão. Em seguida, apresentam-se os princípios de funcionamento de aceleradores de partículas e o papel do CERN como infraestrutura que viabiliza a cadeia de pré-aceleração e a operação do LHC.


A partir desse ponto, o texto progride do ambiente de aceleração para o experimento: descrevem-se as características do LHC relevantes para a operação dos detectores, a arquitetura do ATLAS e seus subsistemas. Na sequência, discute-se a calorimetria do ATLAS com ênfase no TileCal, incluindo a formação, conformação e digitalização do pulso eletrônico, bem como o impacto do *pile-up* na reconstrução de energia. Por fim, apresentam-se o sistema de *trigger* do ATLAS e o panorama das fases de operação e atualização do LHC e do ATLAS, culminando no cenário do HL-LHC, no qual a elevação de luminosidade impõe requisitos mais severos à estimação de energia.

2.1 FÍSICA DE PARTÍCULAS

A Física de Partículas é o ramo da física que investiga os constituintes mais elementares da matéria e as interações fundamentais responsáveis pela dinâmica dos sistemas físicos em escalas subatômicas. Seu objetivo é compreender a estrutura básica da matéria, identificar as partículas elementares que a compõem e descrever, por meio de modelos teóricos, as forças que governam suas interações (THOMSON, 2013). A teoria atualmente aceita para essa descrição é o Modelo Padrão das Partículas Elementares (Figura 3), que organiza as partículas em férmions, associados à constituição da matéria, e bósons mediadores, responsáveis pelas interações fundamentais conhecidas (PARTICLE DATA GROUP, 2022).

O estudo da Física de Partículas é motivado não apenas pela busca por uma descrição mais completa da natureza, mas também pela necessidade de testar as limitações dos modelos teóricos existentes. Embora o Modelo Padrão tenha obtido notável sucesso na

Figura 3 – Ilustração conceitual associada ao Modelo Padrão das Partículas Elementares.



Fonte: Extraído de ABDALLA (2019).

descrição de uma ampla gama de fenômenos experimentais, ele não responde a questões fundamentais, como a natureza da matéria escura, a origem das massas das partículas ou a unificação das interações. Essas lacunas motivam a realização de experimentos cada vez mais precisos e a exploração de regimes de energia mais elevados, nos quais novas partículas ou desvios sutis das previsões teóricas podem se manifestar (ELLIS, 2020).

Do ponto de vista experimental, o estudo da Física de Partículas impõe desafios significativos, uma vez que muitas das partículas de interesse possuem tempos de vida extremamente curtos ou massas elevadas, impossibilitando sua observação direta. Como consequência, suas propriedades devem ser inferidas indiretamente a partir da análise dos produtos finais das interações fundamentais, em especial processos de espalhamento e decaimento governados pelas interações forte, eletromagnética e fraca. Essa inferência exige a reconstrução detalhada dos eventos físicos a partir das informações experimentais associadas aos produtos dessas interações (PARTICLE DATA GROUP, 2022).

Nesse contexto, a energia assume papel central como uma das principais grandezas observáveis em experimentos de Física de Partículas. A correta estimativa da energia associada aos produtos das interações é fundamental para a reconstrução cinemática dos eventos físicos, para a identificação dos processos envolvidos e para a separação entre sinais de interesse e contribuições de fundo. Incertezas ou distorções nessa estimativa impactam diretamente a sensibilidade dos experimentos e a confiabilidade das conclusões físicas extraídas dos dados (THOMSON, 2013).

A Física de Altas Energias constitui um desdobramento natural da Física de Partículas, concentrando-se no estudo das interações fundamentais em regimes de energia cada vez mais elevados. O aumento da energia disponível nos processos de interação permite acessar escalas de comprimento progressivamente menores, tornando possível sondar a estrutura da matéria em níveis mais profundos. Sob a ótica quântica, energias mais altas correspondem a sondagens mais finas da estrutura espacial dos sistemas físicos, ampliando a sensibilidade experimental a novos estados e fenômenos (THOMSON, 2013).

Em experimentos de Física de Altas Energias, a energia das partículas incidentes é convertida em massa e momento dos produtos finais das interações, de acordo com o princípio da equivalência massa-energia, $E = mc^2$ (EINSTEIN, 2014). Dessa forma, a observação de novas partículas ou de estados massivos depende diretamente da energia disponível no sistema. Além disso, muitos processos de interesse apresentam seções de choque extremamente pequenas, exigindo não apenas altas energias, mas também elevadas taxas de interação para que um número estatisticamente significativo de eventos possa ser observado (PARTICLE DATA GROUP, 2022).

A obtenção dessas informações experimentais requer a produção controlada de interações em regimes de energia suficientemente elevados e com taxas adequadas à observação de processos raros. Para isso, a Física de Partículas moderna baseia-se em experimentos de colisão, nos quais feixes de partículas são acelerados a altas energias e colididos em detectores especialmente projetados. Esses experimentos demandam infraestruturas complexas e sistemas de instrumentação altamente sofisticados. É nesse cenário que se inserem os aceleradores de partículas e os grandes experimentos de Física de Altas Energias (CERN, 2025).

2.2 ACELERADORES DE PARTÍCULAS

Os aceleradores de partículas constituem a principal ferramenta experimental da Física de Altas Energias, permitindo a produção controlada de interações em regimes de energia inacessíveis por processos naturais em laboratório. Esses dispositivos aceleram partículas carregadas por meio da ação combinada de campos elétricos e magnéticos, conduzindo-as a velocidades próximas à da luz e possibilitando colisões com energias no centro de massa suficientes para a produção de estados massivos e processos raros (LEE, 2019).

O mecanismo de aceleração fundamenta-se na interação entre partículas carregadas e campos elétricos oscilantes, tipicamente gerados em cavidades de radiofrequência (RF). A cada passagem pelas estruturas aceleradoras, as partículas recebem incrementos discretos de energia sincronizados com sua fase de aceleração. A estabilidade longitudinal do feixe é assegurada pelo controle preciso da fase e da frequência dos campos de RF, condição essencial para preservar a coesão do feixe e minimizar perdas ao longo do processo de

aceleração (LEE, 2019).

A dinâmica transversal, por sua vez, é governada por campos magnéticos responsáveis pelo controle espacial do feixe. Em aceleradores lineares (linacs), sistemas de focalização magnética, geralmente baseados em quadrupolos, mantêm o feixe confinado transversalmente ao longo da trajetória aproximadamente retilínea. Já em aceleradores circulares, dipolos magnéticos impõem a curvatura da trajetória, ajustando o raio da órbita ao momento das partículas, enquanto quadrupolos atuam como lentes magnéticas, controlando a evolução das dimensões transversais ao longo do percurso. A caracterização do feixe envolve parâmetros óticos associados à sua geometria no espaço de fases, sendo a emitância uma grandeza fundamental para avaliar sua qualidade e sua densidade espacial no ponto de interação (WIEDEMANN, 2015).

Nos aceleradores lineares, as partículas atravessam cada estrutura aceleradora apenas uma vez, acumulando energia ao longo de um percurso essencialmente retilíneo. Em contraste, nos aceleradores circulares as partículas realizam múltiplas voltas em uma órbita fechada, passando repetidamente pelas cavidades de RF e acumulando energia de forma progressiva. Essa configuração permite atingir energias significativamente mais elevadas em instalações de extensão física limitada, tornando os aceleradores circulares predominantes em experimentos de Física de Altas Energias (LEE, 2019).

Entre os aceleradores circulares, destacam-se os síncrotrons, nos quais os campos magnéticos de curvatura são ajustados dinamicamente em sincronia com o aumento da energia das partículas, mantendo aproximadamente constante o raio da órbita. De maneira coordenada, a frequência das cavidades de RF também é modulada para preservar a estabilidade longitudinal. Essa sincronização caracteriza o regime síncrotron e viabiliza a operação em energias extremas com elevada eficiência (WIEDEMANN, 2015).

Além da energia de colisão, um parâmetro central para experimentos de Física de Altas Energias é a luminosidade, que quantifica a taxa de interações por unidade de seção de choque. Em colisores de feixes opostos com perfis aproximadamente gaussianos e colisões frontais, a luminosidade instantânea pode ser expressa como:

$$\mathcal{L} = \frac{N_1 N_2 f}{4\pi\sigma_x\sigma_y}, \quad (2.1)$$

em que N_1 e N_2 representam o número de partículas por pacote, f é a frequência de colisão e σ_x , σ_y correspondem às dimensões transversais efetivas do feixe no ponto de interação. Em condições mais gerais, fatores geométricos adicionais associados ao ângulo de cruzamento e ao *efeito hourglass* devem ser considerados (WIEDEMANN, 2015).

A operação em regimes de alta energia e alta luminosidade impõe desafios significativos à estabilidade e ao controle do feixe. Efeitos coletivos, como instabilidades dinâmicas, interações feixe-feixe e perdas associadas a fenômenos não lineares, tornam-se fatores

críticos no projeto e na operação dessas máquinas. Em resposta, aceleradores modernos incorporam sistemas avançados de correção orbital, monitoramento contínuo e controle ativo, assegurando condições estáveis para os experimentos de colisão (ZIMMERMANN et al., 2020).

Assim, os aceleradores de partículas devem ser compreendidos como sistemas altamente integrados, nos quais física, engenharia eletromagnética e controle em tempo real atuam de forma indissociável. Essa infraestrutura estabelece o elo entre os fundamentos da Física de Partículas e os grandes experimentos de colisão, nos quais detectores especializados registram os produtos das interações. Entre esses experimentos destaca-se o *Large Hadron Collider*, localizado no CERN.

2.3 O CERN E A INFRAESTRUTURA DE GRANDES EXPERIMENTOS


A Organização Europeia para a Pesquisa Nuclear (CERN), originalmente denominada *Conseil Européen pour la Recherche Nucléaire*, foi fundada em 1954, e é atualmente o maior centro mundial dedicado à pesquisa em Física de Partículas. Localizado na fronteira entre a Suíça e a França, o CERN foi criado com o objetivo de promover a cooperação científica internacional e desenvolver infraestrutura de grande porte para experimentos em Física de Altas Energias. Ao longo de sua história, consolidou-se como um dos principais polos de inovação científica e tecnológica, reunindo milhares de pesquisadores de dezenas de países (CERN, 2025).

A missão do CERN envolve não apenas a investigação das propriedades fundamentais da matéria, mas também o desenvolvimento de tecnologias associadas à instrumentação científica, criogenia, sistemas de vácuo ultra-alto, magnetos supercondutores e processamento de grandes volumes de dados. Muitas dessas tecnologias extrapolam o campo da Física de Partículas e encontram aplicações em áreas como medicina, ciência dos materiais, computação distribuída e engenharia de sistemas complexos (CERN, 2025).

O CERN abriga uma cadeia integrada de aceleradores de partículas, organizados de forma hierárquica, representados na Figura 4. Essa infraestrutura inclui aceleradores lineares, anéis de reforço e síncrotrons intermediários que funcionam como estágios de pré-aceleração, fornecendo feixes com energias progressivamente maiores até sua injeção no acelerador principal. Essa arquitetura em cascata permite otimizar a qualidade e a estabilidade dos feixes, além de garantir eficiência energética e operacional.

O complexo de aceleradores do CERN é composto por diversas instalações, como o Proton Synchrotron (PS), o Super Proton Synchrotron (SPS) e outros anéis de preparação de feixe, que culminam no *Large Hadron Collider* (LHC). Cada estágio desempenha um papel específico no condicionamento do feixe, incluindo aceleração inicial, compressão longitudinal, controle de emitância e sincronização temporal. Essa organização integrada é fundamental para viabilizar a operação estável do LHC em regimes de energia e

Figura 4 – Cadeia de aceleradores do CERN, ilustrando os estágios de pré-aceleração até a injeção no LHC.



Fonte: Adaptado de LOPIENSKA (2022).

luminosidade extremos (EVANS; BRYANT, 2008).

Além da infraestrutura de aceleração, o CERN abriga grandes experimentos multipropósito posicionados nos pontos de interação dos aceleradores. Esses experimentos são compostos por detectores de grande escala, estruturados em múltiplas camadas e subsistemas, capazes de registrar com alta precisão os produtos das colisões. A complexidade dessas instalações demanda uma coordenação global envolvendo física teórica, física experimental, engenharia elétrica e mecânica, ciência da computação e sistemas de controle. O modelo colaborativo adotado pelo CERN tornou-se referência internacional em projetos científicos de grande porte, estabelecendo uma sinergia entre desenvolvimento tecnológico e investigação fundamental.

2.4 O GRANDE COLISOR DE HÁDRONS - LHC

O Grande Colisor de Hádrons, do inglês *Large Hadron Collider* (LHC) é o principal acelerador do complexo do CERN e representa o mais avançado síncrotron hadrônico atualmente em operação. Instalado em um túnel subterrâneo com aproximadamente 27 km de circunferência, originalmente construído para o Grande Colisor de Elétrons e Pósitrons (do inglês *Large Electron-Positron Collider* - LEP), o LHC foi projetado para colidir feixes de prótons em altíssimas energias no centro de massa, permitindo investigar fenômenos físicos em escalas de comprimento extremamente reduzidas (EVANS; BRYANT, 2008).

O LHC opera como um colisor de feixes opostos: dois feixes de prótons circulam em sentidos contrários em tubos de vácuo independentes, mantidos por um sistema de aproximadamente 1.200 ímãs dipolares supercondutores. Esses dipolos geram campos magnéticos da ordem de 8 teslas, necessários para curvar partículas com momento da ordem de TeV ao longo do anel. Para possibilitar essa operação, os ímãs são resfriados

a temperaturas próximas de 1,9 K por meio de hélio superfluido, configurando um dos maiores sistemas criogênicos já construídos (CERN, 2025).

Além dos dipolos responsáveis pela curvatura, o LHC utiliza centenas de quadripolos supercondutores para focalização do feixe, especialmente na região dos pontos de interação. Nessas regiões, os feixes são comprimidos transversalmente para maximizar a densidade de partículas e, conseqüentemente, a luminosidade da colisão. A otimização da focalização nos pontos de interação é um dos elementos centrais para o desempenho do acelerador.

Na configuração atual, o LHC opera com energias de colisão no centro de massa de até 13,6 TeV. Essa energia resulta da aceleração individual de cada feixe a energias da ordem de vários TeV, permitindo acessar regimes físicos sensíveis a processos raros e a possíveis sinais de física além do Modelo Padrão. A capacidade de atingir tais energias é resultado direto da arquitetura síncrotron supercondutora adotada no projeto (EVANS; BRYANT, 2008).


Entretanto, o desempenho experimental do LHC não depende apenas da energia de colisão, mas também da luminosidade. Os feixes são organizados em pacotes (*bunches*) que se cruzam nos pontos de interação a intervalos típicos de 25 ns, correspondendo a uma frequência de cruzamento de aproximadamente 40 MHz. Em cada cruzamento, múltiplas interações próton-próton podem ocorrer simultaneamente. A média de interações por cruzamento, frequentemente representada pelo parâmetro μ , cresce proporcionalmente à luminosidade instantânea do acelerador.

O aumento da luminosidade é essencial para a observação de processos com seção de choque reduzida, mas também implica desafios significativos para os detectores. À medida que a luminosidade aumenta, eleva-se o número de interações simultâneas por cruzamento de feixe, intensificando a ocupação dos detectores e a complexidade da reconstrução dos eventos físicos. Esse cenário torna-se ainda mais relevante no contexto do programa High-Luminosity LHC (HL-LHC), que prevê um aumento substancial da luminosidade integrada ao longo dos próximos anos (APOLLINARI et al., 2017).

O LHC é composto por quatro grandes experimentos instalados em seus principais pontos de interação (Figura 5): ATLAS (*A Toroidal LHC ApparatuS*), CMS (*Compact Muon Solenoid*), ALICE (*A Large Ion Collider Experiment*) e LHCb (*Large Hadron Collider beauty experiment*). Entre esses, ATLAS e CMS são detectores de propósito geral projetados para explorar uma ampla gama de processos físicos, incluindo a busca por novas partículas, medições de precisão do Modelo Padrão e estudos da dinâmica das interações fundamentais. A descoberta do bóson de Higgs em 2012 pelos experimentos ATLAS e CMS constitui um dos marcos científicos mais relevantes da história do LHC (ATLAS Collaboration, 2012; CMS Collaboration, 2012).

A partir dessas características do LHC — energia de colisão, estrutura em *bunches*

Figura 5 – Diagrama do anel do LHC indicando os principais experimentos instalados nos pontos de interação.



Fonte: MOUCHE (2014).

e aumento de luminosidade — torna-se possível compreender o ambiente experimental no qual operam os detectores instalados em seus pontos de interação. Na próxima seção, descreve-se o experimento ATLAS e a organização de seus principais subsistemas.


2.5 O EXPERIMENTO ATLAS

O ATLAS é um detector de propósito geral instalado em um dos principais pontos de interação do LHC. Foi projetado para investigar uma ampla gama de processos físicos produzidos nas colisões próton-próton. Com aproximadamente 46 metros de comprimento, 25 metros de diâmetro e massa superior a 7.000 toneladas, o ATLAS constitui um dos maiores instrumentos científicos já construídos para pesquisa em Física de Partículas (ATLAS COLLABORATION, 2008).

O detector foi concebido para registrar, com alta precisão, as propriedades das partículas produzidas nas colisões, incluindo momento, energia, carga elétrica e tempo de chegada. Sua arquitetura é baseada em uma estrutura cilíndrica concêntrica em torno do ponto de interação, composta por diferentes subsistemas especializados, organizados em camadas radiais (Figura 6). Essa configuração permite a reconstrução completa dos eventos físicos por meio da combinação das informações provenientes de múltiplos detectores.

De maneira geral, o ATLAS pode ser dividido em quatro grandes sistemas, conforme Figura 7: o Detector Interno (*Inner Detector*), os Calorímetros Eletromagnético e Hadrônico, o Espectrômetro de Múons e o Sistema Magnético. Cada um desses subsistemas desempenha um papel complementar na identificação e reconstrução das partículas


Figura 6 – Esquemático do detector ATLAS.



Fonte: Extraído de MEHLHASE(2021).

produzidas nas colisões (ATLAS COLLABORATION, 2008).

Figura 7 – Vista em corte dos principais subsistemas do ATLAS.



Fonte: ATLAS Collaboration(2025).

O Detector Interno é responsável pela reconstrução das trajetórias das partículas carregadas nas proximidades do ponto de interação. Imerso em um campo magnético solenoidal de aproximadamente 2 T (tesla), esse subsistema permite determinar o momento transversal das partículas a partir da curvatura de suas trajetórias. Ele é composto por

detectores de pixel, microtiras de silício e um detector de transição por radiação, fornecendo elevada resolução espacial e precisão na determinação de vértices primários e secundários.

Circundando o Detector Interno encontram-se os calorímetros, responsáveis pela medição da energia depositada pelas partículas ao atravessarem materiais absorvedores. O Calorímetro Eletromagnético, baseado em argônio líquido como meio ativo, é otimizado para a detecção de elétrons e fótons. Já o sistema de calorimetria hadrônica, composto por diferentes tecnologias dependendo da região do detector, é projetado para medir a energia de hádrons — partículas compostas formadas por quarks, como prótons, nêutrons, píons e káons — e contribuir para a determinação da energia total do evento. A correta estimativa da energia nesses subsistemas é fundamental para a reconstrução de jatos, energia transversal faltante e outras grandezas físicas relevantes.

Externamente aos calorímetros está o Espectrômetro de Múons, imerso em um campo magnético toroidal gerado por grandes bobinas supercondutoras. Esse sistema é dedicado à identificação e medição precisa de múons, partículas capazes de atravessar os calorímetros praticamente sem serem absorvidas. A combinação das medidas do Detector Interno e do Espectrômetro de Múons permite alcançar elevada precisão na determinação do momento dessas partículas.

O Sistema Magnético do ATLAS é composto por um solenoide central e três grandes sistemas toroidais, configurando uma geometria magnética complexa que viabiliza a curvatura das trajetórias das partículas carregadas em diferentes regiões do detector. Essa arquitetura é um dos elementos distintivos do experimento e influencia diretamente o desempenho dos subsistemas internos e externos.

A operação do ATLAS não depende apenas da capacidade de seus detectores em registrar partículas, mas também da habilidade de selecionar, em tempo real, os eventos mais relevantes para análise posterior. Para lidar com a elevada taxa de colisões produzidas no LHC, o experimento utiliza um sofisticado sistema de aquisição e filtragem de eventos (*trigger*), responsável por reduzir a taxa de eventos registrados para um volume compatível com armazenamento e análise *offline*.

Esse sistema realiza a seleção em múltiplos níveis, combinando decisões rápidas baseadas em hardware com algoritmos mais complexos implementados em software (ATLAS Collaboration, 2016). Como consequência, o desempenho da calorimetria e dos sistemas de seleção de eventos torna-se particularmente sensível ao aumento da luminosidade e ao crescimento do número médio de interações por cruzamento de feixe.

Entre os subsistemas do ATLAS, a calorimetria desempenha papel especialmente relevante por converter a energia depositada pelas partículas em sinais elétricos mensuráveis, utilizados tanto na reconstrução *offline* quanto em decisões tomadas em tempo real pelo sistema de *trigger*. Nesse contexto, o TileCal ocupa papel central na calorimetria hadrônica da região do barril do detector e será descrito com mais detalhes na seção seguinte.


2.6 O TILE CALORIMETER (TILECAL)

O Calorímetro Hadrônico de Telhas, comumente chamado de TileCal (do inglês *Tile Calorimeter*), é o principal componente da calorimetria hadrônica na região central do experimento ATLAS, cobrindo a faixa de pseudorrapidez aproximada de $|\eta| < 1,7$. Trata-se de um calorímetro por amostragem projetado para medir a energia depositada por hádrons produzidos nas colisões do LHC, além de contribuir de maneira significativa para a reconstrução de jatos e da energia transversal faltante (ATLAS Collaboration, 2008).

Como calorímetro por amostragem, o TileCal é constituído por camadas alternadas de material absorvedor e material ativo. No caso específico do TileCal, o material absorvedor é composto por placas de aço, responsáveis por induzir o desenvolvimento de chuveiros hadrônicos, enquanto o meio ativo é formado por telhas cintiladoras plásticas. Quando partículas carregadas provenientes do chuveiro atravessam as telhas cintiladoras, ocorre a emissão de luz por cintilação, cuja intensidade é proporcional à energia depositada no material ativo (ATLAS Collaboration, 2017).

A luz produzida nas telhas é coletada por fibras ópticas e conduzida até tubos fotomultiplicadores (*Photomultiplier Tubes* – PMTs), onde é convertida em sinais elétricos. Cada célula do TileCal é lida por dois PMTs independentes, estratégia adotada para aumentar a redundância e melhorar a robustez e a estabilidade da medição (ATLAS Collaboration, 2017).

Figura 8 – Layout das células TileCal.




Fonte: ATLAS Collaboration (2024).

Do ponto de vista geométrico, o TileCal é dividido em três regiões principais: o barril central e dois barris estendidos, conforme Figura 9. Cada uma dessas regiões é segmentada azimutalmente em módulos, formando uma estrutura aproximadamente cilíndrica em torno do feixe (Figura 10). A segmentação longitudinal em camadas permite uma amostragem adequada do desenvolvimento do chuveiro hadrônico, contribuindo para a resolução em energia e para a identificação topológica de eventos.

A resposta do TileCal depende da natureza do chuveiro hadrônico, que apresenta

Figura 9 – Vista em corte do TileCal.



Fonte: ATLAS Collaboration (2024).

flutuações intrínsecas associadas aos processos de interação forte, produção de partículas secundárias e componentes eletromagnéticas do chuveiro. Essas flutuações influenciam a linearidade e a resolução do detector, sendo necessárias calibrações detalhadas para garantir a precisão na medição da energia (CHAKRABORTY et al., 2018).


Após a conversão fotoelétrica nos PMTs, o sinal elétrico gerado apresenta a forma de um pulso de corrente com tempo de subida rápido, associado à resposta intrínseca do tubo fotomultiplicador, seguido por um decaimento determinado pelas características do circuito de leitura. Esse sinal é inicialmente pré-amplificado e então encaminhado a um estágio de conformação temporal por meio de circuitos de modelagem (*shapers*), cuja função é otimizar a relação sinal-ruído (SNR), limitar a largura espectral do sinal e adequar sua forma ao processo de amostragem digital (ATLAS Collaboration, 2017).

A conformação eletrônica no TileCal é projetada para produzir um pulso aproximadamente unipolar, com tempo de subida da ordem de dezenas de nanossegundos e largura total que se estende por múltiplos intervalos de 25 ns. A forma resultante é determinada pela convolução entre a resposta do detector (incluindo o tempo de emissão da cintilação), a resposta do PMT e a função de transferência da cadeia eletrônica analógica.

Após a modelagem, o sinal é digitalizado por conversores analógico-digitais (ADCs) operando tipicamente à frequência de 40 MHz, sincronizada com o relógio do LHC. Cada pulso é, portanto, representado por um conjunto discreto de amostras igualmente espaçadas no tempo. Para cada evento aceito pelo sistema de *trigger*, um número fixo de amostras consecutivas é armazenado, permitindo a reconstrução posterior da amplitude máxima do pulso e do seu tempo de chegada (FULLANA et al., 2006).

Matematicamente, o sinal digitalizado pode ser descrito como:

Figura 10 – Esquema de um módulo do TileCal, ilustrando as placas de aço, as telhas cintiladoras e o sistema de leitura óptica.



Fonte: ATLAS Collaboration (2024).

$$s[n] = A \cdot g[n - n_\tau] + \varepsilon[n], \quad (2.2)$$

em que A representa a amplitude proporcional à energia depositada, $g[n]$ corresponde à forma nominal do pulso discretizado, n_τ é o deslocamento temporal associado ao tempo de chegada e $\varepsilon[n]$ modela o ruído eletrônico e contribuições adicionais. A estimação da energia consiste, portanto, na determinação robusta de A a partir de um conjunto finito de amostras sujeitas a ruído e possíveis sobreposições temporais.

Em condições ideais, nas quais apenas uma colisão contribui para o sinal observado, a reconstrução pode ser realizada explorando a forma conhecida do pulso e suas propriedades estatísticas. Entretanto, em regimes de alta luminosidade, o aumento do número médio de interações por cruzamento de feixe, denotado por μ , favorece a sobreposição linear de múltiplos pulsos deslocados no tempo. Como a largura do pulso eletrônico excede o intervalo de 25 ns entre cruzamentos consecutivos, contribuições provenientes de interações anteriores e subsequentes podem interferir na estimação da amplitude do evento de interesse.

Esse fenômeno, conhecido como *pile-up* (Figura 2), altera a forma observada do sinal

e compromete a hipótese de pulso isolado utilizada nos métodos clássicos de reconstrução (ATLAS Collaboration, 2017). Consequentemente, a reconstrução de energia no TileCal passa a depender de modelos de pulso e algoritmos capazes de operar sob sobreposição temporal e ruído de fundo, mantendo desempenho em condições de alta ocupação. Essas limitações tornam-se particularmente críticas quando a estimação de energia alimenta decisões em tempo real, motivando a discussão do sistema de *trigger* do ATLAS a seguir.

Nesse contexto, a reconstrução da energia pode ser formalmente tratada como um problema de estimação estatística da amplitude A a partir de observações discretas temporalmente correlacionadas e potencialmente contaminadas por múltiplas contribuições temporais. Essa formulação estabelece o elo entre o ambiente físico descrito neste capítulo e os métodos de estimação comparados nos capítulos seguintes.

2.7 O SISTEMA DE *TRIGGER* DO ATLAS


A elevada taxa de colisões produzidas pelo LHC impõe desafios substanciais ao armazenamento e processamento dos dados experimentais. Com cruzamentos de feixe ocorrendo a cada 25 ns, a taxa nominal de eventos atinge aproximadamente 40 MHz. Considerando que cada evento completo do ATLAS pode gerar volumes de dados da ordem de megabytes, o armazenamento integral de todos os eventos produzidos é inviável do ponto de vista computacional e logístico. Torna-se, portanto, necessário um sistema de seleção em tempo real capaz de identificar e preservar de forma eficiente e rápida apenas os eventos potencialmente relevantes para a física de interesse. Esse sistema é denominado *trigger* (ATLAS Collaboration, 2016).

Atualmente, o sistema de *trigger* do ATLAS é estruturado em dois níveis principais: o *Level-1* (L1) e o *High-Level Trigger* (HLT) (Figura 11). Esses níveis operam de forma hierárquica, promovendo uma redução progressiva da taxa de eventos desde 40 MHz para uma taxa final da ordem de kHz, compatível com as capacidades de armazenamento e processamento *offline*. Essa redução é realizada combinando processamento dedicado em hardware, com latência fixa e determinística, e algoritmos mais sofisticados executados em infraestrutura computacional de alto desempenho (ATLAS Collaboration, 2020).

O primeiro nível de seleção, conhecido como *Level-1* (L1), é implementado integralmente em hardware dedicado, baseado em FPGAs, ASICs e eletrônica customizada de alta velocidade. Esse estágio opera com latência fixa e determinística, tipicamente da ordem de alguns microssegundos, impondo restrições severas à complexidade dos algoritmos empregados.

As decisões no L1 são tomadas com base em informações parcialmente agregadas provenientes principalmente dos calorímetros e do espectrômetro de múons. No caso da calorimetria, sinais são agrupados em regiões de interesse, (*trigger towers*), e comparados a limiares predefinidos de energia transversal. O L1 é responsável por reduzir a taxa

Figura 11 – Arquitetura do sistema de *Trigger* e Aquisição de Dados (TDAQ) do ATLAS.



Fonte: Extraído de BERNIUS (2020).

de eventos de aproximadamente 40 MHz para valores da ordem de 100 kHz (ATLAS Collaboration, 2016).

Devido às restrições de latência e ao processamento puramente em hardware, os algoritmos do L1 devem ser altamente paralelizáveis, determinísticos e computacionalmente eficientes, características que influenciam diretamente o desenho da eletrônica de leitura dos detectores.

Os eventos aceitos pelo L1 são então encaminhados ao HLT, implementado em software e executado em grandes fazendas de processamento (*computing farms*). Diferentemente do L1, o HLT dispõe de maior flexibilidade algorítmica e pode acessar informações completas do detector.

Nesse estágio, são aplicados algoritmos de reconstrução mais sofisticados, incluindo reconstrução quase completa do evento, identificação de vértices, reconstrução de jatos, cálculo de energia transversal faltante e seleção baseada em assinaturas físicas complexas. O HLT promove uma nova redução na taxa de eventos, de aproximadamente 100 kHz para cerca de 1 kHz, que corresponde à taxa final de armazenamento (ATLAS Collaboration, 2020).

À medida que a luminosidade instantânea do LHC aumenta, cresce também o número médio de interações por cruzamento de feixe, μ . Esse cenário implica maior ocupação dos detectores e maior complexidade na separação entre sinais de interesse e contribuições de fundo associadas ao *pile-up*. Como consequência, o sistema de *trigger*

deve operar com maior robustez e seletividade, evitando taxas excessivas de falso-alarme sem comprometer a eficiência de detecção de processos raros (APOLLINARI et al., 2017).

No contexto específico do TileCal, a precisão na estimação da energia já no L1 torna-se particularmente relevante. Distorções associadas à sobreposição temporal de sinais podem impactar diretamente a eficiência de seleção de jatos e de energia transversal faltante, influenciando a taxa global de aceitação do experimento.


No regime do HL-LHC, espera-se um aumento expressivo no número médio de interações por cruzamento de feixe, com valores projetados da ordem de $\mu \approx 200$ (APOLLINARI et al., 2017). Esse cenário amplia a complexidade do ambiente do *trigger* e reforça a necessidade de modernizações na cadeia de leitura e na disponibilidade de informação calorimétrica em tempo real.

A evolução das condições operacionais do LHC e o programa de atualizações do ATLAS — incluindo a modernização da eletrônica de leitura e a maior disponibilidade de informação calorimétrica no L1 — são descritos na próxima seção.

2.8 ATUALIZAÇÕES DO LHC E DO ATLAS: DA *RUN 1* AO HL-LHC

A operação do LHC iniciou-se em setembro de 2008, com a circulação de feixes em seu anel. As primeiras colisões ocorreram em 2009, sendo as primeiras colisões destinadas à física registradas em 2010. Desde então, o programa experimental foi organizado em períodos de tomada de dados (*Runs*), intercalados por longas paradas técnicas (*Long Shutdowns* – LS), destinadas à consolidação e atualização do acelerador e de seus experimentos (EVANS; BRYANT, 2008).

Figura 12 – Linha do tempo da operação do LHC, indicando os períodos de *Run* e as *Long Shutdowns*, incluindo a transição para o HL-LHC.



Fonte: Adaptado de BRÜNING; ZERLAUTH (2025).

A *Run 1* caracterizou-se por colisões a energias de 7 TeV (2010–2011) e 8 TeV (2012) no centro de massa. Durante esse período, a luminosidade instantânea atingiu valores da ordem de $10^{34} \text{ cm}^{-2} \text{ s}^{-1}$, com número médio de interações por cruzamento de feixe (μ)

tipicamente inferior a 40. Essa fase culminou na descoberta do bóson de Higgs pelos experimentos ATLAS e CMS em 2012, resultado que confirmou experimentalmente o mecanismo de geração de massa previsto pelo Modelo Padrão (ATLAS Collaboration, 2012; CMS Collaboration, 2012).

Entre 2013 e 2014 foi realizada a primeira parada técnica de longa duração (LS1), destinada à consolidação das interconexões elétricas, ao reforço do sistema criogênico e à preparação do acelerador para operar em energias mais elevadas. Durante a LS1 ocorreu a Fase-0 (*Phase-0*) do programa de atualização do ATLAS, onde foi instalado o *Insertable B-Layer* (IBL), melhorando a resolução de vértices do Detector Interno, além de atualizações no sistema de *trigger*. Essas intervenções prepararam o experimento para a operação durante a *Run 2* (ATLAS Collaboration, 2014).

Com o início da *Run 2*, em 2015, o LHC passou a operar a 13 TeV no centro de massa. Nessa fase, foram alcançados valores significativamente maiores de luminosidade instantânea, que ultrapassou $2 \times 10^{34} \text{ cm}^{-2} \text{ s}^{-1}$, e o número médio de interações por cruzamento de feixe frequentemente superou $\mu \approx 50$, atingindo valores próximos de 60–70 em condições extremas.

O aumento significativo do parâmetro μ intensificou o efeito de *pile-up*, elevando a complexidade da reconstrução de jatos, energia transversal faltante e outras grandezas derivadas da calorimetria. Esse cenário demandou aprimoramentos nos algoritmos de reconstrução e nos procedimentos de calibração do TileCal (ATLAS Collaboration, 2024).

Após o término da *Run 2*, foi realizada a segunda parada técnica de longa duração (LS2), entre 2019 e 2021, período dedicado à consolidação do LHC e à implementação da Fase-I (*Phase-I*) do programa de atualizações do ATLAS. No acelerador, intervenções técnicas foram conduzidas para aumentar a confiabilidade operacional e preparar o sistema para regimes de maior luminosidade. No experimento ATLAS, a Fase-I concentrou-se principalmente na modernização do sistema de aquisição e *trigger*, incluindo a atualização do sistema de calorimetria no primeiro nível de decisão e a instalação do *New Small Wheel* no espectrômetro de múons (ATLAS Collaboration, 2020a).

Essas modificações permitiram maior granularidade na informação calorimétrica disponibilizada ao L1, ampliando a capacidade de discriminação entre sinais de interesse e contribuições de fundo já nos primeiros microssegundos após a colisão. Embora o TileCal não tenha sofrido ainda sua substituição completa de eletrônica nessa fase, ajustes e consolidações foram realizados visando preparar sua infraestrutura para as exigências futuras de operação em alta luminosidade.

A *Run 3*, iniciada em 2022, marcou o início de uma etapa intermediária entre o LHC original e o programa *High-Luminosity Large Hadron Collider* (HL-LHC). Operando a 13,6 TeV no centro de massa, essa fase tem como objetivo acumular luminosidade integrada adicional e consolidar as atualizações implementadas na LS2, ao mesmo tempo em que se

aproxima progressivamente dos regimes operacionais previstos para o HL-LHC.

O HL-LHC, cuja entrada em operação está prevista para 2029, após a LS3, representa a etapa mais ambiciosa do programa científico do LHC. O objetivo principal não é aumentar significativamente a energia de colisão, mas elevar substancialmente a luminosidade instantânea e integrada do acelerador. Espera-se atingir luminosidades instantâneas da ordem de $7,5 \times 10^{34} \text{ cm}^{-2}\text{s}^{-1}$, com número médio de interações por cruzamento de feixe podendo alcançar valores próximos de $\mu \approx 200$ (APOLLINARI et al., 2017).

Esse aumento expressivo na taxa de interações implica uma mudança qualitativa no ambiente experimental, no qual a sobreposição temporal de pulsos eletrônicos deixa de ser um efeito secundário e passa a constituir o regime nominal de operação. Para os sistemas de calorimetria, em particular, isso significa que a hipótese de pulsos isolados torna-se cada vez menos representativa da realidade operacional. A reconstrução de energia passa a depender criticamente da capacidade de modelar e separar contribuições temporais sobrepostas, mantendo linearidade, estabilidade e resolução sob valores elevados de μ .

Nesse contexto, está prevista para a LS3 (2026-2028) a implementação da Fase-II (*Phase-II*) do programa de atualizações do ATLAS, associada diretamente ao HL-LHC. No caso do TileCal, essa fase inclui a substituição completa da eletrônica frontal por um sistema totalmente digital, no qual os sinais serão continuamente amostrados e transmitidos ao sistema de *trigger* sem a etapa intermediária de transmissão analógica. A nova arquitetura permitirá acesso integral às amostras digitalizadas no L1, ampliando a flexibilidade algorítmica para estimação de energia e mitigação de *pile-up* já na etapa de *trigger* (ATLAS Collaboration, 2017).

A modernização da eletrônica do TileCal altera significativamente o paradigma de processamento de sinais no detector. A disponibilidade de dados digitalizados com maior granularidade e menor latência amplia o espaço de possibilidades para algoritmos de estimação de energia, incluindo abordagens mais sofisticadas de processamento digital e técnicas baseadas em aprendizado de máquina. Entretanto, o ambiente de alta luminosidade impõe simultaneamente restrições mais severas em termos de robustez, estabilidade e desempenho sob forte *pile-up*.

Em síntese, a evolução do LHC em direção ao HL-LHC não se limita ao aumento de energia e luminosidade, mas transforma as condições estatísticas e temporais sob as quais os sinais eletrônicos são formados e processados no TileCal. Nesse regime, a sobreposição associada ao *pile-up* deixa de ser um efeito residual e passa a integrar o cenário nominal de operação, influenciando diretamente os requisitos de estimação de energia — especialmente quando essa informação é utilizada em decisões em tempo real no *trigger*.

Diante desse cenário, torna-se natural investigar formalmente métodos de estimação capazes de operar sob essas condições estatísticas e temporais, tema abordado no capítulo seguinte.

3 MÉTODOS DE ESTIMAÇÃO DE ENERGIA

A reconstrução de energia no TileCal consiste em estimar, a partir de um número finito de amostras digitalizadas do pulso, a amplitude eletrônica proporcional à energia depositada, sob a presença de ruído eletrônico e, em condições de alta luminosidade, de superposição temporal de sinais (*pile-up*). Este capítulo apresenta o modelo matemático adotado para o sinal amostrado e discute diferentes estratégias de estimação de amplitude compatíveis com a reconstrução por janela e com restrições de latência do sistema de aquisição.

Inicialmente, descreve-se a cadeia de formação do sinal e estabelece-se o modelo discreto para as amostras do pulso, que fundamenta a formulação vetorial utilizada ao longo do capítulo. Em seguida, apresenta-se a reconstrução janelada associada à decisão por evento no *trigger* e revisam-se estimadores lineares clássicos, com ênfase no Filtro Ótimo e no Filtro de Wiener. Por fim, discutem-se abordagens supervisionadas orientadas por dados, incluindo Perceptrons Multicamadas, Máquinas de Vetores de Suporte para regressão e Redes Neurais Convolucionais 1D, destacando hipóteses, custo computacional e limitações sob regimes de alta ocupação.

Neste contexto, o problema investigado neste trabalho consiste na análise comparativa do desempenho desses estimadores sob regimes crescentes de ocupação e sob restrições de latência compatíveis com a arquitetura do sistema de *trigger* do ATLAS.

3.1 MODELAGEM DO SINAL NO TILECAL

A estimação de energia em calorímetros por amostragem constitui um problema central em experimentos de Física de Altas Energias, pois estabelece a ligação direta entre o sinal eletrônico digitalizado e a grandeza física associada à energia depositada pela partícula incidente. No TileCal, essa tarefa consiste em determinar, de forma robusta e estável, a amplitude do pulso eletrônico gerado pelos tubos fotomultiplicadores, a partir de um conjunto finito de amostras discretizadas sujeitas a ruído e possíveis sobreposições temporais.

A cadeia de formação do sinal inicia-se com a deposição de energia E nas telhas cintiladoras. A energia depositada pela partícula incidente induz a emissão de fótons por cintilação, cuja intensidade é proporcional à energia transferida ao meio ativo (WIGMANS, 2000). A resposta luminosa do cintilador pode ser modelada como:

$$L(t) = \alpha E h_{\text{scint}}(t), \quad (3.1)$$

em que $L(t)$ representa a intensidade luminosa emitida, α é o fator de conversão luz-energia do material cintilador e $h_{\text{scint}}(t)$ descreve sua resposta temporal intrínseca, usualmente

caracterizada por um tempo de subida rápido seguido de um decaimento aproximadamente exponencial (ATLAS Collaboration, 2017).

A luz produzida é coletada por fibras ópticas e convertida em corrente elétrica nos PMTs. A resposta do PMT pode ser modelada como um sistema linear com função de resposta impulsiva $h_{\text{PMT}}(t)$, de modo que a corrente de saída seja dada por:

$$i_{\text{PMT}}(t) = L(t) * h_{\text{PMT}}(t), \quad (3.2)$$

onde $*$ denota convolução temporal. Essa corrente é então processada pela cadeia analógica composta por pré-amplificador e modelador temporal (*shaper*), cuja função de transferência global pode ser representada por $h_{\text{elec}}(t)$ (SPIELER, 2005).

Considerando a resposta temporal do PMT e da eletrônica analógica de leitura, o sinal analógico na saída do sistema pode ser descrito como a convolução entre a resposta do detector e a função de transferência da cadeia eletrônica:

$$v(t) = G E h(t), \quad (3.3)$$

onde G representa o ganho global do sistema (fibras ópticas, PMT e amplificação eletrônica) e $h(t)$ corresponde à resposta impulsional equivalente do conjunto detector–eletrônica:

$$h(t) = \alpha h_{\text{scint}}(t) * h_{\text{PMT}}(t) * h_{\text{elec}}(t). \quad (3.4)$$

Após a etapa de conformação temporal e digitalização a 40 MHz, o sinal contínuo é amostrado em instantes discretos $t_n = nT_s$, com $T_s = 25$ ns. O sinal digital pode então ser representado como

$$s[n] = A g[n - n_\tau] + \varepsilon[n], \quad (3.5)$$

em que:

- $A = GE$ é a amplitude eletrônica proporcional à energia depositada;
- $g[n]$ representa a resposta ao impulso $h(t)$ discretizada e normalizada de modo que seu pico seja unitário;
- n_τ corresponde ao deslocamento temporal associado ao tempo de chegada do pulso;
- $\varepsilon[n]$ modela o ruído eletrônico e outras flutuações estocásticas do sistema.

Nessa formulação, a energia física E não é estimada diretamente a partir das amostras digitais. O problema de reconstrução consiste, primeiramente, na estimação da

amplitude eletrônica A , sendo a energia posteriormente obtida por meio das constantes de calibração do detector (CHAKRABORTY et al., 2018).

O termo de ruído $\varepsilon[n]$ pode ser tratado, em primeira aproximação, como um processo estocástico de média nula, cuja estrutura estatística depende das características do ruído térmico, eletrônico e das contribuições residuais de eventos anteriores (SPIELER, 2005). Em regimes de alta luminosidade, depósitos de energia provenientes de diferentes interações próton–próton podem ocorrer em instantes suficientemente próximos para que suas respostas eletrônicas se sobreponham temporalmente, resultando em:

$$r[n] = \sum_k A_k g[n - n_k] + \varepsilon[n], \quad (3.6)$$

caracterizando o efeito de *pile-up* (superposição de pulsos).


Dessa forma, a estimação de energia associada ao evento de interesse deixa de ser um problema escalar simples e passa a envolver a separação de contribuições temporalmente correlacionadas. Neste trabalho, o parâmetro de interesse é a amplitude do depósito associado à amostra central da janela de observação, denotada por A_0 , cuja estimação deve ser realizada na presença de ruído eletrônico e de contribuições provenientes de pulsos temporalmente sobrepostos

A estimação de energia no TileCal pode ser formalmente interpretada como um problema de estimação linear em presença de ruído colorido e possível interferência determinística estruturada. Essa formulação estabelece o modelo matemático subjacente sobre o qual se fundamentam os métodos clássicos, como o Filtro Ótimo, e abordagens alternativas baseadas em filtragem adaptativa e aprendizado de máquina. A qualidade dessa estimação depende tanto da modelagem precisa da forma nominal do pulso quanto da correta caracterização estatística do ruído do sistema.

3.2 RECONSTRUÇÃO JANELADA E DECISÃO POR EVENTO

Conforme discutido no Capítulo 2, a eletrônica de leitura do ATLAS opera sincronizada ao relógio do LHC, com amostragem típica de 40 MHz, enquanto o sistema de *trigger* analisa, para cada cruzamento de feixe (*bunch crossing*), um conjunto limitado de amostras temporais para decidir se o evento deve ser mantido para processamento posterior (ATLAS Collaboration, 2020). Dessa forma, a reconstrução de energia é naturalmente formulada como um problema de estimação por janela temporal (*windowed reconstruction*), em que cada decisão é tomada a partir de um número finito de amostras centradas no cruzamento de interesse (ATLAS Collaboration, 2017). A Figura 13 ilustra esquematicamente essa formulação, destacando uma janela temporal centrada e a amostra central associada ao alvo de regressão.

Figura 13 – Exemplo esquemático de uma janela temporal centrada, composta por $N = 7$ amostras igualmente espaçadas, destacando a amostra central associada ao depósito de energia de referência.



Fonte: Elaborado pela autora.

Na abordagem janelada, para cada evento candidato (tipicamente após uma aceitação no L1), a aquisição armazena uma sequência curta de amostras consecutivas ao redor do máximo do pulso. Denotando o vetor de amostras por:

$$\mathbf{s} = [s[n_0] \quad s[n_0 + 1] \quad \cdots \quad s[n_0 + N - 1]]^T, \quad (3.7)$$

em que o índice n_0 define o início da janela de reconstrução e é escolhido de modo a conter o pulso de interesse, estando associado ao atraso n_τ introduzido no modelo discreto da Seção 3.1. A reconstrução de energia é tratada como um problema de estimação de parâmetros a partir de $\mathbf{s}$, assumindo-se que, dentro da janela, a forma nominal do pulso (ou uma aproximação dela) é conhecida e suficientemente estável (ATLAS Collaboration, 2017).

Essa abordagem de reconstrução por janela está alinhada com a arquitetura tradicional do *trigger*, na qual a decisão de seleção é tomada evento a evento, a partir de um conjunto reduzido de grandezas físicas reconstruídas. Em particular, após a aceitação pelo L1, apenas um número fixo de amostras digitais associadas a cada célula calorimétrica é disponibilizado ao sistema de processamento subsequente. A partir dessas amostras, estima-se a amplitude do pulso e, conseqüentemente, a energia depositada na célula.

As energias reconstruídas são posteriormente combinadas para formar objetos físicos, como jatos e energia transversal faltante, que servem de entrada para os algoritmos do *High-Level Trigger* (HLT). Assim, a reconstrução da energia representa uma etapa intermediária da cadeia de processamento do ATLAS, convertendo a informação calorimétrica do evento

em grandezas físicas mais compactas, reduzindo a taxa de dados de dezenas de megahertz para valores da ordem de quilohertz, compatíveis com armazenamento permanente e análise *offline* (ATLAS Collaboration, 2016).

Essa filosofia pressupõe que a estimação de energia pode ser realizada de forma estável e suficientemente precisa dentro de uma janela temporal limitada, associada a um único cruzamento de feixe (ATLAS Collaboration, 2020). A formulação matemática introduzida na Seção 3.1 fornece a base para esses métodos. Em notação vetorial, um modelo linear para a janela pode ser escrito como:

$$\mathbf{s} = A \mathbf{g}(\tau) + \boldsymbol{\varepsilon}, \quad (3.8)$$

em que A é a amplitude eletrônica proporcional à energia depositada (calibrada posteriormente), $\boldsymbol{\varepsilon}$ representa ruído eletrônico e contribuições estocásticas residuais, e $\mathbf{g}(\tau)$ é o vetor obtido pelo empilhamento das amostras $g[n - n_\tau]$ para $n = n_0, \dots, n_0 + N - 1$ (FULLANA et al., 2006), isto é:

$$\mathbf{g}(\tau) = [g[n_0 - n_\tau] \quad \cdots \quad g[n_0 + N - 1 - n_\tau]]^T. \quad (3.9)$$

Na prática, τ pode variar devido a dispersões de temporização, alinhamentos e efeitos instrumentais, de modo que os métodos clássicos incorporam explicitamente (ou implicitamente) a necessidade de robustez a variações temporais do pulso (ATLAS Collaboration, 2017).

No âmbito dessa modelagem, as estratégias clássicas de reconstrução na calorimetria do ATLAS concentram-se em estimadores lineares (ou linearizados) aplicados ao vetor de amostras do sinal digitalizado, denotado por s , devido à sua eficiência computacional, previsibilidade e boa aderência às restrições de latência impostas pelo processamento em tempo real (ATLAS Collaboration, 2020). Em tais métodos, considera-se que a amplitude do pulso pode ser estimada por meio de uma combinação linear das amostras adquiridas na janela de observação. Assim, sendo:

$$s = [s_1, s_2, \dots, s_L]^T \quad (3.10)$$

o vetor contendo as L amostras do sinal digitalizado, a estimativa da amplitude do pulso de interesse pode ser escrita como:

$$\hat{A} = \mathbf{w}^T \mathbf{s}, \quad (3.11)$$

, em que $\hat{A}$ representa a amplitude estimada do pulso associado ao evento de interesse, s é o vetor de amostras da janela temporal e $\mathbf{w}$ é o vetor de pesos do estimador, determinado a partir da forma temporal do pulso e de hipóteses sobre as estatísticas do ruído (SPIELER, 2005).

Diferentes escolhas de $\mathbf{w}$ levam a métodos com compromissos distintos entre variância, viés (por exemplo, devido a desalinhamento temporal) e sensibilidade a *pile-up*. Em particular, quando o ruído é não branco (“colorido”) e/ou há correlações entre amostras, torna-se natural incorporar uma matriz de covariância $\mathbf{C} = \mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T]$ no projeto do estimador, o que motiva abordagens de filtragem *ótima* sob restrições de não viés (SPIELER, 2005).

A reconstrução janelada foi concebida para operar com um número fixo de amostras por evento e produzir, com baixa latência, estimativas de energia e tempo suficientemente precisas para alimentar o *trigger* e a reconstrução *offline* (ATLAS Collaboration, 2016). Na configuração atualmente utilizada pelo ATLAS, a reconstrução da amplitude no TileCal é realizada a partir de 7 amostras consecutivas, armazenadas após a aceitação do evento pelo sistema de *trigger*.

Nesse contexto, o método padrão atualmente empregado na reconstrução de amplitude no TileCal é o Filtro Ótimo (*Optimal Filtering* – OF), concebido para fornecer um estimador linear não enviesado com variância mínima sob hipóteses específicas sobre a forma nominal do pulso e a estrutura estatística do ruído (CERQUEIRA et al., 2016). A formulação detalhada desse método é apresentada na próxima Seção.

3.3 FILTRO ÓTIMO (OF)

Conforme introduzido na seção anterior, o Filtro Ótimo (*Optimal Filtering* – OF) constitui o método padrão de reconstrução de amplitude no TileCal desde as primeiras fases de operação do ATLAS. Sua formulação baseia-se na teoria de estimação linear sob restrição de não viés, sendo projetado para minimizar a variância do estimador de amplitude em presença de ruído com covariância conhecida (ATLAS Collaboration, 2017).

Partindo do modelo vetorial introduzido na Seção 3.2 (Equação 3.8), assumindo inicialmente que o desalinhamento temporal é pequeno (ou conhecido) e que $\mathbf{g}$ é fixo, o modelo linear pode ser simplificado para:

$$\mathbf{s} = A\mathbf{g} + \boldsymbol{\varepsilon}, \quad (3.12)$$

onde:

- $\mathbf{s}$ é o vetor de N amostras digitalizadas;
- $\mathbf{g}$ é a forma nominal do pulso discretizada;
- A é a amplitude proporcional à energia depositada;
- $\boldsymbol{\varepsilon}$ é um processo estocástico de média nula com matriz de covariância $\mathbf{C}$.

Busca-se um estimador linear da forma:

$$\hat{A} = \mathbf{w}^T \mathbf{s}, \quad (3.13)$$

em que $\mathbf{w}$ é um vetor de pesos a ser determinado. Assumindo que o ruído possui média nula:

$$\mathbb{E}[\boldsymbol{\varepsilon}] = 0, \quad (3.14)$$

e matriz de covariância:

$$\mathbf{C} = \mathbb{E}[\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}^T]. \quad (3.15)$$

Como:

$$\mathbb{E}[\hat{A}] = \mathbf{w}^T \mathbb{E}[\mathbf{s}] = \mathbf{w}^T A \mathbf{g}, \quad (3.16)$$

impondo a condição de não viés:

$$\mathbb{E}[\hat{A}] = A, \quad (3.17)$$

obtém-se a restrição:

$$\mathbf{w}^T \mathbf{g} = 1. \quad (3.18)$$

A variância do estimador é dada por:

$$\text{Var}(\hat{A}) = \mathbf{w}^T \mathbf{C} \mathbf{w}. \quad (3.19)$$

O problema consiste então em minimizar $\mathbf{w}^T \mathbf{C} \mathbf{w}$ sujeito à restrição da Equação 3.18. Utilizando multiplicadores de Lagrange, define-se:

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{C} \mathbf{w} - 2\lambda(\mathbf{w}^T \mathbf{g} - 1). \quad (3.20)$$

Impondo:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = 0, \quad (3.21)$$

obtém-se:

$$\mathbf{C} \mathbf{w} = \lambda \mathbf{g}. \quad (3.22)$$

Multiplicando à esquerda por $\mathbf{g}^T \mathbf{C}^{-1}$ e utilizando a restrição, chega-se à solução clássica:

$$\mathbf{w}_{\text{OF}} = \frac{\mathbf{C}^{-1} \mathbf{g}}{\mathbf{g}^T \mathbf{C}^{-1} \mathbf{g}}, \quad (3.23)$$

e o estimador final da amplitude é, portanto:

$$\hat{A} = \frac{\mathbf{g}^T \mathbf{C}^{-1} \mathbf{s}}{\mathbf{g}^T \mathbf{C}^{-1} \mathbf{g}}. \quad (3.24)$$

Esse resultado corresponde ao estimador linear de mínima variância não viesado (*Best Linear Unbiased Estimator* — BLUE) para a amplitude A no modelo linear (Eq. 3.12), assumindo covariância conhecida $\mathbf{C}$. Quando o ruído é adicionalmente assumido gaussiano, o estimador coincide com o estimador de máxima verossimilhança (MLE) (KAY, 1993).

A variância mínima associada é:

$$\text{Var}(\hat{A}) = \frac{1}{\mathbf{g}^T \mathbf{C}^{-1} \mathbf{g}}. \quad (3.25)$$

O OF pode ser interpretado como um filtro casado (*matched filter*) generalizado para ruído colorido. Na presença de ruído correlacionado a operação de multiplicação por $\mathbf{C}^{-1}$ atua como um pré-branqueador estatístico, transformando o problema em um espaço onde o ruído torna-se aproximadamente branco.

Geometricamente, a solução corresponde à projeção ortogonal do vetor de amostras $\mathbf{s}$ sobre o subespaço unidimensional gerado por $\mathbf{g}$, segundo o produto interno ponderado:

$$\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbf{C}^{-1}} = \mathbf{x}^T \mathbf{C}^{-1} \mathbf{y}. \quad (3.26)$$

Quando o ruído é branco ($\mathbf{C} \propto \mathbf{I}$), o estimador reduz-se à correlação normalizada entre o vetor de amostras e a forma nominal do pulso:

$$\hat{A} \propto \mathbf{g}^T \mathbf{s}, \quad (3.27)$$

recuperando a forma clássica do filtro casado (OPPENHEIM et al., 1999).

Na prática, o pulso pode apresentar pequenos deslocamentos temporais em relação à forma nominal. Pequenos desalinhamentos temporais introduzem viés se não forem tratados explicitamente. Seja τ um deslocamento temporal pequeno, expande-se a forma do pulso em série de Taylor de primeira ordem:

$$\mathbf{g}(\tau) \approx \mathbf{g} + \tau \mathbf{g}', \quad (3.28)$$

onde $\mathbf{g}'$ é a derivada discreta da forma nominal. Assim, o modelo torna-se:

$$\mathbf{s} = A\mathbf{g} + A\tau\mathbf{g}' + \boldsymbol{\varepsilon}. \quad (3.29)$$

Definindo os parâmetros $\theta_1 = A$ e $\theta_2 = A\tau$, obtém-se um problema linear multiparamétrico:

$$\mathbf{s} = \theta_1\mathbf{g} + \theta_2\mathbf{g}' + \boldsymbol{\varepsilon}, \quad (3.30)$$

cujas soluções são obtidas pela resolução de um problema de mínimos quadrados generalizado (GLS), no qual o vetor de parâmetros $\boldsymbol{\theta} = [\theta_1 \ \theta_2]^T$ é estimado por:

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{C}^{-1} \mathbf{s}, \quad (3.31)$$

onde:

$$\mathbf{H} = \begin{bmatrix} \mathbf{g} & \mathbf{g}' \end{bmatrix}. \quad (3.32)$$

O estimador acima é equivalente a um problema de mínimos quadrados após pré-branqueamento por $\mathbf{C}^{-1/2}$, isto é, $\mathbf{C}^{-1}$ induz a métrica estatística do ruído. A estimativa da amplitude é então obtida como $\hat{A} = \hat{\theta}_1$, enquanto o deslocamento temporal é recuperado por:

$$\hat{\tau} = \frac{\hat{\theta}_2}{\hat{\theta}_1}, \quad (3.33)$$

desde que $\hat{\theta}_1 \neq 0$.

Essa extensão aumenta a robustez do estimador frente a pequenas variações temporais, mitigando o viés introduzido por desalinhamentos de fase entre o pulso real e a forma nominal (ATLAS Collaboration, 2017).

Na implementação atualmente empregada, o OF assume a forma de um filtro FIR (*Finite Impulse Response*) não recursivo de ordem $N - 1$, com $N = 7$ amostras consecutivas por evento aceito no *trigger*. A matriz de covariância $\mathbf{C}$ é estimada a partir de dados experimentais (como eventos de pedestal) e incorporada no cálculo dos pesos. Na prática o OF tem:

- Comprimento fixo $N = 7$;
- Coeficientes pré-computados;
- Operação reduzida a uma única combinação linear;
- Complexidade $\mathcal{O}(N)$.

É importante distinguir o custo computacional de obtenção dos coeficientes do filtro do custo de sua aplicação em tempo real. A determinação dos pesos do OF envolve a inversão da matriz de covariância $\mathbf{C}$, operação cuja complexidade é tipicamente da ordem de $\mathcal{O}(N^3)$ para métodos diretos de inversão matricial. Entretanto, essa etapa é realizada *offline*, durante o processo de calibração do detector. Já a aplicação do filtro na reconstrução evento a evento consiste apenas em uma combinação linear de N amostras digitalizadas, implicando custo computacional da ordem de $\mathcal{O}(N)$. Essa estrutura determinística é compatível com as restrições de latência do sistema de *trigger* do ATLAS.

O desempenho ótimo do filtro depende criticamente de:

- Estabilidade da forma nominal $\mathbf{g}$;
- Correta estimação de $\mathbf{C}$;
- Dominância de um único pulso na janela.

Essas hipóteses são válidas em regimes de baixa ocupação, mas tornam-se progressivamente mais frágeis à medida que o parâmetro μ aumenta e a superposição sistemática de múltiplos pulsos passa a dominar a forma do sinal (CERQUEIRA et al., 2016). Além disso, a modernização da eletrônica do TileCal, prevista para a Fase-II do ATLAS, implica a transmissão contínua das amostras digitalizadas ao sistema de *trigger*, eliminando a dependência estrita de uma janela fixa associada à decisão do L1 (ATLAS Collaboration, 2017). Nesse novo paradigma, a reconstrução pode ser formulada em fluxo, incluindo abordagens com janelas deslizantes e, potencialmente, processamento com granularidade por amostra, dependendo das restrições de latência e da arquitetura final do sistema.

Historicamente, o OF mostrou-se extremamente eficaz na reconstrução de energia no TileCal durante as *Runs* 1, 2 e 3. Entretanto, essa transição para o HL-LHC altera substancialmente o problema de estimação. Em vez de estimar a amplitude de um pulso presumidamente isolado dentro de uma janela fixa, torna-se necessário identificar e separar contribuições temporais parcialmente sobrepostas, mantendo simultaneamente restrições severas de latência e robustez operacional.

Nesse contexto, torna-se natural investigar métodos que relaxem as hipóteses estritas de pulso isolado e incorporem explicitamente estruturas temporais mais gerais ou modelos estatísticos alternativos para o ruído e para o sinal.

3.4 FILTRO DE WIENER

O Filtro de Wiener constitui uma solução clássica para problemas de estimação linear no sentido da minimização do erro quadrático médio (MSE, *Mean Squared Error*) (WIENER, 1949). Diferentemente do Filtro Ótimo apresentado na seção anterior, cuja

formulação impõe explicitamente a condição de não viés sob um modelo paramétrico do pulso, o Filtro de Wiener é derivado a partir de um critério puramente estatístico: minimizar diretamente o MSE entre um sinal desejado e sua estimativa linear.

Considerando o modelo discreto introduzido anteriormente:

$$\mathbf{s} = A \mathbf{g} + \boldsymbol{\varepsilon}, \quad (3.34)$$

onde $\mathbf{s}$ representa o vetor de amostras observadas, $\mathbf{g}$ a forma nominal do pulso discretizada, A a amplitude proporcional à energia depositada e $\boldsymbol{\varepsilon}$ um processo estocástico de média nula.

No formalismo do Wiener, define-se um sinal desejado d e busca-se um estimador linear:

$$\hat{d} = \mathbf{w}^T \mathbf{s}, \quad (3.35)$$

tal que o MSE:

$$J(\mathbf{w}) = \mathbb{E} \left[(d - \mathbf{w}^T \mathbf{s})^2 \right] \quad (3.36)$$

seja mínimo.

Derivando $J(\mathbf{w})$ em relação a $\mathbf{w}$ e impondo condição de estacionariedade, obtém-se o sistema de equações de Wiener-Hopf:

$$\mathbf{R}_{ss} \mathbf{w} = \mathbf{r}_{sd}, \quad (3.37)$$

onde:

$$\mathbf{R}_{ss} = \mathbb{E}[\mathbf{s}\mathbf{s}^T] \quad (3.38)$$

é a matriz de autocorrelação do sinal observado e:

$$\mathbf{r}_{sd} = \mathbb{E}[\mathbf{s}d] \quad (3.39)$$

é o vetor de correlação cruzada entre observação e sinal desejado (HAYKIN, 2002).

A solução ótima no sentido do MSE é então:

$$\mathbf{w}_W = \mathbf{R}_{ss}^{-1} \mathbf{r}_{sd}. \quad (3.40)$$

Diferentemente do OF, cujo vetor de pesos é derivado a partir de um modelo físico explícito da forma do pulso, o Filtro de Wiener requer a estimação estatística de $\mathbf{R}_{ss}$ e $\mathbf{r}_{sd}$ a partir de pares rotulados $(\mathbf{s}, d)$. Assim, sua implementação prática caracteriza-se

como um método supervisionado, no qual os coeficientes são obtidos por estimação das correlações a partir dos pares rotulados, equivalendo a uma regressão linear ótima em MSE (HAYKIN, 2002).

No contexto da estimação de energia no TileCal, pode-se definir:

$$d = A, \quad (3.41)$$

amplitude de referência obtida por calibração ou simulação Monte Carlo, de modo que os coeficientes do filtro sejam estimados estatisticamente para mapear o vetor de amostras $\mathbf{s}$ na amplitude desejada.

Assumindo independência entre ruído e amplitude, e $\mathbb{E}[\varepsilon] = 0$, obtém-se:

$$\mathbb{E}[\mathbf{s}\mathbf{s}^T] = \mathbb{E}[A^2] \mathbf{g}\mathbf{g}^T + \mathbf{C} \quad (3.42)$$

e

$$\mathbb{E}[\mathbf{s}A] = \mathbb{E}[A^2] \mathbf{g}. \quad (3.43)$$

Logo,

$$\mathbf{R}_{ss} = \mathbb{E}[A^2] \mathbf{g}\mathbf{g}^T + \mathbf{C} \quad (3.44)$$

e

$$\mathbf{r}_{sd} = \mathbb{E}[A^2] \mathbf{g}. \quad (3.45)$$

Substituindo na equação de Wiener–Hopf:

$$\mathbf{w}_W = (\mathbb{E}[A^2] \mathbf{g}\mathbf{g}^T + \mathbf{C})^{-1} \mathbb{E}[A^2] \mathbf{g}. \quad (3.46)$$

Enquanto o OF pode ser interpretado como um estimador condicional ao modelo físico determinístico do pulso, o Filtro de Wiener admite interpretação Bayesiana linear quando se assume uma distribuição a priori para a amplitude A . Nesse contexto, $\mathbb{E}[A^2]$ incorpora informação estatística prévia sobre a dispersão esperada das amplitudes, e o estimador resultante corresponde ao estimador linear de mínimo erro quadrático médio (LMMSE) (KAY, 1993).

Observa-se que, quando a amplitude A é tratada como parâmetro determinístico e o modelo linear é exato, o estimador de Wiener reduz-se estruturalmente ao estimador de máxima verossimilhança sob ruído gaussiano, coincidindo com o OF sob restrição de não viés. Quando A é modelado como variável aleatória, o Wiener corresponde ao estimador

linear de mínimo erro quadrático médio, admitindo a possibilidade de viés em troca de redução da variância total.

Para processos estacionários, o Filtro de Wiener admite interpretação espectral particularmente elucidativa. No domínio da frequência, a função de transferência ótima é:

$$H(\omega) = \frac{S_{sd}(\omega)}{S_{ss}(\omega)}, \quad (3.47)$$

em que $S_{sd}(\omega)$ é a densidade espectral cruzada entre o sinal desejado d e o sinal observado s , e $S_{ss}(\omega)$ é a densidade espectral de potência do sinal observado, assumindo independência entre sinal e ruído e processos estacionários no sentido amplo (OPPENHEIM et al., 1999).

No caso clássico de recuperação de um sinal conhecido imerso em ruído aditivo, quando se modela o processo desejado associado à forma do pulso como uma componente estocástica de densidade espectral $S_{gg}(\omega)$, a função de transferência ótima assume a forma:

$$H(\omega) = \frac{S_{gg}(\omega)}{S_{gg}(\omega) + S_{\varepsilon\varepsilon}(\omega)}. \quad (3.48)$$

Essa expressão mostra que o filtro atua como ponderador espectral dependente da relação sinal-ruído (SNR), preservando frequências dominadas pelo sinal e atenuando regiões espectrais dominadas por ruído.

O Filtro de Wiener pode ser implementado como:

- Filtro FIR (*Finite Impulse Response*) não causal (janela fixa);
- Filtro FIR causal;
- Filtro IIR (*Infinite Impulse Response*), via fatoração espectral.

Embora existam implementações FIR e IIR do Filtro de Wiener, a reconstrução de energia empregada em sistemas como o TileCal privilegia a estrutura FIR. Isso ocorre porque a estimativa depende apenas de uma janela finita de amostras, produzindo uma resposta em tempo finito e com latência conhecida, o que facilita sua implementação em FPGA e atende às restrições temporais impostas pelo sistema de *trigger*. Em contraste, filtros IIR utilizam realimentação, fazendo com que a saída dependa também de estimativas anteriores, o que aumenta a complexidade de análise, implementação e validação em aplicações de tempo real.

A determinação dos coeficientes envolve a inversão de $\mathbf{R}_{ss}$, cuja complexidade é tipicamente $\mathcal{O}(N^3)$ para métodos diretos. Entretanto, assim como no OF, essa etapa pode ser realizada *offline*. A aplicação do filtro consiste em uma combinação linear de N amostras, implicando custo computacional $\mathcal{O}(N)$ por evento.

Em regimes de alta ocupação, nos quais a superposição temporal de múltiplos pulsos viola a hipótese de pulso isolado, a formulação baseada em correlação estatística pode oferecer maior flexibilidade. Além disso, a possibilidade de formulação em termos de processos estacionários e processamento contínuo aproxima o Wiener de arquiteturas compatíveis com a leitura totalmente digital prevista para a Fase-II do TileCal. Entretanto, sua aplicação prática depende de estimação robusta das matrizes de correlação e da estabilidade estatística do processo, fatores que se tornam críticos em ambientes de alta ocupação.

3.5 PERCEPTRON MULTICAMADAS (MLP)

Os métodos apresentados nas seções anteriores pertencem à classe de estimadores lineares. Embora apresentem excelente desempenho sob hipóteses adequadas sobre o ruído e a forma do pulso, sua estrutura impõe limitações quando a relação entre o vetor de amostras $\mathbf{s}$ e a amplitude A torna-se não linear, como pode ocorrer em regimes de alta ocupação, presença de *pile-up* sistemático ou variações instrumentais complexas.

Sob uma perspectiva mais geral, a estimação de energia pode ser reinterpretada como um problema de regressão. A partir do modelo vetorial introduzido anteriormente, a reconstrução da amplitude pode ser formulada como a aproximação de uma função desconhecida que mapeia o vetor de amostras digitalizadas $\mathbf{s} \in \mathbb{R}^N$ na amplitude verdadeira A .

Nesse enquadramento, os métodos lineares clássicos, como o Filtro Ótimo e o Filtro de Wiener, correspondem a hipóteses específicas para essa função de mapeamento — essencialmente restritas a combinações lineares das amostras. Torna-se, portanto, natural recorrer ao formalismo de aprendizado supervisionado, no qual o mapeamento entre $\mathbf{s}$ e A é aprendido a partir de dados rotulados (BISHOP, 2006; GOODFELLOW et al., 2016). Nesse contexto, modelos lineares representam casos particulares, enquanto arquiteturas não lineares ampliam significativamente o espaço de funções representáveis.

No paradigma supervisionado, considera-se um conjunto de treinamento composto por pares $(\mathbf{s}^{(m)}, A^{(m)})$, onde $\mathbf{s}^{(m)} \in \mathbb{R}^N$ representa o vetor de amostras digitalizadas do pulso e $A^{(m)}$ a amplitude de referência obtida por calibração ou simulação Monte Carlo. O objetivo consiste em ajustar um modelo paramétrico $f(\mathbf{s}; \boldsymbol{\theta})$ que aproxime o mapeamento subjacente entre o vetor de amostras e a amplitude.

O ajuste dos parâmetros $\boldsymbol{\theta}$ é realizado por meio da minimização de uma função de custo que quantifica o erro entre as amplitudes previstas e as amplitudes de referência. No caso mais comum, utiliza-se o erro quadrático médio (MSE) empírico:

$$\mathcal{L}(\boldsymbol{\theta}) = \frac{1}{M} \sum_{m=1}^M \left(A^{(m)} - f(\mathbf{s}^{(m)}; \boldsymbol{\theta}) \right)^2, \quad (3.49)$$

em que M é o número de exemplos de treinamento.

O treinamento por minimização do MSE é equivalente à estimação por máxima verossimilhança sob hipótese de ruído gaussiano aditivo:

$$A = f(\mathbf{s}; \boldsymbol{\theta}) + \varepsilon, \quad (3.50)$$

com $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ (BISHOP, 2006). Esse critério conecta diretamente ao formalismo do Filtro de Wiener. Quando f é restrita a combinações lineares das amostras, recupera-se um problema de regressão linear, cuja solução coincide com o estimador de Wiener, desde que as matrizes de correlação sejam estimadas empiricamente a partir dos dados. Assim, a regressão linear pode ser interpretada como caso particular desse formalismo. Além disso, sob regularização adequada (como penalização ℓ_2), o treinamento pode ser interpretado como uma estimação Bayesiana com prior gaussiano sobre os pesos (BISHOP, 2006).

Entre os modelos não lineares capazes de realizar esse mapeamento, o Perceptron Multicamadas (*Multilayer Perceptron* – MLP) destaca-se como uma das arquiteturas mais fundamentais e amplamente utilizadas. O MLP é uma rede neural do tipo *feedforward* composta por camadas sucessivas de transformações afins seguidas de não linearidades. Em sua forma mais simples, com uma única camada oculta, o mapeamento entre o vetor de entrada $\mathbf{s} \in \mathbb{R}^N$ e a estimativa da amplitude $\hat{A}$ pode ser descrito por:

$$\hat{A} = f(\mathbf{s}) = \mathbf{v}^T \boldsymbol{\phi}(\mathbf{W}\mathbf{s} + \mathbf{b}) + c, \quad (3.51)$$

onde:

- $\mathbf{W} \in \mathbb{R}^{H \times N}$ é a matriz de pesos da camada oculta;
- $\mathbf{b} \in \mathbb{R}^H$ é o vetor de vieses da camada oculta;
- $\boldsymbol{\phi}(\cdot)$ é a função de ativação não linear aplicada elemento a elemento;
- $\mathbf{v} \in \mathbb{R}^H$ e $c \in \mathbb{R}$ correspondem aos parâmetros da camada de saída;
- H é o número de neurônios na camada oculta.

Essa estrutura pode ser interpretada como uma composição de funções:

$$f(\mathbf{s}) = f_2(f_1(\mathbf{s})), \quad (3.52)$$

onde f_1 realiza uma transformação linear seguida de não linearidade e f_2 executa uma combinação linear das ativações intermediárias.

As funções de ativação introduzem não linearidade na arquitetura e são fundamentais para expandir o espaço de funções representáveis. Entre as mais utilizadas destacam-se:

$$\text{ReLU}(x) = \max(0, x), \quad (3.53)$$

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}, \quad (3.54)$$

$$\sigma(x) = \frac{1}{1 + e^{-x}}. \quad (3.55)$$

A escolha da função de ativação influencia propriedades como estabilidade numérica, propagação de gradiente e capacidade de modelagem (GOODFELLOW et al., 2016).

A transformação linear inicial $\mathbf{W}\mathbf{s}$ pode ser interpretada como a aplicação de um banco de filtros FIR (*Finite Impulse Response*) aprendidos a partir dos dados. Cada linha $\mathbf{w}_i^T$ de $\mathbf{W}$ atua como um filtro linear aplicado ao vetor de amostras digitais:

$$z_i = \mathbf{w}_i^T \mathbf{s} + b_i. \quad (3.56)$$

Assim, a primeira camada do MLP realiza uma decomposição adaptativa do sinal de entrada em H componentes filtradas, cuja combinação posterior, após a aplicação da não linearidade $\phi(\cdot)$, permite capturar interações não lineares entre essas componentes.

Enquanto o OF projeta o vetor de amostras sobre a direção definida pela forma nominal do pulso segundo a métrica $\mathbf{C}^{-1}$, o MLP aprende subespaços discriminativos diretamente a partir dos dados, sem impor explicitamente um modelo paramétrico fixo para a forma temporal do pulso. Nesse sentido, a camada linear pode ser interpretada como uma generalização *data-driven* do conceito de filtro casado.

Considerando que o vetor $\mathbf{s}$ contém amostras temporais igualmente espaçadas, a operação linear $\mathbf{W}\mathbf{s}$ equivale à aplicação de combinações lineares no domínio do tempo. Essas combinações lineares podem ser interpretadas como filtros FIR com respostas em frequência determinadas pelos coeficientes aprendidos. Assim, a rede é capaz de aprender implicitamente ponderações espectrais que favorecem a separação entre padrões associados a diferentes amplitudes ou condições de *pile-up*.

Em contraste com o Filtro de Wiener, cuja resposta em frequência é obtida analiticamente a partir das densidades espectrais de potência do sinal e do ruído, o MLP ajusta seus filtros de maneira empírica, podendo explorar estruturas espectrais não modeladas explicitamente.

Cada neurônio da camada oculta define um hiperplano no espaço $\mathbb{R}^N$ das amostras. A aplicação da função de ativação introduz uma partição não linear desse espaço, permitindo que a rede construa regiões do espaço de entrada com regimes locais distintos. A camada de saída combina essas regiões de forma linear, resultando em uma superfície de estimação não linear para a amplitude. Essa flexibilidade estrutural torna-se particularmente relevante

em cenários de alta ocupação, nos quais a superposição de múltiplos pulsos pode deslocar o vetor $\mathbf{s}$ para regiões do espaço de entrada que não são bem descritas por modelos lineares globais.

Quando o ruído apresenta correlação entre amostras, como discutido nas seções anteriores, métodos lineares incorporam explicitamente a matriz de covariância $\mathbf{C}$. No MLP, $\mathbf{C}$ não é inserida analiticamente. As correlações são internalizadas durante o treinamento, desde que o conjunto de dados seja representativo. Nesse sentido, a rede pode aprender transformações funcionais que desempenham papel análogo ao pré-branqueamento estatístico implícito, desde que tal estrutura esteja representada nos dados de treinamento. Essas transformações são então combinadas com projeções não lineares subsequentes. Tal característica aproxima o MLP de um estimador adaptativo cuja estrutura não é restrita a hipóteses gaussianas ou lineares.

A estimação dos parâmetros $\boldsymbol{\theta}$ é realizada por meio de métodos de otimização baseados em gradiente, tipicamente utilizando o algoritmo de retropropagação (*backpropagation*) em conjunto com variações de descida do gradiente estocástico (GOODFELLOW et al., 2016). A atualização iterativa dos parâmetros pode ser expressa genericamente como:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta \nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}_t), \quad (3.57)$$

onde η é a taxa de aprendizado e $\nabla_{\boldsymbol{\theta}} \mathcal{L}$ representa o gradiente da função de custo em relação aos parâmetros.

Diferentemente dos estimadores lineares clássicos, cuja solução pode ser obtida de forma analítica (por exemplo, via inversão matricial), o treinamento do MLP envolve a resolução de um problema de otimização não convexo. Consequentemente, a solução encontrada corresponde, em geral, a um mínimo local ou ponto estacionário da função de custo.

Para um MLP com uma única camada oculta contendo H neurônios e entrada de dimensão N , o número total de parâmetros livres é dado por:

$$P = HN + H + H + 1 = H(N + 2) + 1, \quad (3.58)$$

onde:

- HN corresponde aos pesos da matriz $\mathbf{W}$;
- H corresponde aos vieses da camada oculta $\mathbf{b}$;
- H corresponde aos pesos da camada de saída $\mathbf{v}$;
- 1 corresponde ao viés escalar c .

Observa-se que o número de parâmetros cresce linearmente com a dimensão da entrada N e com o número de neurônios H . Para arquiteturas profundas com múltiplas camadas ocultas, o crescimento torna-se aproximadamente proporcional ao número total de conexões entre camadas consecutivas. No problema específico da estimação de energia no TileCal, a dimensão da entrada é tipicamente pequena (por exemplo, $N = 7$ amostras digitalizadas), o que mantém o número de parâmetros moderado mesmo para valores relativamente elevados de H .

É importante distinguir a complexidade do treinamento da complexidade de inferência. O treinamento requer múltiplas passagens pelo conjunto de dados, sendo a complexidade aproximada por época (uma passagem pelos M exemplos) da ordem de:

$$\mathcal{O}(M \cdot HN), \quad (3.59)$$

Por outro lado, a inferência (aplicação do modelo já treinado a um evento individual) envolve essencialmente multiplicações e somas associadas às transformações lineares e à aplicação das funções de ativação. Para uma única camada oculta, o custo por evento é da ordem de:

$$\mathcal{O}(HN), \quad (3.60)$$

superior ao custo $\mathcal{O}(N)$ do OF, mas ainda compatível com implementação em arquiteturas modernas de hardware, incluindo FPGA e sistemas embarcados, desde que H permaneça moderado.

Uma questão central no uso de arquiteturas baseadas em MLP refere-se à capacidade de aproximação da rede e ao papel da profundidade (número de camadas ocultas) na representação de funções complexas. O Teorema da Aproximação Universal estabelece que um MLP com uma única camada oculta e número suficiente de neurônios é capaz de aproximar qualquer função contínua definida em um compacto de $\mathbb{R}^N$, com precisão arbitrária (HORNIK et al., 1989). Esse resultado garante, do ponto de vista teórico, que mesmo arquiteturas rasas possuem capacidade de modelagem suficientemente geral.

É importante observar, contudo, que esse resultado refere-se à capacidade de representação da arquitetura e não constitui garantia de que o procedimento de treinamento convergirá para tal aproximação em termos práticos. A obtenção de soluções adequadas depende do método de otimização, da inicialização dos parâmetros e da disponibilidade de dados suficientemente representativos.

Entretanto, a profundidade influencia diretamente a eficiência representacional da rede. Funções que exigiriam um número muito elevado de neurônios em uma única camada podem ser representadas de forma mais compacta quando distribuídas em múl-

tiplas camadas. Isso permite a composição hierárquica de transformações não lineares (GOODFELLOW et al., 2016).

No contexto da estimação de energia em calorimetria, essa propriedade é particularmente relevante. Efeitos como superposição sistemática de pulsos, variações instrumentais dependentes da ocupação e possíveis não linearidades eletrônicas podem introduzir dependências estruturais entre as amostras que não são bem descritas por um modelo linear global. Arquiteturas mais profundas permitem modelar essas interações de forma progressiva, extraindo representações intermediárias que capturam padrões temporais compostos.

Cada camada adicional aplica uma nova transformação afim seguida de não linearidade, deformando sucessivamente o espaço de entrada. Essa sequência de transformações aumenta a complexidade das superfícies de estimação possíveis, ampliando o espaço de hipóteses considerado durante o treinamento.

Contudo, maior profundidade implica aumento do número de parâmetros livres. Consequentemente, cresce o risco de sobreajuste (*overfitting*) quando o conjunto de treinamento não captura adequadamente a variabilidade operacional do detector. Assim, a escolha da arquitetura envolve um compromisso entre capacidade de modelagem, estabilidade estatística e viabilidade computacional.

Apesar de sua flexibilidade, o MLP apresenta limitações importantes no contexto de aplicações em sistemas de aquisição em tempo real:

- Dependência de dados rotulados representativos;
- Sensibilidade a mudanças de regime operacional;
- Ausência de interpretação física explícita dos parâmetros;
- Necessidade de validação contínua para evitar degradação de desempenho.

Diferentemente do OF, cuja estrutura é diretamente derivada de um modelo físico e estatístico explícito do pulso e do ruído, o MLP constitui um estimador paramétrico orientado por dados. Sua aplicação eficaz requer, portanto, um equilíbrio entre flexibilidade funcional, estabilidade estatística e viabilidade computacional, especialmente em contextos de operação em tempo real.

Em síntese, o Perceptron Multicamadas pode ser interpretado como uma extensão não linear dos estimadores clássicos apresentados nas seções anteriores, oferecendo maior capacidade de modelagem ao custo de maior complexidade estrutural e dependência de dados de treinamento.

3.6 MÁQUINAS DE VETORES DE SUPORTE (SVM/SVR)

Os métodos discutidos nas seções anteriores podem ser organizados em duas famílias:

- (i) estimadores com solução analítica sob hipóteses estatísticas bem definidas (OF e Wiener), e
- (ii) modelos paramétricos orientados por dados, treinados por otimização numérica (MLP).

Uma alternativa clássica, particularmente relevante em cenários de amostras de entrada de baixa dimensionalidade e com necessidade de controle explícito de complexidade, é a família de Máquinas de Vetores de Suporte (*Support Vector Machines* - SVM) (Vapnik, 1995; Schölkopf e Smola, 2002; Hastie, Tibshirani e Friedman, 2009).

Embora originalmente proposta para classificação, a extensão para regressão — conhecida como SVR (*Support Vector Regression*) — fornece um estimador supervisionado para a amplitude, no qual o mapeamento $\mathbf{s} \mapsto A$ é obtido por minimização de risco empírico regularizado, com uma perda robusta do tipo ε -insensível (Smola e Schölkopf, 2004; Vapnik, 1998). No contexto do TileCal, essa formulação é atraente porque:

- A entrada é tipicamente curta ($N = 7$ amostras por janela);
- O problema é naturalmente supervisionado por meio de pares rotulados $(\mathbf{s}^{(m)}, A^{(m)})$;
- A regularização é controlada por hiperparâmetros com interpretação direta, permitindo mitigar sobreajuste mesmo com bases de treinamento finitas.

Considere um conjunto de treinamento composto por M pares $(\mathbf{s}^{(m)}, A^{(m)})$, com $\mathbf{s}^{(m)} \in \mathbb{R}^N$ e $A^{(m)} \in \mathbb{R}$. No SVR linear, procura-se uma função afim:

$$f(\mathbf{s}) = \mathbf{w}^T \mathbf{s} + b, \quad (3.61)$$

determinada de modo a equilibrar fidelidade aos dados e complexidade do modelo. A medida de complexidade é tipicamente a norma $\|\mathbf{w}\|_2^2$, enquanto a fidelidade é expressa pela perda ε -insensível:

$$L_\varepsilon(r) = \max(0, |r| - \varepsilon), \quad (3.62)$$

onde $r = A - f(\mathbf{s})$ é o resíduo (Smola e Schölkopf, 2004; Hastie, Tibshirani e Friedman, 2009).

A partir disso, a forma primal do SVR pode ser escrita como o problema convexo:

$$\min_{\mathbf{w}, b, \xi, \xi^*} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{m=1}^M (\xi_m + \xi_m^*) \quad (3.63)$$

sujeito a:

$$\begin{aligned} A^{(m)} - \mathbf{w}^T \mathbf{s}^{(m)} - b &\leq \varepsilon + \xi_m, \\ \mathbf{w}^T \mathbf{s}^{(m)} + b - A^{(m)} &\leq \varepsilon + \xi_m^*, \\ \xi_m &\geq 0, \quad \xi_m^* \geq 0, \quad m = 1, \dots, M, \end{aligned}$$

em que ξ_m e ξ_m^* são variáveis de folga, $C > 0$ controla a penalização de violações da faixa de tolerância ε , e $\varepsilon \geq 0$ define a largura do “tubo” de insensibilidade (Vapnik, 1998; Smola e Schölkopf, 2004).

Do ponto de vista estatístico, o termo de regularização $\|\mathbf{w}\|_2^2$ atua como um prior implícito de suavidade (ou preferência por funções de baixa complexidade), enquanto a perda ε -insensível induz robustez a perturbações pequenas nos alvos, característica útil quando $A^{(m)}$ é uma amplitude de referência sujeita a incertezas de calibração e flutuações experimentais (BISHOP, 2006).

Em regimes de alta ocupação, *pile-up* e variações instrumentais, é plausível que o mapeamento entre $\mathbf{s}$ e A apresente componentes não lineares que não são bem representadas por uma função afim global. A extensão padrão consiste em substituir o produto interno por uma função núcleo (*kernel*):

$$K(\mathbf{s}, \mathbf{s}') = \langle \Phi(\mathbf{s}), \Phi(\mathbf{s}') \rangle, \quad (3.64)$$

o que equivale a realizar a regressão linear em um espaço de características (possivelmente de alta dimensão) sem construir explicitamente o mapeamento Φ (Schölkopf e Smola, 2002; Smola e Schölkopf, 2004).

Na forma dual, a solução do SVR pode ser expressa como:

$$f(\mathbf{s}) = \sum_{m=1}^M (\alpha_m - \alpha_m^*) K(\mathbf{s}^{(m)}, \mathbf{s}) + b, \quad (3.65)$$

onde apenas um subconjunto dos exemplos apresenta coeficientes não nulos; esses exemplos são os *vetores de suporte* e determinam a predição final (Vapnik, 1998; Smola e Schölkopf, 2004). *Kernels* comuns incluem:

- **Linear:** $K(\mathbf{s}, \mathbf{s}') = \mathbf{s}^T \mathbf{s}'$;
- **Polinomial:** $K(\mathbf{s}, \mathbf{s}') = (\gamma \mathbf{s}^T \mathbf{s}' + r)^p$;
- **RBF/Gaussiano:** $K(\mathbf{s}, \mathbf{s}') = \exp(-\gamma \|\mathbf{s} - \mathbf{s}'\|_2^2)$.

O *kernel* RBF, em particular, é frequentemente empregado quando não se deseja impor uma forma paramétrica explícita para a não linearidade, ajustando sua escala por meio de γ (Hastie, Tibshirani e Friedman, 2009; Schölkopf e Smola, 2002). O parâmetro γ atua como um fator de escala na distância quadrática entre amostras, modulando o decaimento exponencial da similaridade no espaço de entrada. Em implementações práticas, uma parametrização frequentemente adotada para o caso do núcleo RBF define automaticamente o valor de γ como:

$$\gamma = \frac{1}{n_{\text{features}} \cdot \hat{\sigma}_X^2}, \quad (3.66)$$

em que n_{features} corresponde à dimensionalidade do vetor de entrada e $\hat{\sigma}_X^2$ representa a variância média empírica por característica no conjunto de treinamento. Essa escolha ajusta a largura efetiva do núcleo à escala dos dados, tornando o parâmetro menos sensível à magnitude absoluta das entradas.

Quando as variáveis de entrada são previamente padronizadas para média nula e variância unitária, tem-se $\hat{\sigma}_X^2 \approx 1$, resultando aproximadamente em:

$$\gamma \approx \frac{1}{n_{\text{features}}}. \quad (3.67)$$

Nesse caso, a largura efetiva do núcleo passa a depender principalmente da dimensionalidade da janela temporal utilizada como entrada do modelo.

Com entrada temporal curta (N amostras igualmente espaçadas), o caso linear do SVR (3.63) produz um estimador do tipo:

$$\hat{A} = \mathbf{w}^T \mathbf{s} + b, \quad (3.68)$$

ou seja, uma combinação linear que pode ser interpretada como um filtro FIR de comprimento N com termo de *offset* b , semelhante na forma aos estimadores lineares apresentados anteriormente. A diferença fundamental reside no critério de projeto: enquanto OF e Wiener obtêm pesos a partir de hipóteses explícitas sobre $\mathbf{g}$ e/ou sobre as correlações do ruído, o SVR aprende $\mathbf{w}$ por minimização de risco regularizado a partir de dados rotulados, incorporando robustez por meio da perda ε -insensível e controle de complexidade via $\|\mathbf{w}\|_2^2$ (Hastie, Tibshirani e Friedman, 2009).

Na versão não linear com *kernel*, a predição (3.65) pode ser vista como uma expansão em uma base de funções centradas nas amostras de treinamento, o que permite capturar variações não lineares do espaço de sinais (como padrões de *pile-up* recorrentes) sem impor um modelo físico determinístico para essas distorções (Schölkopf e Smola, 2002; Smola e Schölkopf, 2004).

Diferentemente do MLP, cujo treinamento resolve um problema não convexo, o SVR resolve um problema convexo; portanto, para hiperparâmetros fixos (C, ε, γ), a solução

é global (Vapnik, 1998; Smola e Schölkopf, 2004). Na prática, os hiperparâmetros são escolhidos por validação cruzada ou busca em grade, com normalização das entradas $\mathbf{s}$ sendo usual para estabilizar a otimização e tornar comparáveis escalas entre amostras (Hastie, Tibshirani e Friedman, 2009).

A complexidade de treinamento de métodos baseados em *kernel* pode crescer de forma acentuada com M , devido à necessidade de manipular matrizes densas de *kernel*, sendo comum reportar custos polinomiais em M no pior caso, podendo variar entre $\mathcal{O}(M^2)$ e $\mathcal{O}(M^3)$ em formulações clássicas baseadas em programação quadrática, a depender do algoritmo de otimização empregado e da estrutura dos dados (Hastie, Tibshirani e Friedman, 2009; Smola e Schölkopf, 2004).

Em contraste, a inferência para um evento é proporcional ao número de vetores de suporte S . Assim, o custo por evento pode ser:

- $\mathcal{O}(N)$, se SVR linear, ou
- $\mathcal{O}(S \cdot N)$, se SVR com *kernel* (como RBF).

Desse modo, para aplicações de baixa latência, o caso linear ou abordagens com redução de S (por exemplo, seleção de suporte, aproximações ou treinamento com restrições) tendem a ser mais compatíveis com implementação em sistemas embarcados e FPGA (Hastie, Tibshirani e Friedman, 2009).

No SVR linear, a dimensionalidade do modelo é diretamente dada por N (mais o termo de viés b), o que é particularmente favorável para o TileCal quando $N = 7$:

$$P_{\text{linear}} \approx N + 1. \quad (3.69)$$

Isso contrasta com o MLP, cujo número de parâmetros cresce com H e, em arquiteturas profundas, com o total de conexões entre camadas.

No SVR com *kernel*, a capacidade do modelo não é convenientemente descrita por um número fixo de parâmetros na forma primal; operacionalmente, ela se manifesta via o número de vetores de suporte e pela escolha dos hiperparâmetros (C, ε, γ) (Schölkopf e Smola, 2002; Hastie, Tibshirani e Friedman, 2009). Isso fornece um controle de complexidade muitas vezes mais transparente do que em modelos de rede, mas introduz limitações relevantes:

- **Custo de treinamento:** pode tornar-se elevado para grandes bases rotuladas;
- **Custo de inferência com *kernel*:** depende de S e pode crescer em cenários complexos;

- **Sensibilidade a hiperparâmetros:** requer validação cuidadosa e padronização das entradas;
- **Transferência de domínio:** mudanças de regime operacional podem exigir revalidação e reajuste de (C, ε, γ) , tal como em outros métodos supervisionados.

Em síntese, o SVR oferece um compromisso distinto dos métodos anteriores: mantém a interpretação de um estimador por regressão supervisionada com regularização explícita, possui treinamento convexo (solução global) e, no caso linear, preserva custo de inferência próximo ao de um filtro FIR. Por outro lado, extensões por *kernel* ampliam a capacidade de modelagem não linear à custa de maior custo computacional e maior sensibilidade à escolha de hiperparâmetros, aspectos que devem ser avaliados à luz das restrições de latência e robustez operacional do TileCal.

3.7 REDES NEURAIAS CONVOLUCIONAIS (CNN)

Assim como discutido na Seção 3.5, métodos baseados em aprendizado supervisionado permitem aprender diretamente, a partir de dados rotulados, o mapeamento entre o vetor de amostras $\mathbf{s}$ e a amplitude A (BISHOP, 2006; GOODFELLOW et al., 2016). No caso do Perceptron Multicamadas, a primeira camada realiza combinações lineares globais das entradas. Em contrapartida, Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNNs) incorporam explicitamente o princípio de *processamento local* e *compartilhamento de pesos*, o que é particularmente adequado quando a informação relevante está organizada como padrões locais no tempo (ou em representações tempo-frequência) (LeCun et al., 1998).

No contexto da reconstrução janelada do TileCal, o vetor de entrada $\mathbf{s} \in \mathbb{R}^N$ contém amostras igualmente espaçadas no tempo. Uma CNN 1D aplica, em cada camada, um conjunto de operações de convolução/correlação discretas (implementadas, na prática, como correlação cruzada) com núcleos (*kernels*) curtos. Para um canal de entrada $x[n]$ e um *kernel* $h_k[\ell]$ de comprimento L , a saída convolucional (na forma usada em implementações modernas, frequentemente como correlação) pode ser escrita como:

$$y_k[n] = \sum_{\ell=0}^{L-1} h_k[\ell] x[n + \ell] + b_k, \quad (3.70)$$

onde b_k é um viés associado ao filtro k . Nesta dissertação, as expressões seguem a convenção de correlação cruzada adotada nas principais bibliotecas de *deep learning*.

Após a operação linear, aplica-se uma não linearidade ponto a ponto, como ReLU, obtendo-se:

$$\tilde{y}_k[n] = \phi(y_k[n]). \quad (3.71)$$

Cada *kernel* $h_k[\ell]$ pode ser interpretado como um filtro FIR de baixa ordem aprendido a partir dos dados. A principal diferença em relação ao MLP é que o filtro é aplicado de maneira *deslizante* na entrada, explorando estrutura local e produzindo mapas de características (*feature maps*). Esse mecanismo impõe um viés indutivo útil: padrões locais semelhantes (como variações do pulso em torno do máximo) são detectados por um mesmo conjunto de coeficientes, reduzindo a quantidade de parâmetros necessários em comparação a camadas totalmente conectadas (GOODFELLOW et al., 2016).

Para estimação de energia, o objetivo é uma saída escalar $\hat{A}$, e não uma classe. Uma arquitetura típica consiste em:

- (i) blocos convolucionais 1D (convolução + ativação, eventualmente normalização),
- (ii) uma etapa de agregação/compactação (*pooling* ou agregação global), e
- (iii) uma camada final linear para regressão.

Representando a saída do último bloco convolucional por um conjunto de mapas $\tilde{y}_k[n]$, uma estratégia comum é a agregação por *global average pooling*:

$$u_k = \frac{1}{N'} \sum_{n=1}^{N'} \tilde{y}_k[n], \quad (3.72)$$

onde N' é o comprimento do mapa de características na saída do bloco convolucional (dependente de *stride* e *padding*). Seguida por uma regressão linear:

$$\hat{A} = \mathbf{a}^T \mathbf{u} + c, \quad (3.73)$$

onde $\mathbf{u} = [u_1, \dots, u_K]^T$, K é o número de filtros no último bloco, $\mathbf{a}$ são pesos de saída e c é um viés. Essa escolha reduz sensibilidade a pequenas translações temporais e estabiliza a dimensionalidade da representação intermediária (GOODFELLOW et al., 2016).

Quando o conjunto de entrada inclui múltiplos canais (por exemplo, amostras de mais de uma célula, ou *features* adicionais por amostra), pode-se organizar os dados como $x_c[n]$ com $c = 1, \dots, C$, e a convolução passa a somar também sobre canais:

$$y_k[n] = \sum_{c=1}^C \sum_{\ell=0}^{L-1} h_{k,c}[\ell] x_c[n + \ell] + b_k. \quad (3.74)$$

Essa formulação é útil para cenários em que parte da informação sobre *pile-up* e ruído correlacionado aparece de forma distinta em canais/entradas.

O treinamento segue o paradigma supervisionado com pares $(\mathbf{s}^{(m)}, A^{(m)})$. Para regressão, é usual minimizar o MSE empírico, como na Seção 3.5, ou variantes robustas (por exemplo, perda de Huber, que combina comportamento quadrático para resíduos

pequenos e linear para resíduos grandes) quando se deseja menor sensibilidade a *outliers* (BISHOP, 2006). Sob hipótese de ruído gaussiano aditivo na variável alvo, a minimização do MSE é equivalente à maximização de verossimilhança (BISHOP, 2006). A estimação dos parâmetros é realizada por retropropagação e otimizadores baseados em gradiente (SGD, Adam), em um problema tipicamente não convexo (RUMELHART et al., 1986; GOODFELLOW et al., 2016).

Uma vantagem central de CNNs é o compartilhamento de pesos. Em uma camada convolucional 1D com C canais de entrada, K filtros e *kernel* de comprimento L , o número de parâmetros é:

$$P_{\text{conv}} = K(CL + 1), \quad (3.75)$$

onde o termo $+1$ corresponde ao viés por filtro. Comparativamente, uma camada totalmente conectada mapeando $\mathbb{R}^{CN}$ para $\mathbb{R}^H$ teria número de parâmetros:

$$P_{\text{FC}} \approx H(CN + 1), \quad (3.76)$$

que cresce mais rapidamente com N . No TileCal, N é pequeno (tipicamente 7), mas a economia de parâmetros ainda é relevante quando se deseja robustez e melhor generalização, especialmente ao empilhar camadas e aumentar o número de filtros K , caso em que o compartilhamento de pesos evita crescimento proporcional a N em cada bloco.

A complexidade de inferência por camada convolucional é proporcional ao número de operações de MAC (multiplicação-acumulação). Para uma saída de comprimento N' tem-se:

$$\mathcal{O}(K C L N'). \quad (3.77)$$

Como L é pequeno (*kernels* curtos) e N' é da ordem de N , a inferência pode ser compatível com implementação em *hardware* dedicado, desde que o número de filtros e camadas seja moderado. Tal como nos métodos anteriores, a etapa custosa é o treinamento, realizado *offline*.

Blocos convolucionais implementam uma cascata de bancos de filtros (FIR aprendidos) seguida de não linearidades, o que permite construir representações que se aproximam de operações clássicas (detecção, realce, supressão de ruído) mas ajustadas empiricamente aos dados. Em regimes de *pile-up*, onde a forma do pulso observado pode resultar de superposição de contribuições e de ruído colorido, a CNN pode aprender filtros que respondem a padrões locais associados ao pulso de interesse e atenuam padrões típicos de interferência, sem impor explicitamente uma forma nominal única $\mathbf{g}$.

Apesar disso, vale destacar que essa flexibilidade depende de dados de treinamento representativos do regime operacional: mudanças de distribuição (como variações de

temporização, ganho, ou condições de ocupação) podem degradar o desempenho se não forem contempladas na validação e, eventualmente, em pré-treinamentos periódicos (GOODFELLOW et al., 2016).

Embora CNNs apresentem boa eficiência paramétrica e forte aderência a sinais com estrutura local, existem limitações relevantes para aplicações em tempo real:

- Dependência de dados rotulados representativos (calibração/MC) e risco de *dataset shift*;
- Sensibilidade a escolhas de arquitetura (profundidade, número de filtros, tamanho de *kernel*) e hiperparâmetros;
- Menor interpretabilidade física direta dos parâmetros, quando comparada a filtros derivados analiticamente;
- Necessidade de verificação de latência/recursos em implementação embarcada, especialmente com múltiplas camadas.

Em síntese, CNNs constituem uma alternativa não linear com viés indutivo apropriado para sinais temporais: combinam filtragem local aprendida, não linearidade e agregação, podendo capturar padrões associados à estimação de amplitude em condições onde modelos lineares globais se tornam limitados (LeCun et al., 1998; GOODFELLOW et al., 2016).

4 METODOLOGIA EXPERIMENTAL E AVALIAÇÃO DE DESEMPENHO

Este capítulo descreve o protocolo experimental adotado para a comparação dos métodos de estimação de energia apresentados no Capítulo 3. Inicialmente, são apresentados o simulador utilizado, a base sintética gerada e as hipóteses assumidas para a modelagem do sinal e do ruído. Em seguida, detalham-se as etapas de preparação dos dados, implementação dos estimadores e definição das métricas de desempenho. Por fim, são discutidos os resultados obtidos em diferentes regimes de ocupação, com ênfase na degradação associada ao aumento de *pile-up* e nas diferenças de comportamento entre os métodos lineares e não lineares.

4.1 Base de Dados e Configuração Experimental

A avaliação comparativa dos métodos de estimação de energia foi conduzida a partir de uma base sintética representativa do sinal do Calorímetro Hadrônico de Telhas (TileCal), gerada por um simulador de canal de leitura que modela, de forma simplificada, a cadeia de aquisição como um sistema convolucional amostrado a 40 MHz ($T_s = 25$ ns). Esse enquadramento é consistente com a instrumentação do TileCal e com a filosofia de leitura digital sincronizada ao relógio do LHC, na qual depósitos de energia são traduzidos em amostras discretas do pulso após condicionamento eletrônico (ATLAS Collaboration, 2017). O simulador adotado foi implementado em `Python`, porém segue a mesma ideia central apresentada por (LUNA et al., 2024): gerar um sinal de deposição de energia como sequência esparsa de eventos e, em seguida, obter o sinal de leitura via convolução com um pulso característico do canal.

O processo de simulação foi organizado em três etapas:

- (i) geração dos instantes de ocorrência de eventos (ou *hits*);
- (ii) atribuição de amplitude aos eventos;
- (iii) formação do sinal lido pela eletrônica por convolução com o pulso do canal.

A ocorrência de eventos foi modelada por uma seleção aleatória de posições ao longo do vetor de amostras, de modo que a fração total de amostras com depósitos correspondesse à ocupação ρ . Nesse contexto, a ocupação parametriza a taxa média de eventos no canal e pode ser interpretada como a fração esperada de amostras com depósitos não nulos (LUNA et al., 2024). Na prática, foram geradas bases independentes para ocupações de 10%, 20%, 30%, ..., 80%, cobrindo um espectro crescente de sobreposição temporal compatível com cenários de maior complexidade de reconstrução. Computacionalmente, uma função

seleciona aleatoriamente um conjunto de posições sem reposição e preenche essas posições com amplitudes sorteadas, produzindo o vetor de referência (*truth*).


Para cada valor de ocupação ρ , o simulador gerou um par de sequências unidimensionais com o mesmo comprimento, correspondendo ao sinal observado $r[n]$ e à referência $A[n]$ (*truth*). Em todas as simulações consideradas neste trabalho, cada sequência possui $N_s = 203\,130$ amostras, isto é, $r[n], A[n] \in \mathbb{R}^{N_s \times 1}$, o que garante estatística suficiente para avaliação consistente das métricas em diferentes regimes de *pile-up*.

Condicional à ocorrência de um evento, a amplitude do depósito de energia foi modelada por uma distribuição exponencial, estratégia alinhada ao simulador descrito por (LUNA et al., 2024) para representar a variabilidade de amplitudes associada a depósitos no canal. Na implementação utilizada, a média da distribuição exponencial foi fixada em $\mu_A = 187,7839$ contagens de ADC, de modo que as amplitudes sorteadas A satisfaçam:

$$A \sim \text{Exp}(\lambda), \quad \text{com } \mathbb{E}[A] = \frac{1}{\lambda} = \mu_A. \quad (4.1)$$

Nas amostras sem evento, a referência assume $A = 0$, resultando em uma sequência esparsa no tempo. A Figura 14 ilustra, de forma conceitual, o vetor de referência (depósitos por amostra) para uma ocupação representativa, evidenciando a natureza impulsiva e esparsa do processo.

Figura 14 – Exemplo conceitual do sinal de referência (*truth*): depósitos de energia por amostra como sequência esparsa de impulsos com amplitudes aleatórias.



Fonte: Elaborado pela autora com base em (LUNA et al., 2024).


O sinal observado é obtido pela convolução do sinal de referência com o pulso característico do canal de leitura, assumindo linearidade e invariância no tempo para a cadeia de condicionamento:

$$r[n] = (h * s)[n] + \varepsilon[n], \quad (4.2)$$

em que $h[n]$ representa o pulso característico discretizado, $r[n]$ é o sinal de leitura e $\varepsilon[n]$ é ruído aditivo. Essa modelagem resume, em um único pulso, os efeitos combinados de sensor e eletrônica de condicionamento (LUNA et al., 2024; ATLAS Collaboration, 2017).

Nos resultados apresentados nesta dissertação, foi adotado o pulso obtido a partir do arquivo de resposta impulsiva da placa FENICS, desenvolvida no contexto da atualização da eletrônica de leitura do TileCal para o HL-LHC. Esse pulso representa a resposta temporal da cadeia eletrônica de condicionamento e digitalização do detector, incluindo os efeitos de modelagem do conformador analógico e da eletrônica de aquisição. Sua utilização permite reproduzir, na simulação, uma resposta impulsiva mais próxima daquela esperada para a eletrônica da Fase II do TileCal. A Figura 15 apresenta o pulso característico empregado na convolução (normalizado no pico), indicando o intervalo de amostragem $T_s = 25$ ns.

Figura 15 – Pulso característico $h[n]$ utilizado na simulação, discretizado a 40 MHz e normalizado no pico.



Fonte: Elaborado pela autora a partir do arquivo de pulso utilizado na simulação.

O ruído eletrônico foi modelado como um processo gaussiano aditivo de média nula, com desvio padrão fixado em $\sigma = 2$ contagens de ADC. Essa hipótese constitui uma aproximação amplamente empregada em estudos de processamento digital de sinais e permite representar, de forma simplificada, a contribuição aleatória dominante da eletrônica de leitura, além de ser compatível com a formulação estatística dos estimadores avaliados neste trabalho (KAY, 1993; HAYKIN, 2002). Assim, após a convolução, o sinal recebe a perturbação:


$$\varepsilon[n] \sim \mathcal{N}(0, \sigma^2). \quad (4.3)$$

Ressalta-se que essa modelagem não pretende reproduzir integralmente o comportamento do ruído observado na eletrônica do TileCal. Em condições reais, o ruído pode apresentar componentes correlacionadas entre amostras, variações lentas de pedestal (*baseline*), efeitos decorrentes da cauda longa do pulso e outras contribuições instrumentais. Entretanto, a adoção de um modelo gaussiano aditivo permite isolar o impacto da superposição temporal de pulsos sobre o desempenho dos estimadores, mantendo controladas as condições estatísticas da comparação entre os métodos.

Após a geração do sinal, foi aplicado um ajuste de borda para remover efeitos transientes associados à convolução, mantendo somente a região central do vetor. Esse recorte evita que amostras nas extremidades sejam influenciadas por preenchimento com zeros e garante consistência entre sinal observado e referência.

A Figura 16 apresenta um trecho do sinal simulado $r[n]$, após convolução com o pulso característico e adição de ruído eletrônico, juntamente com o vetor de referência (*truth*). Observa-se que cada depósito instantâneo é convertido em um pulso alargado, cuja largura temporal é determinada por $h[n]$. Quando dois ou mais depósitos ocorrem em intervalos inferiores a essa largura efetiva, as formas de onda passam a se sobrepor parcialmente (*pile-up*), aumentando a complexidade da estimação de energia.

Figura 16 – Trecho ilustrativo do sinal simulado $r[n]$ e do *truth* $s[n]$ correspondente.



Fonte: Elaborado pela autora.


O simulador impõe ainda um padrão temporal inspirado na estrutura do feixe do LHC, conhecido como trem de pacotes (*bunch train*). Nesse modo, a sequência de depósitos $s[n]$ é reorganizada para refletir regiões de maior e menor probabilidade de ocorrência de eventos ao longo de um ciclo de aquisição, em conformidade com a estrutura periódica de preenchimento dos pacotes no anel do LHC.

A Figura 17 apresenta um trecho do sinal simulado no modo de *bunch train*, comparando o sinal $r[n]$ com a sequência $s[n]$. Observa-se que determinadas regiões temporais concentram maior número de eventos, enquanto outras apresentam menor atividade.

A partir desses sinais, foram construídas as janelas de entrada compatíveis com os métodos do Capítulo 3, preservando a correspondência entre o vetor de amostras e a amplitude de referência associada ao evento de interesse. Esse protocolo assegura que todos os métodos avaliados operem sob condições estatísticas idênticas, permitindo comparar desempenho em diferentes regimes de ocupação e analisar a degradação associada ao aumento de sobreposição temporal de pulsos.

Todo o procedimento de treinamento e avaliação foi repetido independentemente para oito regimes de ocupação, variando de 10% a 80% em incrementos de 10%. Para cada

Figura 17 – Trecho do sinal simulado no modo de *bunch train*, mostrando o sinal simulado $r[n]$ e a sequência de depósitos $s[n]$.



Fonte: Elaborado pela autora, com base em (LUNA et al., 2024).

valor de ocupação foi considerado um conjunto independente de sinais, permitindo analisar a degradação progressiva dos estimadores sob aumento de *pile-up*. No pipeline de treinamento e avaliação, adotou-se semente fixa igual a 42 nas rotinas estocásticas de inicialização e ajuste dos modelos, bem como nos procedimentos de subamostragem utilizados na etapa de seleção de hiperparâmetros do SVR, visando garantir reprodutibilidade computacional.

4.2 Implementação dos Estimadores de Energia

O conjunto de dados foi particionado em três subconjuntos disjuntos:

- 70% das amostras para treinamento;
- 15% das amostras para validação;
- 15% das amostras para teste.

O conjunto de validação foi utilizado exclusivamente para seleção de hiperparâmetros e monitoramento de desempenho durante o ajuste, enquanto o conjunto de teste permaneceu completamente isolado até a etapa final de avaliação quantitativa.

Em cada subconjunto, o sinal digitalizado do calorímetro, denotado por $r[n]$, foi reorganizado em janelas temporais deslizantes de comprimento $L = 7$ amostras. Cada vetor de entrada é definido como:

$$\mathbf{x}[n] = [r[n-3], r[n-2], r[n-1], r[n], r[n+1], r[n+2], r[n+3]]. \quad (4.4)$$

A energia alvo associada a cada janela corresponde ao depósito central da sequência de referência:

$$y[n] = s[n], \quad (4.5)$$

onde $s[n]$ representa a sequência de depósitos de energia gerada pelo simulador. Essa estrutura permite que os modelos explorem relações temporais locais associadas à formação e sobreposição de pulsos no calorímetro.

As variáveis de entrada foram padronizadas utilizando estatísticas calculadas exclusivamente no conjunto de treinamento. Para cada componente j do vetor de entrada, a transformação aplicada foi:

$$\tilde{x}_j[n] = \frac{x_j[n] - \mu_{x_j}}{\sigma_{x_j}}, \quad (4.6)$$

em que μ_{x_j} e σ_{x_j} representam, respectivamente, a média e o desvio padrão da j -ésima componente calculados exclusivamente sobre o conjunto de treinamento e aplicados sem alteração aos subconjuntos de validação e teste. Essa padronização garante que cada variável apresente média aproximadamente nula e variância unitária, evitando diferenças de escala que possam prejudicar o processo de otimização (GOODFELLOW et al., 2016).

O alvo supervisionado foi escalonado segundo:

$$\tilde{y}[n] = \frac{y[n]}{\sigma_y}, \quad (4.7)$$

em que σ_y é o desvio padrão calculado somente no conjunto de treinamento, sendo reutilizado para escalonamento de validação e teste. A centralização explícita do alvo não foi realizada, uma vez que o termo de *bias* presente nos modelos lineares e na camada de saída das redes neurais é capaz de capturar o deslocamento médio da variável resposta. Dessa forma, o escalonamento pelo desvio padrão mostrou-se suficiente para garantir estabilidade numérica sem alterar a interpretação física da energia estimada.

Após a predição, os valores estimados foram reescalados multiplicando-se novamente por σ_y , retornando às unidades físicas originais.

4.2.1 Filtro de Wiener

O Filtro de Wiener foi implementado como solução linear de mínimos quadrados sobre os dados padronizados. Considerando a matriz de entrada aumentada com termo de *bias*,

$$\mathbf{X}_b = \begin{bmatrix} \mathbf{X} & \mathbf{1} \end{bmatrix}, \quad (4.8)$$

a implementação adotada corresponde à estimação empírica das matrizes de correlação envolvidas na solução de Wiener, isto é,

$$\mathbf{R}_{ss} = \mathbf{X}_b^T \mathbf{X}_b, \quad (4.9)$$

e

$$\mathbf{r}_{sd} = \mathbf{X}_b^T \mathbf{y}. \quad (4.10)$$

A solução fechada é dada por:

$$\mathbf{w} = \mathbf{R}_{ss}^{-1} \mathbf{r}_{sd} = (\mathbf{X}_b^T \mathbf{X}_b)^{-1} \mathbf{X}_b^T \mathbf{y}. \quad (4.11)$$

Na implementação computacional foi incluído um termo de regularização numérica muito pequeno, $\lambda = 10^{-8}$, resultando na solução estabilizada:

$$\mathbf{w} = (\mathbf{X}_b^T \mathbf{X}_b + \lambda \mathbf{I})^{-1} \mathbf{X}_b^T \mathbf{y}, \quad (4.12)$$

o que evita problemas de condicionamento numérico sem alterar significativamente a solução. O último coeficiente do vetor $\mathbf{w}$ corresponde ao termo de *bias*.

4.2.2 Perceptron Multicamadas (MLP)

O Perceptron Multicamadas foi implementado com uma única camada oculta e função de ativação tangente hiperbólica (**tanh**). Foram avaliadas arquiteturas com diferentes números de neurônios na camada oculta, e a seleção final foi realizada com base no erro de validação. Durante essa etapa, foi utilizado mecanismo de parada antecipada (*early stopping*) baseado na evolução do erro de validação interno do algoritmo, visando reduzir sobreajuste e estabilizar o compromisso entre desempenho e custo de treinamento.

Após a seleção da melhor dimensão oculta, o modelo final foi reestimado utilizando a união dos conjuntos de treinamento e validação, mantendo o conjunto de teste completamente isolado para a avaliação final.

4.2.3 Regressão por Vetores de Suporte (SVR)

A Regressão por Vetores de Suporte (SVR) foi implementada com *kernel* radial (RBF). O SVR busca minimizar o erro dentro de uma zona de tolerância ϵ , penalizando apenas desvios superiores a esse limite (Smola e Schölkopf, 2004). Foram avaliados diferentes valores do parâmetro ϵ com o objetivo de investigar o compromisso entre precisão e custo computacional.

Devido à complexidade computacional do treinamento de Máquinas de Vetores de Suporte com *kernel*, foi utilizada subamostragem aleatória do conjunto de treinamento durante a etapa de seleção do hiperparâmetro ϵ . No treinamento final, uma subamostra maior foi utilizada para estimar o modelo definitivo, preservando o conjunto de teste totalmente isolado para a avaliação final (Hastie, Tibshirani e Friedman, 2009; Smola e Schölkopf, 2004).

Foram utilizados os seguintes hiperparâmetros:

- parâmetro de regularização: $C = 200$;
- núcleo radial (RBF);
- $\gamma = \text{scale}$;
- margem ε variável.

No caso do núcleo RBF, a parametrização $\gamma = \text{scale}$ define automaticamente:

$$\gamma = \frac{1}{n_{\text{features}} \cdot \hat{\sigma}_X^2}, \quad (4.13)$$

em que $n_{\text{features}} = 7$ corresponde ao número de amostras por janela e $\hat{\sigma}_X^2$ representa a variância média empírica das características no conjunto de treinamento. Como as entradas foram previamente padronizadas para variância unitária, obtém-se aproximadamente:

$$\gamma \approx \frac{1}{7}. \quad (4.14)$$

Foram avaliados três valores distintos para o parâmetro de margem ε . Primeiramente, foi definido um valor proporcional ao nível de ruído normalizado do sinal. Considerando que o ruído eletrônico possui desvio padrão $\sigma = 2$ contagens de ADC, e que o alvo foi escalonado por σ_y do conjunto de treino, tem-se:

$$\sigma_n = \frac{2}{\sigma_y}. \quad (4.15)$$

A margem foi então definida como metade desse valor:

$$\varepsilon = 0.5 \sigma_n = \frac{1}{\sigma_y}. \quad (4.16)$$

Além desse valor baseado no ruído, foram também testados os valores fixos:

$$\varepsilon \in \{0,01, 0,1\}. \quad (4.17)$$

A escolha final de ε foi realizada com base no conjunto de validação, levando em consideração simultaneamente o desempenho preditivo e o custo computacional associado ao número de vetores de suporte.

4.2.4 Rede Neural Convolutacional

A Rede Neural Convolutacional unidimensional (CNN 1D) foi construída com três camadas convolucionais unidimensionais seguidas por camadas densas, buscando equilibrar capacidade de representação e custo computacional. As camadas convolucionais foram

empregadas para extrair padrões locais presentes na forma temporal dos pulsos e em suas possíveis sobreposições, enquanto as camadas densas realizam a combinação dessas características para estimar a energia depositada.

A arquitetura inclui:

- camadas *Conv1D* com função de ativação *ReLU*, responsáveis pela extração de características locais do sinal e pela introdução de não linearidade no modelo;
- camadas de *Batch Normalization*, utilizadas para estabilizar a distribuição das ativações internas e acelerar o treinamento;
- camadas de *MaxPooling1D*, empregadas para reduzir a dimensionalidade das representações intermediárias e aumentar a robustez a pequenas variações locais do sinal;
- uma camada densa intermediária, responsável por integrar as características extraídas pelas convoluções;
- uma camada de saída linear, adequada ao problema de regressão da amplitude da energia.

A configuração da rede foi definida a partir de experimentos preliminares, buscando uma arquitetura suficientemente expressiva para modelar as distorções introduzidas pelo *pile-up*, mas sem aumentar excessivamente o custo computacional. Como a entrada possui apenas sete amostras temporais, optou-se por utilizar convoluções unidimensionais de pequeno suporte, capazes de explorar as relações locais entre amostras adjacentes mantendo compatibilidade com aplicações em processamento de sinais.

O treinamento da rede foi realizado utilizando as configurações resumidas a seguir:

- otimizador Adam, devido à sua capacidade de adaptar automaticamente a taxa de aprendizado de cada parâmetro, proporcionando convergência rápida e estável em problemas de otimização não convexos;
- função de perda MSE, por ser compatível com a natureza regressiva do problema e corresponder diretamente ao critério utilizado para comparação entre todos os estimadores investigados neste trabalho;
- tamanho de lote igual a 32, valor amplamente empregado na literatura e que apresentou bom compromisso entre estabilidade do treinamento e eficiência computacional nos experimentos realizados;

- máximo de 300 épocas, definido como limite superior suficientemente elevado para permitir a convergência do modelo, sem impor interrupção prematura do processo de otimização;
- critério de **EarlyStopping** com paciência de 15 épocas, empregado para interromper automaticamente o treinamento quando não fossem observadas melhorias na perda de validação, reduzindo o risco de sobreajuste e evitando treinamento desnecessário.

O critério de parada antecipada foi empregado com base na perda de validação, restaurando-se os pesos correspondentes à melhor época observada. Embora esses hiperparâmetros não tenham sido objeto de otimização sistemática, sua escolha baseou-se em configurações amplamente utilizadas na literatura de aprendizado profundo para problemas de regressão e em experimentos preliminares conduzidos neste trabalho, buscando conciliar estabilidade do treinamento, capacidade de generalização e custo computacional.

4.3 Métricas de Desempenho

A avaliação dos estimadores de energia foi conduzida sob duas perspectivas complementares:

- (i) qualidade da estimação contínua da amplitude;
- (ii) capacidade de detecção da presença de depósito de energia na amostra central.

Essa abordagem permite analisar tanto o erro quantitativo da regressão quanto o comportamento dos modelos como detectores de eventos sob diferentes regimes de ocupação. A métrica principal utilizada para avaliação da regressão foi o Erro Médio Quadrático (*Mean Squared Error* – MSE), definido como:

$$\text{MSE} = \frac{1}{N_{\text{test}}} \sum_{n=1}^{N_{\text{test}}} (\hat{A}[n] - A[n])^2, \quad (4.18)$$

onde N_{test} é o número de amostras usadas no conjunto de teste, $A[n]$ representa a energia verdadeira e $\hat{A}[n]$ a energia estimada pelo modelo.

A Raiz do Erro Médio Quadrático é dada por:

$$\text{RMSE} = \sqrt{\text{MSE}}, \quad (4.19)$$

e possui a mesma unidade física da variável alvo, facilitando a interpretação direta do erro médio típico do estimador.

O Erro Absoluto Médio (*Mean Absolute Error* – MAE) foi definido como:

$$\text{MAE} = \frac{1}{N} \sum_{n=1}^N |\hat{A}[n] - A[n]|. \quad (4.20)$$

Além das métricas globais, foi analisado o erro residual:

$$e[n] = \hat{A}[n] - A[n], \quad (4.21)$$

o viés médio, definido como:

$$\text{Bias} = \frac{1}{N} \sum_{n=1}^N e[n], \quad (4.22)$$

e a dispersão do erro, quantificada pelo desvio padrão dos resíduos:

$$\sigma_e = \sqrt{\frac{1}{N-1} \sum_{n=1}^N (e[n] - \text{Bias})^2}. \quad (4.23)$$

A resolução relativa foi estimada a partir do erro relativo ponto a ponto:

$$e_{\text{rel}}[n] = \frac{A[n] - \hat{A}[n]}{A[n]}, \quad (4.24)$$

considerando apenas amostras com sinal significativo, isto é,

$$\mathcal{M} = \{n : A[n] > 3\sigma\}. \quad (4.25)$$

Como $\sigma = 2$ contagens de ADC, tem-se:

$$\mathcal{M} = \{n : A[n] > 6\}. \quad (4.26)$$

A resolução relativa é então estimada como:

$$\text{Res} = \sqrt{\frac{1}{|\mathcal{M}| - 1} \sum_{n \in \mathcal{M}} (e_{\text{rel}}[n] - \bar{e}_{\text{rel}})^2}. \quad (4.27)$$

Outra métrica utilizada foi o coeficiente de determinação:

$$R^2 = 1 - \frac{\sum_{n=1}^N (A[n] - \hat{A}[n])^2}{\sum_{n=1}^N (A[n] - \bar{A})^2}, \quad (4.28)$$

em que $\bar{A}$ é a média das energias verdadeiras.

As métricas apresentadas até este ponto avaliam a qualidade da estimação contínua da energia, permitindo quantificar o erro cometido pelos diferentes métodos de regressão. Entretanto, em aplicações de calorimetria, também é relevante analisar a capacidade do

estimador em distinguir amostras que contêm um depósito de energia daquelas correspondentes apenas a ruído ou flutuações de fundo. Essa análise é particularmente útil para avaliar o potencial de utilização desses estimadores em sistemas de seleção de eventos, como aqueles empregados no *trigger* do ATLAS, nos quais a identificação confiável da ocorrência de um evento é um dos primeiros passos para a tomada de decisão.

Com esse objetivo, além da avaliação como problema de regressão, as estimativas produzidas pelos modelos foram reinterpretadas como escores para um problema de detecção binária da presença de depósito de energia na amostra central. Define-se:

$$\text{Evento positivo} \quad \text{se} \quad A[n] > \tau, \quad (4.29)$$

com $\tau = 2\sigma$. Utilizando a energia estimada $\hat{A}[n]$ como escore contínuo, constrói-se a curva ROC (*Receiver Operating Characteristic*), a partir da Taxa de Verdadeiros Positivos:

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad (4.30)$$

e da Taxa de Falsos Positivos:

$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}. \quad (4.31)$$

A área sob a curva ROC (AUC) foi utilizada como medida global da capacidade discriminativa do modelo (Fawcett, 2006).

Todas as métricas descritas foram avaliadas em diferentes regimes de ocupação, de 10% a 80%, permitindo analisar a degradação de desempenho associada ao aumento de *pile-up*.

Concluída a definição da base de dados, dos procedimentos de pré-processamento, da implementação dos estimadores e das métricas de avaliação, o protocolo experimental encontra-se completamente estabelecido. No capítulo seguinte, esse protocolo é empregado para analisar comparativamente o desempenho dos métodos implementados sob diferentes níveis de ocupação, discutindo tanto seus resultados quantitativos quanto aspectos relacionados à robustez e ao custo computacional.

5 RESULTADOS E DISCUSSÃO


Este capítulo apresenta os resultados obtidos a partir da metodologia descrita no capítulo anterior. Inicialmente, são discutidos os hiperparâmetros selecionados e o comportamento do treinamento dos modelos. Em seguida, realiza-se uma análise comparativa do desempenho dos estimadores — Filtro de Wiener, MLP, SVR e CNN — em diferentes regimes de ocupação, considerando tanto métricas quantitativas quanto análises qualitativas das estimativas produzidas. Por fim, é apresentada uma síntese dos principais resultados observados.

5.1 Seleção de hiperparâmetros e comportamento do treinamento

A escolha dos hiperparâmetros foi conduzida separadamente para cada regime de ocupação, utilizando exclusivamente o conjunto de validação. No caso do MLP, a seleção da arquitetura foi realizada a partir da comparação entre diferentes números de neurônios na camada oculta, adotando-se como critério o menor erro de validação. Após essa etapa, o modelo final foi reestimado utilizando a união dos conjuntos de treinamento e validação, mantendo o conjunto de teste isolado para avaliação final.

No SVR com núcleo RBF, a seleção do parâmetro ε buscou equilibrar precisão e custo computacional. A Figura 18 ilustra esse compromisso para uma ocupação representativa, evidenciando que ganhos marginais de desempenho passam a ocorrer às custas de aumento expressivo de complexidade computacional.

Figura 18 – Comparação da raiz do erro médio quadrático (RMSE) e do tempo de treinamento para diferentes valores do parâmetro ε no SVR com núcleo RBF e $\rho = 60$.




Fonte: Elaborado pela autora.

Observa-se que valores muito pequenos de ε conduzem a modelos mais complexos, com maior número de vetores de suporte e aumento significativo do tempo de treinamento. Por outro lado, o ganho em termos de erro de validação torna-se marginal abaixo de determinados valores do parâmetro, caracterizando um compromisso entre precisão e custo computacional.

No caso da CNN, o treinamento foi monitorado por meio da evolução da perda em treinamento e validação, com critério de parada antecipada. A Figura 19 apresenta a evolução da perda de treinamento e validação para o cenário com ocupação de 60%.

Figura 19 – Curvas de perda (MSE) durante o treinamento da CNN para o cenário com ocupação de 60%.



Fonte: Elaborado pela autora.

Todos os modelos foram avaliados segundo um protocolo de particionamento do tipo *hold-out*, no qual a base foi dividida em conjuntos independentes de treinamento (70%), validação (15%) e teste (15%). O conjunto de validação foi utilizado exclusivamente para seleção de hiperparâmetros, enquanto o conjunto de teste permaneceu completamente isolado durante o desenvolvimento dos modelos, sendo utilizado apenas na avaliação final apresentada nesta seção. Portanto, não foi empregada validação cruzada (*cross-validation*), uma vez que o objetivo foi reproduzir um protocolo de treinamento compatível com o fluxo de desenvolvimento de modelos supervisionados para aplicações em reconstrução de energia. A Tabela 1 resume, para cada ocupação, os hiperparâmetros selecionados e algumas informações associadas ao treinamento dos modelos não lineares.

Tabela 1 – Resumo dos hiperparâmetros selecionados por ocupação para os modelos MLP, SVR e CNN.

Ocupação (%)	H_{best} (MLP)	$\varepsilon_{\text{best}}$ (SVR)	nSV/N	Épocas CNN
10	64	0.1000	0.0143	24
20	32	0.0681	0.0303	29
30	128	0.0316	0.0920	28
40	8	0.0464	0.0966	23
50	32	0.0316	0.1957	46
60	8	0.0316	0.2545	57
70	32	0.0681	0.1343	48
80	128	0.0464	0.2838	46
90	128	0.0464	0.3354	25

Fonte: Elaborado pela autora.

5.2 Desempenho global em função da ocupação

O desempenho dos estimadores foi analisado por meio das métricas introduzidas na Seção 4.3, com ênfase em RMSE, MAE, resolução relativa, viés e AUC. Como esperado, o aumento da ocupação produz degradação progressiva do desempenho de todos os métodos, refletindo o crescimento da superposição temporal de pulsos e da dificuldade de associar corretamente a janela de entrada ao depósito central de energia.

A Tabela 2 apresenta um resumo comparativo das métricas obtidas em diferentes cenários de ocupação, permitindo visualizar a evolução do erro e da capacidade discriminativa dos modelos à medida que o cenário se torna mais severo. Embora o Filtro Ótimo (OF) constitua o método de referência historicamente empregado na reconstrução de energia do TileCal, ele não foi incluído na comparação experimental desta dissertação. Essa decisão decorre do fato de que o objetivo do trabalho foi comparar um estimador linear fundamentado no critério de erro quadrático mínimo (Filtro de Wiener) com abordagens baseadas em aprendizado de máquina, utilizando uma implementação única e um protocolo experimental homogêneo. Além disso, estudos anteriores já documentam de forma consistente o comportamento comparativo entre o Filtro Ótimo e o Filtro de Wiener em cenários de *pile-up* (CERQUEIRA et al., 2016), permitindo que o presente trabalho concentre a análise na comparação entre o Wiener e os métodos supervisionados não lineares.

A evolução global do erro em função da ocupação pode ser observada na Figura 20. Nota-se que o aumento de *pile-up* produz degradação sistemática do desempenho de todos os métodos, embora com intensidades distintas. Em baixa ocupação, os estimadores apresentam desempenhos relativamente próximos, enquanto em regimes mais severos as diferenças de robustez tornam-se mais evidentes.


Diferentemente dos demais métodos, o SVR apresentou comportamento não mono-

Tabela 2 – Resumo do desempenho dos estimadores em ocupações representativas.

Ocupação	Método	RMSE	MAE	Resolução	Bias	AUC
10%	Wiener	2.394	1.898	0.070	-0.096	0.9995
10%	MLP	2.375	0.597	0.188	0.210	0.9877
10%	SVR	11.170	1.709	0.200	-1.361	0.9986
10%	CNN	2.852	0.190	0.301	-0.034	0.9554
50%	Wiener	5.734	4.572	0.159	-0.643	0.9915
50%	MLP	5.603	3.200	0.134	-0.425	0.9949
50%	SVR	18.541	3.045	0.273	-0.153	0.9933
50%	CNN	3.891	1.247	0.206	0.230	0.9885
80%	Wiener	9.883	7.811	0.278	0.477	0.9773
80%	MLP	8.700	6.771	0.273	-0.169	0.9795
80%	SVR	11.838	6.311	0.333	0.551	0.9810
80%	CNN	7.350	4.189	0.237	0.651	0.9880

Fonte: Elaborado pela autora.

Figura 20 – Evolução da raiz do erro médio quadrático (RMSE) em função da ocupação para os métodos Wiener, MLP, SVR e CNN. Observa-se degradação global do desempenho com o aumento de *pile-up*, com diferenças entre os estimadores tornando-se mais pronunciadas em regimes de maior ocupação.




Fonte: Elaborado pela autora.

tônico em função da ocupação. Essa oscilação está associada ao processo de seleção de hiperparâmetros e ao treinamento realizado sobre subconjuntos dos dados, fazendo com que pequenas variações estatísticas entre as bases sintéticas produzam diferenças mais pronunciadas no desempenho do modelo.

A Figura 21 complementa essa análise ao apresentar a evolução da resolução relativa com a ocupação. Como essa métrica enfatiza a dispersão relativa do erro nas amostras com sinal significativo, ela permite avaliar de forma mais sensível o impacto do aumento

da superposição temporal sobre a qualidade da reconstrução.

Figura 21 – Evolução da resolução relativa em função da ocupação para os métodos Wiener, MLP, SVR e CNN. O aumento da ocupação tende a ampliar a dispersão relativa do erro, refletindo a maior dificuldade de reconstrução sob intensificação do *pile-up*.



Fonte: Elaborado pela autora.


De forma geral, os resultados mostram que os métodos lineares permanecem competitivos em regimes de baixa ocupação, nos quais a hipótese de pulso relativamente isolado ainda é uma aproximação razoável. À medida que a ocupação aumenta, contudo, tornam-se mais evidentes as diferenças de comportamento entre as abordagens lineares e não lineares, indicando que a maior flexibilidade funcional dos modelos baseados em aprendizado de máquina pode ser benéfica em cenários de superposição temporal mais intensa, ainda que a um custo computacional superior e com maior dependência de dados representativos.

A extensão dessas abordagens para dados experimentais requer estratégias específicas de obtenção de rótulos confiáveis para o treinamento supervisionado. Uma possibilidade consiste em utilizar amostras provenientes de calibrações do detector e de testes em feixe (*test beam*), nos quais a energia incidente é conhecida e controlada. Outra alternativa é empregar grandes conjuntos de dados simulados pelo método de Monte Carlo, amplamente utilizados na Física de Altas Energias para reproduzir a resposta do detector, realizando posteriormente procedimentos de adaptação ou recalibração com dados experimentais. Dessa forma, os modelos supervisionados podem ser treinados em ambientes controlados e posteriormente validados e ajustados para condições reais de operação.


5.3 Análise qualitativa das estimativas

Além das métricas agregadas, foram analisadas representações gráficas das predições em diferentes regimes de ocupação. A Figura 22 apresenta diagramas do tipo *hexbin* da energia estimada em função da energia de referência para os quatro métodos avaliados: Wiener, MLP, SVR e CNN, considerando cenários de baixa e alta ocupação. Esses gráficos permitem avaliar simultaneamente a concentração das estimativas em torno da reta identidade e o espalhamento introduzido pelo aumento do *pile-up*, evidenciando diferenças qualitativas entre os métodos quanto à precisão e à robustez das estimativas.


Figura 22 – Diagramas *hexbin* da energia estimada em função da energia de referência para os métodos Wiener, MLP, SVR e CNN, considerando ocupações de $\rho = 10\%$ e $\rho = 80\%$. A linha tracejada representa a correspondência ideal entre a energia estimada e a energia de referência.




(a) Wiener — $\rho = 10\%$



(b) Wiener — $\rho = 80\%$



(c) MLP — $\rho = 10\%$



(d) MLP — $\rho = 80\%$

Fonte: Elaborado pela autora.






(e) SVR — $\rho = 10\%$ (f) SVR — $\rho = 80\%$ (g) CNN — $\rho = 10\%$ (h) CNN — $\rho = 80\%$

Figura 22 – Diagramas *hexbin* da energia estimada em função da energia de referência (continuação).

A Figura 23 apresenta as distribuições do erro relativo da energia estimada para os quatro métodos avaliados, considerando ocupações de $\rho = 10\%$ e $\rho = 70\%$. De forma geral, observa-se um alargamento progressivo das distribuições com o aumento da ocupação, refletindo a degradação da precisão das estimativas em cenários com maior superposição temporal de pulsos. A comparação entre Wiener, MLP, SVR e CNN também evidencia diferenças na dispersão, na simetria e na ocorrência de valores extremos, permitindo uma avaliação qualitativa do comportamento estatístico dos erros sob diferentes níveis de *pile-up*.

Por fim, a Figura 24 apresenta as curvas ROC obtidas a partir da reinterpretação da tarefa de estimação como um problema de detecção binária da presença de depósito de energia na amostra central, para os quatro métodos avaliados. A energia estimada é utilizada como escore contínuo de decisão, permitindo analisar a capacidade discriminativa

Figura 23 – Distribuições do erro relativo da energia estimada, comparando os métodos de Wiener, MLP, SVR e CNN. O aumento da ocupação de $\rho = 10\%$ para $\rho = 70\%$ provoca alargamento das distribuições, indicando degradação da precisão sob maior *pile-up*.



Fonte: Elaborado pela autora.

de Wiener, MLP, SVR e CNN em diferentes níveis de ocupação. Observa-se que o aumento da ocupação de $\rho = 10\%$ para $\rho = 70\%$ reduz gradualmente o desempenho de detecção, refletindo o impacto do aumento do *pile-up* na separação entre eventos com e sem depósito de energia.

5.4 Síntese dos resultados

Em conjunto, os resultados mostram que o aumento da ocupação degrada de forma sistemática o desempenho de todos os estimadores avaliados, confirmando que a superposição temporal de pulsos constitui um fator limitante central para a estimação de energia no TileCal. Em regimes de baixa ocupação, métodos lineares apresentam desempenho competitivo, beneficiando-se de sua simplicidade estrutural, baixa latência de inferência e aderência ao modelo de pulso aproximadamente isolado.

À medida que a ocupação cresce, contudo, modelos não lineares baseados em redes






(e) SVR — $\rho = 10\%$ (f) SVR — $\rho = 70\%$ (g) CNN — $\rho = 10\%$ (h) CNN — $\rho = 70\%$


Figura 23 – Distribuições do erro relativo da energia estimada (continuação).

neurais passam a oferecer maior capacidade de adaptação às distorções induzidas por *pile-up*, ainda que a um custo computacional superior e com maior dependência de dados representativos. O comportamento observado para o SVR indica que essa vantagem não se estende automaticamente a todos os métodos de aprendizado de máquina, evidenciando a importância da arquitetura e da estratégia de modelagem adotadas.


Figura 24 – Curvas ROC obtidas a partir da reinterpretação da tarefa de estimação como problema de detecção binária da presença de depósito de energia na amostra central. As curvas utilizam a energia estimada como escore contínuo de decisão.




(a) Wiener — $\rho = 10\%$




(b) Wiener — $\rho = 70\%$




(c) MLP — $\rho = 10\%$



(d) MLP — $\rho = 70\%$



(e) SVR — $\rho = 10\%$



(f) SVR — $\rho = 70\%$

Fonte: Elaborado pela autora.



(g) CNN — $\rho = 10\%$ (h) CNN — $\rho = 70\%$

Figura 24 – Curvas ROC (continuação).

6 CONCLUSÕES

Esta dissertação investigou o problema de estimação de energia em calorimetria hadrônica de altas energias no contexto do Tile Calorimeter (TileCal) do experimento ATLAS, com ênfase nas condições operacionais associadas ao regime de alta luminosidade do HL-LHC. O foco do trabalho foi a avaliação comparativa de um estimador linear estatisticamente fundamentado, representado pelo Filtro de Wiener, e de modelos supervisionados não lineares baseados em aprendizado de máquina, nomeadamente Perceptron Multicamadas (MLP), Regressão por Vetores de Suporte (SVR) e Rede Neural Convolutacional unidimensional (CNN). O objetivo central consistiu em analisar o comportamento desses métodos sob diferentes níveis de ocupação e superposição temporal de sinais, considerando não apenas métricas de erro, mas também robustez estatística e custo computacional compatíveis com aplicações associadas ao sistema de *trigger* do ATLAS.

A motivação do estudo está diretamente relacionada à evolução do ambiente operacional do LHC em direção ao HL-LHC, no qual o aumento de luminosidade intensifica o fenômeno de *pile-up* e torna progressivamente menos representativa a hipótese de pulsos isolados. Nesse cenário, a reconstrução de energia passa a exigir métodos capazes de operar com maior robustez frente à superposição temporal de sinais, mantendo simultaneamente precisão, estabilidade e viabilidade computacional. A modernização da eletrônica do TileCal e a disponibilidade ampliada de amostras digitalizadas no sistema de *trigger* reforçam a relevância de investigar, de forma sistemática, estratégias alternativas de estimação.

O trabalho formulou a reconstrução de energia como um problema de estimação de amplitude a partir de janelas temporais de amostras digitalizadas. Para isso, foi utilizada uma base sintética construída a partir de um simulador de canal de leitura, com variação controlada da ocupação, geração de depósitos de energia aleatórios, convolução com o pulso característico do canal e adição de ruído gaussiano aditivo. Sobre essa base, foram implementados e avaliados quatro estimadores: Filtro de Wiener, MLP, SVR com núcleo RBF e CNN 1D. A comparação foi conduzida a partir de métricas como MSE, RMSE, MAE, viés, desvio padrão dos resíduos, resolução relativa e AUC, complementadas por análises qualitativas baseadas em diagramas de dispersão, distribuições de erro relativo e curvas ROC.

O Filtro de Wiener foi adotado como representante dos estimadores lineares, uma vez que a comparação entre Wiener e Filtro Ótimo encontra-se amplamente documentada na literatura do TileCal. Dessa forma, esta dissertação concentrou-se na avaliação do Wiener frente a métodos baseados em aprendizado de máquina sob um protocolo experimental único e homogêneo para todos os modelos avaliados.

Os resultados obtidos mostram, de forma consistente, que o aumento da ocupação

degrada o desempenho de todos os métodos avaliados. Essa tendência confirma que a superposição temporal de sinais constitui um dos principais fatores limitantes para a estimação precisa de energia no TileCal em regimes de alta luminosidade. Em baixa ocupação, os métodos lineares mantêm desempenho competitivo, o que está de acordo com a aderência dessas abordagens ao modelo de pulso aproximadamente isolado e com sua simplicidade estrutural. Nesses regimes, o Filtro de Wiener mostrou-se uma referência sólida, combinando boa qualidade de estimação com baixa complexidade de inferência.

À medida que a ocupação aumenta, contudo, tornam-se mais evidentes as limitações impostas por modelos estritamente lineares. Em particular, os resultados indicam que modelos não lineares podem capturar de forma mais eficaz distorções introduzidas pela superposição sistemática de pulsos, especialmente em regimes mais severos de *pile-up*. Entre os métodos avaliados, a CNN apresentou desempenho particularmente promissor nas condições mais desafiadoras, sugerindo maior capacidade de adaptação a padrões temporais locais e a relações não lineares entre o vetor de amostras e a energia de referência. O MLP também apresentou bom desempenho global, com resultados competitivos em diferentes regimes, embora com sensibilidade à escolha da arquitetura. O SVR, por sua vez, mostrou comportamento mais dependente da seleção de hiperparâmetros e maior custo de treinamento, o que limita sua atratividade prática em comparação com as demais abordagens testadas.

De forma geral, a análise comparativa mostra que não existe um método universalmente superior em todos os cenários. A escolha do estimador mais adequado depende do regime operacional considerado e dos requisitos de implementação. Em cenários de menor ocupação, métodos lineares continuam sendo alternativas atrativas devido à sua interpretação estatística clara, previsibilidade e baixo custo computacional. Em contrapartida, em regimes de maior ocupação, os modelos baseados em aprendizado de máquina tornam-se mais interessantes por sua flexibilidade funcional, ainda que essa vantagem venha acompanhada de maior dependência de dados representativos, maior sensibilidade à configuração de treinamento e maior custo de desenvolvimento e validação.

Sob a perspectiva de aplicação em sistemas associados ao *trigger*, os resultados sugerem que a discussão sobre viabilidade não deve se restringir ao menor erro médio. É necessário considerar conjuntamente desempenho de estimação, robustez à mudança de regime, custo de treinamento, custo de inferência e compatibilidade com restrições de latência e implementação em hardware dedicado. Nesse sentido, o trabalho contribui ao mostrar que a comparação entre métodos de estimação para calorimetria em alta luminosidade deve ser orientada por critérios múltiplos e pelo contexto operacional de uso.

Como principais contribuições desta dissertação, destacam-se: a formulação unificada do problema de estimação de energia sob condições de alta ocupação; a implementação comparativa de métodos lineares e não lineares sob um protocolo experimental comum; a

análise do comportamento dos estimadores em diferentes regimes de *pile-up*; e a discussão da relação entre qualidade de reconstrução e viabilidade computacional no contexto do TileCal e do HL-LHC.

Este trabalho também apresenta limitações que devem ser reconhecidas. A base utilizada é sintética e adota hipóteses simplificadoras quanto à modelagem do ruído e da cadeia de leitura. Embora isso seja adequado para uma análise controlada e comparativa, a generalização dos resultados para condições experimentais reais exige cautela. Além disso, a avaliação concentrou-se em janelas temporais fixas e em arquiteturas específicas de modelos, o que deixa espaço para investigações mais amplas sobre estratégias alternativas de representação de entrada, otimização e implantação em hardware.

Como desdobramentos futuros, destacam-se: a modelagem explícita de contribuições de pedestal induzidas pela cauda longa do pulso característico do canal, que pode introduzir deslocamentos lentos do nível de base quando múltiplos pulsos se sobrepõem temporalmente em regimes de alta ocupação; a avaliação dos métodos com dados mais próximos das condições experimentais do detector; a investigação de arquiteturas mais compactas e otimizadas para implementação embarcada; e o estudo de estratégias de processamento em fluxo ou com janelas deslizantes maiores.

Em síntese, conclui-se que a estimação de energia no TileCal sob condições de alta luminosidade constitui um problema em que a superposição temporal de sinais altera substancialmente as premissas tradicionais de reconstrução. Os resultados desta dissertação indicam que métodos lineares permanecem relevantes e competitivos em determinados regimes, mas também mostram que abordagens não lineares baseadas em aprendizado de máquina representam alternativas promissoras para cenários mais severos de *pile-up*. Dessa forma, o trabalho contribui para a discussão sobre estratégias de reconstrução de energia no ambiente do HL-LHC e reforça a importância de alinhar o desenvolvimento de estimadores às restrições estatísticas, instrumentais e computacionais do experimento.

REFERÊNCIAS

- AAD, G. et al. **The ATLAS Experiment at the CERN Large Hadron Collider: Status and Performance**. Journal of Instrumentation, 2022.
- AAD, G. et al. **A detailed map of Higgs boson interactions by the ATLAS experiment ten years after the discovery**. Nature, v. 607, p. 52–59, 2022.
- ABDALLA, B. O Maior Acelerador de Partículas do Mundo passa por um Upgrade. *Jornal da USP*, 2019. Acessado em: 2026. Disponível em: <https://jornal.usp.br/ciencias/ciencias-exatas-e-da-terra/o-maior-acelerador-de-particulas-do-mundo-passa-por-um-upgrade/>.
- ALONSO, J. R. et al. **Performance challenges for calorimetry at the HL-LHC**. Nuclear Instruments and Methods in Physics Research A, 2023.
- ANDRADE FILHO, L. M.; PERALVA, B. S.; SEIXAS, J. M.; CERQUEIRA, A. S. **Calorimeter response deconvolution for energy estimation in high-luminosity conditions**. IEEE Transactions on Nuclear Science, v. 62, n. 6, p. 3265–3273, dez. 2015.
- APOLLINARI, G. et al. **High-Luminosity Large Hadron Collider (HL-LHC): Technical Design Report**. CERN Yellow Reports: Monographs, 2017.
- ATLAS COLLABORATION. **The ATLAS Experiment at the CERN Large Hadron Collider**. Journal of Instrumentation, v. 3, p. S08003, 2008.
- ATLAS COLLABORATION. **The ATLAS detector**. Acessado em: 2026. Disponível em: <https://atlas.cern/Discover/Detector>.
- ATLAS Collaboration. **Technical Design Report for the Phase-II Upgrade of the ATLAS Tile Calorimeter**. CERN-LHCC-2017-019, 2017.
- ATLAS Collaboration. **Observation of a new particle in the search for the Standard Model Higgs boson**. Physics Letters B, v. 716, p. 1–29, 2012.
- ATLAS Collaboration. **Performance of the ATLAS Trigger System in 2015**. European Physical Journal C, v. 77, 2017.
- ATLAS Collaboration. **The ATLAS Tile Calorimeter: Technical Design Report**. CERN-LHCC-96-042, 2008.
- ATLAS Collaboration. **The ATLAS Trigger and Data Acquisition System: Phase-I Upgrade**. Eur. Phys. J. C 80, 1205 (2020).
- ATLAS Collaboration. **Operation and performance of the ATLAS Tile Calorimeter in LHC Run 2**. *European Physical Journal C*, v. 84, n. 12, p. 1313, 2024. doi:10.1140/epjc/s10052-024-13151-4. Acessado em: 2026. Disponível em: <https://cds.cern.ch/record/2887689>.
- ATLAS Collaboration. **ATLAS Insertable B-Layer Technical Design Report**. CERN-LHCC-2010-013. ATLAS-TDR-19, 2010. Addendum CERN-LHCC-2012-009, 2012.

ATLAS Collaboration. **Technical Design Report for the Phase-I Upgrade of the ATLAS Trigger and Data Acquisition System**. CERN-LHCC-2013-018. ATLAS-TDR-023, 2013.

BERNIUS, Catrin. **The ATLAS Trigger & Data Acquisition (TDAQ) System**. CERN Document Server, 14 set. 2020. Acessado em: 2026. Disponível em: <https://cds.cern.ch/record/2730760/files/ATL-DAQ-SLIDE-2020-356.pdf>.

BISHOP, C. M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006.

BRÜNING, Oliver; ZERLAUTH, Markus. *LHC operation and the High-Luminosity LHC upgrade project*. Geneva: CERN, 2025. (CERN Accelerator School: Advanced Accelerator Physics, Spa, Belgium, 10–22 nov. 2024). Acessado em: 2026. Disponível em: <https://cds.cern.ch/record/2935496>.

CARMINATI, M. e SCANDURRA, G. **Advances in measurements and instrumentation leveraging embedded systems**. Review of Scientific Instruments, v. 92, n. 12, p. 121601, 2021.

CERN. **Aerial view of the Large Hadron Collider**. CERN Document Server, 2020. Acessado em: 2025. Disponível em: <https://cds.cern.ch/record/2729751>.

CERN. **Accelerators**. 2025. Página institucional. Acessado em: 2025. Disponível em: <https://home.cern/science/accelerators>.

CERN. **About CERN**. Acessado em: 2025. Disponível em: <https://home.cern/about>.

CERN. **CERN technologies**. Acessado em: 2025. Disponível em: <https://home.cern/science/engineering>.

CERN. **The Large Hadron Collider**. Acessado em: 2025. Disponível em: <https://home.cern/science/accelerators/large-hadron-collider>.

CERQUEIRA, A. S. et al. **Optimal filtering techniques for pile-up mitigation in calorimeter signals**. IEEE Transactions on Nuclear Science, v. 63, n. 2, p. 1234–1241, 2016.

CHAKRABORTY, D. et al. **The upgraded calibration system for the ATLAS Tile Calorimeter**. Nucl. Instrum. Methods A, 2018.

CITRON, Z. et al. **Future physics opportunities for high-density QCD at the LHC**. CERN Yellow Reports, 2023.

CLELAND, W. E.; STERN, E. G. **Signal processing considerations for liquid ionization calorimeters in a high rate environment**. Nuclear Instruments and Methods in Physics Research Section A, v. 338, n. 2–3, p. 467–497, 1994.

CMS Collaboration. **Observation of a new boson at a mass of 125 GeV with the CMS experiment at the LHC**. Physics Letters B, v. 716, p. 30–61, 2012.

DAVIDEK, T. et al. **Signal reconstruction techniques for calorimetry under high pile-up conditions**. Nuclear Instruments and Methods in Physics Research A, 2022.

DUCKWORTH, Angela. **Grit: The Power of Passion and Perseverance**. New York: Scribner, 2016.

EINSTEIN, A. **The Meaning of Relativity: Including the Relativistic Theory of the Non-Symmetric Field**. Princeton: Princeton University Press, 2014.

ELLIS, J. **Physics Beyond the Standard Model**. Philosophical Transactions of the Royal Society A, v. 378, n. 2166, p. 20190014, 2020.

EVANS, L. R.; BRYANT, P. **LHC machine**. Journal of Instrumentation, v. 3, p. S08001, 2008.

FAWCETT, T. An introduction to ROC analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006.

FULLANA, E. et al. **Digital signal reconstruction in the ATLAS hadronic Tile Calorimeter**. IEEE Transactions on Nuclear Science, v. 53, p. 2139–2143, 2006.

GONÇALVES, Dayane O. **Métodos de estimação e detecção de sinais aplicados ao sistema TileMuon**. 2021. Tese (Doutorado) – Universidade Federal de Juiz de Fora, Juiz de Fora, 2021.

GONÇALVES, G. I.; PERALVA, B. S.; SEIXAS, J. M.; ANDRADE FILHO, L. M.; CERQUEIRA, A. S. **Performance of optimal linear filtering methods for signal estimation in high-energy calorimetry**. Journal of Control, Automation and Electrical Systems, v. 33, n. 5, p. 1601–1611, 2022.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge, MA: MIT Press, 2016.

GUEST, D. et al. **Deep learning and its application to LHC physics**. Annual Review of Nuclear and Particle Science, v. 68, p. 161–181, 2018.

HANAGAKI, K.; TANAKA, J.; TOMOTO, M.; YAMAZAKI, Y. **Experimental Techniques in Modern High-Energy Physics: A Beginner's Guide**. Cham: Springer, 2023.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. ed. New York: Springer, 2009.

HAYKIN, S. **Adaptive Filter Theory**. 4th ed., Prentice Hall, 2002.

HORNIK, K.; STINCHCOMBE, M.; WHITE, H. **Multilayer feedforward networks are universal approximators**. Neural Networks, v. 2, p. 359–366, 1989.

IOFFE, S.; SZEGEDY, C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. In: *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015. p. 448–456.

KAY, S. M. **Fundamentals of Statistical Signal Processing: Estimation Theory**. Upper Saddle River: Prentice Hall, 1993.

LECUN, Y.; BOTTOU, L.; BENGIO, Y.; HAFFNER, P. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998.

LEE, S. Y. **Accelerator Physics**. 4. ed. Singapore: World Scientific, 2019.

LOPIENSKA, Ewa. The CERN accelerator complex, layout in 2022. CERN Document Server, 2022. Acessado em: 2026. Disponível em: <https://cds.cern.ch/record/2800984>.

LUNA, Fábio Cardani; DIAS, Ualison Ferreira; LISBOA, Pedro Henrique Braga; PASCHOALIN, Thiago Campos Acacio; QUIRINO, Tiago Motta; ANDRADE FILHO, Luciano de Manhaes. Real-time FPGA-based simulator for the Tile Calorimeter readout system in the ATLAS experiment. In: **Encontro Nacional de Modelagem Computacional e Encontro de Ciência e Tecnologia de Materiais (ENMC/ECTM)**, 2024, Ilhéus, BA. Anais [...]. Ilhéus, BA, 2024. Acessado em: 2025. Disponível em: <https://www.even3.com.br/anais/enmc2024/920998-REAL-TIME-FPGA-BASED-SIMULATOR-FOR-THE-TILE-CALORIMETER-READOUT-SYSTEM-IN-THE-ATLAS-EXPERIMENT>.

MARCASTEL, F. **CERN's Accelerator Complex: La chaîne des accélérateurs du CERN**. CERN Graphic, CDS 1621583, 2013.

MEHLHASE, Sascha. **ATLAS detector slice (and particle visualisations)**. CERN Document Server, 2021. Disponível em: <https://cds.cern.ch/record/2770815>. Acesso em: 26 fev. 2026.

MOUCHE, P. **Overall view of the LHC**. CERN Document Server, 2014. Acessado em: 2025. Disponível em: <https://cds.cern.ch/record/1708847>.

OLIVEIRA, M. S. et al. **Energy estimation methods for calorimeter signals under high pile-up**. 2024. Artigo submetido.

OPPENHEIM, A. V.; SCHAFFER, R. W.; BUCK, J. R. **Discrete-Time Signal Processing**. 2nd ed., Prentice Hall, 1999.

PARTICLE DATA GROUP. **Review of Particle Physics**. Progress of Theoretical and Experimental Physics, v. 2022, n. 11, p. 113H01, 2022. Disponível em: <https://doi.org/10.1093/ptep/ptac139>

RADOVIC, A. et al. **Machine learning at the energy and intensity frontiers of particle physics**. Nature, v. 560, p. 41–48, 2018.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. **Learning representations by back-propagating errors**. Nature, v. 323, p. 533–536, 1986.

SCHÖLKOPF, B.; SMOLA, A. J. *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. Cambridge, MA: MIT Press, 2002.

SMOLA, A. J.; SCHÖLKOPF, B. A tutorial on support vector regression. *Statistics and Computing*, v. 14, n. 3, p. 199–222, 2004.

SPIELER, H. **Semiconductor Detector Systems**. Oxford University Press, 2005.

THOMSON, M. **Modern Particle Physics**. Cambridge: Cambridge University Press, 2013.

VAPNIK, V. N. *The Nature of Statistical Learning Theory*. New York: Springer, 1995.

VAPNIK, V. N. *Statistical Learning Theory*. New York: Wiley, 1998.

WIEDEMANN, H. **Particle Accelerator Physics**. 4. ed. Cham: Springer, 2015.

WIENER, N. **Extrapolation, Interpolation, and Smoothing of Stationary Time Series**. MIT Press, 1949.

WIGMANS, R. **Calorimetry: Energy Measurement in Particle Physics**. Oxford University Press, 2000.

WIKIMEDIA. **Wikimedia Commons**. 2016. Acessado em: 2025. Disponível em: https://commons.wikimedia.org/wiki/File:Standard_Model_of_Elementary_Particles-pt-br.svg.

ZIMMERMANN, F. et al. **Challenges for highest energy circular colliders**. *Physical Review Accelerators and Beams*, v. 23, p. 051001, 2020.