

UNIVERSIDADE FEDERAL DE JUIZ DE FORA
FACULDADE DE ENGENHARIA
CURSO DE GRADUAÇÃO EM ENGENHARIA ELÉTRICA

**RECONSTRUÇÃO DE ENERGIA NO CALORÍMETRO HADRÔNICO
DO ATLAS PARA FASE DE ALTA LUMINOSIDADE DO LHC**

ALESSA MONAY E SILVA

JUIZ DE FORA

2020

UNIVERSIDADE FEDERAL DE JUIZ DE FORA
CURSO DE GRADUAÇÃO EM ENGENHARIA ELÉTRICA

**RECONSTRUÇÃO DE ENERGIA NO CALORÍMETRO HADRÔNICO
DO ATLAS PARA FASE DE ALTA LUMINOSIDADE DO LHC**

ALESSA MONAY E SILVA

JUIZ DE FORA
FACULDADE DE ENGENHARIA

2020

RECONSTRUÇÃO DE ENERGIA NO CALORÍMETRO HADRÔNICO DO ATLAS PARA FASE DE ALTA LUMINOSIDADE DO LHC

Trabalho Final de Curso apresentado ao Colegiado do Curso de Engenharia Elétrica da Universidade Federal de Juiz de Fora, como requisito parcial à obtenção do título de Engenheiro Eletricista.

Área de conhecimento: Engenharia Elétrica

Orientador: Luciano Manhães Andrade Filho

JUIZ DE FORA
FACULDADE DE ENGENHARIA

2020

RECONSTRUÇÃO DE ENERGIA NO CALORÍMETRO HADRÔNICO DO ATLAS PARA FASE DE ALTA LUMINOSIDADE DO LHC

ALESSA MONAY E SILVA

Trabalho Final de Curso submetido à banca examinadora constituída de acordo com o Artigo 9º do Capítulo IV das Normas de Trabalho Final de Curso estabelecidas pelo Colegiado do Curso de Graduação em Engenharia Elétrica, como parte dos requisitos necessários para a obtenção do grau de Engenheiro Eletricista.

Aprovado em: //2020

Por:

Orientador: Prof. Dr. Luciano Manhães Andrade Filho

Prof^a. Dr^a. Dayane Oliveira Gonçalves

Prof. Dr João Paulo Bittencourt da Silveira Duarte

AGRADECIMENTOS

Agradeço primeiramente aos meus pais, que me proporcionaram todas as ferramentas necessárias para que eu alcançasse meus objetivos.

Agradeço também ao meu esposo, Hugo, meu apoio em todos os momentos difíceis. Aos meus sogros, Marco Antônio e Luciana, pelo carinho e incentivo.

Agradeço às minhas amigas de colégio, com quem compartilhei momentos maravilhosos ao longo de todos esses anos. À minha amiga e fisioterapeuta Luciana, cujo carinho e profissionalismo me ajudaram a seguir o curso com saúde.

Agradeço aos meus colegas de laboratório, sempre dispostos a ajudar e compartilhar seus conhecimentos.

Agradeço ao meu orientador Luciano Andrade, que me acompanha desde o início do curso, pela sua paciência e didática durante toda a minha formação.

E agradeço, por fim, a todos os demais professores, essenciais para minha formação.

“Don’t judge each day by the harvest you reap but by the seeds that you plant.”.

Robert Louis Stevenson

RESUMO

Este trabalho está ambientado no calorímetro hadrônico (TileCal) do ATLAS, no LHC. O TileCal possui milhares de canais de leitura e opera sob elevada taxa de eventos.

No calorímetro, a reconstrução da energia do evento se dá através de detecção e estimação da amplitude do sinal digitalizado. Essa estimativa é realizada através de um método linear que visa minimizar a variância, o Filtro Ótimo (do inglês, *Optimal Filter* - *OF*).

Entretanto, em ambientes de alta luminosidade (alta taxa de eventos) ocorre o fenômeno conhecido como empilhamento de sinais (do inglês *pile-up*). É sabido que, em cenários onde a probabilidade de empilhamento de sinais é alta, os métodos lineares apresentam significativa perda de performance.

Com isso em mente, este trabalho explora a associação de um método não-linear - no caso, uma rede neural MLP - ao método linear em vigor, e avalia o ganho em desempenho bem como os benefícios de se fazer tal associação.

Palavras-chave: Processamento digital de sinais; Física de partículas; Rede Neural; Método de Estimação linear; Empilhamento de Sinais;

LISTA DE ILUSTRAÇÕES

Figura 1 – Complexo de Aceleradores do CERN Gonçalves <i>et al.</i> (2017)	16
Figura 2 – Visão geral do LHC e seus experimentos. (Gonçalves <i>et al.</i> , 2017) . . .	17
Figura 3 – Região de detecção das partículas nos sub-detectores do ATLAS. (Peralva, 2015)	18
Figura 4 – Estrutura básica do experimento ATLAS (Gonçalves <i>et al.</i> , 2017) . . .	19
Figura 5 – Calorimetria do ATLAS. (Peralva, 2015)	21
Figura 6 – Partições do TileCal (Carrió <i>et al.</i> , 2014)	22
Figura 7 – Esquemático de um módulo do barril central e um módulo do barril estendido (Peralva; Seixas, 2015)	22
Figura 8 – Visão em corte do TileCal (Meyer, 2013)	23
Figura 9 – Exemplo de pulso de referência do TileCal (Meyer, 2013).	24
Figura 10 – Ilustração do efeito do <i>pile-up</i> no sinal do TileCal. O sinal de interesse encontra-se centrado na quarta amostra e um outro sinal, 50 ns atrasado, sobrepõem-se a ele, distorcendo o pulso resultante (Meyer, 2013). . . .	25
Figura 11 – Esquemático simplificado de um neurônio humano (Borges <i>et al.</i> , 2015) .	29
Figura 12 – Modelagem de um neurônio artificial (Zanetti <i>et al.</i> , 2012)	30
Figura 13 – Exemplo de Função de Ativação: Linear.	31
Figura 14 – Exemplo de Função de Ativação: Degrau.	31
Figura 15 – Exemplo de Função de Ativação: Sigmoide.	32
Figura 16 – Exemplo de Função de Ativação: Tangente Hiperbólica.	32
Figura 17 – <i>Feedforward</i> Camada Única.	34
Figura 18 – <i>Feedforward</i> de Múltiplas Camadas.	34
Figura 19 – Rede com supervisão	35
Figura 20 – Rede sem supervisão	36
Figura 21 – Diagrama de blocos da proposta deste trabalho.	38
Figura 22 – Estudo de topologia para uma camada - Ocupação 0%	40
Figura 23 – Estudo de topologia para uma camada - Ocupação 10%	40
Figura 24 – Estudo de topologia para uma camada - Ocupação 50%	41
Figura 25 – Estudo de topologia para duas camadas - Ocupação 0%	42
Figura 26 – Estudo de topologia para duas camadas - Ocupação 10%	42
Figura 27 – Estudo de topologia para duas camadas - Ocupação 50%	43
Figura 28 – Topologia usada para a rede neural.	44
Figura 29 – Resultados para ocupação 0%	46
Figura 30 – Resultados para ocupações de 10% e 20%	47
Figura 31 – Resultados para ocupação 50%	48
Figura 32 – Resultados para ocupação 80%	49

Figura 33 – Topologia usada para a rede neural.	51
Figura 34 – Sistema de Coordenadas do ATLAS.	55

LISTA DE TABELAS

Tabela 1 – Médias para ocupação 0%	45
Tabela 2 – Desvio padrão para ocupação 0%	45
Tabela 3 – Média para todas as ocupações avaliadas	50
Tabela 4 – Desvio padrão para todas as ocupações avaliadas	50

SUMÁRIO

1	INTRODUÇÃO	11
1.1	RELEVÂNCIA DO TEMA	11
1.2	MOTIVAÇÃO	12
1.3	OBJETIVOS	12
1.4	METODOLOGIA	12
1.5	ORGANIZAÇÃO DO TRABALHO	13
2	O CERN E O EXPERIMENTO ATLAS	15
2.1	CERN	15
2.1.1	LHC	16
2.2	ATLAS	18
2.2.1	CALORIMETRIA DO ATLAS	20
2.3	O CALORÍMETRO HADRÔNICO - TILECAL	21
2.3.1	O PROBLEMA DO <i>PILE-UP</i>	25
3	ESTIMAÇÃO DE ENERGIA NO TILECAL	26
3.0.1	<i>OPTIMAL FILTER - OF</i>	26
4	REDES NEURAIS	29
4.0.1	CONTEXTUALIZAÇÃO	29
4.0.2	MODELAGEM	30
4.0.3	FUNÇÕES DE ATIVAÇÃO	31
4.0.4	CLASSIFICAÇÃO INICIAL	32
4.0.5	REDES CAMADA ÚNICA - SLP	33
4.0.6	REDES DE MÚLTIPLAS CAMADAS - MLP	33
4.0.7	TREINAMENTO	35
4.0.7.1	APRENDIZADOS SUPERVISIONADO E NÃO SUPERVISIONADO	35
4.0.7.2	<i>BACKPROPAGATION</i>	36
5	MÉTODO PROPOSTO	38
5.1	BANCO DE DADOS	38
5.2	TOPOLOGIA ESCOLHIDA	39
6	RESULTADOS E DISCUSSÃO	45
7	CONCLUSÃO E TRABALHOS FUTUROS	52

	REFERÊNCIAS	53
A	SISTEMA DE COORDENADAS DO ATLAS	55

1 INTRODUÇÃO

1.1 RELEVÂNCIA DO TEMA

As áreas de instrumentação e processamento de sinais têm tido grande protagonismo no desenvolvimento científico e tecnológico, especialmente nas últimas décadas. Inovações na área de algoritmos de reconhecimento de voz, dispositivos de realidade virtual e sistemas de automação são apenas alguns dos exemplos de tecnologias desenvolvidas recentemente que se baseiam fortemente no processamento de sinais.

Como consequência direta de tais avanços temos sistemas cada vez mais complexos e com maior volume de informações a serem processadas em intervalos de tempo cada vez menores. Dessa forma, surge a necessidade de se desenvolver técnicas mais rápidas e complexas para o tratamento de tais informações.

Ainda no contexto do processamento de sinais, encontramos o ambiente de física de partículas, tema deste trabalho. Nos colisores de partículas as taxas de eventos são elevadas, o que faz com que uma grande quantidade de informação tenha que ser processada em curto período de tempo. Adicionalmente, a ocorrência de sinais de interesse é rara e os sinais encontram-se imersos em um cenário de alta incidência de ruído.

Dentre os colisores de partículas existentes atualmente, o *Large Hadron Collider* (LHC), com seus 27km de circunferência, recebe o título de maior do mundo. Em seu interior, feixes de prótons de hidrogênio são acelerados, em sentidos opostos, até velocidades que muito se aproximam à da luz e colididos em intervalos de 25ns. As colisões se dão no interior de um dos quatro detectores existentes ao longo do anel (Evans; Bryant, 2008).

ATLAS (*A Toroidal LHC Apparatus*), o maior dentre os quatro experimentos presentes no LHC, é um detector de propósito geral projetado para analisar a maior variedade possível de fenômenos físicos que podem ser obtidos nas colisões próton-próton (Aad *et al.*, 2008).

Os calorímetros são um dos principais instrumentos usados nesses experimentos e têm por função absorver e medir a energia das partículas que incidem em sua superfície. Neles, existem segmentações (células) que captam as informações de deposição de energia deixadas pela partícula passante.

Embora haja dissipação da energia inicial das partículas na forma de calor, uma parte da energia restante, proporcional a energia inicial, é detectada sob a forma de sinal. Adicionalmente, cada tipo existente de subproduto da colisão tem uma característica de deposição particular.

1.2 MOTIVAÇÃO

Detectores de partículas como o ATLAS apresentam altas taxas de eventos acontecendo em seu interior e sendo captadas por uma grande quantidade de células simultaneamente. Cada uma dessas células é interpretada pelo sistema de aquisição de dados como sendo uma entrada única que precisa ser processada paralelamente.

Adicionalmente, o sinal que se deseja captar está imerso em um ambiente com elevada incidência de ruído gaussiano, o que insere características que prejudicam a estimação. Este cenário, que por si só já apresenta desafios, é agravado pela presença de *pile-up* no interior dos calorímetros do ATLAS.

Este fenômeno se dá como consequência do aumento do número de colisões, o aumento da luminosidade. Com elevadas taxas de colisões, aliado ao grande número de eventos por colisão, tem-se que o intervalo entre colisões é menor que a janela de tempo do sinal e, com isso, poderá ocorrer uma sobreposição de pulsos adjacentes. Esta sobreposição gera uma alteração nas características do ruído, fazendo com que uma técnica de estimação que trata o ruído como gaussiano perca eficácia (M. de A. Filho *et al.*, 2015).

Desse modo, a fim de obter uma estimativa de pulso o mais próximo da realidade possível, são necessárias técnicas de processamento de sinais que levem em consideração, não somente a influência do ruído gaussiano, como também das sobreposições.

Esta monografia está inserida neste contexto e propõe aprimorar os métodos de estimação de energia em vigor atualmente, visando aumentar a eficiência em ambientes fortemente influenciados por ruído e *pile-up*.

1.3 OBJETIVOS

O presente trabalho tem como principais objetivos:

- Realizar a modelagem do ruído presente no detector levando em conta o empilhamento de sinais;
- Projetar um estimador que seja o mais eficiente possível para esta nova modelagem do ruído;
- Simular e comparar os resultados com o método em vigor atualmente.

1.4 METODOLOGIA

Os pulsos fornecidos pelos calorímetros possuem um formato característico, constituído pelo pulso de interesse e pelo ruído de fundo. A amplitude do pulso de interesse, que

é proporcional energia depositada pela partícula em algum ponto do detector, é justamente o parâmetro que a estimação tenta obter.

Algoritmo de estimação presente atualmente no calorímetro hadrônico do ATLAS é uma técnica linear baseada na soma ponderada da janela de sete amostras e que considera o ruído como sendo determinístico e gaussiano. Este método é conveniente para sistemas que necessitam de uma resposta rápida da estimação, trazendo simplicidade e bom desempenho com baixo custo computacional (Peralva, 2015).

Entretanto, com o aumento da luminosidade, o feixe de partículas torna-se mais denso e o número de eventos por colisão se eleva ainda mais, acarretando no aparecimento de sobreposições de sinais provenientes de colisões subsequentes. Desse modo, o ruído deixa de ser gaussiano e ocorre a distorção da forma do pulso de interesse, comprometendo a estimação da amplitude e fazendo com que a técnica atualmente implementada, perca performance (M. de A. Filho *et al.*, 2015).

Com isto em mente, neste trabalho é desenvolvido um outro método de estimação, onde as características do ruído em condições de empilhamento de eventos são levadas em consideração. O método proposto baseia-se em aliar o método linear em vigor atualmente (*Optimal Filter* - *OF*) a um corretor não-linear constituído por uma rede neural. Os coeficientes da rede neural foram encontrados, utilizando algoritmos já consolidados neste meio, através de buscas exaustivas dentro de um intervalo de valores determinado.

As análises realizadas levam em consideração diversos valores de ocupação das células e a figura de mérito utilizada para validação dos resultados foi a raiz do erro médio quadrático (RMS). Ao final do processo ficam disponíveis: a estimativa linear original do método OF, o valor do ajuste fino fornecido pela rede e o resultado final, formado pela combinação da estimativa linear com o ajuste não-linear. Com isso, a informação linear ainda fica disponível e o ajuste fino pode ser usado caso desejado.

Por fim, é interessante ressaltar que esse trabalho foi realizado em colaboração com o experimento ATLAS, onde a autora ficou por um ano, para desenvolver essa e outras atividades. O presente trabalho foi também publicado como um capítulo no livro (Peralva *et al.*, 2017)

1.5 ORGANIZAÇÃO DO TRABALHO

O Capítulo 2 detalha o ambiente no qual este trabalho foi desenvolvido, apresentando um pouco sobre o CERN, o LHC e seus experimentos. O experimento ATLAS é elucidado de forma mais profunda com destaque para o calorímetro hadrônico (*TileCal*);

O Capítulo 3 apresenta em detalhes os métodos de detecção e estimação em vigor

atualmente, bem como a solução proposta neste trabalho para estimação em calorimetria de altas energias;

O Capítulo 4 traz um aprofundamento a cerca do ruído, detalhando suas características através do uso de análises das distribuições estatísticas;

O Capítulo 5 detalha os resultados obtidos com as simulações da solução proposta.

O Capítulo 6 encerra este trabalho, trazendo as conclusões inferidas a partir dos resultados obtidos e analisa possibilidades de expansão deste tema em trabalhos futuros.

2 O CERN E O EXPERIMENTO ATLAS

Este capítulo foi desenvolvido com o intuito de descrever o ambiente no qual este trabalho se insere. Inicialmente, a Organização Europeia para Pesquisa Nuclear (CERN) é introduzida, bem como o colisionador de partículas Large Hadron Collider (LHC). Em seguida, é apresentado o experimento ATLAS e seus subsistemas, com ênfase no Calorímetro Hadrônico de Telhas (TileCal), tema deste trabalho. Por último, são examinados os efeitos decorrentes do aumento da luminosidade no LHC.

2.1 CERN

O *Conseil Européen pour la Recherche Nucléaire* (CERN), construído na fronteira entre França e Suíça, teve sua fundação em 1954 e atualmente recebe o título de maior centro de pesquisa nuclear do mundo.

Inicialmente o objetivo do CERN era o de impulsionar desenvolvimento científico na Europa, tendo em vista que, como consequência da Segunda Guerra Mundial, o desenvolvimento científico europeu encontrava-se em declínio.

Atualmente, conta com mais de 2500 pessoas de variadas nacionalidades e 23 países-membros. Os países-membros pertencem ao continente europeu e contribuem financeiramente para manter a organização, cobrindo custos operacionais e tendo representação no conselho da instituição. Além destes, existem também países não-membros, que possuem acordos de cooperação com o CERN. Esta é a situação atual do Brasil.

Nos dias de hoje, a motivação primária do CERN tem sido aprofundar o entendimento do universo, focando nos estudos a cerca da física de partículas. A saber, as estruturas que compõem a matéria e as forças de interação eletromagnéticas que a mantêm unida.

Com esse objetivo em mente foi construído, ao longo dos anos, um complexo de aceleradores de partículas.

O último deles, denominado *Large Hadron Collider* (LHC), entrou em operação no dia 10 de setembro de 2008 e é considerado, até o presente momento, como o maior e mais energético acelerador de partículas do mundo.

Estas estruturas são responsáveis por acelerar feixes de partículas até velocidades próximas a da luz, fazendo com que colidam em um dos quatro detectores existentes ao longo do anel. Os aceleradores fazem uso de campos elétricos para acelerar as partículas e as guiam, com auxílio e campos magnéticos, através de tuneis de vários quilômetros.




Figura 1 – Complexo de Aceleradores do CERN Gonçalves *et al.* (2017)

2.1.1 LHC

Localizado a 100m da superfície em um túnel circular com 27 km de comprimento, o LHC foi projetado para realizar colisões que ocorrem a cada 25ns com uma energia de 14 TeV. Uma visão geral do LHC, juntamente com seus principais experimentos, é ilustrada na Figura 2 (Evans; Bryant, 2008).

O colisor possui quatro pontos de colisão, nos quais estão localizados os quatro principais detectores, responsáveis por absorver e amostrar a energia das partículas subatômicas passantes. Posteriormente, pesquisadores do mundo todo se utilizam dos dados coletados pelos sistemas de aquisição para, entre outras razões, identificar essas partículas elementares e reconstruir o evento de origem. Estes trabalhos aprofundam os conhecimentos sobre as interações entre as partículas e trazem novos entendimentos sobre a estrutura fundamental da matéria.

Tendo em vista a complexidade do propósito a que se destina, o LHC foi segmentado em quatro principais experimentos. Esses experimentos são os pontos principais onde ocorrem as colisões de partículas. São eles:

- LHCb (Large Hadron Collider Beauty Experiment): é um detector de médio porte dedicado, especialmente, à busca de um modelo físico além do Modelo Padrão,




Figura 2 – Visão geral do LHC e seus experimentos. (Gonçalves *et al.*, 2017)

através do estudo da quebra de simetria entre matéria e anti-matéria presentes no universo (Collaboration *et al.*, 2008b);

- ALICE (A Large Ion Collider Experiment): detector de íons pesados, projetado para estudar a física envolvida na formação do estado da matéria denominado de plasma de quark-glúon. Acredita-se que o plasma de quark-glúon tenha se formado milissegundos após o Big Bang (Collaboration; Aamodt *et al.*, 2008);
- CMS (Compact Muon Solenoid): experimento construído para observação de uma elevada variedade de fenômenos físicos resultantes das colisões próton-próton. Estuda desde o Modelo Padrão, incluindo o bóson de Higgs, até múltiplas dimensões e partículas que possam constituir a matéria escura (Collaboration *et al.*, 2008a).
- ATLAS (A Toroidal LHC AparatuS): similar ao CMS, é um experimento que investiga diversos fenômenos físicos, em especial a existência do Bóson de Higgs, a existência de múltiplas dimensões e partículas constituintes da matéria escura. Embora tenha objetivos similares aos do CMS, faz uso de soluções técnicas diferentes (Ros, 2003).

Em julho de 2012, estes detectores comprovaram a existência do Bóson de Higgs, uma partícula elementar prevista pelo Modelo Padrão que possibilita explicar a origem da massa das outras partículas e cuja teoria já existia desde sua publicação, em 1964, pelo físico Peter Higgs.




Figura 3 – Região de detecção das partículas nos sub-detectores do ATLAS. (Peralva, 2015)

Esses detectores são baseados em um modelo de camadas, onde cada uma delas se especializa em alguns tipos de partículas. A Figura 3 ilustra quais partículas interagem em quais regiões do ATLAS.

O experimento ATLAS é o ambiente no qual este trabalho foi desenvolvido e, na próxima seção, serão vistos maiores detalhes sobre o mesmo.

2.2 ATLAS

O Detector ATLAS, mostrado na Figura 4, é um detector de propósito geral e o maior do LHC. Está em operação desde 2010 e possui cerca de 44 metros de comprimento, 25 metros de altura e aproximadamente 7 mil toneladas, peso similar ao da Torre Eiffel e metade do tamanho da Catedral de Notre Dame de Paris (Nakahama, 2015).

Foi desenvolvido com o objetivo de identificar e medir aspectos de um evento como trajetória, velocidade e carga das partículas que interagem com ele. Vale observar que, dependendo da trajetória da partícula e de seu padrão de deposição de energia, é possível identificá-las.

O ATLAS é subdividido em seis subsistemas, dispostos em camadas cilíndricas, cada um com objetivo de medir propriedades específicas das partículas absorvidas (Ros,




Figura 4 – Estrutura básica do experimento ATLAS (Gonçalves *et al.*, 2017)

2003):

- Detector de Traço (*Inner Detector*): reside na camada mais interna do ATLAS e está subdividido em mais três sub-detectores (*Pixel Detector*, *Semiconductor Tracker* e *Transition Radiation Tracker*), possuindo função de determinar a trajetória das partículas carregadas;
- Solenóide (*Solenoidal Magnets*): projetado para gerar um campo magnético axial de 2T para o detector de traço;
- Calorímetro Eletromagnético (*Liquid Argon Calorimeter - LAr*): projetado para medir a energia depositada por partículas eletromagnéticas;
- Calorímetro Hadrônico (*Hadronic Calorimeter*): é formado pelo o Calorímetro de Telhas (*Tile Calorimeter - TileCal*) e pela Tampa Hadrônica (*Hadronic End Cap*) e visa medir a energia das partículas que interagem de forma hadrônica;
- Toróide (*Toroid Magnets*):juntamente com as duas Tampas (end-cap toroids), produz um campo magnético de 0.5T para os detectores de múons;
- Espectrômetro de Múons (*Muon Spectrometer*): responsável pela identificação e medição do momento de múons e, já que os múons são as partículas detectáveis que alcançam maior distância, o espectrômetro fica localizado na camada mais externa.

As seções seguintes apresentam o sistema de calorimetria, com ênfase no Calorímetro de Telhas - *TileCal*, visto que é onde está inserido a proposta deste trabalho.

2.2.1 CALORIMETRIA DO ATLAS

As partículas, após passarem pelo Detector de Trajetórias, atingem os calorímetros. Ao entrarem em contato com o material do calorímetro, as partículas decaem, formando um chuveiro de partículas.

Em Física de Altas Energias, os calorímetros são blocos de matéria bastante densos, com o objetivo de absorver, amostrar e medir a energia dos hádrons, elétrons e fótons. Para tal, os calorímetros devem ser volumosos e densos, de modo a absorver o máximo possível do chuveiro de partículas. Com exceção dos múons e dos neutrinos, todas as outras partículas são absorvidas no interior dos calorímetros.

Nos experimentos de Física de Partículas, os calorímetros apresentam um papel de destaque, sobretudo devido aos seguintes motivos:

- A informação da energia absorvida pode ser utilizada para filtrar apenas os eventos de interesse;
- Podem ser segmentados longitudinalmente e transversalmente, permitindo a detecção da trajetória em adição à medição da energia;
- Versatilidade devido à detecção de ampla variedade de partículas
- Podem identificar partículas neutras e carregadas;
- Rápida resposta na detecção, algo muito valorizado em um ambiente com elevada taxas de eventos;
- Alta eficácia na detecção das partículas devido às nuances apresentadas nas deposições de energia.

O sistema de calorimetria do ATLAS é apresentado na Figura 5. Ele é formado por dois tipos de calorímetros: Eletromagnético e Hadrônico (Gonçalves *et al.*, 2017).

O calorímetro Eletromagnético, chamado de Calorímetro de Argônio Líquido (do Inglês Liquid Argonic Calorimeter - LArg), encontra-se localizado logo após o detector de traços e absorve a energia de partículas eletromagnéticas (como elétrons e fótons).

O calorímetro Eletromagnético é composto pelo barril e por duas tampas (END-CAP). É formado de cobre e chumbo rodeados de argônio líquido. Durante a passagem

de uma partícula, o argônio líquido é ionizado, liberando elétrons que são traduzidos em corrente elétrica através de eletrodos conectados às placas de cobre.




Figura 5 – Calorimetria do ATLAS. (Peralva, 2015)

No entorno do calorímetro eletromagnético está o calorímetro hadrônico. Este é formado pelo Calorímetro de Telhas (do inglês Tile Calorimeter - TileCal) e a Tampa Hadrônica (do inglês Hadronic End Cap - HEC). Ele absorve principalmente a energia dos hádrons. O calorímetro hadrônico será melhor descrito na próxima seção.

2.3 O CALORÍMETRO HADRÔNICO - TILECAL

O calorímetro hadrônico do ATLAS, encontra-se localizado no entorno do calorímetro LAr. Seu princípio de funcionamento baseia-se no uso de telhas plásticas cintilantes como material ativo e placas de aço como material absorvedor. Por conta da existência das telhas, também é conhecido por Calorímetro de Telhas (do inglês, Tile Calorimeter - Tilecal).

O TileCal possui uma forma cilíndrica com 2,3 m de raio interno e 4,3 m de raio externo, cobrindo a maior parte da região central do ATLAS, ocupando de $0 < |\eta| < 1,7$. (Peralva, 2015)

Como ilustrado na Figura 6, o TileCal é subdividido estruturalmente em um barril central (Long Barrel) com 5,6 m de comprimento e dois barris estendidos (Extended

Barrel) com 2,9 m de comprimento cada um. O barril central é dividido, por sua vez, em duas partições distintas - LBA e LBC. De forma análoga, cada lado do barril estendido recebe uma denominação: EBA para o lado direito e EBC para o lado esquerdo.




Figura 6 – Partições do TileCal (Carrió *et al.*, 2014)

Um módulo do barril central e um módulo do barril estendido podem ser observados na Figura 7. Cada barril é dividido em 64 módulos e cada módulo do barril central e do barril estendido possui, respectivamente, 23 e 16 células. Visando redundância, cada uma dessas células apresenta dupla leitura (cada célula é lida por duas PMT). Como cada PMT representa um canal de leitura, o TileCal possui em torno de 10.000 canais no total.




Figura 7 – Esquemático de um módulo do barril central e um módulo do barril estendido (Peralva; Seixas, 2015)

O principal objetivo do calorímetro hadrônico é medir com precisão a energia de jatos, taus e hádrons.

Ao serem atravessadas pelas partículas de interesse, fótons são emitidos pelas telhas cintiladoras. Estes, por sua vez, são levados por fibras óticas até as PMTs (células foto-multiplicadoras - *PhotoMultiplier Tube*), responsáveis por fazer a conversão do sinal luminoso em sinal elétrico. Um desenho ilustrativo de uma telha do TileCal pode ser visto na Figura 8

O sinal elétrico obtido pelas PMTs passa, em seguida, por um processo de amplificação e conformação, através de um circuito conformador de pulsos (*shaper*).

O circuito conformador é responsável por dar ao sinal um formato determinístico e uma amplitude proporcional à energia depositada pela partícula passante. Com isso, obtém-se um pulso de forma aproximadamente invariante e é possível estimar a energia depositada em um dado canal a partir da estimativa da amplitude.

Em seguida, os sinais analógicos passam por um conversor Analógico-Digital (ADC) e são convertidos com frequência de amostragem de 40MHz (intervalo de 25ns entre amostras) em uma janela de 7 amostras. Essa janela total de 150ns é suficiente para englobar o pulso em sua totalidade (Gonçalves *et al.*, 2017).




Figura 8 – Visão em corte do TileCal (Meyer, 2013)

A Figura 9 traz uma representação do sinal analógico e suas amostras digitais, observados em um canal do TileCal. É possível também a observação de outros parâmetros como pedestal, fase e amplitude.




Figura 9 – Exemplo de pulso de referência do TileCal (Meyer, 2013).

A fase é definida como a diferença de tempo entre a amostra quarta amostra (amostra central) e o pico do pulso. Por sua vez, o pedestal é o *offset* do pulso (linha de base do sinal) e a amplitude é a medida da distância entre o pedestal e o pico do sinal (Peralva, 2015) .

Para a obtenção dos dados para o cálculo do pedestal, são feitas tomadas de dados (*runs*) especificamente para essa finalidade. O detector é posto em funcionamento, entretanto sem que ocorram colisões. Deste modo, é possível inferir que a informação captada será advinda principalmente do ruído existente na eletrônica do experimento.

Como resultado das *runs* de pedestal, têm-se um conjunto de milhares de entradas com 7 amostras. O o valor do pedestal poderá então ser estimado através da média da primeira amostra digital deste conjunto de dados.

Além da alta taxa de eventos, o ambiente do calorímetro ainda sofre com a influência de ruído de fundo. Portanto, reconstruir a energia que foi depositada na célula, o TileCal faz uso de um método de estimação para a amplitude denominado Método OF (*Optimal Filter*), que será melhor descrito posteriormente.

2.3.1 O PROBLEMA DO *PILE-UP*

Atualmente, a taxa vista no ponto de interesse dos detectores, ou seja, a taxa de colisões do LHC, é de 40MHz (40 milhões de eventos por segundo). Como consequência, o espaçamento entre as amostras na janela do sinal fica reduzido a 25ns.

Com o aumento de luminosidade, que está previsto para os próximos anos, têm-se o aumento da probabilidade de ocorrência de eventos em um mesmo canal e em colisões sucessivas. Com isso, se a resposta das células do calorímetro durar mais de um *bunch crossing*, pode-se ter como consequência a sobreposição de sinais - denominado empilhamento de sinais (*pile-up*, em inglês).

O algoritmo de estimação de energia atualmente em uso no TileCAI (*Optimal Filter*), descrito detalhadamente no Capítulo 3, não prevê o efeito do empilhamento de sinais em seu modelo. Deste modo, este algoritmo pode sofrer significativas perdas de performance, visto que o *pile-up* distorce a forma padrão do pulso, fazendo com que ele deixe de condizer com o pulso de referência e ocasionando erros de estimação da amplitude (Marshall, 2014).

O foco deste trabalho encontra-se justamente na busca de um método alternativo para ser usado nesses cenários de alta luminosidade.




Figura 10 – Ilustração do efeito do *pile-up* no sinal do TileCal. O sinal de interesse encontra-se centrado na quarta amostra e um outro sinal, 50 ns atrasado, sobrepõem-se a ele, distorcendo o pulso resultante (Meyer, 2013).

3 ESTIMAÇÃO DE ENERGIA NO TILECAL

3.0.1 OPTIMAL FILTER - OF

Na maioria dos calorímetros modernos, o ruído é composto basicamente de ruído eletrônico. Este ruído é usualmente considerado estacionário e modelável por uma distribuição gaussiana.

Deste modo, técnicas de estimação que visam minimizar a variância do sinal são extensivamente utilizadas e, no geral, apresentam uma boa performance. Entretanto, como será apresentado posteriormente, esses métodos não levam em consideração possíveis deformações no pulso, perdendo performance na presença de empilhamento de sinais, por exemplo.

A maioria dos algoritmos usados na reconstrução de energia dos sistemas de calorimetria são baseados em uma soma ponderada. A amplitude do sinal é estimada através de uma combinação linear de tempo discreto que contém o sinal de interesse em N amostras digitais.

Semelhantemente, no TileCal, a estimação de energia é feita através de um estimador linear denominado Filtro Ótimo (do inglês, *Optimal Filter*). Esta técnica utiliza a minimização de variância e o conhecimento da forma do pulso para estimar a amplitude do sinal e, conseqüentemente, a energia (Bertuccio *et al.*, 1992):

$$\hat{A}_{OF} = \sum_{i=0}^{N-1} w[i]r[i] \quad (3.1)$$

Onde:

- $r[i]$ é o valor do sinal no tempo i
- $w[i]$ é o i -ésimo coeficiente do filtro
- $\hat{A}_{OF}$ é a estimativa encontrada para a amplitude

Os pesos $w[i]$ são calculados através da matriz de covariância do ruído de cada canal e do pulso de referência do sinal neste respectivo canal. O processo visa minimizar a variância da distribuição de amplitude, sendo eficaz para sinais determinísticos imersos em ruído gaussiano.

Para que se possa computar os pesos do filtro, o sinal do recebido do calorímetro hadrônico é modelado através de uma aproximação de primeira ordem na sua série de

Taylor:

$$s[i] = Ag[i] - A\tau\dot{g}[i] + n[i] + ped \quad i = 0, 1, 2, \dots, N-1 \quad (3.2)$$

Onde:

- $s[i]$ é o sinal digital no tempo i
- A é a amplitude a ser estimada
- N é o número total de amostras disponíveis i -ésimo coeficiente do filtro
- $g[i]$ é o pulso de referência do canal
- $\dot{g}[i]$ é a derivada do pulso de referência
- τ é a fase do sinal
- $n[i]$ é o ruído de fundo
- ped é o pedestal do sinal, valor constante adicionado ao sinal analógico antes de sua conversão para digital

Para um estimador não tendencioso, tem-se que o valor esperado de A é idêntico a $\hat{A}$. Adicionalmente, como ruído foi assumido como Gaussiano de média zero, pode-se reescrever a equação 3.1 como sendo (Bertuccio *et al.*, 1992):

$$E[\hat{A}_{OF}] = \sum_{i=0}^{N-1} (Aw[i]g[i] - A\tau w[i]\dot{g}[i] + w[i]ped) = A \quad (3.3)$$

Para que se obtenha $E[\hat{A}_{OF}] = A$ pode-se deduzir as seguintes restrições:

$$\sum_{i=0}^{N-1} w[i]g[i] = 1 \quad (3.4)$$

$$\sum_{i=0}^{N-1} w[i]\dot{g}[i] = 0 \quad (3.5)$$

$$\sum_{i=0}^{N-1} w[i] = 0 \quad (3.6)$$

Com isso, a variância do estimador é tida como:

$$var(\hat{A}_{OF}) = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} w[i]w[j]C[i, j] = \mathbf{w}^T \mathbf{C} \mathbf{w} \quad (3.7)$$

Onde $\mathbf{C}$ corresponde à matriz de covariância do ruído e $\mathbf{w}$ corresponde ao vetor de pesos do filtro. Para encontrar os pesos do estimador, as restrições das equações (3.4), (3.5) e (3.6) são adicionadas ao processo de minimização, que é feito através dos multiplicadores de Lagrange.

4 REDES NEURAIS

Este capítulo traz informações sobre as redes neurais artificiais, especialmente sobre suas aplicações, principais topologias e técnicas de treinamento.

4.0.1 CONTEXTUALIZAÇÃO

O cérebro humano possui capacidade para lidar com uma quantidade enorme de informações. Esse processamento é ainda, paralelo e não-linear, o que dá ao mesmo uma elevada complexidade. Os neurônios, unidade fundamental da cadeia de processos, apresentam ainda a capacidade de se adaptar às mudanças do meio ambiente.

Redes neurais artificiais são modelos computacionais capazes de realizar os mais diversos processamentos e tem sido utilizadas especialmente em tarefas difíceis de realizar com programação convencional. Estes modelos computacionais foram inspirados no sistema nervoso central do corpo humano.

Nos neurônios humanos, encontramos basicamente três componentes principais: dendritos, axônios e corpo celular. Na Figura 11 é possível observar melhor esses componentes.




Figura 11 – Esquemático simplificado de um neurônio humano (Borges *et al.*, 2015)

Uma cadeia simples de propagação do impulso nervoso se inicia com os neurônios pré-sinápticos excitando os dendritos, o que gera um potencial elétrico que é somado no corpo celular. Caso o valor desse impulso seja maior que um valor patamar, o impulso nervoso é transmitido.

Apesar de as redes neurais não serem tão complexas quanto o cérebro humano, elas apresentam duas semelhanças principais com os mesmos: os blocos fundamentais de processamento são elementos simples (computacionais) altamente interconectados e a forma como os neurônios se conectam determina a função exercida pela rede.

4.0.2 MODELAGEM

O modelo simplificado de um neurônio é apresentado na Figura 12, sendo constituído de quatro elementos principais (Hagan, 1996) :

- Pesos sinápticos: à cada sinapse é atribuído um peso w_{kj} onde k indica a qual neurônio esse peso pertence e j a qual entrada esse peso está relacionado. Os pesos podem ser ajustados de acordo com o propósito pretendido para a rede neural;
- Bias (b_k): desloca o valor de entrada na função de ativação por uma constante. Da mesma forma que os pesos, o *bias* também pode ser ajustado de acordo com o propósito pretendido para a rede;
- Junção aditiva: é um combinador linear que soma todas as ponderações sinápticas das entradas;
- Função de ativação (ϕ): responsável por limitar o sinal de saída do neurônio para que este se encontre dentro de um intervalo definido (geralmente entre 0 e 1 ou entre -1 e 1). A função de ativação pode ou não ser linear.




Figura 12 – Modelagem de um neurônio artificial (Zanetti *et al.*, 2012) .

O sinal de saída y_k pode ser então modelado do seguinte modo:

$$y_k = \phi(v_k) \quad (4.1)$$

Onde:

$$v_k = \sum_{j=1}^n w_{k,j} x_j + b_k \quad (4.2)$$

4.0.3 FUNÇÕES DE ATIVAÇÃO

Antes que se possa projetar uma rede neural para resolver qualquer tipo de tarefa, é necessária a escolha de uma função de ativação. Alguns exemplos de funções de ativação - a saber, linear, degrau, sigmoidal e tangente hiperbólica - são apresentados a seguir (Hagan, 1996).

A função Linear, representa uma combinação simples e linear das entradas, sendo dada por:

$$\phi(v_k) = v_k \quad (4.3)$$




Figura 13 – Exemplo de Função de Ativação: Linear.

A função degrau tem, para valores do domínio menor que 0, valor 0, já para valores maiores ou iguais a 0, a saída vale 1.

$$\phi(v_k) = \begin{cases} 0, & \text{se } v_k < 0 \\ 1, & \text{se } v_k \geq 0 \end{cases} \quad (4.4)$$




Figura 14 – Exemplo de Função de Ativação: Degrão.

As funções sigmoidais tendem monotonicamente à uma constante, quando o domínio tende a $\pm \infty$. São amplamente utilizadas em redes neurais por possuírem um excelente

equilíbrio entre um comportamento não-linear e um linear. Podem ser descritas segundo a equação abaixo, onde β pode ser variado para se obter diferentes inclinações na origem.

$$\phi(v_k) = \frac{1}{1 + \beta e^{v_k}} \quad (4.5)$$




Figura 15 – Exemplo de Função de Ativação: Sigmoide.

Funções ímpares tem a tendência de produzir resultados com médias pequenas, próximas a zero, o que faz com que o processo de treinamento da rede seja realizado mais rapidamente. Com isso, uma função de ativação amplamente utilizada na construção de redes neurais artificiais é a tangente hiperbólica.

$$\phi(v_k) = \tanh(v_k) = \frac{e^{v_k} - e^{-v_k}}{e^{v_k} + e^{-v_k}} \quad (4.6)$$




Figura 16 – Exemplo de Função de Ativação: Tangente Hiperbólica.

Neste trabalho foi feito uso de duas dessas funções de ativação: tangente hiperbólica e linear.

4.0.4 CLASSIFICAÇÃO INICIAL

É usual classificar-se as redes neurais de duas formas distintas: redes *feedforward* (ou não-cíclicas) e redes recorrentes.

Redes *feedforward* são aquelas onde as conexões entre os neurônios se dá de forma linear. Ou seja, o fluxo de informação não forma um ciclo. A informação chega pelos nós de entrada, passa para as camadas ocultas de neurônios (se houverem), e segue, subsequentemente, para a camada de saída e para os nós de saída (Hagan, 1996).

As redes recorrentes, por sua vez, possuem pelo menos um laço de realimentação. São especialmente úteis quando os dados de entrada são sequenciais e dependem da saída anterior.

As redes *feedforward* foram o primeiro tipo a ser concebido e são de implementação mais simples em relação às redes recorrentes.

Um bom exemplo de uso de redes recorrentes é em previsões de ações no mercado financeiro, onde o preço atual dependerá fortemente o valor anterior. Já as redes *feedforward* são muito utilizadas em aplicações de controle automático de processos e em filtragem adaptativa, foco deste trabalho.

As redes são chamadas de totalmente conectadas (do inglês, *fully connected*) quando possuem todos os nós conectados aos nós da camada seguinte. Caso contrário, diz-se que a rede é parcialmente conectada (do inglês, *partially connected*).

Além das classificações mencionadas, às redes neurais podem ainda ser diferenciadas entre redes de camada simples (também conhecidas como *single layer perceptron* - *SLP*) e redes multicamadas (*multilayer perceptron* - *MLP*).

Este trabalho foi desenvolvido com base em uma rede neural *feedforward* multicamadas e, por isso, a esta será dado um enfoque maior nas subseções seguintes.

4.0.5 REDES CAMADA ÚNICA - SLP

Uma *SLP* é o tipo mais simples de rede neural *feedforward* que pode ser construído e são utilizadas em padrões linearmente separáveis que possuem alvos binários (0 ou 1).

Apresentam uma camada de nós entrada (*node input layer*), por onde o sinal é transmitido diretamente para os neurônios da camada de saída (*output layer*). Seu nome se origina justamente da presença de uma única camada de neurônios, a camada de saída.

A Figura 17 ilustra uma rede neural de camada única. Na figura, cada seta representa uma conexão sináptica e tem associada a ela um peso, da mesma forma como descrito em 4.0.2.

4.0.6 REDES DE MÚLTIPLAS CAMADAS - MLP

As redes de múltiplas camadas são redes *feedforward* que diferem das de camada única por possuírem mais de uma camada de neurônios entre a entrada e a saída. Estas




Figura 17 – *Feedforward* Camada Única.

camadas recebem o nome de camadas escondidas (ou *hidden layers*, em inglês) (Hagan, 1996) .

Sendo uma rede *feedforward*, se comporta de forma análoga ao descrito anteriormente. Após receber um estímulo nos nós de entrada, repassa esse estímulo sempre da esquerda para a direita, passando das camadas escondidas até a camada de saída.

Ao se adicionar camadas extras de neurônios é possível lidar com aplicações mais complexas. Desse modo, as redes multicamadas se tornam ferramentas muito mais robustas que as de camada simples.




Figura 18 – *Feedforward* de Múltiplas Camadas.

4.0.7 TREINAMENTO

A característica mais marcante de uma rede neural é sua habilidade de aprender e se adaptar, melhorando seu desempenho. Esse aprendizado se dá através de um processo iterativo no qual seus pesos são sucessivamente ajustados, reforçando caminhos que obtiveram saídas mais próximas ao alvo e atenuando os caminhos com maior desvio da resposta almejada. A este processo dá-se o nome de treinamento da rede.

O conjunto de procedimentos necessários para o aprendizado da rede recebe o nome de algoritmo de aprendizado. Existem vários desses tipos de algoritmos, diferindo entre si sobretudo pela forma como os pesos são ajustados.

Uma outra característica importante é a maneira pela qual uma rede neural se relaciona com o ambiente. O tipo de aprendizado determinará como seus parâmetros serão ajustados. Nesse sentido, há dois paradigmas principais de aprendizado: o supervisionado e o não-supervisionado.

4.0.7.1 APRENDIZADOS SUPERVISIONADO E NÃO SUPERVISIONADO




Figura 19 – Rede com supervisão

No aprendizado supervisionado a rede neural é treinada usando uma parcela de dados que já contém a resposta desejada para o padrão de entrada inserido. É o método mais comumente utilizado de aprendizado, sendo computacionalmente mais simples.

Durante o treinamento, são fornecidos pares entrada e saída para a rede e a mesma é treinada visando atingir um critério pré-estabelecido de erro. Todo esse processo é iterativo e, a cada iteração, os pesos sinápticos recebem um ajuste de valor.

Com isso em vista, é possível perceber a presença de um problema de otimização. Tem-se que a função custo se torna o erro entre o alvo e a resposta da rede e deve ser minimizada durante o treinamento.

Para o erro mencionado, geralmente usa-se o erro médio quadrático, tanto para a função custo quanto como medida de desempenho no processo (Haykin, 1999).




Figura 20 – Rede sem supervisão

No aprendizado não supervisionado não existe um agente externo influenciando a resposta da rede. Durante o treinamento, são fornecidos para a rede apenas os dados de entrada, ficando a rede incumbida de trabalhar, sozinha, em busca da informação.

Com isso, é possível utilizar o aprendizado não supervisionado para resolver processamentos mais complexos do que os possíveis aprendizado supervisionado. Entretanto, é um método bem mais imprevisível.

A rede neural implementada neste trabalho foi treinada através de um algoritmo de aprendizado supervisionado, o Levenberg-Marquardt, um algoritmo de *backpropagation*. O conceito de *backpropagation* será melhor abordado no tópico seguinte.

4.0.7.2 BACKPROPAGATION

Até o final da década de 70, não existiam algoritmos de treinamento que permitissem a existência de camadas ocultas, o que limitava as redes da época a terem apenas uma camada de neurônios. O que, por sua vez, limitava o uso de redes neurais à aplicações mais simples.

O que se possuía como algoritmo de treinamento era baseado na regra Delta. Esta regra utiliza o gradiente descendente para atualizar os pesos sinápticos em redes de camada única. Os pesos são atualizados na direção contrária do gradiente desta função, consequentemente, na direção onde o erro é minimizado.

A Figura 19 ilustra o processo de aprendizado supervisionado. Para um neurônio k , tem-se que o erro para esse neurônio, na iteração n , será:

$$\epsilon(n) = x_k(n) - y_k(n) \quad (4.7)$$

Como mencionado anteriormente, o erro médio quadrático instantâneo é utilizado como função custo que deve ser minimizada e é dado pela equação abaixo:

$$E_k(n) = \frac{\epsilon^2(n)}{2} \quad (4.8)$$

Como mencionado, um problema da regra delta é que ela só pode ser usada em neurônios visíveis, o que limita os usos possíveis para o método. Quando, em meados da década de 80, o algoritmo de retro-propagação do erro (*backpropagation*, em inglês) foi desenvolvido, expandiu-se enormemente as possibilidades de uso das redes. Seu objetivo é calcular o gradiente da Equação 3.8 (função custo) em relação a qualquer peso sináptico presente na rede.

O *backpropagation* pode ser entendido como generalização da regra delta, capaz de treinar redes multicamadas. O passo inicial para a implementação desse algoritmo é a inicialização dos pesos da rede, que recebem valores aleatórios e com distribuição uniforme em torno de zero.

O algoritmo ajusta os valores dos pesos sinápticos de acordo com a diferença entre o valor obtido e o valor alvo recebido no treinamento. Para tal, faz uso de dois passos de computação: o processamento direto e o processamento reverso.

O algoritmo de *backpropagation* pode ser resumidamente descrito pelos seguintes passos (Haykin, 1999):

1. Os pesos da rede são iniciados aleatoriamente;
2. Processamento direto: os pesos sinápticos são mantidos fixos e é aplicada uma entrada à rede, são computados os efeitos produzidos em todos os neurônios e o erro é calculado;
3. Processamento reverso: o sinal de erro é propagado no sentido reverso e novos pesos são calculados para cada neurônio da rede;
4. Se o critério de parada adotado for satisfeito, o algoritmo se encerra;
5. Caso contrário retorna-se ao passo 2

Dependendo da aplicação, o treinamento de redes multicamadas com algoritmo de *backpropagation* pode ser bastante demorado.

Vale ressaltar que, para que se atenda aos critérios de funcionamento do algoritmo de *backpropagation*, as funções de ativação usadas na construção da rede neural devem ser diferenciáveis.

5 MÉTODO PROPOSTO

Métodos lineares de reconstrução de energia não são totalmente aptos a lidar com as não-linearidades que o empilhamento de sinais insere no sinal. Com isso, torna-se interessante o uso de inteligência computacional no auxílio da reconstrução de energia fornecido pelo método linear.

Um corretor não-linear pode ser usado concomitantemente ao método linear, de forma a melhor lidar com as não linearidades do sinal de origem. Esta foi precisamente a premissa deste trabalho. O método linear de estimação atualmente usado no TileCal - a saber, *Optimal Filter* - *OF*, descrito no Capítulo 3 - foi associado à uma rede neural.

O diagrama de blocos ilustrativo da proposta deste trabalho pode ser encontrado na Figura 21. Como mencionado, o objetivo do processamento da rede neural é corrigir o modelo linear. Para isso, a rede não estima a amplitude do pulso, apenas proporciona um ajuste fino à estimativa linear do método OF. Essa correção é variável e depende das condições de *pile-up* à que o sinal esta sujeito.




Figura 21 – Diagrama de blocos da proposta deste trabalho.

Como uma vantagem deste método combinado, tem-se que a estimativa do método linear fica disponível para uso, e a correção pode ou não ser usada dependendo da vontade do usuário. Além disso, para situações onde o ruído tem origem puramente da eletrônica do calorímetro, a contribuição da rede neural deverá ser mínima e a estimativa será dada predominantemente pelo método linear.

5.1 BANCO DE DADOS

Antes que se possa descrever a montagem do banco de dados utilizado, é importante definir o conceito de ocupação.

Ocupação significa a probabilidade de uma colisão produzir um sinal válido que é lido por um dado canal. Em um canal de ocupação elevada, é muito provável que o sinal de interesse esteja corrompido tanto com ruído da eletrônica quanto com empilhamento de sinais (*pile-up*).

O banco de dados utilizado nas análises deste trabalho foi desenvolvido considerando sinais corrompidos com ruído Gaussiano de média zero, o que é tipicamente o encontrado em calorímetros modernos. A amplitude dos sinais foi escolhida randomicamente de acordo com uma distribuição exponencial de valor médio 300 ADC counts (Peralva *et al.*, 2017).

Para o primeiro cenário estudado, o sinal de interesse não está superposto a nenhum outro sinal dentro da janela de leitura considerada, isto é, não há empilhamento de sinais. É dito então, para este caso, que existe 0% de ocupação neste canal.

Outros conjuntos de dados foram construídos para que se pudesse avaliar a eficiência do método proposto em diferentes condições de ocupação. Os sinais de *pile-up* foram, primeiramente, modelados como distribuições exponenciais cuja média depende do valor de ocupação considerado e, posteriormente, adicionados ao ruído de eletrônica. (Marshall, 2014)

Estes conjuntos são representativos dos canais que sofrem com o efeito do empilhamento de sinais, seja por estarem próximos ao ponto de colisão, seja por estarem localizados em uma região de ocupação elevada.

Neste trabalho foram consideradas as ocupações de 5%, 10%, 20%, 50% e 80%. Cada um dos conjuntos de dados utilizados contém 50,000 eventos, onde metade destes é passado à rede neural durante o treinamento e a outra metade é usada para validação de ambos os métodos.

5.2 TOPOLOGIA ESCOLHIDA

Durante a elaboração deste trabalho, optou-se pela utilização de redes feedforward multicamadas (*multilayer perceptron* - *MLP*), devido à sua semelhança com os filtros FIR em aplicações de processamento de sinais. Redes recorrentes, por sua vez, devido à presença de realimentação, são comparadas aos filtros IIR.

Para a escolha da quantidade de camadas e do número de neurônios presentes em cada camada, foi realizada uma análise de diversas topologias diferentes. Inicialmente, as redes com uma única camada oculta foram aplicadas ao sinal de entrada. O número de neurônios foi gradualmente acrescido e o teste foi repetido múltiplas vezes, para cada rede e para cada valor de ocupação. Em todos os testes, o parâmetro usado a título de comparação de performance foi o erro médio quadrático.

Os resultados obtidos para as ocupações de 0%, 10% e 50% são evidenciados nas Figuras 22, 23 e 24.




Figura 22 – Estudo de topologia para uma camada - Ocupação 0%




Figura 23 – Estudo de topologia para uma camada - Ocupação 10%




Figura 24 – Estudo de topologia para uma camada - Ocupação 50%

Percebe-se que, para o projeto de uma MLP de uma camada oculta de neurônios, a quantidade de cinco neurônios nessa camada é satisfatória para um amplo conjunto de valores de ocupação. Uma vantagem dessa implementação com cinco neurônios é o baixo custo computacional e a rápida velocidade com que se pode fazer as análises.

Em seguida, um estudo semelhante foi feito, considerando agora a montagem de uma MLP com duas camadas ocultas. O número de neurônios foi gradualmente acrescido em ambas as camadas. O teste foi repetido múltiplas vezes, para cada rede e para cada valor de ocupação.

Os resultados obtidos para as ocupações de 0%, 10% e 50% são evidenciados nas Figuras 25, 26 e 27.




Figura 25 – Estudo de topologia para duas camadas - Ocupação 0%




Figura 26 – Estudo de topologia para duas camadas - Ocupação 10%




Figura 27 – Estudo de topologia para duas camadas - Ocupação 50%

Com uma comparação entre todos os resultados obtidos, evidencia que o projeto de uma MLP de apenas uma camada oculta, de cinco neurônios, já apresenta resultados excelentes e com baixo custo computacional. Desse modo, a topologia escolhida é mostrada na Figura 28.

Os nós de entrada recebem as amostras do sinal digitalizado. Na camada oculta, os neurônios receberam a função de ativação de tangente hiperbólica e na camada de saída, a função linear foi empregada.

O algoritmo de treinamento utilizado foi o Levenberg-Marquardt devido, sobretudo, a sua eficiência em convergir para o mínimo da função de erro médio quadrático.(Peralva *et al.*, 2017)

O vetor de alvos usado na fase de treinamento corresponde à diferença absoluta entre o valor verdadeiro (obtido durante a criação dos dados) e a estimativa do método OF.

O conjunto usado para treino corresponde à metade do banco de dados disponível e, o vetor usado para validação da performance corresponde à outra metade.




Figura 28 – Topologia usada para a rede neural.

6 RESULTADOS E DISCUSSÃO

Para que a eficiência dos métodos possa ser comparada, foram analisados o erro de estimação, a complexidade de implementação dos métodos e a linearidade.

A medida de erro na estimação é tomada como a diferença absoluta entre o valor estimado pelo método e o valor de referência (conhecido através da simulação do banco de dados).

A Figura 29a traz um comparativo entre as distribuições de erro de estimação dos dois métodos, para ocupação de 0%. É possível observar também, na Figura 29b, a contribuição feita pela rede neural na estimativa final. Como esperado, a contribuição foi mínima, visto que as não-linearidades introduzidas pelo empilhamento de sinais não estão presentes neste cenário de ocupação.

Pode-se perceber que, mesmo assim, o desempenho do método combinado é superior ao do método linear. Isso se deve ao fato de ainda restarem as não-linearidades intrínsecas do sinal. Ou seja, ainda existem não linearidades a serem corrigidas pela rede neural.

A Tabela 1 traz os valores encontrados para as médias do método puramente linear (OF) e para o método combinado (OF+MLP).


Média OF	-2.13
Média OF+MLP	0

Tabela 1 – Médias para ocupação 0%


Os valores obtidos para o desvio padrão são evidenciados na Tabela 2. É possível perceber que, mesmo em um cenário de 0% de ocupação, o do método proposto tem menor dispersão, mostrando uma melhor eficiência na reconstrução.

Desvio padrão OF	3.63
Desvio padrão OF+MLP	0.85

Tabela 2 – Desvio padrão para ocupação 0%




(a) Comparativo entre as distribuições de erro




(b) Ajuste feito pela rede neural

Figura 29 – Resultados para ocupação 0%

Em seguida, resultados semelhantes são mostrados para as ocupações de 10% e 20%. É possível notar que a presença do empilhamento de sinais, mesmo que em menor quantidade, já faz com que o método linear perca em performance e a contribuição feita pela rede neural torna-se fundamental na diminuição do erro.




(a) Distribuições de erro para ocupação de 10%




(b) Distribuições de erro para ocupação de 20%

Figura 30 – Resultados para ocupações de 10% e 20%

Ao se analisar a resposta para um valor mais elevado de ocupação (50%), obtém-se os resultados ilustrados pela Figura 31a. Observa-se que o método combinado (OF+MLP) apresenta um desvio 47.37% menor que o método linear (OF). Além disso, a Figura 31 evidencia que a rede insere apenas um ajuste fino na estimativa final.




(a) Distribuições de erro para ocupação de 50%




(b) Ajuste feito pela rede neural

Figura 31 – Resultados para ocupação 50%

Por último, foi feito o estudo de caso para a situação extrapolada de uma ocupação de 80%. Observa-se, na Figura 32a, que mesmo nesse cenário, embora o erro tenha aumentado para ambos, ainda assim o método combinado apresenta performance significativamente melhor. O método combinado (OF+MLP) apresenta um desvio 38.93% menor que o método linear (OF).



(a) Distribuições de erro para ocupação de 80%



(b) Ajuste feito pela rede neural

Figura 32 – Resultados para ocupação 80%

As Tabelas 3 e 4 trazem um resumo dos resultados obtidos. Levando-se em consideração todos os resultados, percebe-se que o erro da estimativa de amplitude aumenta gradativamente com a ocupação. Entretanto, o método proposto permanece com melhor performance em todos os casos analisados.

Ocupação	Média OF	Média OF+MLP
0%	-2.13	0.00
10%	-18.70	0.17
20%	-14.65	-0.07
50%	-1.74	0.14
80%	11.55	0.30

Tabela 3 – Média para todas as ocupações avaliadas

Ocupação	Desvio Padrão OF	Desvio Padrão OF+MLP
0%	3.63	0.85
10%	47.62	16.18
20%	50.55	23.21
50%	56.89	29.94
80%	56.66	34.6

Tabela 4 – Desvio padrão para todas as ocupações avaliadas

Para comprovar que o desvio do erro diminui de forma correta, os resultados obtidos para a ocupação de 80% são escolhidos para uma análise mais aprofundada.

Realizando-se a soma quadrática entre o erro médio quadrático (RMS) do método combinado e o RMS do ajuste feito pela rede neural, tem-se:

$$RMS_{OF+MLP}^2 + RMS_{MLP}^2 = 34.60^2 + 44.43^2 = 3.1712 \times 10^3 \quad (6.1)$$

Analogamente, o RMS do erro obtido para o método linear, é dado por:

$$RMS_{OF}^2 = 56.66^2 = 3.2104 \times 10^3 \quad (6.2)$$

Comparando-se ambos os resultados é possível notar que os resultados são aproximadamente idênticos. Com isso, pode-se comprovar que o desvio do erro realmente está diminuindo de forma correta.

Por fim, na Figura 33, é possível notar que para valores pequenos de ocupação (até em torno de 5%), o desempenho do método combinado muito se assemelha ao do método linear puro. Isso se deve ao fato de que, com pouco empilhamento de sinais, o ruído ainda tem um comportamento majoritariamente gaussiano.

Na região de ocupações compreendidas entre 10% e 30%, há a maior presença de não-linearidades. Com isso, têm-se a maior contribuição da rede neural para o ajuste da estimativa.

Já para valores muito elevados de ocupação (50% em diante), nota-se novamente uma aproximação dos desvios. Isso ocorre visto que a sobreposição de sinais é tão intensa que o ruído começa, novamente, a se portar como gaussiano, melhorando o desempenho do método *OF*.




Figura 33 – Topologia usada para a rede neural.

7 CONCLUSÃO E TRABALHOS FUTUROS

O empilhamento de sinais introduz uma energia adicional ao sinal de interesse. Com isso, o objetivo da rede neural é adicionar uma compensação para esse efeito.

Em todos os cenários de ocupação, a matriz de covariância do ruído foi usada no projeto do filtro linear. Pode-se notar que o projeto de um filtro linear, como vem sendo usado até agora no TileCal, opera de forma sub-ótima, uma vez que o ruído eletrônico é aproximado por uma distribuição gaussiana.

Foi possível comprovar facilmente a melhor performance do método proposto, independentemente dos valores da ocupação empregada. Isso se deve ao fato de o método *OF* não levar em consideração a estatística de mais alta ordem, presente, tanto no ruído de *pile-up*, quanto nas deformações inerentes ao pulso característico.

Em todos os cenários estudados, o ajuste feito pelo método não-linear trouxe ganhos de performance, reduzindo significativamente o erro na estimativa. Este ajuste é tão mais eficaz quanto maiores foram as não-linearidades presentes no ruído da medida. Isso fica mais evidente em ocupações moderadas, onde o ruído é ainda menos gaussiano. Para baixas ocupações, a ausência de empilhamento evidencia apenas o ruído eletrônico, que é gaussiano por natureza. Já para altas ocupações, a quantidade muito grande de sobreposição de sinais torna a estatística mais gaussiana, de acordo com o Teorema do Limite Central.

A implementação do método proposto, tendo sido realizada com apenas uma camada oculta de 5 neurônios, demanda pouco dos recursos computacionais e pode ser implementada em circuitos digitais modernos, de alta velocidade, baseados em FPGAs. Porém, este desenvolvimento está fora do escopo deste trabalho, entrando como projeção de trabalhos futuros.

Por fim, é importante ressaltar que a estimativa linear também é disponibilizada ao final do processo, cabendo ao usuário a decisão de usar ou não a correção não linear. Isto traz controle e segurança na utilização de redes neurais em experimentos de fronteira na pesquisa científica, como é o caso do acelerador de partículas LHC.

REFERÊNCIAS

- AAD, G. *et al.* The ATLAS Experiment at the CERN Large Hadron Collider. **JINST**, v. 3, p. S08003, 2008.
- BERTUCCIO, G.; GATTI, E.; SAMPIETRO, M.; REHAK, P.; RESCIA, S. Sampling and optimum data processing of detector signals. **Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment**, v. 322, n. 2, p. 271 – 279, 1992. ISSN 0168-9002. Disponível em: <<http://www.sciencedirect.com/science/article/pii/016890029290040B>>.
- BORGES, Rafael; IAROSZ, Kelly; BATISTA, Antonio; CALDAS, Ibere; BORGES, Fernando; LAMEU, Ewandson. Sincronização de disparos em redes neuronais com plasticidade sináptica. **Revista Brasileira de Ensino de Física**, v. 37, p. 2310–1, 06 2015.
- CARRIÓ, Fernando; KIM, H.; MORENO, P.; REED, Robert; SANDROCK, C.; SCHETTINO, Vinícius; SHALYUGIN, A.; SANCHEZ, Carlos Solans; SOUZA, J.; USAI, G.; VALERO, A. Design of an fpga-based embedded system for the atlas tile calorimeter front-end electronics test-bench. **Journal of Instrumentation**, v. 9, 02 2014.
- COLLABORATION, ALICE; AAMODT, K *et al.* The alice experiment at the cern lhc. **Jinst**, v. 3, n. 420, p. S08002, 2008.
- COLLABORATION, CMS *et al.* **The CMS experiment at the CERN LHC**. [S.l.]: Jinst, 2008.
- COLLABORATION, L; ALVES, A Augusto; FILHO, LM Andrade; BARBOSA, AF; BEDIAGA, I; CERNICCHIARO, G; GUERRER, G; LIMA, HP; MACHADO, AA; MAGNIN, J *et al.* The lhcb detector at the lhc. **Journal of instrumentation**, v. 3, n. 08, p. S08005–S08005, 2008.
- EVANS, Lyndon; BRYANT, Philip. Lhc machine. **Journal of instrumentation**, IOP Publishing, v. 3, n. 08, p. S08001, 2008.
- GONÇALVES, Dayane Oliveira *et al.* Fast online filtering based on data fusion of two highly segmented detectors. Universidade Federal de Juiz de Fora (UFJF), 2017.
- HAGAN, Martin T. **Neural Network Design**. 2. ed. [S.l.]: PWS publishing company Boston, 1996.
- HAYKIN, Simon. **Neural networks, a comprehensive foundation**. 2. ed. [S.l.]: PWS publishing company Boston, 1999. ISBN 81-7808-300-0.
- M. de A. Filho, L.; Peralva, B. S.; M. de Seixas, J.; Cerqueira, A. S. Calorimeter response deconvolution for energy estimation in high-luminosity conditions. **IEEE Transactions on Nuclear Science**, v. 62, n. 6, p. 3265–3273, 2015.
- MARSHALL, Zachary. Simulation of Pile-up in the ATLAS Experiment. **J. Phys. Conf. Ser.**, v. 513, p. 022024, 2014.

MEYER, Chris. The ATLAS Tile Calorimeter Calibration and Performance. **EPJ Web Conf.**, v. 60, n. arXiv:1310.2945. ATL-TILECAL-PROC-2013-008, p. 20051. 3 p, Oct 2013. Comments: 3 pages, 8 figures. Proceeding to LHCP 2013: First Large Hadron Collider Physics Conference, Barcelona, Spain, 13-18 May 2013. Disponível em: <<https://cds.cern.ch/record/1558952>>.

NAKAHAMA, Yu. The atlas trigger system: Ready for run-2. In: IOP PUBLISHING. **Journal of Physics: Conference Series**. [S.l.], 2015. v. 664, n. 8, p. 082037.

PERALVA, Bernardo; SILVA, Alessa; FILHO, Luciano; CERQUEIRA, Augusto; SEIXAS, José. Nonlinear correction for an energy estimator operating at severe pile-up conditions. In: _____. [S.l.: s.n.], 2017. v. 664, p. 87–107.

PERALVA, Bernardo Sotto-Maior. **Reconstrução de energia para calorímetros finamente segmentados**. 2015.

PERALVA, Bernardo Sotto-Maior; SEIXAS, José Manoel de. **The TileCal Energy Reconstruction for LHC Run2 and Future Perspectives**. [S.l.], Oct 2015. Comments: 5 pages, 7 figures, LISHEP 2015, 2-9 August 2015, Manaus. Disponível em: <<https://cds.cern.ch/record/2057907>>.

ROS, Eduardo. Atlas inner detector. **Nuclear Physics B-Proceedings Supplements**, Elsevier, v. 120, p. 235–238, 2003.

ZANETTI, Sidney; SOUSA, Elias; CARVALHO, Daniel; BERNARDO, Salassier. **ETo RedeNeural Agriambi**. 09 2012.

A SISTEMA DE COORDENADAS DO ATLAS

No lugar do sistema polar, mais comumente encontrado, o ATLAS faz uso de um sistema de coordenadas diferente. Este sistema foi desenvolvido para adequar-se ao formato cilíndrico dos detectores, que envolvem o ponto de impacto das partículas. Ou seja, trata-se de um sistema que acompanha a direção do feixes de partículas provenientes da colisão.

A Figura 34 auxilia no entendimento desse sistema de coordenadas. Nela é possível visualizar como um detector genérico é segmentado, acompanhando as coordenadas, tanto para o barril, quanto para uma tampa.




Figura 34 – Sistema de Coordenadas do ATLAS.

Para este sistema, temos as coordenadas η , ϕ e z . Onde:

$$\phi = \arctan \frac{x}{y} \quad (\text{A.1})$$

$$\eta = -\log\left(\tan \frac{\phi}{2}\right) \quad (\text{A.2})$$

A variável ϕ representa a rotação e a variável η representa a direção de projeção das partículas, após a ocorrência de uma colisão. É possível verificar que os detectores possuem simetria em relação ao eixo ϕ .

Em situações onde a partícula alcança o eixo z ($\eta = 1$), usualmente, não há informações pertinentes a serem analisadas. Isso se dá pois essas colisões representam choques elásticos, onde as partículas do feixe apenas se desviaram.